

因果推理深度读本

从哲学问题到现代形式方法

序言

因果推理研究一个看似平常、实则层次繁复的问题：我们凭什么说一件事使另一件事发生？日常语言中的“原因”可能是在追究责任，也可能是在寻找机制；实验科学中的因果问题通常要求比较干预后的结果；历史学的因果解释则常常关心一个事件在复杂背景中是否不可或缺。若不先分清问题，形式工具越精密，答案反而越可能答非所问。

本书以“问题先于工具”为原则。前三章从因果问题的层次、思想史和当代哲学理论建立概念基础；第4至第7章用潜在结果、结构因果模型、图形识别和研究设计形成完整的形式主线；第8至第10章讨论发现、迁移、机器学习和跨学科应用；第11章比较不同框架并审查开放问题。四个附录集中提供比较哲学专题、术语与学习路径、综合练习和原始文献精读指南。

本书不是论文原文汇编，也不试图用一套理论消灭所有其他理论。它是一部自学型读本：每章先说明学习目标，再展开概念、论证或形式结构，最后给出小结、问题和可继续查阅的原始文献。读者不必预先掌握高等统计学，但应熟悉基本概率、条件概率和函数概念。涉及较深数学时，正文着重解释对象、假设和推论的关

系，而将技术证明留给延伸阅读。

术语翻译上，全书尽量采用汉语学界已经通行的译名，并在术语首次出现时附上英文原文，以便读者回到原始文献。同一英文概念在不同传统中存在多种译法时，正文说明采用的版本及理由；关键术语均收入书末主题索引，读者可以循译名找到它在全书中的讨论位置。公式记号大体与所引文献保持一致，仅在可能引起混淆时作统一调整，并就地说明调整内容。

本书对未经核实的“最新工作”和过度概括的中西比较保持审慎；do-calculus、潜在结果假设、因果发现算法等内容依据原始文献表述，形式工具只在有助于澄清概念、识别条件和推理边界时使用。全书文献核查截止于 2026 年 7 月 23 日。

本书必然存在疏漏与可商榷之处。形式工具的表述、案例的取舍和比较哲学专题的边界都可以批评；读者若发现事实错误或论证漏洞，应当回到原始文献核验，而不是把读本当作最终依据。写作一部读本的意义不在于替读者下结论，而在于把可以检验的理由摆清楚。

因果推理没有把经验研究变成自动演算。它真正提供的是一种更严格的提问纪律：写出目标，陈述假设，区分观察与干预，说明哪些结论来自数据、哪些来自模型，并诚实标记尚不可识别之处。若读者读完全书后养成这种纪律，本书的目标就已经实现。

如何使用本书

三条阅读路径

哲学路径依次阅读第 1 至第 3 章和第 11 章。重点是因果关系、因果解释和因果判断之间的差别，以及反事实、机制、概率、力量与干预等分析方案的得失。希望继续研究形而上学的读者，可在此基础上阅读附录 A 中的中国思想、自由意志和量子因果专题。

统计与社会科学路径从第 1 章开始，随后集中阅读第 4 至第 7 章、第 9 章和第 10 章。这条路径围绕四个问题展开：估计目标是什么？因果效应在何种假设下可识别？数据支持何种估计？结论能够迁移到谁？

计算机与人工智能路径建议依次阅读第 1、5、6、8、9、10、11 章。重点不是把图画出来，而是理解图的语义、识别与发现的区别，以及分布变化时稳定性主张需要什么额外结构。

全书的共同语法

本书反复使用四个步骤。第一，定义**目标量**，例如平均处理效应或某一反事实概率。第二，列出从目标量到可观测分布所需的**识别假设**。第三，在已经识别的前提下讨论**估计**与不确定性。第四，检查从样本到目标人群的**外部效度**。把识别和估计混为一谈，是因果分析中最常见的错误之一。

符号方面，大写字母表示随机变量，小写字母表示其取值； $P(Y | X = x)$ 表示观察到 $X = x$ 后的条件分布， $P(Y | \text{do}(X = x))$ 表示外部干预将 X 设为 x 后的分布。 $Y(1)$ 、 $Y(0)$ 是潜在结果， Y_x 是结构因果模型中的反事实变量；二者在适当语义下可以对应，但记号相似不意味着模型假设完全相同。

关键辨析

“数据中有相关性”“模型中有一条箭头”“改变变量会改变结果”和“某个具体事件造成了结果”是四种不同断言。它们可能相关，却不能在额外论证时互相替换。

每章的学习闭环

本书篇幅较长，顺序通读并不是唯一有效方法。更可靠的单位是一个由“提问、重构、运算、质疑、迁移”组成的学习闭环。开始一章之前，先不用术语写出自己真正想回答的问题。例如，不写“研究中介效应”，而写“政策经由就业状况改变健康的部分有多大”；不写“讨论因果实在论”，而写“如果两个模型给出相同预测，什么证据还能说明其中一个描述了真实产生过程”。问题越具体，越容易发现本章工具究竟有没有回答它。

第一遍阅读只找本章的对象和结论。对象可能是事件、变量、总体平均、结构方程、机制部件或解释关系；结论可能是概念分析、识别公式、估计建议或不可识别证明。把每个结论改写成“在条件甲、乙成立时，可以得到丙”的形式。若一句话无法补上条件，它多半还只是口号。哲学章节也应如此处理：反事实分析依赖何种可能世界比较，机制论对组织和活动要求什么，操纵论中的干预变量需满足哪些限制，都可以明确写成论证前提。

第二遍重构本章最关键的一条推理链。形式章节应从目标量写到可观测量，并在等号上方注明使用了哪个假设；概念章节应从反例写到理论修正，说明反例攻击的是充分性、必要性还是分析对象。不要抄下整页公式却跳过一个条件独立，也不要摘录一段名言却不说明它在论证中承担什么作用。若重构失败，应回到定义，而不是立即寻找更浅的二手解释。

第三步是做一个最小算例或最小反例。对于潜在结果，六至十个单位的表格通常足以暴露“个体两种结果不能同时观察”的困难；对于有向图，三至五个节点已经能够区分链、叉、碰撞点和选择偏差；对于哲学理论，一组先占、遗漏或对称过度决定案例足以检查分析边界。小例子的价值在于每项假设都能看见。复杂案例应当在小例子已经理解之后再进入，否则读者可能只记住领域故事，没有掌握结构。

第四步实行“逆向阅读”：主动寻找本章方法失败的世界。改变一个假设，观察结论在哪一步断裂。删除重叠会使哪个总体无法估计？加入隐藏共同原因会使哪条后门路径打开？处理有多个版本时一致性为什么变得含糊？环境改变结果机制时不变预测为何不再不变？反事实相似性排序若已经依赖因果判断，理论的还原目标是否改变？把失败点说清楚，比泛泛地写“方法有局限”更接近真正掌握。

第五步把方法迁移到自己的领域，但迁移时保留问题结构。医学中的“治疗”可能对应教育中的课程、经济学中的政策或计算机系统配置变更；可它们在干预可行性、依从、溢出、时间零点和结局测量上并不相同。迁移记录至少回答四项：单位是谁，处理有哪些版本，结局何时测量，哪些路径被设想为稳定。只有变量名称改变而假设没有重新审查，不算成功迁移。

完成闭环后，用三种颜色或三类标签整理笔记：一类标记由定义或数学推出的内容，一类标记需要经验与制度知识支持的假设，一类标记价值判断或决策偏好。例如，后门公式是给定图模型后的识别结论；某变量集是否足以阻断混杂，是经验与因果知识问题；是否值得以副作用换取平均收益，则是决策问题。三类材料共同出现在研究中，但证成方式不同。把它们混在一起，常会造成“公式正确所以政策正确”之类的跨层跳跃。

公式、图与自然语言的互译

形式表达不应成为压缩歧义的装饰。遇到任何公式，先逐项读成自然语言，再把自然语言反写为公式。以平均处理效应为例， $E[Y(1) - Y(0)]$ 不是“处理组均值减对照组均值”的定义，而是同一目标总体在两个处理制度下潜在结果差的平均；只有在随机化或相应交换性成立时，观测组差才识别它。这个互译过程会揭示等式何时偷偷把目标量换成了估计量。

读图时也要区分语法与语义。箭头首先编码直接因果关系及相应的概率分解或结构方程限制，不表示相关强弱、时间长度或道德责任。没有箭头可能来自模型的排除限制，也可能只是当前问题没有细分该过程。每画一条边，应能够写出至少一个机制或干预解释；每删一条边，应能够说明哪种直接作用被排除。图若只

把所有已知变量连起来，就没有提供可检验或可识别的结构。

自然语言问题进入模型时，先写“问题表”，再写“变量表”。问题表包括目标总体、处理策略、对比、结局、时间范围和效应尺度；变量表包括测量时点、单位、允许取值、缺失机制以及它在图中的角色。诸如“年龄”“疾病严重度”“平台参与度”看似普通，实际可能随时间变化或因处理而改变。若变量定义无法稳定对应研究问题，增加算法复杂度不会修复目标漂移。

练习与答案应怎样使用

章末问题分为概念辨析、形式推导、案例诊断和研究设计四类。概念题不以背定义为目标，答案应给出相邻概念的边界与反例；推导题应保留每个等式所用条件；诊断题应指出错误发生在目标、识别、估计还是迁移；设计题则应给出一个能够被反驳的方案，而不只是列出方法名称。附录中的参考分析展示一种合格答案的结构，不是唯一措辞。

建议先在限定时间内独立作答，再对照参考分析。对照时不要只标“对”或“错”，而要标记缺失的推理步骤。如果自己的结论正确但没有写出交换性、正值、一致性或模型范围，仍应视为不完整；如果结论与参考答案不同，却能够指出另一组明确假设，也可能是更好的回答。因果问题经常没有脱离模型的单一数值答案，严谨性体现在分歧能否追溯到具体前提。

对研究设计题，可以使用“预分析审稿”方式：假想数据尚未收集，写一份最严厉的评审意见，说明选择机制、测量误差、处理版本、溢出和失访如何使方案失败；随后只允许通过改变设计来回应，暂不允许用更复杂模型补救。这样能训练“设计优先”的习惯，也能区分统计效率问题与结构性不可识别问题。

如何选择学习进度

不必把所有读者放进同一张周历。自学者先在本章的三条阅读路径中确定主线，再根据时间选择附录B的六周核心路径或十二周课程路径。六周路径用于快速建立全图，十二周路径用于完成章末任务和综合研究作业。若希望进行更慢的精读，可把每个课程周拆成“正文与算例”和“练习与原始文献”两周，而不另造一套章节次序。

任何进度都应保留三个不可压缩的环节：第1章的问题分层，第4至第7章中从目标量到识别再到估计的链条，以及第11章对证据边界的综合。进度差异应体现在练习数量和原始文献深度上，而不是删掉因果推理的关键步骤。

完成学习的可检验标准

“读完”不能只由页码判断。最低完成标准是：面对一个新的因果问题，能够在不调用算法名称的情况下先规定目标总体、处理、对比、结局和时间；能够画出至少两种可竞争的结构，并指出数据无法在何处区分它们；能够把核心识别假设翻译成领域语言；能够选择与目标量匹配的估计方法，并报告不确定性、敏感性与适用范围；能够说明结论是总体层面的平均差异、个体决策依据、实际因果归因还是解释性机制主张。

更高标准是能够发现一个“漂亮结果”为什么可能答错问题。显著系数可能只反映选择，预测增益可能来自碰撞点，稳定平均效应可能掩盖不可接受的分布后果，跨域准确率可能依赖偶然不变的代理变量，机制图可能只列部件没有产生过程。读者若能把批评定位到对象、假设或推理步骤，并提出一种更可行的设计或

更诚实的结论，即已获得本书希望培养的因果素养。

目录

序言	ii
如何使用本书	iv
第一部分 因果概念、历史与哲学	1
第一章 因果问题：概念、解释、证据与行动	2
1.1 因果问题的层次：存在、知识、解释与行动	2
1.1.1 任务分层与查询表达	2
1.1.2 模型、价值与分析次序	5
1.1.3 贯穿案例与常见误判	6
1.2 因果论证的结构	8
1.2.1 因果主张与反事实承诺	8
1.2.2 证据整合与论证审计	10
1.3 预测、价值与系统边界	11
1.3.1 预测与因果的分界	11

1.3.2 个体、群体与系统尺度	13
延伸阅读	14
第二章 因果观念的历史谱系：从四因到科学解释	16
2.1 从四因到机械论：古代、中世纪与近代转折	16
2.1.1 四因、科学与知识与经院传统	16
2.1.2 机械论、充足理由与近代转折	18
2.1.3 历史案例、解释误区与目的语言	20
2.2 休谟：经验、必然联系与归纳问题	21
2.2.1 必然联系、恒常结合与习惯	21
2.2.2 归纳循环、因果定义与反事实校正	23
2.2.3 休谟问题的现代意义与建设性作用	24
2.3 从先验秩序到科学解释：康德、穆勒、罗素与亨普尔	26
2.3.1 康德与穆勒：秩序条件和比较方法	26
2.3.2 罗素与亨普尔：从原因批判到覆盖律解释	28
2.3.3 方案比较、案例重构与解释约束	29
2.4 历史理论对现代方法的约束	32
延伸阅读	35
第三章 当代因果哲学：反事实、概率、机制与干预	36
3.1 反事实因果：刘易斯及其难题	36
3.1.1 反事实语义、依赖与因果链	36
3.1.2 先占、过度决定与遗漏难题	38
3.1.3 因果类型、事件粒度与证据来源	40
3.2 概率、机制、力量与干预：多元因果理论	41
3.2.1 概率、共同原因与 INUS 条件	41

3.2.2	机制、因果力量与干预主义	44
3.2.3	理论互补、解释层级与选择准则	46
3.3	理论选择、证据整合与模型责任	48
3.3.1	用反例检验理论	48
3.3.2	实在论、工具主义与模型责任	49
	延伸阅读	51

第二部分 现代因果推断的形式基础 53

第四章 潜在结果、估计目标与识别 54

4.1	潜在结果：用替代状态定义因果效应	54
4.1.1	潜在结果、基本难题与估计目标	54
4.1.2	一致性、干扰与随机化可比性	56
4.1.3	动态处理、异质性与连续暴露	58
4.1.4	复合处理、主层与潜在结果表	60
4.2	识别：从反事实目标到可观测分布	61
4.2.1	识别、标准化与可交换性	61
4.2.2	选择、测量与缺失机制	63
4.2.3	目标试验、敏感性与部分识别	65
4.3	从目标合同到知识边界	67
4.3.1	从目标合同到逐行识别证明	67
4.3.2	纵向问题与不可识别边界	69
4.3.3	目标量合同：先固定问题，再证明识别	70
	延伸阅读	73

第五章 结构因果模型与图形语言 75

5.1	从联合分布到结构因果模型	75
5.1.1	概率模型、DAG 与 d-分离	75
5.1.2	结构方程、Markov 条件与干预	77
5.1.3	等价性、因果阶梯与数值验证	79
5.1.4	干预类型、线性模型与误用检查	81
5.2	图与结构模型的工作方法	82
5.3	扩展结构：潜变量、测量与动态系统	85
5.3.1	潜变量、代理、选择与测量	85
5.3.2	循环、时间与模型版本管理	87
5.3.3	完整建模案例：治疗、依从与康复	88
5.3.4	图模型、参数模型与数据证据的边界	91
	延伸阅读	93
第六章 图形识别、do-calculus 与反事实		95
6.1	图形识别：后门、前门与调整的边界	95
6.1.1	后门调整及其风险边界	95
6.1.2	前门、工具变量与分析流程	98
6.1.3	目标敏感的调整集与图不确定性	100
6.2	do-calculus、反事实与中介分析	101
6.2.1	三条演算规则与识别算法	101
6.2.2	结构反事实、效应分解与实际因果	104
6.2.3	演算实例、反事实图与错误诊断	106
6.3	识别工作的深化与边界	108
6.3.1	识别层级与完整工作记录	108
6.3.2	中介含义与不可识别证明	110

6.3.3 完整识别档案：同一问题的三种图	111
延伸阅读	114
第七章 研究设计、估计方法与不确定性	116
7.1 从识别到估计：设计、模型与不确定性	116
7.1.1 结果建模、匹配与倾向得分	116
7.1.2 双重稳健、正交化与试验估计	119
7.1.3 方法选择、数值诊断与分层不确定性	120
7.1.4 稳健性、标准误与决策解释	122
7.2 从设计到可复核估计	123
7.2.1 设计原则与正交估计	123
7.2.2 分层不确定性与可复核分析	124
7.3 复杂数据结构与可靠实现	126
7.3.1 删失、竞争事件与相关数据	126
7.3.2 完整估计实例与数值稳定性	127
7.3.3 完整估计案例：从粗比较到目标总体	128
7.3.4 有限样本推断：随机性来自哪一层	131
延伸阅读	133
第三部分 发现、迁移、机器学习与应用	135
第八章 因果发现与结构学习	136
8.1 因果发现：从条件独立到结构搜索	136
8.1.1 发现目标、约束方法与评分搜索	136
8.1.2 函数限制、连续优化与时间结构	138
8.1.3 环境变化、评估规范与贯穿案例	139

8.1.4	稳定性、隐藏结构与比较对象	141
8.2	发现分析的完整 workflow	142
8.2.1	方向信息来自哪些假设	142
8.2.2	动态边界与发现到识别的衔接	144
8.3	算法推演与报告规范	145
8.3.1	约束方法与评分搜索的最小推演	145
8.3.2	多环境不变性与最低报告规范	146
8.3.3	完整发现案例：从独立表到新实验	147
8.3.4	算法比较实验：必须先统一问题	150
	延伸阅读	152
第九章	外部效度、可迁移性与数据融合	154
9.1	外部效度、可迁移性与数据融合	154
9.1.1	目标人群、标准化与变量选择	154
9.1.2	选择图、多源融合与时间变化	156
9.1.3	敏感性、数值标准化与测量协调	158
9.2	从迁移公式到政策责任	160
9.2.1	迁移目标与选择图表达	160
9.2.2	测量协调与规模效应	161
9.3	迁移分析的计算、诊断与治理	163
9.3.1	标准化计算与普遍化诊断	163
9.3.2	证据冲突与部署后审计	164
9.3.3	完整迁移案例：从专科试验到城市系统	165
9.3.4	多源数据融合：每个来源只提供它识别的部分	168
	延伸阅读	170

第十章 因果机器学习与跨学科应用 172

10.1 因果机器学习：异质性、策略与表示	172
10.1.1 因果机器学习的任务位置与元学习器	172
10.1.2 因果森林与策略学习	174
10.1.3 因果表示、分布外泛化与解释边界	175
10.1.4 异质性验证、策略评估与合作边界	177
10.2 跨学科案例：从问题到可辩护结论	179
10.2.1 健康与教育：观察研究和工具变量	179
10.2.2 政策评估：断点回归与双重差分	181
10.2.3 算法系统：公平路径与网络干扰	183
10.2.4 跨案例综合、冲突证据与行动建议	184
10.3 从效应学习到可信部署	186
10.3.1 端到端因果机器学习 workflow	186
10.3.2 可信部署的共同失败点	187
10.3.3 完整策略学习案例：有限容量下如何分配	188
延伸阅读	193

第十一章 框架综合、理论边界与开放问题 195

11.1 框架比较：Rubin、Pearl、Woodward 与机制论	195
11.1.1 任务比较、框架翻译与设计优先性	195
11.1.2 干预、图与机制的本体论分歧	197
11.1.3 可统一的工作流与不可消除的差异	199
11.1.4 证明、证据多元与整合失败	200
11.2 开放问题：可检验性、复杂系统与 AI 辅助研究	202
11.2.1 可检验性、模型不确定性与变量形成	202

11.2.2 复杂系统、自动化与 AI 边界	203
11.2.3 开放科学、研究议程与学科纪律	205
11.2.4 预注册、失败案例与停止规则	207
11.3 综合研究的实践规范	208
11.3.1 框架翻译与成熟研究链	208
11.3.2 受限 AI 与经验可检验性	209
11.3.3 停止规则与有纪律的无知	210
延伸阅读	212

第四部分 专题附录与学习工具 213

附录 A 比较哲学专题：中国思想、自由意志与量子因果 214

A.1 中国哲学中的因果相关问题	214
A.1.1 比较研究的方法限制	214
A.1.2 “故”“由”“生”与解释语言	215
A.1.3 儒家：行动、德性与后果	215
A.1.4 道家：生成、自发与控制限度	216
A.1.5 佛教：缘起不是简单链式因果	217
A.1.6 业与道德责任	217
A.1.7 可以怎样开展严谨比较	218
A.2 因果性、自由意志与责任	219
A.2.1 四个经常混淆的问题	219
A.2.2 兼容主义与理由响应	220
A.2.3 不兼容主义的挑战	220
A.2.4 Libet 实验能说明什么	221

A.2.5	预测行为是否消除自由	222
A.2.6	责任归属的因果层次	222
A.2.7	一个谨慎的综合	223
A.3	量子因果：经典模型的边界	224
A.3.1	经典因果模型预设了什么	224
A.3.2	纠缠相关与无信号	225
A.3.3	量子因果模型在推广什么	225
A.3.4	不定因果顺序	226
A.3.5	量子结果没有证明什么	226
A.3.6	量子因果与本书主线的关系	226
附录 B	术语、时间线与学习路径	228
B.1	术语与符号表	228
B.1.1	常用符号	233
B.2	时间线、学习路径与综合练习	233
B.2.1	选择性时间线	233
B.2.2	六周核心路径	236
B.2.3	十二周课程路径	237
B.2.4	综合研究作业模板	238
B.2.5	同伴审查问题	239
B.2.6	原始文献阅读法	239
附录 C	综合练习与参考分析	240
C.1	概念、历史与哲学	240
C.2	形式基础与研究设计	244
C.3	发现、迁移与机器学习	248

C.4 综合、比较与因果审计	251
附录 D 核心原始文献精读指南	256
D.1 如何精读因果文献	256
D.2 因果哲学与科学解释	257
D.3 潜在结果、结构图与识别	261
D.4 因果发现与结构学习	262
D.5 估计、迁移与因果机器学习	264
D.6 阅读产出与核验工具	266
D.7 十二周原始文献研讨方案	272
参考文献	275
主题索引	305

第一部分

因果概念、历史与哲学

因果问题：概念、解释、证据与行动

学习目标

读完本章，你应当能够：区分因果语言承担的存在论、认识论、解释与行动任务；把宽泛问题改写成明确的因果查询；说明模型、数据与价值判断如何共同限制结论；建立贯穿全书的审计顺序。

1.1 因果问题的层次：存在、知识、解释与行动

1.1.1 任务分层与查询表达

“吸烟导致肺癌”“这次短路引起火灾”“提高利率会降低通胀”“如果当时没有手术，病人会怎样”都使用因果语言，但它们并未完成同一种工作。第一句话通常是关于一类暴露对一类结局的平均影响；第二句话追问具体事件的责任归属；第三句话预测政

策干预；第四句话要求评价一个已经与事实相反的个体情形。若把四种问题交给同一个统计量，错误往往不是计算错误，而是问题设定错误。

因果研究至少包含四个相互关联的层次。

1. **本体论问题**：世界中是否存在独立于观察者的因果关系？原因是事件、事实、变量值、机制、力量，还是规律中的结构位置？
2. **认识论问题**：我们如何知道某个因果命题为真？重复观察、实验操纵、机制知识和反事实判断各能提供什么证据？
3. **解释论问题**：一个答案为什么具有解释力？把现象归入定律、展示产生机制、指出差异制造者，分别满足了什么理解需求？
4. **方法论问题**：给定数据、模型与研究设计，某个因果目标是否可识别，如何估计，其不确定性和适用范围是什么？

这些层次不能完全分开。若把原因理解为干预下稳定的差异制造者，就已经对“什么算原因”作了本体论或概念承诺；若使用有向无环图表达研究假设，就已经决定哪些变量和路径值得进入分析。但是，它们也不能混为一谈。一个形而上学上很有吸引力的因果理论，不会自动给出观测研究的估计式；一个预测准确的模型，也不会仅凭准确性获得因果解释。

从模糊问题到因果查询 考虑问题：“职业培训有效吗？”这里至少遗漏了五项信息：接受什么培训；与什么替代状态比较；效果作用于何种结果；在什么时间尺度上测量；针对哪个人群。将它改写为“对于 2026 年登记失业者，参加为期十二周的培训，相比收到常规就业服务，对一年后就业率的平均影响是什么”，才形成了能够连接研究设计的查询。

这种改写体现了因果问题的**对照性**。原因不是孤立地产生结果，而是在一个实际或假想的替代状态背景下造成差异。潜在结

果框架把这种结构写为

$$ATE = E\{Y(1) - Y(0)\},$$

其中处理水平 1 和 0 必须有清楚含义。结构因果模型则可询问

$$P(Y = y \mid \text{do}(X = x))$$

或个体层面的反事实 $Y_x(u)$ 。公式不会替研究者完成概念工作；如果“培训”在不同机构代表完全不同的方案， $X = 1$ 就不是一个稳定处理。

四类常见查询

关联查询问“看到什么”：接受培训者与未接受者的就业率是否不同？它由联合分布中的条件概率描述。关联可能来自因果影响，也可能来自共同原因、选择机制或测量过程。

干预查询问“做了什么”：若外部机制把符合条件者分配到培训，结果分布如何变化？它要求将处理赋值机制与平常生成过程区分开。

反事实查询问“本来可能怎样”：对一个实际参加培训且就业的人，若他没有参加，是否仍会就业？这不仅比较总体干预，还把实际观测与另一个假想世界联系起来。

实际因果查询问“这次是谁造成的”：某次培训是否是某人就业的原因？这类判断常涉及充分性、必要性、正常性、责任和法律规范，不能直接由平均处理效应推出。

因果解释不等于因果效应估计 假定随机试验显示某药物使住院风险平均下降五个百分点。研究可能已经很好地识别了平均效应，却仍未说明药物通过什么生物过程起效、为什么只对部分人有效，或这名病人的康复是否应归因于药物。反过来，实验室可能详细揭示一个受体通路，却不能在目标人群中量化治疗策略的净效应。

因果解释与效应估计的关系因研究目的而异。机制知识可以支持变量选择、外推和异常结果诊断；效应估计可以检验机制的某些可观察后果。但“有机制叙述”不保证因果效应已经识别，“有显著效应”也不保证机制叙述正确。Woodward (2003)把解释与回答“若改变什么，结果会怎样”的反事实信息联系起来；机制论者则强调产生现象的实体、活动和组织。二者可以互补：干预模式刻画差异关系，机制模型说明这种关系为何在某些背景中稳定。

1.1.2 模型、价值与分析次序

模型不只是数据的压缩。一个因果图 $X \rightarrow Y$ 声称：在模型边界与变量粒度下， X 是 Y 的直接原因之一。所谓“直接”总相对于模型中的其他变量；加入中介变量后，原先的一条边可能变成两条边。因此，图不是未经解释的世界照片，而是背景知识、时间顺序、实验经验和建模目的共同约束的表示。这也说明为什么“让算法从数据自动发现真因果图”必须附带条件。观测分布通常只限制一组统计等价的图；要进一步定向，需要无隐藏混杂、忠实性、非高斯噪声、时间结构或干预数据等假设。数据能够反驳某些模型，却很少在没有背景假设时唯一决定因果方向。

价值判断进入因果问题的地方 因果模型可以是数学对象，但研究问题从不完全价值中立。选择测量何种结果、把何种差异视为需要解释、允许何种干预、把谁纳入目标人群，都可能带有伦理与政

策判断。算法公平研究尤其明显：若把受歧视历史形成的变量当作理所当然的背景条件，某种形式上的“公平”可能固化不正义。承认价值参与不等于放弃客观性。恰恰相反，它要求把价值选择显式化，使事实假设、规范目标和决策约束分别接受审查。因果分析能够告诉我们某政策对不同群体的后果，却不能独自决定何种分配才公平。

一套贯穿全书的分析次序 面对经验因果问题，可以依次完成六项工作：

1. 明确单位、处理或暴露、替代状态、结果、时间和目标人群；
2. 写出目标量，而不是先选择回归模型；
3. 画出或叙述支持识别的因果结构，列明不可观测因素；
4. 判断目标量能否由现有数据识别；若不能，说明需要何种新设计或数据；
5. 在识别成立后选择估计方法，报告抽样和模型不确定性；
6. 分析干预版本、溢出、选择、测量和迁移限制。

这一顺序把“统计上能算什么”置于“科学上想知道什么”之后。现代因果推断的进步，不只是提供了更复杂的估计器，更在于把隐藏在传统分析中的假设转写成可以讨论、比较和部分检验的结构。

1.1.3 贯穿案例与常见误判

设研究者观察到细颗粒物浓度较高的城市死亡率也较高。第一步不是运行回归，而是拆分可能的问题。描述问题是不同城市的污染与死亡如何共同分布；干预问题是把目标城市年均暴露从某水平降低到另一水平会怎样；机制问题是颗粒物经炎症、心血管和呼吸路径如何造成损伤；实际因果问题是某位患者的死亡能

否归因于某次污染暴露；政策问题还要比较减排成本、分配影响和替代措施。

若目标是“将未来一年日均污染控制在某阈值以下，相比维持现状，对 65 岁以上居民一年死亡风险的影响”，处理已经从一个自然属性变成策略。研究者需说明阈值如何实现：关闭工厂、调整交通或过滤室内空气可能产生同样污染读数，却通过就业、出行和医疗可及性产生不同附带路径。一致性要求的不是一个抽象数值，而是足够明确的干预版本。

候选共同原因包括城市收入、年龄结构、吸烟率、医疗资源、温度和产业构成。迁移到另一个城市时，即使平均污染下降相同，人口易感性、颗粒成分和住宅通风不同也会改变效应。机制证据可支持哪些差异相关，但不能替代目标人群中的量化；观察研究能量化关联，却需要自然实验、时间变化设计或充分调整来支持因果解释。该案例还显示个例归因为何困难。人群风险差可以说明污染增加多少额外死亡，却未必标识哪一个具体死亡“本来不会发生”。若病人同时有严重基础疾病，污染可能提前死亡、触发急性发作或只与死亡时间共同变化。法律赔偿需要选择实际因果与责任标准，不能直接从 ATE 读出。

证据矩阵

可以把证据按两条轴组织。一条轴是查询层级：关联、干预、机制、个例；另一条轴是来源：监测数据、准实验、毒理实验、临床记录和制度资料。监测数据覆盖广但易混杂；准实验提供局部外生变化但处理版本特殊；毒理实验揭示路径但剂量与物种迁移有限；临床记录接近个体却受选择和测量影响。结论的可信度来自不同证据对同一结构的互相限制，而非寻找一个“最权威数据集”。

常见误判与改写 “相关不等于因果”只是起点，不是分析结论。更有用的改写是：“该关联还可能由哪些开放路径产生，现有设计阻断了哪些，剩余哪些？”“不能做随机试验”也不等于“不能作因果研究”；应追问自然制度、时间、工具变量、负对照或部分识别能提供什么。相反，“用了因果推断方法”也不等于已得到因果结论；方法必须与结构假设配套。另一误判是把可行性当作存在性标准。我们不能操纵出生年份，却能研究出生队列通过制度暴露造成的差异；不能移动地震发生，却能定义地震强度对建筑结果的理想变化。真正限制来自替代状态是否连贯、模型是否支持相应不变性，而非研究者是否实际能按按钮。

1.2 因果论证的结构

1.2.1 因果主张与反事实承诺

一句“X 导致 Y”至少同时承诺了对象、对照和稳定范围。对象回答因果关系发生在个体、群体、事件还是变量类型之间；对照说明究竟把现实与哪个替代状态比较；稳定范围则限定这种差异制造关系在哪些背景中保持。若三者没有写清，同一句话可以在不同研究者手中变成完全不同的问题。例如“远程办公提高生产率”可能指一家企业在下一季度全面远程相对于维持现场办公的平均产出差，也可能指某位员工每周增加一天远程工作的个体效应，还可能只是在解释疫情期间产出为何没有下降。

对象含混会造成单位错置。城市污染研究中的处理可以是个人暴露，也可以是城市排放政策；前者的变化未必能代表后者，因为政策还会改变就业、交通和人口流动。对照含混会造成版本混合。“不治疗”可能包括观察等待、安慰剂、其他药物和无法获得

医疗，这些状态的潜在结果并不相同。范围含混则使局部规律被无条件外推：在有完善冷链和高接种率的地区估计出的策略效果，不自动适用于供应不稳或流行毒株不同的地区。

因果主张还包含方向性承诺。若模型说降低空气污染会减少住院，它并不只是在报告污染与住院的联合分布，而是在排除一组替代解释：例如住院率高的地区因监测更密集而记录更多污染，或低收入同时造成高暴露与高疾病风险。方向性不是由动词“导致”提供的修辞效果，而要由时间、机制、设计与排除限制共同承担。写作时应把这些负担显式展开，使读者能够指出哪一项证据不足。

从事实描述到反事实比较 描述事实世界通常只需要回答发生了什么；因果问题则必须构造至少一个未同时观察到的替代状态。这个替代状态不是任意想象，而要与研究对象、时间零点和干预版本相容。若研究教育政策，就不能把“接受新课程的学生”与“从未出生在该地区的同一学生”比较；后者改变了过多背景条件。可辩护的反事实通常保持单位身份与处理前历史，只改变一个明确策略及其允许的后续过程。

反事实比较因此有三层纪律。第一层是语义纪律：替代状态要能被清楚描述，处理的多个版本不能被同一标签掩盖。第二层是科学纪律：模型必须说明改变处理时哪些机制随之变化、哪些背景结构保持不变。第三层是证据纪律：数据和设计必须提供连接事实分布与替代分布的桥梁。随机化、自然实验、调整公式和机制实验都可能承担桥梁作用，但它们依赖的稳定性范围不同。

以学校早餐计划为例。目标可以是“在本学年开学时向所有符合条件学生提供免费早餐，相对于维持申请制，对学期末出勤率的影响”。这一表述固定了总体、分配时点、策略和结局。若只比较实际领取早餐者与未领取者，家庭困难、健康和学校参与度会同时

影响领取与出勤；观察差异不能直接代表策略效果。若政策还改变同伴互动或课程开始时间，单位间干扰与处理版本又进入目标定义。一个看似简单的政策问题由此展开成可审查的反事实结构。

1.2.2 证据整合与论证审计

因果证据经常被画成从专家意见到随机试验的单一等级。这种图示有助于提醒选择偏差，却会掩盖不同证据回答不同子问题。随机试验能在规定总体和处理版本中识别平均效应，但未必揭示作用机制，也未必覆盖罕见伤害和长期反馈。自然实验提供制度造成的局部外生变化，却可能只识别阈值附近或服从者人群。实验室机制研究能够隔离过程，但从剂量、物种或装置迁移到现实系统需要额外论证。

更合理的组织方式是证据网络。时间顺序排除某些反向路径；领域机制支持或反驳图中的边；负对照检查残余混杂与测量过程；不同数据源在目标总体、处理版本和结局定义对齐后相互约束；敏感性分析说明结论需要多强的未测因素才会改变。网络中的证据并非越多越好，关键是它们是否针对同一因果查询，并在彼此不共享的失败模式上形成互补。实验、准实验与机制证据各自的有效性威胁及互补关系，可结合研究设计与证据多元论的系统讨论理解(Illari, Russo, 2014; Shadish et al., 2002)。

证据综合还必须容纳冲突。若试验显示短期平均收益，而长期观察数据提示伤害，不能简单按“证据等级”删除后一结果。应检查随访长度、依从、结局测量、选择进入和治疗版本是否改变；也可能短期与长期效应本来就不同。把冲突定位到目标、识别、估计或迁移层，才可能决定需要新数据、替代模型还是不同政策。

把因果推理写成可审计论证 一份完整分析可以压缩成六个相互连接的陈述。第一，给出目标总体、时间零点、处理策略、对照、结局和效应尺度。第二，说明数据中的单位如何对应这些对象。第三，列出识别假设，并用图、潜在结果或制度机制解释其科学含义。第四，从目标量逐步推导到可观测表达式。第五，说明估计器、诊断与抽样不确定性。第六，限定结论向其他时期、人群和实施方式迁移的范围。

六步中的任何一步都可能失败，而且失败类型不同。目标不清不是换一个算法能修复的问题；正值性结构缺口不能靠更复杂的回归创造不存在的比较；模型错设可能通过稳健估计和交叉拟合缓解，却不能消除未测混杂；样本内识别成立也不保证跨制度迁移。审稿和自我检查应逐层定位，而不是用“可能存在偏差”概括所有风险。这种写法也改变结论语言。与其说“研究证明了 X 造成 Y”，更准确的表述是：在指定总体、处理版本和时间范围内，给定哪些可交换性与测量假设，哪些数据支持某个效应区间；哪些替代解释已由设计排除，哪些仍由敏感性分析约束。限制条件不是削弱论文气势的附录，而是因果结论本身的一部分。

1.3 预测、价值与系统边界

1.3.1 预测与因果的分界

预测模型只需在相似数据分布中利用稳定关联，因果模型则要回答分布被行动改变后会发生什么。医院模型发现吸氧与死亡正相关，可以准确预测高风险患者，却不能推出停止吸氧会降低死亡；吸氧是病情严重的结果。若模型用于床位预警，这个关联可能有价值；若用于治疗决策，同一关联就会造成伤害。区分两类任

务的一个办法，是问输入变量能否在预测时观察、是否会被行动改变，以及模型输出要支持什么操作。纯预测允许使用接近结局的代理，甚至允许处理后信息；因果决策必须限定在决策时可用历史，并明确行动对后续变量的影响。评价指标也不同：预测关注保留数据误差，因果评价关注效应校准、策略价值和识别假设的敏感性。

预测与因果并非敌对。良好的结局与处理模型可以提高效应估计效率，稳定预测可以帮助发现测量错误和人群变化，因果结构则能指导特征选择与分布外风险。但合作的前提是任务边界清楚：预测性能不能替代可交换性，因果标签也不能赦免糟糕的拟合与验证。

价值判断的进入点 因果分析常被描述为先求事实、再由决策者加入价值。实际上价值更早进入。选择研究哪种伤害和哪个总体，决定谁的经验被计入；定义处理版本，决定哪些现实行动被视为等价；选择平均值、分位数或最坏群体，决定如何汇总分配差异；设定结局时间窗，决定短期收益与长期代价的权重；决定证据阈值，则反映误行动与不行动的相对损失。承认价值介入不等于放弃客观约束。研究者仍需区分规范选择与经验主张。例如“优先减少最弱势群体风险”是分配原则，“某政策使该群体风险下降”是因果主张；前者不能由数据推出，后者也不能只靠道德意愿成立。报告可以把两者分栏，展示在不同价值权重下相同效应证据会支持哪些行动。由局部效应进入现实政策还需另行论证实施条件与支撑因素，而不能把一项有效性研究直接当作普遍行动处方(Cartwright, Hardie, 2012)。

公众参与的作用也应具体化。受影响者能够指出研究者忽略的处理版本、伤害结局和实施障碍，但不因此自动决定统计识别。

共同设计应把经验知识转成变量、路径与决策约束，再由相应证据检验。这样既避免把价值伪装成技术默认，也避免把事实争议简化为立场表达。

1.3.2 个体、群体与系统尺度

许多问题无法在孤立个体层完成。传染病处理会改变他人暴露，教育改革影响同伴组成，平台推荐改变内容供给，税收政策改变价格和劳动市场。若每个单位的潜在结果依赖全体处理向量，SUTVA 的无干扰部分失败；目标必须包含网络、覆盖率或制度配置。系统目标可以是集群策略的平均效果、某一覆盖率下的直接与间接效应，或市场达到新均衡后的总体福利。识别需要与尺度匹配的设计，例如集群随机化、两阶段随机化、分阶段推广或结构均衡模型。用个体回归系数推断全国政策，隐含了无溢出和背景不变，两项都需要实质理由。尺度还改变解释。个体机制说明政策如何影响一个人，系统机制说明行为响应怎样汇总、资源约束怎样反馈。两种机制可能方向相反：培训在固定预算的小试点提高就业，全面推广却因岗位数量不变而主要改变竞争排序。深度因果分析必须明确从微观效应到宏观结果所增加的假设。

本章小结

因果语言承担多种任务：描述世界结构、说明知识根据、提供解释、预测干预和评价具体责任。严谨分析始于区分查询类型，并明确对照、目标量、识别假设与适用人群。关联、干预、反事实和实际因果处在不同推理层级；任何从一层到另一层的跨越都需要额外结构。

自测与研讨

1. 将“教育提高收入吗”改写成至少两个不同目标人群、不同处理版本的因果查询。
2. 举例说明：一个研究可以识别因果效应却没有提供机制解释；另一个研究可以提供机制证据却没有识别人群平均效应。
3. 为什么预测准确性不能单独证明模型中的箭头具有因果含义？
4. 在你熟悉的一项政策争论中，分别列出事实假设和规范判断。

延伸阅读

作为现代方法论导论，可读Holland (1986)对统计因果问题的经典表述、Pearl (2009)对结构因果模型的系统说明，以及Hernán, Robins (2020)以目标试验为中心的流行病学教材。研究设计与外部效度可对照Shadish et al. (2002)，从证据走向政策的条件分析见Cartwright, Hardie (2012)。哲学读者可从Woodward (2003)进入干预主义，并以Illari, Russo (2014)和Hitchcock (2024)提供的概念地图扩展阅读。

若希望比较不同学科怎样规定同一因果问题，可把社会科学中的反事实设计(Morgan, Winship, 2015)、应用计量教材(Cunningham, 2021)与潜在结果和 DAG 的并行评述(Imbens, 2020)放在一起阅读。随机试验的证据能力与外推限制可由Deaton, Cartwright (2018)检验；从局部规律走向可用原因的论证见Cartwright (2007)。实验、表示与实在论承诺之间的历史关系可读Hacking (1983)，因果和解释概念的总体地图可由Psillos

(2002)补足。

如果问题同时涉及实际因果、机制和证据整合,可用Paul, Hall (2013)区分不同因果任务,再以Russo, Williamson (2007)检查统计关联和机制证据怎样在同一健康科学主张中协同。

因果观念的历史谱系：从四因到科学解释

学习目标

读完本章，你应当能够：重构从亚里士多德四因、经院哲学与机械论到休谟、康德、穆勒、罗素和亨普尔的论证转折；区分历史继承与概念断裂；比较目的、规律、反事实与解释在不同时期承担的角色。

2.1 从四因到机械论：古代、中世纪与近代转折

2.1.1 四因、科学知识 with 经院传统

亚里士多德并没有在现代统计意义上提出四个因果变量。他讨论的是对“为什么如此”的完整回答类型。在《物理学》第二卷和《形而上学》第五卷中，常被译为“原因”的希腊词 *aitia* 也有说明、责任根据之意(Aristotle, 1996, 2016)。以一尊铜像为例：铜

是**质料因**，形状或定义是**形式因**，雕塑者的制作活动是**动力因**，纪念或审美目的则是**目的因**。四种回答不是把同一个位置分给四个竞争候选。它们回答不同维度的问题：由什么构成、成为什么、从何而来、为了什么。自然物与人工物的解释结构也不同。一张床的目的来自制作者，而生物体的目的性在亚里士多德那里属于自然过程自身的组织。若把目的因简化为行动者的主观意图，就会误解其自然哲学。

在现代科学中，形式因和目的因没有简单消失。结构生物学仍说明某种空间构型如何实现功能，进化论和系统生物学也使用功能语言。不过，这些说明通常被重释为历史选择、组织约束或机制贡献，而不是把未来目的当作向过去施力的事件。因而，古今之间既有概念延续，也有解释标准的改变。

科学知识为何要求把握原因 亚里士多德的《后分析篇》把科学与证明联系起来：知道一个事实还不够，还要知道使其必然如此的“为什么” (Aristotle, 1994)。理想证明从真实、首要且更可知的前提出发，通过中项揭示结论所依赖的原因。这种模式把因果解释、分类和本质知识紧密结合。这里的“必然”不能直接等同于现代逻辑中的材料蕴涵。一个有效三段论可以从任意真实前提推出结论，却未必解释结论。解释性的证明要求中项抓住适当原因。例如，说明行星为何不闪烁，需要指出它们距离较近并呈现可辨圆盘，而不是从“行星不闪烁”本身重新推出同一事实。解释由此具有方向性和相关性要求。现代因果推断同样强调“统计等式不等于解释结构”，但不应据此声称亚里士多德已经预见了 DAG 或 do-calculus。二者共享的只是一个宽泛洞见：知识不仅要求现象之间的规律联系，还要求说明哪些依赖具有解释意义。具体的数学对象、干预语义和识别问题属于完全不同的理论背景。

经院哲学：第一因与次级原因 中世纪拉丁哲学在亚里士多德框架中讨论创造、保存、偶然性和神意。阿奎那的“五路”不是五种自然科学实验，而是从运动、动力因、可能与必然、等级和目的秩序出发的形而上学论证(Aquinas, 2006)。以第二路为例，论证认为没有事物能在同一意义上成为自身的动力因；若所有动力因都只是先前原因的结果而不存在首要根据，便无法说明整个秩序。把这一路径简化为“因果链在时间上必须有第一件事”并不准确。阿奎那特别关心依赖秩序：某些系列中的成员在当下发挥因果作用，是因为它们从更根本者获得作用能力。现代宇宙学关于宇宙是否有时间开端，并不会直接判定这种形而上学论证。

同时，经院传统发展了**第一因与次级原因**的区分。上帝作为存在秩序的根本根据，并不排斥自然物具有真实因果能力。相反，自然研究可以追问火为何加热、水为何结冰，而不必把每个具体变化都当作直接神迹。这一区分为神学框架内的自然因果研究保留了空间。奥卡姆等思想家对必然联系、本质和共相采取更节制的立场，但“唯名论导致现代经验科学”不是一条单线历史规律。思想史解释需要区分文本主张、制度条件和后世重构，避免用现代科学的胜利倒推某一哲学立场必然先进。

2.1.2 机械论、充足理由与近代转折

十六、十七世纪的新自然哲学逐步把物体的大小、形状、位置和运动视为基本解释资源。笛卡尔的物质概念以广延为本质，自然变化通过接触运动和定律描述(Descartes, 1983)。这种机械论不只是新增一种动力因，而是改变了何种说明可被接受：目的、隐秘性质和不可分析的形式被排除或重新解释。

机械论带来两个重要效果。第一，它把自然解释与数学描述结合，使定量预测成为因果理论的重要检验。第二，它强化了系统的

封闭理想：给定初始状态和运动规律，后续状态应由同一种机械原则说明。然而，笛卡尔本人仍以上帝的创造和持续保存保证自然秩序，并面对非物质心灵如何影响身体的困难。所谓“近代因果观”从一开始就不是纯粹世俗且无争议的统一方案。

莱布尼茨：理由、原因与可能世界 莱布尼茨的**充足理由律**通常表述为：没有事实为真或存在，除非有充分理由说明它为什么如此而非相反(Leibniz, 2014)。这里的“理由”范围比事件原因更广。数学真理的根据可以是定义和同一律，偶然事实的理由则涉及世界秩序与上帝选择。把充足理由律直接说成“每个节点必须有父节点”会混淆解释根据、逻辑理由和结构方程中的直接原因。

莱布尼茨以**前定和谐**处理身心关系：心灵与身体并非在每一时刻互相施力，而是各自依照内部法则发展，并在创世安排中保持对应。这个方案保留了经验中的协调，却否认通常意义上的跨实体因果互动。它提醒我们：观察到两条序列完美同步，并不足以决定它们之间存在直接因果作用。现代共同原因模型表达了类似的逻辑可能性，但其数学与形而上学基础不同。

从目的秩序到有效作用 古代到近代的变化不能概括为“迷信让位于科学”。更准确的说法是，解释优先级与可接受证据发生了重组：

- 亚里士多德框架要求从构成、形式、生成和目的多个方面回答为什么；
- 经院哲学把自然因果嵌入创造与依赖的形而上学秩序，同时保留次级原因；
- 机械论优先使用可数学化的运动、接触与定律，限制目的和形式在基础物理解释中的位置；

- 理性主义继续追求充分解释，却在身心关系、偶然性与自由问题上展示出机械图景的张力。

现代“因果效应”概念主要继承了对差异制造和有效作用的关心，而不是完整继承四因说。即便如此，现代研究仍要回答变量如何被构造、机制如何组织、干预为何有政策意义；这些问题说明因果研究从来不只是计算动力因的单一任务。

2.1.3 历史案例、解释误区与目的语言

若问一颗种子为什么长成橡树，四因框架会要求多维回答。组织与营养物质构成质料条件；橡树的形态与发展组织提供形式说明；母树、授粉、发芽和细胞活动构成生成过程；成熟、繁殖与物种生活方式进入目的性或功能性解释。现代生物学不会接受一个未来橡树从前方拉动种子的简单图景，却仍区分材料、结构、发育机制和功能。机械论式回答会把生长分解为水分、光照、基因表达、激素和细胞分裂的局部过程。它能够提出可干预预测：改变光周期或赤霉素会怎样。进化论又解释为何这种发育结构在种群历史中被保留。于是，同一“为什么”可能包含近因机制和远因历史，不能由一条回归边完全容纳。

若用现代 SCM 表达，可令基因型 G 、环境 E 和发育调控 M 影响生长 Y 。这有助于研究 E 的干预效应，却没有把形式因“翻译完毕”：变量如何划分、什么算正常发育、为何以成熟橡树为解释对象，仍来自生物理论。古代框架提供问题分类，现代模型提供局部识别；两者关系是重构而非同一。

历史解释的三种错误 第一是**先驱叙事**：只要古代文本出现“条件”“作用”或“所以”，就称其预见现代因果图。这样做忽略了数学语义与问题背景，也使古代思想的独特目标消失。第二是**淘汰叙**

事：把形式因和目的因一概视为被科学革命消灭的迷信。现代结构与功能解释虽然不等于亚里士多德目的论，却说明解释词汇并未只剩碰撞运动。第三是**单因叙事**：把现代科学兴起归给唯名论、机械论或某一宗教立场。真实变化涉及仪器、数学、制度、工艺和多种哲学争论。

严谨思想史至少要区分原始语词、作者论证、当时论敌、后世接受和现代重构。例如阿奎那的“第一因”若脱离其存在论与依赖秩序，只剩一条时间链，就会遭到一个并非原论证核心的反驳。反过来，指出原论证不是时间开端论证，也不等于它已经成功；只是把评价对象放回正确位置。

目的语言的现代使用条件 现代科学说“心脏的功能是泵血”，通常包含选择历史或系统贡献，而不是说未来血流导致心脏形成。功能归属可以产生可检验预期：若结构是为该功能组织，破坏关键部分应系统损害泵血，并存在补偿与失效模式。目的语言由此能被机制和反事实约束。政策与工程中的目的则来自行动者设计。“学校改革为了提高公平”陈述的是规范目标，不保证实际机制实现该目标。因果评估必须区分设计意图、实施活动和真实结果；否则会把目的因式说明误当效果证据。

2.2 休谟：经验、必然联系与归纳问题

2.2.1 必然联系、恒常结合与习惯

休谟从不否认人类会进行因果推理。他的问题是：这种推理的根据是什么？当我们看到火焰便预期热、听见撞击声便推断物体接触时，心灵从已出现的印象跨越到未出现的事实。这个跨越既不是

对词义的分析，也不是演绎证明，因为否定“火将带来热”并不包含逻辑矛盾(Hume, 1999, 2000)。休谟把知识对象大致区分为**观念关系与事实问题**。前者如数学命题，其否定导致矛盾；后者涉及世界如何，其相反情形始终可设想。所有超出当前感官和记忆的事实推断都依赖原因与结果关系。因此，若因果推理没有理性根据，我们的大部分经验知识都会受到影响。

从单一实例中看不到什么 假设一个人第一次见到两只台球碰撞。他可以观察到第一只球运动、接触、第二只球随后运动，却无法仅从第一只球的可感性质演绎第二只球必然如何。无论把观察放慢多少倍，我们看到的仍是事件的时间先后、空间邻近与运动变化，而不是一个额外的“必然联系”感官性质。这一步论证针对的是从单一事件中读取必然性的企图。原因的全部可观察性质并不包含结果；想象相同原因伴随另一结果，至少在逻辑上是可能的。因此，对新对象的因果预期必须来自过去经验中的重复模式，而非对对象本质的纯理性洞察。

恒常结合与习惯 当相似的 *A* 类事件反复伴随相似的 *B* 类事件，心灵逐渐形成从 *A* 的出现过渡到 *B* 的期待。休谟称这种经验模式为**恒常结合**，称由重复产生的推断倾向为习惯或惯例。必然性观念的印象来源，不在外部对象之间被直接感知的纽带，而在心灵被决定从一个观念转向另一个观念的感受。这不是简单地说“因果就是相关”。第一，恒常结合要求相似类型在经验中有规律地相继，不是任意统计相关。第二，休谟同时要求原因先于结果，并讨论邻近性。第三，他的分析既涉及对象之间的规律，也涉及心灵的推断。后世所谓“休谟式规律论”往往把其中的心理发生学改写为关于世界规律的形而上学理论，不能不加区分地归给休谟本人。

2.2.2 归纳循环、因果定义与反事实校正

我们为何相信尚未观察的实例将类似于已经观察的实例？一种回答是：因为过去这种推断经常成功。但这已经用过去经验支持未来可靠性，正是需要辩护的推理形式。另一种回答是：自然过程保持一致。可是“自然齐一”不是逻辑真理；若以过去的齐一性证明未来仍齐一，同样发生循环。所以，**归纳问题**不是问有限样本怎样通过更多样本接近总体，也不是抱怨统计估计有误差。它追问的是从已观察到未观察的推断规则本身如何获得非循环的理性证明。增加样本可以改善一套已经接受的统计程序，却不能通过演绎证明未来必须像过去。休谟的回答具有自然主义色彩：人类并非经由论证才开始归纳，而是由心理习惯不可避免地形成期待。这可以解释我们为何推理，却没有按传统理性主义标准证明这种推理必然可靠。此后哲学家分别尝试以先验条件、概率确认、实用成功、最佳解释或可靠主义回应这一挑战。

两种因果定义 《人类理解研究》给出两种彼此关联的界定。第一种从对象关系出发：一个对象先于并邻近另一个对象，且与第一对象相似的对象都伴随与第二对象相似的对象。第二种从心灵过渡出发：一个对象的出现使心灵形成另一个对象的观念，并对其存在产生更强信念(Hume, 1999, 第七节)。

两种定义反映了休谟分析的双重面向。若只保留第一种，就容易把因果理解为无例外规律；若只保留第二种，又可能把因果变成主观联想。休谟试图说明，我们关于外在必然关系的观念如何由规律经验和心灵活动共同产生。学界对他最终是怀疑实在必然性，还是承认不可知的因果力量，存在“旧休谟”与“新休谟”等解释争论。本书不把其中任何一种直接当作无争议结论。

反事实萌芽与规则校正 休谟有时说，如果没有第一个对象，第二个对象便不会存在。这句话常被视为反事实因果分析的先声。然而，成熟的可能世界语义、结构方程反事实和潜在结果都远晚于休谟。更谨慎的理解是：他意识到因果判断不仅报告实际共现，还包含对缺席和替代情形的期待。习惯也不是盲目记录频率。休谟提出若干判断因果的规则，包括原因先于结果、相似原因产生相似结果、效果差异对应原因差异等。这些规则试图校正偶然共现、复杂原因和不完全观察。它们仍无法从纯经验中推出形而上学必然性，却展示了从粗糙联想到受约束经验推理的距离。

2.2.3 休谟问题的现代意义与建设性作用

随机试验、因果图和潜在结果没有“解决”休谟问题到使其消失。它们做的是在明确假设与设计下回答更局部的问题。例如，随机化可以使处理组与对照组在概率意义上可比较，从而识别平均处理效应；它并不证明自然规律在所有未来情形中保持不变。图模型可以编码干预不变性；这种不变性仍是关于系统的实质假设。

休谟的持久贡献是迫使我们区分：

- 在数据中观察到的规律；
- 从规律推向未观察情形的推断习惯或规则；
- 声称世界中存在的必然联系；
- 支持特定干预结论的设计和背景假设。

现代因果科学的严谨性不在于重新观察到“必然纽带”，而在于把跨越这几个层次所用的假设公开化，并让替代模型接受经验与理论检验。

休谟问题与现代概率学习 贝叶斯方法以先验分布和似然更新不确定性：

$$P(\theta | D) \propto P(D | \theta)P(\theta).$$

它能够给出内部一致的学习规则，却仍需模型类、先验与数据生成机制在新情形中适用。若世界机制突然改变，依据过去数据形成的后验不会凭逻辑保证未来校准。贝叶斯主义回答“给定概率模型应如何更新”，不自动回答模型为何适用于未观察世界。

频率主义的大样本保证同样带条件：样本来自稳定分布、观测满足相应独立或弱依赖、模型或估计方程正确。大数定律是数学定理，但从现实抽样过程到定理条件仍需经验判断。休谟问题因此不因选择某一统计学派而消失；它转化为对稳定性、可交换性和模型适用域的说明。现代因果推断进一步把稳定性局部化。研究者不必假定“整个自然完全齐一”，而可假定某些结构模块在特定干预和目标域中不变。例如接种机制可能跨医院稳定，而接种概率随政策变化。选择图与模块性使“哪些方面继续像过去”成为可分解问题。这不是对归纳的演绎证明，而是一种更透明、可被局部反驳的实践回应。

可投射规律与偶然规律 并非一切过去共现都适合投射。一个工厂每天中午汽笛响起，附近工人随后用餐；若汽笛因维护停响，工人仍可能按钟表吃饭。汽笛与用餐有稳定序列，却不是维持结果的机制。另一个例子是所有样本中的药品批次号恰好与疗效相关，换批次后关联消失。“可投射性”要求模式连接到能够在相关变化下保持的结构。机制、干预和跨环境数据都在帮助区分偶然规律与稳定规律。若改变汽笛不改变用餐，而改变工作制度会改变用餐，后者更接近解释变量。Woodward 的不变性和 SCM 模块性可被看作对休谟遗产的一种现代重构：不声称观察到必然纽带，而

以反事实稳定性刻画因果规律。

怀疑论的建设性作用 休谟式怀疑不是要求停止经验研究，而是阻止研究者把习惯期待包装成逻辑必然。对一项因果结论，可提出四个休谟式问题：实际观察到了哪些重复关系？从观察到干预跨越时增加了哪些假设？相似实例由何种分类标准构成？背景变化到何种程度会使规律不再可投射？这些问题尤其适合审查大数据分析。样本规模可以使极小关联精确，却不会自行回答变量分类是否合理、未来平台规则是否相同或推荐算法是否改变用户行为。休谟问题在算法时代不是古老障碍，而是防止“精确的习惯”冒充因果知识的长期纪律。

2.3 从先验秩序到科学解释：康德、穆勒、罗素与亨普尔

2.3.1 康德与穆勒：秩序条件和比较方法

康德承认休谟证明了因果必然性不能从重复经验中抽取，却不同意因果只是习惯。其“哥白尼式转向”追问：具有客观时间秩序的经验如何可能？在《纯粹理性批判》的“经验第二类比”中，康德区分主观知觉次序与对象事件次序(Kant, 1998)。

观察一所房屋时，我们可以先看屋顶再看地基，也可以反向观看；知觉先后不代表房屋部分在对象中先后发生。观察船顺流而下时，船在上游的状态先于下游状态，次序不能任意倒置。要把一串主观表象判断为一个客观事件，我们必须把后继状态理解为依规则依赖于先前状态。因果范畴由此不是从经验概括出来，而是经验对象能够具有确定事件次序的条件。

康德的论证不是说人类心理无法想象无因事件，也不是给出每个具体事件的经验原因。它试图建立更一般的先验原则：经验世界中的变化必须能够置于规则规定的时间统一体中。至于某种药物是否造成康复，仍需要经验调查。先验原则规定了可经验对象的一般形式，不提供具体因果律清单。

这一回应的代价是限制。因果范畴适用于现象，即对象在我们的经验条件下如何呈现；它不能被无条件推广到物自身。自由问题因此获得特殊位置：作为经验中的行动，行为服从自然因果；作为理性主体的自发性，它又不能简单被现象因果穷尽。后来的科学哲学通常不接受整套先验唯心论，却持续关注因果结构与客观时间、规则和经验可判定性之间的关系。

穆勒：从比较案例寻找原因 十九世纪的穆勒把因果研究置于归纳逻辑中。《逻辑体系》总结的“五法”不是五种充分可靠的自动算法，而是组织比较证据的模式(Mill, 1974)。

契合法 如果若干出现结果的案例只有一个共同因素，该因素可能是原因或不可缺少的条件。

差异法 若两个尽可能相似的案例只在一个因素和结果上有差异，该因素可能造成结果差异。

契合差异并用法 结合阳性案例的共同因素与阴性案例的缺失因素。

剩余法 从复杂结果中扣除已知原因可解释的部分，把剩余部分归给剩余前件。

共变法 当某因素的量变化伴随结果系统变化时，以共同变化支持因果判断。

差异法最接近受控实验：若除处理外其他条件相同，结果差异可归于处理。但现实中“其他条件相同”通常不是观察事实，而是

设计目标或模型假设。契合法容易把共同背景、选择条件误当原因；共变法则直接面对混杂和反向因果。穆勒本人知道复杂社会现象存在原因复合和效应交织，不能靠机械套表消除困难。现代匹配、分层和回归有时被称为差异法的统计化版本，这种说法有启发但也有限。现代方法明确区分样本平衡、潜在结果可交换性和估计不确定性；穆勒五法没有潜在结果语义，也没有一般的概率识别理论。历史联系应当理解为共同的比较逻辑，而非现代方法已经隐含在十九世纪文本中。

2.3.2 罗素与亨普尔：从原因批判到覆盖律解释

罗素在 1912 年《论因果概念》中尖锐地声称，哲学家所说的因果律像君主制一样，只因被误认为无害而继续存在(Russell, 1912)。他的主要靶子是含混的传统原则：同样原因产生同样结果、原因先于结果、每个事件都有原因。这些原则在精确物理学中要么不真，要么因“事件相同”“原因足够完整”等限定而变得空洞。经典物理方程往往给出变量之间对称的函数关系，而不是把世界切成离散事件对并指定单向产生。例如，微分方程与边界条件可以从不同时间方向求解；若基本规律时间反演对称，从较早状态到较晚状态的日常因果箭头就不是方程形式本身直接给出的。

罗素的论证没有证明一切科学都应放弃因果概念。生物学、医学与社会科学关心局部干预和非对称控制，而不是只寻找封闭系统的基本方程。即使物理定律以对称关系表达，初始条件、热力学箭头、控制结构与实际可干预性仍可能产生有意义的非对称。罗素更准确的贡献，是迫使因果理论说明其概念在什么科学任务中不可替代，而不能把含混常识抬为普遍定律。

亨普尔：解释作为定律下的推导 覆盖律传统把科学解释理解为论证。**演绎律则模型**（D-N 模型）要求从普遍定律和特定初始条件演绎推出待解释现象；待解释项是结论，解释项包含定律与条件（Hempel, 1965）。例如，给定理想气体定律、容器体积等条件和温度变化，可推出压力变化。

归纳统计模型处理概率规律：解释项不保证结论，而赋予它较高概率。这里出现一个问题：低概率事件也可能有良好因果解释，如一种罕见副作用确由药物引起；高概率结果也可能被无关信息“预测”。概率大小本身不能取代解释相关性。

D-N 模型的几个反例揭示了纯推导结构的不足。

- **方向性反例**：旗杆高度和太阳角度可推出影长，影长和太阳角度也可推出旗杆高度；前者通常解释影长，后者却不解释旗杆为何如此高。
- **无关性反例**：在足以推出结论的前提中加入“病人服用了避孕药”等无关信息，论证仍有效，却没有获得更好的解释。
- **共同结果反例**：气压计读数可预测暴风雨，但气压计不是暴风雨的原因；共同原因大气压力变化同时影响二者。

这些例子表明，解释需要的不只是逻辑蕴涵或统计支持，还需要正确的依赖方向和相关结构。Salmon 的因果过程理论、机制解释和 Woodward 的干预主义都可以看作对这一缺口的不同回应。

2.3.3 方案比较、案例重构与解释约束

从康德到亨普尔，可以看到“规则”概念不断变形。康德把因果规则视为客观事件经验的先验条件；穆勒把比较规则作为从经验寻找原因的归纳方法；罗素要求用精确函数关系取代含混因果格言；亨普尔则以定律在解释论证中的角色重建科学说明。四者

都反对把因果判断视为未经约束的直觉，但约束来源不同：先验认知条件、经验比较、数学物理结构或逻辑推导。现代因果模型吸收了其中若干要求——明确变量关系、支持比较、尊重定律和提供方向——却没有简单继承任何单一方案。

关键辨析

预测、推导和解释是三种不同成就。正确方程可能允许双向计算，统计指标可能准确预测，演绎论证可能形式有效；只有当模型还刻画了与问题相关的方向性依赖时，它们才构成因果解释。

深读：同一现象的四种解释 设一座沿海城市发生严重洪水。康德式问题不是找出洪水的具体经验原因，而是说明我们何以把潮位上升、堤坝破损和街区淹没理解为有客观次序的事件，而非任意知觉串联。穆勒式比较会寻找其他风暴、相邻城市和未受损堤段之间的共同与差异条件。罗素会要求用流体方程、地形与边界条件精确描述水位，而警惕“风暴导致洪水”过于粗糙。亨普尔式解释则尝试从水动力规律和初始条件推出淹没结果。

四种回答各自遗漏一些东西。方程可以从已知水深反算某些边界条件，却不表示水深解释风暴；城市比较若未控制海拔和维护，差异法失效；从规律推出洪水也未必说明为何恰是这道堤坝首先破损。机制调查需要进入材料疲劳、施工缺陷和水压传播；政策解释还要追问维护预算与治理责任。案例表明，科学解释并非在“定律”与“原因”中二选一。定律约束什么过程可能发生，初始条件定位具体情形，因果结构给出方向，机制描述过程，比较设计支持某个差异归因。完整解释往往是这些元素按问题需求的组合。

穆勒方法的现代重构练习 假设五所学校中只有两所采用新课程，且这两所成绩提高。契合法会把新课程视为共同因素，但两校也可能有更优秀师资。差异法会寻找采用与未采用、其他方面相似的学校；然而“相似”需要对潜在结果有意义，而非表面变量接近。若采用由校长能力决定，而校长能力也影响成绩，匹配规模和地区仍不足。现代潜在结果语言把差异法的理想写为处理赋值与潜在结果可交换。DAG 则把需要阻断的共同原因画出来。它们没有让比较原则过时，而是把“除一项外相同”改成概率与结构条件，并允许在不完全相同单位间估计平均效应。剩余法也可现代理解。分解空气污染来源时，已知交通、工业与自然尘埃共同形成浓度；从总量扣除已验证来源后把残差归于某来源，需要测量模型与质量守恒。统计残差本身不是“剩余原因”，因为它还包含误差和模型错设。

解释反例告诉我们的三条约束 旗杆反例要求**方向约束**：解释项应处于使被解释项改变的上游。共同结果反例要求**结构相关性**：即使一个指标预测结果，也要排除共同原因与选择路径。无关前提反例要求**问题相关性**：解释不是包含越多真实信息越好，而要挑出对所问对照产生差异的信息。这三条约束在现代模型中分别由箭头方向、d-分离和目标查询表达。但图本身仍相对于变量与问题：同一方程在控制问题中可从输入到输出使用，在诊断问题中可从输出反推故障。计算方向可逆，不使因果方向可逆；推断任务改变，也不必改变产生结构。

2.4 历史理论对现代方法的约束

思想史如何形成方法论约束 思想史对现代方法的价值，不在于寻找谁最早说出今天的术语，而在于重建问题怎样改变。古代“为什么”包含构成、本质、生成和目的；近代机械论缩小基础解释资源；休谟追问必然联系的经验根据；康德追问客观次序的可能条件；穆勒、罗素和亨普尔又分别把比较、函数与定律推导置于中心。若把这些方案排成一条通往现代 DAG 的进步线，就会错过每次转折所牺牲和保留的内容。

严谨比较至少使用三种尺度。第一是文本尺度：作者在回应什么论敌，关键术语在原语境中承担什么作用。第二是问题尺度：该方案主要解释事件产生、知识正当性、科学说明还是行动控制。第三是重构尺度：现代概念能否帮助澄清论证，而不冒充历史同一性。例如可用共同原因说明“同步不等于直接作用”的逻辑结构，却不能因此把莱布尼茨称为概率图模型先驱。

历史案例还能暴露当代方法的盲区。现代效应估计强于回答明确干预对比，却可能弱化形式、功能和解释相关性；机械论强调局部过程，却可能忽视制度和规范对象怎样构成变量；覆盖律强调一般性，又被旗杆与共同结果反例逼迫加入方向。历史不是方法课之前可删去的装饰，而是一组关于“什么算充分解释”的压力测试。

从定律和机制到可干预模型 现代因果模型同时继承并改造了历史上的三种要求。定律要求关系不只是样本偶合，而在某些变化下保持稳定；机制要求模型说明变化如何经由中间组织产生；干预要求方向性能够支持对行动后果的判断。三者并不总能由同一研究一次满足。结构方程可以编码稳定关系，却可能把机制压缩

为一个函数；机制叙述可以细致，却未给出总体效应大小；随机试验识别行动差异，却未说明效应为何产生。

完整研究通常在这些层次之间往返。领域理论先界定变量与可能路径，设计制造或寻找有信息的比较，统计模型量化目标量，机制与异质性证据再检查关系是否能迁移。历史上的理论分歧由此没有被一个统一公式消灭，而是被重新分工：不同证据对不同推理环节负责。这种分工也说明为什么“数据驱动”不能等于无理理论。选择测量对象已经决定哪些形式和机制进入模型；把一项政策编码为二元处理，已经假定不同实施版本可被合并；选择平均效应，已经把分布与个体差异放到次要位置。历史训练的意义，是让这些被现代符号压缩的选择重新可见。

本章小结

四因说是四类解释性回答，不是四个竞争的统计原因。经院哲学区分根本依赖与自然中的次级原因；近代机械论则缩小基础自然解释的词汇，并把数学定律与运动过程置于中心。充足理由律比事件因果原则更广。理解这些差别，可以防止用现代模型粗暴改写历史，也能揭示现代方法仍未消除的解释问题。休谟从因果推理的经验来源出发，指出单一实例不呈现必然联系；重复的恒常结合通过习惯产生期待。归纳问题针对从已观察到未观察的非演绎跨越，不能靠简单增加样本解决。休谟的对象定义与心灵定义共同构成其分析，把他概括成“因果等于相关”既不准确，也遮蔽了现代模型仍需承担的不变性假设。康德以因果规则说明客观时间次序如何可能；穆勒把比较案例组织为五种归纳方法；罗素质疑传统因果律在基础物理中的精确意义；亨普尔以定律和条件对现象作演绎或概率推导。覆盖律反例进一步表明，科学解释需要相关性和方向性，而不仅是逻辑或概

率关系。

自测与研讨

1. 用四因框架分别解释一枚疫苗，并指出哪些回答能够由现代机制语言重新表述。
2. 为什么阿奎那的第一因论证不等于“宇宙中最早发生的事件必有原因”？
3. 机械论排除了哪些解释资源，又留下了哪些新的哲学问题？
4. 充足理由与结构因果模型中的父节点有何区别？
5. 为什么“太阳过去每天升起”不能非循环地演绎证明“太阳明天升起”？
6. 恒常结合与现代统计相关有哪些共同点和差别？
7. 比较休谟两种因果定义：它们分别遗漏了什么，又为何需要彼此？
8. 随机试验解决了哪些局部推断问题，为什么没有消除一般归纳问题？
9. 用“观察房屋”和“船顺流而下”的差别说明康德的第二类比。
10. 为一项公共政策分别设计契合法和差异法比较，并指出各自最可能的偏差。
11. 罗素对因果概念的批评在哪些科学中最有力，在哪些任务中较弱？
12. 构造一个有效预测但不能解释的例子，并说明缺少哪一种方向性信息。

延伸阅读

原始文本以Aristotle (1996)第二卷、Aristotle (1994)和Aristotle (2016)相关条目为核心；经院部分可参阅Aquinas (2006)第一部第二题；近代转折可对照Descartes (1983)与Leibniz (2014)。阅读时应优先使用带导论和注释的可靠译本。

首要文本是Hume (2000)第一卷第三部和Hume (1999)第四至七节。建议对照可靠注释本阅读，而不要只依赖“恒常结合”这一标签。关于休谟因果观的实在论解释争论，可从Strawson (1989)与当代休谟研究综述入手。康德部分以Kant (1998, 第二类比)为核心；归纳逻辑参阅Mill (1974, 第三卷)；分析哲学转折可读Russell (1912)；覆盖律模型与经典反例集中见Hempel (1965)，随后可与Salmon (1984)和Woodward (2003)比较。

培根的归纳与实验纲领应回到Bacon (2000)而不是只用“科学方法之父”的标签概括；现代实验实在论及其历史反思可续读Hacking (1983)。休谟研究中的规则性、必然联系与投射问题可由Beebe (2006)深化，康德第二类比在整个先验唯心论中的位置见Allison (2004)。若要把思想史重新连接到当代因果解释争论，可用Psillos (2002)检查哪些历史问题被保留、哪些只是术语相似。

当代因果哲学：反事实、概率、机制与干预

学习目标

读完本章，你应当能够：比较反事实、概率、机制、能力与干预理论的分析对象；检验先占、过度决定、遗漏和共同原因等反例；说明多元证据怎样形成受约束的整合，而非概念拼贴。

3.1 反事实因果：刘易斯及其难题

3.1.1 反事实语义、依赖与因果链

日常判断原因时，我们自然会问：“如果原因没有发生，结果还会发生吗？”若苏茜投出的石块击碎玻璃，而没有这次投掷玻璃便不会碎，我们倾向于把投掷视为原因。这个**若无检验**（*but-for test*）抓住了原因作为差异制造者的直觉，并给出因果方向：结果依赖原因，原因通常不以同样方式依赖结果。困难在于反事实前

件与事实相反。我们不能简单查看实际数据中“同一个对象同时未受处理”的结果，也不能只用材料蕴涵，因为一个前件为假的材料条件句会自动为真。反事实理论需要说明：在保留多少实际背景的前提下，怎样评价“若 A 未发生， C 会怎样”。

可能世界与相似性 Lewis (1973b) 提出可能世界语义：反事实“若 A ，则 C ”为真，当且仅当最接近现实的 A 世界都是 C 世界。这里的世界不是平行宇宙的经验假说，而是评价模态命题的理论装置。“最接近”也不是表面相似度的简单加总，而由一套受语境与自然规律约束的相似性排序决定。

评价“若火柴没有被划，是否会燃烧”时，我们通常允许一个小的局部偏离使划火柴事件不发生，同时尽可能保留现实规律和广泛事实。若为了保持更多局部事实而允许大规模违反规律，反事实判断会失去稳定性。Lewis 在讨论因果时给予避免巨大、广泛奇迹较高优先级，再考虑事实吻合范围。相似性语义的优点是能够处理非因果反事实，并解释为何“回溯式”反事实通常不成立。例如，若结果没有发生，我们通常不会反推原因也未发生，而倾向于假定因果过程在原因之后出现局部偏离。但相似性排序本身也受到批评：若我们已经凭因果判断决定哪些世界更接近，再用接近关系定义因果，就可能产生循环。

从反事实依赖到因果链 Lewis 早期分析把事件理解为时空区域中具有特定性质的个体。若 c 和 e 都实际发生，且

$$\neg O(c) \stackrel{\text{cf}}{\Rightarrow} \neg O(e),$$

即在最接近的无 c 世界中也没有 e ，则 e 对 c 存在**因果依赖**(Lewis, 1973a)。这里 $O(c)$ 表示事件 c 发生。

简单依赖并不总是传递。若按下开关导致继电器动作，继电器动作导致灯亮，我们希望开关是灯亮的远因，即使某些复杂背景使端点之间的直接反事实依赖失败。Lewis 因此把因果关系定义为因果依赖链的祖先关系：存在事件序列 $c, d_1, \dots, e$ ，每个后项因果依赖前项。这一做法恢复了因果传递性，却也制造过度传递问题。一个人向右躲开巨石，因此恰好站到后来被树枝击中的位置；躲避依赖巨石，受伤依赖躲避，但说巨石造成树枝击伤可能很勉强。是否传递取决于我们追踪的是能量过程、机会条件，还是与问题相关的变量路径。

3.1.2 先占、过度决定与遗漏难题

早期先占的经典例子中，苏茜和比利都向瓶子投石。苏茜的石块先击中并打碎瓶子，比利的石块稍后到达原位置。苏茜是实际原因，比利只是备份。然而，若苏茜没有投掷，比利仍会打碎瓶子，所以“没有苏茜投掷，瓶子不会碎”为假。简单若无检验遗漏了苏茜这个原因。

因果链方法可以区分实际过程：苏茜投掷经由飞行、撞击和裂纹形成到达破碎；比利链条在撞击前被截断。但**晚期先占**更困难：两条过程可以延伸很远，直到后期一个过程阻止另一个。要指出“哪条链是实际链”，理论往往需要对过程结构作比简单端点反事实更细的描述。

对称过度决定中，两枚同时且各自足够的炸弹共同摧毁目标。没有任意一枚，另一枚仍足够，因而两者都不通过若无检验；直觉却把两者都视为原因。可以把检验改成“在适当背景或某个事件子集中，改变该因素会改变结果”，但何谓适当背景必须防止任意挑选。

从是否发生到如何发生 Lewis 后期提出**因果影响**分析。一个事件 c 影响事件 e ，不是只要求“无 c 则无 e ”，而是要求 c 的一系列细微变化与 e 的一系列变化之间存在系统反事实对应(Lewis, 2000)。投石时间、速度或方向的变化会改变玻璃破碎的时间、方式或碎片分布；即使备份原因保证“最终仍破碎”，实际结果的具体方式仍受苏茜投掷影响。这一修正把二值发生扩展为事件的时间和方式，使先占案例更可处理。它仍依赖恰当的事件变更和相似性排序，也可能在微小改变引发复杂连锁时过宽。值得注意的是，《作为影响的因果》发表于 2000 年，而非有些二手资料误记的 1986 年。

遗漏、双重防止与规范背景 “园丁没有浇水导致植物死亡”把一个缺席当作原因。若事件是时空中的具体个体，缺席似乎不是可进入因果链的事件；若允许一切缺席成为原因，则任何未发生的救援都可能被说成结果原因。我们通常依赖职责、常规或期待筛选相关遗漏：受雇园丁的不浇水比陌生人的不浇水更容易被视为原因。

双重防止也挑战简单过程直觉：保镖阻止刺客阻止解药送达，因而保镖的行动使解药到达。反事实上，保镖行动与获救存在依赖，但两者之间未必有从原因向结果传递的连续物理过程。反事实理论能自然容纳这类“让某过程不受阻”的因果，纯能量传递理论则较困难。

这些案例表明，实际因果判断可能同时依赖反事实结构、过程连接、事件描述粒度与正常性规范。结构因果模型中的实际因果定义尝试把这些要素形式化，但不同定义在先占、投票、法律责任等案例上仍有分歧。

3.1.3 因果类型、事件粒度与证据来源

“吸烟导致肺癌”通常是**类型因果**命题，涉及人群中的暴露分布与风险变化；“张某的吸烟导致了她的肺癌”是**个例因果**命题。前者可由试验、观测设计和机制证据支持，后者还需评价该个体的替代历史与实际过程。群体平均效应为零并不排除对不同亚组存在方向相反的作用，平均效应为正也不自动确定每一患者的实际原因。现代政策评估大多以类型因果效应为目标；法律、历史和故障诊断则频繁提出个例因果问题。选用框架时应先看查询，而不是假定所有因果句都由同一个若无条件定义。

深读案例：委员会投票与结构敏感性 五人委员会以至少三票通过提案，实际五人都投赞成。对任一成员，若只有他改投反对，提案仍通过，所以简单若无检验不把任何一票视为原因。若允许把其他两票设为反对作为应急背景，则某一票会成为关键；同样推理又把每票都算作原因。这是否正确取决于查询。若问每位成员是否参与形成充分多数，全部赞成票都有贡献；若问谁的改变本可阻止提案，单独没有人；若问法律责任，职务、信息和串谋可能改变答案。结构模型需要明确聚合规则和应急情形，不能用一个“实际原因”标签消除问题差异。再设主席只在平票时投票，实际普通成员三比一通过，主席未投票。主席的缺席不是提案通过的原因；但制度规则允许他的潜在票在其他背景中关键。这里必须区分因果能力、实际贡献和制度权力。反事实理论若不限定实际过程，可能把广泛备份能力误作具体原因。

事件描述粒度 “苏茜投石”可以描述为一次具体肌肉动作、石块以某速度离手、石块击中某位置，或更抽象的“有人投掷”。反事实依赖会随描述变化。若苏茜没有以每秒十米速度投掷，她可能以

九米速度投掷，瓶子仍碎；若她完全没有投掷，比利会接替。粗粒度决定哪些替代世界最接近。结果描述也一样。“瓶子碎了”在备份存在时不依赖苏茜，但“瓶子在 12 点 00 分以这种裂纹碎裂”可能依赖。后期影响理论利用这种细节，但过细结果会使几乎任何微小背景都成为原因。适当粒度应由解释问题决定，并保持在相似案例中一致，而不是为了得到直觉答案临时调整。结构方程把事件粒度转化为变量选择。二元变量适合某些责任规则，过程变量适合先占路径。模型比较应说明新增变量如何对应真实过程及可获得证据，而非只证明“存在一幅图能给出想要答案”。

反事实判断的证据来源 我们无法直接观察反事实，却可由多类证据约束。重复试验估计类型层面的干预差异；机制知识说明改变如何传播；时间与物理连续性识别实际路径；相似案例支持背景稳定；制度规则规定哪些替代情形可行。个例因果判断通常综合这些来源。例如判断药物是否导致某患者过敏，群体试验显示风险提升，免疫检测显示特异机制，给药后时间吻合，停药后症状缓解，再暴露后复发。任何单项证据都可能不足，组合则强化“若无给药便无此次反应”的模型。反事实不是纯粹想象，而是受实际证据约束的模型推论。

3.2 概率、机制、力量与干预：多元因果理论

3.2.1 概率、共同原因与 INUS 条件

反事实理论突出差异制造，却可能难以刻画实际过程；规律论说明事件类型的稳定联系，却容易遗漏方向；机制论展示结果如何产生，却未必给出效应大小；概率理论适合不确定系统，却必须

处理混杂；干预主义连接实验实践，却需要说明何种变化算合格干预。二十世纪后半叶的因果哲学由此呈现多元格局。多元不等于所有理论都同样正确，也不意味着同一句因果话语可以任意解释。较稳妥的看法是：科学中的因果概念承担若干彼此相关的功能——预测操纵结果、解释生成过程、支持迁移、归属责任。不同理论把其中某一种功能当作分析中心。评价它们时，应同时问理论处理何种对象、服务何种查询、依赖何种背景。

概率提升与共同原因 在随机或不完全观测系统中，原因不必保证结果。吸烟者并非人人患肺癌，未吸烟者也可能患病。概率因果理论据此把原因理解为提高结果概率的因素。最简单形式是

$$P(E | C) > P(E | \neg C).$$

Suppes 把时间优先和概率提升结合起来讨论“表面原因”与“真正原因” (Suppes, 1970)。

简单概率提升面临三类困难。第一是**混杂**：冰淇淋销售与溺水同时上升，是炎热天气共同影响二者，并非购买冰淇淋使人溺水。第二是**辛普森反转**：总体概率提升可能在每个相关亚组中消失或反向。第三是**预防原因**：安全带对死亡具有负向因果作用，表现为降低而非提高概率。因而更一般的语言应谈论概率改变，并要求在恰当背景中比较。

Reichenbach 的**共同原因原则**指出：若两个事件相关，且彼此不是原因，则应寻找一个共同原因，使相关在适当条件下被“筛除” (Reichenbach, 1956)。在简单情形中，若 C 是 A 与 B 的共同原因，可期待

$$P(A, B | C) = P(A | C)P(B | C).$$

现代图模型把这种思想推广为条件独立结构，但共同原因原则不是无条件定理。选择偏差、确定关系、量子相关和不完整变量描述都会使简单筛除形式需要修正。

Mackie 的 INUS 条件 现实结果常由原因复合产生。电路短路并非任何情况下都引起火灾；它可能需要可燃物、氧气和保护装置失效共同出现。Mackie 把许多日常原因分析为 **INUS 条件**：一个不充分但为某个不必要而充分条件之必要部分 (Mackie, 1974)。

设火灾 F 可以由两组条件产生：

$$(S \wedge O \wedge D) \vee (L \wedge G) \rightarrow F,$$

其中 S 为短路， O 为有氧环境， D 为保护失效；另一条路径由雷击 L 与干燥 G 构成。 S 单独不足以导致火灾，但在组合 $S \wedge O \wedge D$ 中不可缺；这个组合足以导致火灾，却不是必要的，因为还有另一条路径。因此 S 是 F 的一个 INUS 条件。

INUS 分析有两项贡献。它避免要求单一原因既必要又充分，并突出因果场景与替代充分集合。但形式中的“充分”通常相对于背景和模型，而非宇宙中绝对无例外；如何选择正常背景、如何处理概率结果和连续变量，也不是析取范式本身能够解决。INUS 更像揭示复合原因结构的分析工具，而不是完整的因果形而上学。

Salmon：解释必须进入因果网络 Salmon 反对把科学解释仅仅看成定律下的推导。他早期使用统计相关模型，后来发展**因果过程理论**：能够传递结构或“标记”的过程，与只呈现运动轨迹的伪过程不同 (Salmon, 1984)。一束光可以携带调制信息；墙上的光斑可以超光速移动，却没有一个物体或信号沿光斑轨迹传播。因果过程在交互中改变并把变化继续传递。两辆汽车碰撞后速度和形

变改变，交互把此前过程连接到此后过程。解释一个事件，就是说明它如何嵌入产生它的因果网络，而不是仅仅展示一个包含它的统计规律。“标记传递”后来受到批评：什么算可传递标记可能依赖反事实，难以覆盖场、持续约束和非局部结构。Salmon 转向以守恒量传递刻画因果过程，但这更适合物理情形，对社会制度和生物调控未必直接适用。其核心遗产不是某个永恒定义，而是解释相关性要求追踪实际产生结构。

3.2.2 机制、因果力量与干预主义


生命科学中的机制解释通常不要求一条单独守恒量链，而把机制理解为实体和活动以特定时空方式组织并产生现象。Machamer、Darden 与 Craver 强调“实体做什么”，Glennan 则强调部件相互作用形成稳定行为(Glennan, 2017; Machamer et al., 2000)。以动作电位为例，完整机制涉及膜、电压门控离子通道、离子浓度梯度以及通道依时间开闭的组织。仅说刺激与放电相关不能解释波形如何产生；仅列出部件也不够，必须说明活动顺序和组织。机制模型往往是多层且不完整的：研究目的决定需要向下分解到何种程度。机制证据对外推尤其重要。若某药物在试验人群中有效，而目标人群缺少关键受体，平均效应未必可迁移。不过，机制叙述也可能只是“故事”。可靠机制解释需要独立测量、干预部件、追踪中间过程并排除竞争路径。

因果力量与能力 Cartwright 批评把自然定律视为处处无条件成立的普遍概括。实验定律常描述精心隔离的情形；现实结果由多种因果能力共同作用(Cartwright, 1989)。阿司匹林具有缓解疼痛的能力，并不意味着每次服用都实际止痛，因为剂量、吸收、病因和其他药物会改变表现。力量或能力语言抓住了原因在不同背景

中仍可被识别的倾向性，也说明效应不是裸相关。但它面临测量和判准问题：若我们只通过效果知道某物有能力，再用能力解释效果，便有循环危险。实际科学需要通过多种独立表现、机制和干预来校准能力归属。

Woodward：不变性与干预 Woodward 的干预主义不把因果简化为人类实际能够操纵的东西，而是用理想干预定义变量层面的因果关系(Woodward, 2003)。粗略地说，若存在对 X 的合格干预，改变 X 会改变 Y ，则 X 是 Y 的原因之一。合格干预 I 应改变 X ，并且除经由 X 外不通过其他路径直接影响 Y ；它还应切断 X 与其通常原因的联系。

这种要求可以用图表示：



理想干预使 I 只通过 X 影响 Y ，并替代 $U \rightarrow X$ 的通常生成方式。随机试验是实现这种结构的一种设计，但干预主义也评价不可实际操作变量：只要能够清楚定义合适的反事实改变，例如地壳运动或恒星质量，就可以讨论其因果影响。Woodward 还以**不变性**说明解释深度。一条关系若在多种针对输入的干预下保持稳定，就比只在狭窄数据范围内拟合良好的相关式更具有因果解释力。温度计读数与温度稳定共变，但直接改变温度计指针不会改变环境温度，显示关系方向不是由回归对称性决定。干预定义会否循环？要判断 I 不通过其他路径影响 Y ，似乎已经使用因果概

念。Woodward 的回应不是把所有因果词还原为非因果词，而是提供相互约束的网络分析：变量关系、干预条件与不变性共同澄清科学实践中的因果主张。这是一种非还原分析，而非传统意义上的概念消除。

3.2.3 理论互补、解释层级与选择准则

以药物安全为例，概率数据说明药物如何改变不良事件风险；潜在结果或图模型说明在何种设计下该变化可归因于药物；机制研究追踪代谢与受体通路；能力语言描述药物在不同背景中的倾向；实际因果分析判断某病例的不良事件是否由药物造成。这些答案不能相互代替，却可以形成证据链。理论多元的纪律在于明确接口：机制知识如何转化为图结构假设？概率效应在哪些背景中保持？干预改变的是机制中的哪个环节？个例归因是否有群体数据与过程证据支持？只有回答这些接口问题，多种理论才是互补；否则“综合”只是把不同术语并列。

贯穿案例：医院内感染 某医院发现中心静脉导管患者血流感染率升高。概率理论首先比较置管与未置管风险，但病情严重者更可能置管，简单概率提升包含适应证混杂。潜在结果与图模型要求定义“在符合置管条件者中采用某种导管策略”的效应，并调整病情等共同原因。机制调查追踪皮肤菌群、置管过程、导管表面生物膜和免疫反应。它解释为何无菌操作、敷料和拔管时机可能改变风险。INUS 分析可把“导管存在、无菌屏障破坏、足够留置时间、易感宿主”视为一条充分条件组合；另一条感染路径可能来自远处感染播散。没有哪个因素单独必要充分。因果能力语言说导管表面具有支持生物膜的倾向，但这种能力在涂层、抗菌措施和宿主不同条件下表现不同。干预主义要求检查改变导管材料、操作

规范或留置时间是否系统改变感染，并区分这些可控变量的路径。实际病例归因还要判断培养结果、时间与替代来源。

这个案例显示，证据不是简单投票。若观察关联强但机制检测显示主要病例菌株来自另一来源，因果解释需修订；若机制在实验室成立但医院随机改进措施无效果，可能是实施失败、机制贡献太小或替代路径补偿。不同证据之间的冲突用于诊断模型，而非选择自己偏好的理论。

解释层级与干预层级 医院可以在分子、设备、操作人员、病房和制度层面干预。同一结果具有多层原因：材料属性影响附着，护士工作负荷影响无菌操作，采购制度影响材料选择。低层机制不一定使高层因果失真；若改变排班稳定改变感染，高层变量具有政策相关的干预意义。层级之间可能出现实现关系。工作负荷通过多种具体动作影响感染，不存在一个固定微观中介；要求把政策效应完全还原为每次手部动作才算“真正因果”，会让有用的宏观解释失效。反过来，高层标签若无法对应任何稳定实施方式，效应也难迁移。因果多元主义由此不是给每层一个互不相干真理，而是要求跨层约束：宏观干预改变哪些机制分布，微观机制为何汇总成观察效应，背景变化如何改变实现。机制、概率和干预关系在这些接口上互相检验。

理论选择的实用准则 如果目标是政策净效果，优先明确处理策略与人群平均反事实；如果目标是故障诊断，优先追踪实际过程和部件；如果目标是风险预警，概率关系可以在不承担干预解释时发挥作用；如果目标是迁移，机制与不变性尤为关键；如果目标是责任，需在实际因果之外加入规范标准。同一项目可随阶段改变工具：探索阶段以概率和发现算法缩小假设，验证阶段以试验

识别差异，解释阶段分解机制，部署阶段检验环境不变性。理论的价值由它对具体查询的约束力衡量，而不是由它能否把所有因果语言压成一句定义衡量。

3.3 理论选择、证据整合与模型责任

3.3.1 用反例检验理论

因果理论的差异只有放入困难案例才会清楚。先占案例中，两条潜在路径都足以产生结果，但其中一条先完成过程；简单若无检验可能把被截断的备份也算原因。对称过度决定中，两项因素同时足以，删除任一项结果仍发生，若无条件又把两个直觉原因都排除。遗漏案例中，不行动可能是结果的原因，却难以用能量传递描述。共同原因案例则提醒概率提升可以由上游因素制造。

检验理论时应逐项记录它改变了什么。刘易斯式方案可能修改事件描述、引入因果链或采用影响关系；机制论可能要求追踪实际过程；结构模型可能加入应急情形和正常性排序；概率理论可能条件化背景集合。修正解决一个反例时，往往同时增加新的理论负担。例如加入正常性有助于区分园丁浇水与植物存活，却需要解释正常判断来自统计、功能还是规范。

反例不必迫使所有理论竞争一个定义。若研究任务是分配法律责任，实际因果和规范背景不可避免；若任务是估计药物平均效应，个例正常性可能不是主要对象；若任务是解释细胞过程，机制组织比总体风险差更重要。真正需要统一的是同一任务中的概念使用，而不是把所有因果问题压进一个必要充分条件。

多元证据如何形成共同约束 理论多元主义容易滑向“每种说法都有道理”。受约束的多元主义则要求不同表示在共享部分相互校验。反事实模型给出若改变条件结果会怎样；机制模型说明该改变通过哪些活动传播；概率证据估计关系的总体强度与异质性；干预模型检查关系能否在外部改变下保持。若机制声称存在强而稳定的通路，干预数据却长期没有任何差异，就必须解释补偿、剂量不足或测量失败，不能各说各话。

整合的基本单位应是同一个查询。例如研究高温对老年死亡的影响，时间序列提供短期风险变化，自然实验利用异常天气，生理研究说明心血管与体温调节机制，建筑和社会资料刻画空调、居住隔离与照护网络。它们只有在暴露时间窗、目标人群和结局含义对齐后才能共同支持结论。若机制实验使用极端剂量，而人口研究关注日常波动，二者的表面一致不足以完成迁移。

证据之间也可分配否认任务。负对照针对某类未测混杂，过程测量针对路径时序，剂量反应针对机制强度，跨地区重复针对背景稳定性。没有单项检验能证明整个因果模型，但多项具有不同失败模式的证据可以缩小仍然可行的解释集合。多元主义的严格性体现在明确每项证据排除了什么，而非罗列文献数量。

3.3.2 实在论、工具主义与模型责任

因果实在论主张模型试图描述世界中真实的产生或依赖结构；工具主义更强调模型组织预测和行动的效用。实践中二者并非总是截然对立。一个用于政策的模型若对环境改变后持续失败，研究者会追问是否遗漏真实机制；一个声称刻画真实结构的模型，也必须展示它带来哪些可检验差异。争论焦点通常不是要不要接触现实，而是有什么证据足以支持超出观测分布的结构承诺。

模型责任因此包含两面。表示责任要求说明节点、事件和机制为何以这种粒度划分，以及缺边和模块性假设凭什么成立。使用责任要求说明模型将服务预测、解释、干预还是归责，并防止输出跨越任务边界。一个为群体资源配置估计的平均效应，不应被直接解释为某个个体必然获益；一个用于机制探索的细胞模型，也不应未经迁移就支持全国政策。

采取这种立场不要求先解决全部形而上学争论。研究者可以承认因果结构有实在论意图，同时对当前模型保持可错性；也可以重视行动成功，却不把短期预测成功当作结构真理。关键是让结构承诺、经验风险和使用后果同时可审查。

本章小结

反事实理论把原因理解为在适当替代世界中制造结果差异的因素。Lewis 用可能世界相似性解释反事实，以依赖链处理间接原因，并以“影响”分析捕捉结果发生方式的变化。先占、过度决定、遗漏和双重防止显示，简单若无检验不足以覆盖实际因果；事件描述、过程和正常性也可能进入判断。概率理论适合处理不确定结果，但必须控制背景与混杂；INUS 分析揭示复合充分路径；因果过程与机制论说明现象如何产生；力量论强调倾向在复杂背景中的表现；干预主义用合格变化和不变性连接因果与实验。它们聚焦不同查询，可在明确接口下共同构成因果证据。

自测与研讨

1. 为什么材料条件句不能表达反事实？“最接近世界”需要保留哪些事实？
2. 分别画出早期先占与对称过度决定的事件结构，说明若无

检验为何失败。

3. “作为影响的因果”如何利用结果发生方式，而不仅是结果是否发生？
4. 选择一个遗漏因果案例，说明规范期待在判断中发挥什么作用。
5. 构造一个 $P(E | C) > P(E | \neg C)$ 但 C 不是 E 原因的例子。
6. 把一个现实故障写成至少两条充分路径，并识别其中的 INUS 条件。
7. 为什么列出机制部件不等于给出机制解释？
8. 对一个教育政策定义理想干预，并说明现实实施可能违反哪些条件。

延伸阅读

反事实语义以Lewis (1973b)为基础，早期因果分析见Lewis (1973a)，后期修正见Lewis (2000)。关于依赖与产生过程这两类因果概念的区分可读Hall (2004)；实际因果的结构模型路线可在第11章后结合Halpern (2016)阅读。

概率路线参阅Reichenbach (1956)与Suppes (1970)；复合条件分析见Mackie (1974)；因果过程可对照Salmon (1984)与Dowe (2000)；新机制论可读Machamer et al. (2000)、Craver (2007)与Glennan (2017)；能力、行动者和干预路线分别以Cartwright (1989)、Menzies, Price (1993)和Woodward (2003)为核心。

当代争论的系统入口是Paul, Hall (2013)，而Collins et al. (2004)汇集了先占、过度决定和反事实语义的代表性分歧。对比式解释见Schaffer (2005)，结构模型中的实际因果判准可从Halpern,

Pearl (2005) 进入；解释为何有深浅之分则可读Strevens (2008)。干预主义在生命科学层级问题中的适用条件见Woodward (2010)。

机制路线不应停在定义：Craver, Darden (2013) 展示机制如何在实际发现过程中被逐步约束，Glennan, Illari (2018) 提供跨科学领域的专题地图。力量论的系统方案见Mumford, Anjum (2011)；医学中的机制证据与统计证据怎样共同承担因果论证，可由Russo, Williamson (2007) 作为批判性案例。

第二部分

现代因果推断的形式基础

潜在结果、估计目标与识别

学习目标

读完本章，你应当能够：用潜在结果定义处理效应和目标总体；区分一致性、可交换性、正值性与无干扰假设；从反事实目标推导可观测表达式，并诊断选择、测量、缺失与外推造成的识别失败。

4.1 潜在结果：用替代状态定义因果效应

4.1.1 潜在结果、基本难题与估计目标

潜在结果框架把因果比较写进结果变量本身。对单位 i ， $Y_i(1)$ 表示该单位接受处理时的结果， $Y_i(0)$ 表示未接受处理时的结果。个体因果效应是

$$\tau_i = Y_i(1) - Y_i(0).$$

这里的“处理”不必是药物，也可以是政策、教育方案、暴露水平或信息呈现；但两个处理状态必须足够明确，能够说明它们何时

开始、持续多久、如何实施。

这种表述继承 Neyman 在随机试验中的思想，并由 Rubin 等推广到更一般的因果推断(Holland, 1986; Neyman, 1990; Rubin, 1974)。它的核心不是某一种匹配算法，而是先定义同一单位在互斥替代状态下的结果，再讨论这些不可同时观察的量如何由研究设计识别。

因果推断的根本问题 对同一单位和同一时点，我们最多观察 $Y_i(1)$ 或 $Y_i(0)$ 之一。令实际处理为 $A_i \in \{0, 1\}$ ，观测结果满足

$$Y_i = A_i Y_i(1) + (1 - A_i) Y_i(0).$$

缺失的潜在结果不是普通漏填数据：我们不能回到同一历史起点让同一个人同时接受另一处理。因此，个体效应通常不可直接观察。这是**因果推断的根本问题**。

根本问题不意味着因果效应永远不可知。总体平均效应可以在随机化或其他可交换条件下识别：不同单位为彼此提供反事实信息。代价是从个体确定性问题转向人群分布问题，并依赖单位之间在处理赋值上的可比性。

估计目标不是只有一个 最常见的平均处理效应为

$$ATE = E\{Y(1) - Y(0)\}.$$

但研究问题可能要求其他目标：

$$ATT = E\{Y(1) - Y(0) \mid A = 1\},$$

$$ATC = E\{Y(1) - Y(0) \mid A = 0\},$$

$$CATE(x) = E\{Y(1) - Y(0) \mid X = x\}.$$

ATE 回答在目标人群中普遍实施与普遍不实施的平均差异；ATT 回答实际接受者若不接受会怎样；CATE 描述协变量为 x 的亚组。三者 in 人群组成和效应异质性存在时不同。算法输出一个数之前，研究者必须说明目标是哪一个。

对于二元结果，常用尺度包括风险差

$$E\{Y(1)\} - E\{Y(0)\},$$

风险比和优势比。效应尺度会改变“无交互”和异质性的表现。风险差上的零效应不等于风险比上的一；优势比具有非可合并性，即使没有混杂，条件优势比与边缘优势比也可能不同。选择尺度应服从决策与科学问题，而非只看软件默认。

4.1.2 一致性、干扰与随机化可比性

一致性通常写为：若 $A_i = a$ ，则 $Y_i = Y_i(a)$ 。这看似只是记号，实则要求观察到的处理版本与潜在结果中定义的干预相对应。若“接受治疗”包括不同剂量、依从性和联合用药， $Y(1)$ 可能没有唯一含义。

处理定义需要包括：启动规则、具体版本、随访起点、允许的后续策略和结果测量时点。把肥胖、教育程度或种族直接当作可设定开关尤其困难，因为“将变量设为另一值”可能对应许多不同

干预路径。此时应优先定义可执行或至少机制明确的干预，如提供某项教育资源，而不是含混询问“教育本身的效应”。一致性也依赖无隐藏的多版本处理。不同版本若对结果相同，可以在问题目的下合并；若效果不同，就应扩展处理变量或把目标改写为随机策略效应。

SUTVA 与单位间干扰 稳定单位处理值假设 (SUTVA) 通常包括两个方面：处理没有未说明版本；一个单位的结果不受其他单位处理影响。后者可写为 $Y_i(a_i)$ ，而不是依赖全体赋值向量的 $Y_i(\mathbf{a})$ 。

疫苗、社交网络、教育班级和市场政策经常违反无干扰。一个人接种会改变他人感染风险，平台向部分用户展示内容会改变其朋友体验，价格政策会通过均衡影响未处理者。此时“处理效应”不能只比较个体自己的 a_i ，还要定义暴露映射，例如个体处理与邻居处理比例，并区分直接效应、溢出效应和总体效应。SUTVA 不是越强越好的技术便利。若科学问题本就关心传播或均衡效应，应显式建模干扰，而不是把它当作小偏差。单位边界也需与机制匹配：以学校而非学生为随机化单位，可能使校内干扰成为处理的一部分。

随机化如何提供可比性 在理想随机试验中，处理赋值与潜在结果独立：

$$A \perp\!\!\!\perp \{Y(1), Y(0)\}.$$

因此

$$E(Y | A = 1) = E\{Y(1)\},$$

$$E(Y | A = 0) = E\{Y(0)\},$$

从而

$$E(Y | A = 1) - E(Y | A = 0) = ATE.$$

逻辑关键不是“随机化使所有协变量在样本中完全相同”。有限样本仍可能不平衡。随机化保证赋值机制已知，并在重复随机化意义下使处理与潜在结果独立，使差异估计具有无偏性或可控的随机化分布。随机化也不自动解决依从性、失访、测量错误、干扰和外部效度。若部分被分配治疗者未接受治疗，按分配比较得到的是意向治疗效应；若想估计实际接受治疗的效应，需要额外假设或工具变量框架。试验内部效度与结果能否推广到其他人群是两件事。

4.1.3 动态处理、异质性与连续暴露

现实处理常随时间变化。令 A_t 为时点 t 的处理， $\bar{A}_t = (A_0, \dots, A_t)$ 为处理历史，潜在结果写为 $Y(\bar{a}_T)$ 。时间变化协变量 L_t 可能同时受先前处理影响，并影响以后处理与结果。若在普通回归中直接调整 L_t ，既可能阻断部分处理效应，也可能引入碰撞点偏差。纵向 g 公式、边际结构模型和结构嵌套模型用于这类问题(Hernán, Robins, 2020; Robins, 1986)。在进入方法前，必须先统一**时间零点**：资格判定、处理分配和随访开始应当对齐。若把必须存活一段时间才能进入“处理组”的人从早期开始计入，会产生不死时间偏差。失访可视为一种选择过程。若删失与潜在结果在给定历史后独立，可用逆概率删失权重等方法；若失访由未测因素决定，数据本身无法保证校正。报告失访原因和敏感性分析与选择估计器同样重要。

个体效应与异质性 虽然 τ_i 通常不可识别，我们可以估计某些可观测亚组的 CATE。但预测谁获益不等于恢复每个人确定的个体效应。即使准确估计 $E\{Y(1) - Y(0) \mid X = x\}$ ，同一 $X = x$ 亚组内仍可能存在未解释异质性。数据驱动寻找亚组还会产生多重比较和过拟合。可靠异质性分析应预先区分验证性与探索性目标，使用样本分割或诚实估计，并报告不确定性。更重要的是，亚组差异可能反映基线风险而非机制改变；应在适当效应尺度上解释。

关键辨析

潜在结果不是“数据库中缺失的一列”，而是由处理定义、单位边界、时间结构和干预版本共同构造的反事实量。若这些概念没有定义清楚，再精确的估计也只是在计算一个含义不明的差值。

多水平与连续处理 处理不必二元。对剂量 $a \in A$ ，每个单位有潜在剂量—反应曲线 $Y_i(a)$ ，目标可以是

$$E\{Y(a) - Y(a')\} \quad \text{或} \quad \frac{\partial}{\partial a} E\{Y(a)\}.$$

连续处理的正值性更严格：每个协变量层不可能在有限数据中拥有所有精确剂量，只能依赖平滑和局部支持。把剂量线性放进回归等于假定整条反应曲线形状，需用领域知识和灵活模型检查。

多版本问题在连续处理中更突出。同样名义剂量因给药速度、制剂和依从不同而作用不同。可把处理扩展为向量 (a, v) ，或把研究问题定义为现实策略产生的版本混合。后者的效应依赖版本分布，迁移到另一系统时可能改变。

4.1.4 复合处理、主层与潜在结果表

若同时研究药物 A 与心理干预 B ，潜在结果写为 $Y(a, b)$ 。加法尺度上的交互可表示为

$$E\{Y(1,1) - Y(1,0) - Y(0,1) + Y(0,0)\}.$$

非零说明一种处理的效果随另一处理状态改变。交互是尺度相关的：加法交互存在时，乘法交互可能不存在，反之亦然。

析因随机试验能有效估计主效应与交互，但前提是处理组合可共同实施且没有隐藏版本。若药物改变参与心理干预的依从性，分配组合的意向治疗效应仍清楚，实际接受组合的效应则需要依从建模。“协同机制”与统计交互也不相同。机制上两因素共同必要可能在某尺度表现强交互，但人群背景分布、结果阈值和测量会改变统计形态。不能仅凭回归乘积项显著就断言发现生物协同。

主层与处理后分层 研究者有时想比较“无论分配哪组都会存活的人”中的生活质量。存活是处理后变量，直接只分析存活者会比较不同构成的人群。主层按联合潜在中间状态 $(S(1), S(0))$ 定义，例如始终存活者、仅处理下存活者等。主层在概念上避免条件化实际处理后变量造成的混合，却通常不可完全观察：每人只看到一个 $S(a)$ 。识别需要单调性、排除限制或模型，且目标人群“始终存活者”难以在实践中定位。主层效应适合某些截断死亡、依从与替代终点问题，不是处理后偏差的免费修复(Frangakis, Rubin, 2002)。

潜在结果表的思维实验 设四人的潜在结果分别为

$$(1, 0), \quad (1, 1), \quad (0, 0), \quad (0, 1),$$

其中前项为 $Y(1)$ ，后项为 $Y(0)$ 。个体效应依次为 $1, 0, 0, -1$ ，ATE 为 0。若只报告 ATE，会遗漏一个获益者和一个受害者；若处理赋值偏向本来会在处理下成功者，观察组差异还可能为正。这个表说明平均零不等于人人无效，也说明效应异质性与选择偏差是不同问题。随机化可使平均比较识别 ATE，却不能显示每人的两列；额外协变量可解释部分异质性，但不能一般恢复个体效应。

4.2 识别：从反事实目标到可观测分布

4.2.1 识别、标准化与可交换性

一个因果目标若能在给定假设下唯一写成观测数据分布的函数，就称为**可识别**。识别是在总体层面连接反事实量与可观测量的逻辑问题。**估计**则是在有限样本中近似这个函数，并量化随机误差。两者的次序不能颠倒。例如，若未测混杂使两个不同因果模型产生完全相同的观测分布，却给出不同 ATE，则无论样本多大、机器学习预测多准，ATE 仍不可由该数据识别。相反，一个目标可能在原则上可识别，但样本太小、正值性接近违反或模型过拟合，使估计极不稳定。

标准化公式的推导 设 A 为二元处理， $Y(a)$ 为潜在结果， L 为处理前协变量。若满足条件可交换性

$$Y(a) \perp\!\!\!\perp A \mid L,$$

一致性以及正值性，则

$$\begin{aligned}
 E\{Y(a)\} &= \sum_l E\{Y(a) \mid L = l\}P(L = l) \\
 &= \sum_l E\{Y(a) \mid A = a, L = l\}P(L = l) \\
 &= \sum_l E(Y \mid A = a, L = l)P(L = l).
 \end{aligned}$$

第二行使用条件可交换性，第三行使用一致性；正值性保证每个相关 l 层中确实能观察到 $A = a$ 。右侧完全由观测分布组成，称为**标准化公式**或**调整公式**。ATE 是 $a = 1$ 与 $a = 0$ 两个标准化均值之差。这个推导展示识别分析的价值：每一步都对应一项可质疑的假设。若处理定义含混，一致性失败；若某类人必然接受处理，正值性失败；若存在未测共同原因，可交换性失败。估计器不能弥补概念或设计缺口。

可交换性与混杂 可交换性表示在用于比较的层次中，处理组与对照组在潜在结果分布上可以互换。随机化在设计上提供无条件可交换性；观察研究通常只能主张给定充分协变量 L 后可交换。

混杂不是“协变量与处理、结果都相关”这一纯统计定义，而是处理与结果之间存在会扭曲目标因果比较的共同原因结构。一个变量是否应调整取决于图中角色：

- 处理与结果的共同原因通常需要控制；
- 处理后的中介若用于估计总效应，通常不应控制；
- 碰撞点不应仅因同时预测处理和结果而控制；
- 共同原因的代理变量可能减少混杂，也可能引入额外测量问题；
- 结果的强预测因子即使不是混杂，也可能提高精度。

因此，“把所有可用变量放进回归”不是保守策略。变量选择应以时间、领域知识和因果结构为基础，再用统计方法提高估计稳健性。

正值性：结构缺口与数据稀疏 正值性要求对目标人群中每个具有正概率的协变量层，都有

$$0 < P(A = a | L = l) < 1.$$

结构性违反发生在某些人依法或生理上绝不可能接受某处理。例如，治疗方案只适用于某疾病阶段，却把其他阶段也纳入目标人群。解决办法不是改变估计器，而是重新定义目标人群或干预。

实践性违反发生在概率理论上非零但样本中极少。逆概率权重会因此极大，估计由少数单位支配。诊断包括查看倾向得分重叠、极端权重和有效样本量。截断权重可以降低方差，却改变偏差；应报告截断规则并做敏感性分析。正值性与研究问题密切相关。条件越细，重叠越难；但遗漏真正混杂又破坏可交换性。这里不存在纯数据驱动的万能平衡，需要在科学充分性与支持范围之间作透明取舍。

4.2.2 选择、测量与缺失机制

研究样本通常经过进入、留存和完整测量等选择。若选择 S 同时受处理或其原因与结果或其影响，给定 $S = 1$ 会打开非因果路径。例如治疗影响存活，疾病严重度也影响存活；只分析存活者可能使治疗与严重度相关，即使原始试验已随机化。选择偏差不同于混杂：混杂在处理之前造成不可比，选择是在纳入或条件化过程中扭曲关联。二者可同时存在，处理方法也不同。若在给定已

测历史后选择独立于目标潜在结果，可用选择权重或删除权重重建目标分布；若选择依赖未测因素，必须依靠界限或敏感性分析。病例对照研究说明“选择在结果上”并非总是错误。该设计有意按结局抽样，但在适当抽样机制和目标尺度下，优势比等量仍可估计。关键不是永远不条件化碰撞点，而是目标量、采样机制和分析公式是否配套。

测量并非透明窗口 误分类与测量误差可以改变因果问题本身。若处理由回忆问卷测量，结果状态可能影响暴露报告，形成差异性误差；若结局评估者知道治疗分组，测量过程可能成为处理影响观测结果的额外路径。简单地说“非差异性误差只会把效应拉向零”并不普遍成立，尤其在多分类、非线性模型和多个误测变量中。应区分潜在构念与观测指标。例如“抑郁”可能由量表分数操作化，政策真正改变的是症状、报告行为还是诊断机会，需要在测量模型中说明。验证子样本、重复测量、负对照和定量偏差分析可以评估误差影响，但仍需外部信息。

缺失数据与因果缺失 普通缺失数据术语——完全随机缺失、随机缺失、非随机缺失——描述缺失机制与数据的关系。因果研究还要问缺失发生在处理、协变量还是结果，以及缺失机制是否受处理影响。处理后缺失可能是因果路径的一部分；把所有完整案例直接分析，相当于条件化在一个选择变量上。多重插补、逆概率加权和联合模型各依赖不同假设。插补模型应与分析目标相容，并包括预测缺失和结果的变量。任何方法都不能从数据内部验证“给定已观测变量后缺失与未观测结果独立”；这正是需要敏感性分析的地方。

4.2.3 目标试验、敏感性与部分识别

目标试验策略要求先写出希望模拟的理想随机试验方案(Hernán, Robins, 2016):

1. 资格标准;
2. 待比较的治疗策略;
3. 分配程序;
4. 随访起点与终点;
5. 结局;
6. 因果对比;
7. 分析计划。

然后说明观测数据如何模拟每一项。该方法能够暴露时间零点错位、不死时间、既往使用者偏差和处理策略含混。它不让观察研究自动等于试验，也不消除未测混杂，而是使设计选择清楚可审计。

敏感性分析是主分析的一部分 关键识别假设通常不可由数据完全检验。严谨报告不应只在限制部分写一句“可能存在残余混杂”，而应评估结论对违反程度的敏感性。常见策略包括：

- 指定一个未测混杂与处理、结果关联的范围，计算校正后效应；
- 使用负对照暴露或结局发现共享偏差结构；
- 对失访、误分类或处理版本进行情景分析；
- 报告部分识别界限，而不是强迫给出点识别；
- 比较多种合理图与变量定义下结果是否稳定。

敏感性参数应有领域解释，而不只是抽象数值。分析的目标不是证明结论不受任何偏差影响，而是说明需要多强的未建模因素

才能改变决策。

部分识别：不知道也可以被形式化 当假设不足以点识别时，可以求目标的上下界。设二元结果的随机试验存在部分结局缺失，若不对缺失机制作假设，可把处理组所有缺失者分别设为 0 或 1，得到极端风险范围；两组范围组合成风险差界限。界限可能很宽，却准确表达数据能排除什么。以最少附加假设报告可行集合，是部分识别传统的基本做法(Manski, 1990)。增加可信假设可逐步收窄。例如认为失访者结局风险不低于已观察者，或风险最多高出某个幅度；每项收窄都应有实质解释。与一次性宣布“随机缺失”相比，分层界限让读者看到结论由哪条假设获得精度。未测混杂也可用界限和偏差参数处理。若能根据外部研究限制混杂与处理、结果的最大关联，就可计算校正区间。目的不是制造一个“正确调整值”，而是展示何种偏差强度足以跨过决策阈值。

负对照的逻辑 负对照结局应不受处理因果影响，却与目标结局共享某些混杂或测量过程。例如研究药物对某疾病时，选择机制相似但生物上不可能受药物影响的结局。若处理与负对照仍相关，提示残余偏差(Lipsitch et al., 2010)。

负对照暴露 不应影响目标结局，却共享处理的混杂结构，例如在合理时间关系下选择未来暴露。负对照不是凭“结果不显著”证明无混杂；需要明确共享偏差和排除直接作用的结构。负对照本身若有未知效应，会产生误导。

更强方法可在两个负对照和代理结构下识别某些未测混杂，但承担完备性等技术条件。基础实践中，负对照至少能把“未测混杂不可检验”转化为部分可观察的模型检查。

识别审计与设计改进 高质量研究应保存一张从目标到公式的审计表。第一列写目标量及目标人群；第二列写每项假设的数学形式；第三列用领域语言解释；第四列列支持证据；第五列列潜在违反；第六列写诊断或敏感性分析。例如可交换性对应“给定病情、年龄等后，治疗选择不再包含预后信息”，证据可能是临床流程，风险是医生未记录判断，敏感性分析则为负对照和偏差参数。

审计表迫使“已调整所有混杂”变成可质疑陈述。它也便于团队协作：领域专家审查临床流程，统计人员审查公式，数据工程人员审查变量时间，决策者审查目标人群。

识别失败后的研究设计 如果图显示未测共同原因使目标不可调整识别，不应立即换更复杂模型。可以收集共同原因或可靠代理；寻找影响处理但满足排除限制的制度工具；在关键节点开展小型随机或鼓励试验；获取中介以满足前门结构；融合另一个域的实验；或把问题改为可识别的局部目标。识别分析由此具有建设性：失败证明告诉我们哪类新信息最有价值。一个明确的不可识别结论加下一步设计，优于一个依赖不可说明机器学习外推的精确数字。

4.3 从目标合同到知识边界

4.3.1 从目标合同到逐行识别证明

只写 ATE 并没有完成目标定义。一个可执行的估计目标至少包括总体、处理策略、对照策略、结局、时间范围、汇总尺度和竞争事件处理。总体决定对谁求平均；策略说明何时开始、允许哪些版本与依从路径；结局必须有测量规则；尺度决定风险差、风险

比、比值比或生存时间差怎样表达决策意义。任何一项变化，都可能产生不同数值而不构成统计矛盾。

例如评价降压治疗，可以比较确诊后立即启动方案与延迟三个月，也可以比较始终维持不同血压区间的动态策略。前者接近治疗启动效果，后者还包含随访中剂量调整和依从。若结局是五年卒中风险，死亡是使卒中不再发生的竞争事件；把死亡者简单删失会改变目标。若临床决策关心每千人避免多少事件，绝对风险差通常比比值比更直接。

目标合同还要说明时间零点。资格判定、策略分配和随访开始若不对齐，会产生不死时间与选择偏差。数据分析中的每行记录都应能追溯到合同中的单位和时点。先写合同不是形式主义，而是防止分析过程中随着可得变量和显著结果悄悄更换问题。

识别证明应当逐行书写 识别不是一句“控制所有混杂因素”，而是一条从反事实到观测量的等式链。以二元处理为例，目标是 $E\{Y(1)\}$ 。先用迭代期望写成

$$E\{Y(1)\} = \sum_l E\{Y(1) \mid L = l\}P(L = l).$$

若给定处理前协变量满足 $Y(1) \perp\!\!\!\perp A \mid L$ ，可把第一项换成处理组中的反事实均值；再由一致性，在 $A = 1$ 的单位中以观测结果替代 $Y(1)$ ，得到

$$E\{Y(1)\} = \sum_l E(Y \mid A = 1, L = l)P(L = l).$$

正值性保证每个需要的层中存在接受处理者，使右侧确实由数据分布定义。

逐行书写的价值在于每个等号都有责任主体。全概率公式来自概率论；交换反事实与处理来自因果假设；一致性来自处理和结局定义；正值性来自目标总体与数据支持。估计器只近似最后的可观测表达式，不能倒过来证明前面的交换。若某层无人接受处理，机器学习平滑产生的预测是外推，不是恢复了非参数识别。同一习惯适用于复杂设计。纵向 g 公式要在每个时点交换处理历史与未来潜在结果；迁移公式要交换试验参与和目标人群结果；前门公式要逐步标明行动与观察的交换。把推导写完整，能在建模之前发现究竟缺少测量、设计还是科学知识。

4.3.2 纵向问题与不可识别边界

许多处理不是一次性开关。药物剂量随症状调整，平台推荐随点击更新，公共政策随疫情或经济指标改变。此时既往处理影响后续协变量，后续协变量又影响下一次处理和结果。若把这些协变量当普通基线混杂因素直接回归，可能阻断既往处理的中介路径；若不调整，又留下后续处理的混杂。设处理历史为 $\bar{A}_t$ ，随时间变化的协变量为 $\bar{L}_t$ 。动态策略 g 根据已有历史指定每期处理。识别需要序贯可交换性：在每个时点，给定已经观察的历史，实际处理选择与策略下未来潜在结果独立；还需要各历史下策略选择有正概率。纵向 g 计算、逆概率加权的边际结构模型和结构嵌套模型，是处理这种双重角色的不同道路。

这些方法的主要困难不在公式长度，而在历史定义。就诊频率可能同时是病情信息和医疗系统选择结果；上一期处理会改变它，使其既是中介又是后续混杂。研究者必须说明测量时点、决策可用信息和失访过程。离散时间过粗会把处理与协变量顺序颠倒，过细又造成稀疏历史与极端权重。时间尺度是因果假设的一部分。

不可识别时仍然可以推进知识 识别失败不等于研究结束。第一种选择是重新设计：收集关键共同原因、利用随机分配或制度阈值、改变抽样以补足重叠。第二种是改变目标：从总体效应转向有支持区域的效应，从自然中介效应转向可实施的干预型效应。第三种是部分识别，用界限表达现有信息允许的范围。第四种是敏感性分析，把不可观测假设参数化并报告结论在何处改变。

重要的是不要把这些策略包装成完全识别。限制到重叠人群会得到更可靠但不同的总体；假定单调性收紧界限会增加实质承诺；负对照发现残余偏差能反驳简单模型，却通常不能唯一校正。研究贡献可以是证明某个热门问题在现有数据下不可回答，并指出哪种新信息最有价值。在决策场景中，宽界限也可能有用。若所有合理偏差情景下政策净收益仍为正，精确点估计并非必要；若界限跨越重要伤害阈值，就应延迟部署或采用可逆试点。把不可识别性连接到行动规则，比用一个未经说明的模型填补空白更诚实。

4.3.3 目标量合同：先固定问题，再证明识别

一份可复核的目标量合同至少需要固定六项内容。以“远程工作是否改善员工健康”为例，不能在分析时才根据数据可得性决定处理、时间和人群。

合同项	明确定义	不合格写法
单位与总体	在 2026 年 1 月 1 日在职、可远程履职的全职员工	“某公司人员”
处理策略	连续十二周每周至少三天远程，与每周不超过一天比较	“远程或不远程”
时间零点	资格确认、策略分配与随访同日开始	用后来的出勤定义基线组别
结局与时窗	第十二周标准化心理健康量表及病假天数	“健康变好”
因果对比	同一目标总体两套策略下的平均结局差	两个自选出勤组的观测差
失访与干扰	离职、换岗、团队协作和管理者排班如何处理	把没有末次量表者直接删除

目标固定后，才能问观察数据是否识别它。假设 L 包含基线健康、职位、照护责任、通勤距离与团队排班，候选识别链为：给定 L 后实际策略选择与两个潜在结果可交换；每个目标 L 层都有两种出勤策略；实际符合某策略时观测结果等于该策略下潜在结果；团队成员的远程安排不通过未定义的溢出影响个人结局。

完整算例：识别失败时如何改目标

若所有外地职位员工都必须全远程，而所有安全敏感职位都必须到岗，则对包含这两类职位的全体 ATE 存在结构性正值性失败。一种合格修改是把目标收缩到制度上两种策略都可行的职位；另一种是把处理改为可执行的排班选择权，而不是实际远程天数。两种修改都得到与原 ATE 不同的问题，必须在结果表和摘要中重新命名。使用光滑回归为从未存在的比较填值，不算修复识别。

处理版本也可使一致性失败。远程工作可以伴随设备补贴、弹性时间或监控软件；如果不同版本对健康的影响不同，“每周三天远程”没有唯一潜在结果。可以把设备、时间自主和监管方式写入策略包，或者分别定义多个处理版本。这种修改是在重建因果对象，不是增加一个控制变量。

失败诊断：识别假设只出现在讨论部分

若结果表先给出“远程工作效应”，最后才在局限中说“可能有未测混杂”，读者无法知道数字依赖哪个等式。正确顺序是在估计之前列出目标、一致性、可交换性、正值性和干扰假设，并说明每项由设计、领域知识还是统计诊断支持。局限不是主结果之后的礼貌性附言，而是数字拥有因果含义的条件。

本章小结

潜在结果以同一单位的替代处理状态定义因果效应。由于只能观察一个潜在结果，个体效应通常不可直接观察；随机化或可交换性使人群平均效应可识别。ATE、ATT 与 CATE 回答不同问题。一致性、处理版本、无干扰和时间零点是目标量定义的一部分，而不是估计阶段的附注。识别是在明确假设下把反事实目标写成观测分布函数；估计是在样本中计算该函数。条件可交换性、一致性与正值性共同支持标准化。混杂、选择、测量和缺失是不同机制，不应以“多变量调整”统一处理。目标试验与敏感性分析把设计和假设置于估计器之前。

自测与研讨

1. 为“远程办公的效应”定义单位、两个处理版本、结果和时间零点。
2. 在什么情况下 ATE 与 ATT 会明显不同？给出带效应异质

性的例子。

3. 疫苗研究为何违反简单无干扰假设？应区分哪些效应？
4. 随机化保证什么，又不保证什么？
5. 逐行说明标准化公式推导分别使用了哪项假设。
6. 举出结构性与实践性正值性违反各一例，并提出不同解决方案。
7. 为什么控制所有处理和结果的预测变量可能增加偏差？
8. 为一项电子健康记录研究写出目标试验的七个要素。

延伸阅读

潜在结果的经典表述见Rubin (1974)与Holland (1986)；系统教材为Imbens, Rubin (2015)。主层的原始框架见Frangakis, Rubin (2002)。纵向观察研究、目标试验和时间相关偏差可读Hernán, Robins (2020)。干扰问题可从Hudgens, Halloran (2008)和Tchetgen Tchetgen, VanderWeele (2012)入手。

识别与标准化的系统教材是Hernán, Robins (2020)和Imbens, Rubin (2015)。目标试验方法见Hernán, Robins (2016)。部分识别的经典界限见Manski (1990)，负对照方法见Lipsitch et al. (2010)。选择偏差与图形解释可结合Greenland (2003)阅读；未测混杂的定量敏感性分析可参阅VanderWeele, Ding (2017)。

随机化在贝叶斯因果推断中的作用见Rubin (1978)。一致性不是一句符号约定：其基本声明与争议可对照Cole, Frangakis (2009)和VanderWeele (2009)，处理必须可定义以及同一标签可能包含多个版本的问题分别见Hernán, Taubman (2008)与VanderWeele, Hernán (2013)。选择机制的结构分析见Hernán et al. (2004)，时间变化处理与混杂的边际结构模型入口

是Robins et al. (2000)。正值性在实际数据中的含义见Westreich, Cole (2010)；如何在分析之前以设计减少观察研究偏差，可续读Rosenbaum (2010)。

结构因果模型与图形语言

学习目标

读完本章，你应当能够：掌握 DAG、d-分离、结构方程、干预与截断分解；区分概率分解、因果语义和反事实语义；能够把领域假设翻译成可审查的图与结构方程。

5.1 从联合分布到结构因果模型

5.1.1 概率模型、DAG 与 d-分离

联合分布 $P(X, Y, Z)$ 描述变量如何共同变化。由它可以计算条件概率、边缘概率和预测最优规则，但联合分布本身对变量角色是对称的：

$$P(X, Y) = P(Y | X)P(X) = P(X | Y)P(Y).$$


两个分解同样正确，却不能告诉我们改变 X 是否改变 Y 。如果 X 是气压计读数、 Y 是暴风雨， $P(Y | X)$ 可以有很强预测力；转动指

针并不改变天气。

因果模型增加了概率分布没有编码的结构：哪些变量由哪些机制生成，这些机制在局部干预时如何改变，以及同一单位在替代干预下会怎样。结构并非从符号方向自动产生；必须由研究设计、时间顺序、领域理论和可检验后果共同支持。

DAG 的基本语法 有向无环图 (DAG) 由节点和有向边组成，不允许沿箭头最终回到起点。节点通常表示变量， $X \rightarrow Y$ 表示在图中其他变量给定的粒度下， X 是 Y 的直接原因。图中的三种基本局部结构决定条件化的行为。

链、叉与碰撞点



在链 $X \rightarrow M \rightarrow Y$ 中， X 与 Y 通常相关，给定中介 M 会阻断这条路径。在叉 $X \leftarrow Z \rightarrow Y$ 中， Z 是共同原因，给定 Z 通常消除由这条路径产生的关联。在碰撞结构 $X \rightarrow C \leftarrow Y$ 中，路径默认关闭；给定 C 或其后代反而会打开路径，使原本独立的 X 与 Y 条件相关。碰撞点偏差反直觉却常见。假设能力和家庭资源都会提高进入名校的概率，即 $A \rightarrow S \leftarrow R$ 。在全体申请者中二者可能独立；只观察已录取者，相对低资源者往往需要更高能力才能录取，于是能力与资源出现负相关。这不是二者互为原因，而是选择在共同结果上造成的关联。

d-分离与条件独立 **d-分离**是一套从图判断条件独立的准则。一条路径在给定集合 Z 后被阻断，如果路径包含一个已给定的非碰撞点，或者包含一个既未给定、其后代也未给定的碰撞点。若 X 与 Y 之间所有路径都被阻断，则记为

$$X \perp\!\!\!\perp Y \mid Z \quad [G].$$

d-分离是图结构与概率含义的接口。它不是根据样本相关系数大小画图的规则，而是在模型假设成立时推出条件独立。有限样本中“未显著”不等于独立；统计检验也无法确认所有需要的条件独立，特别是在维度高、关系非线性或效应接近零时。条件独立的概率论性质与图模型的系统处理分别可见Dawid (1979)和Lauritzen (1996)。

5.1.2 结构方程、Markov 条件与干预

结构因果模型 (SCM) 可写成四元组(Pearl, 2009)

$$M = \langle U, V, F, P(U) \rangle.$$

U 是模型外生变量， V 是内生变量， F 是为每个内生变量指定的结构函数， $P(U)$ 描述外生背景的分布。一个简单模型为

$$\begin{aligned} X &= f_X(U_X), \\ Y &= f_Y(X, U_Y), \\ Z &= f_Z(X, Y, U_Z). \end{aligned}$$

方程不是普通回归等式。 $Y = f_Y(X, U_Y)$ 声称有一个生成机制

以 X 和背景因素 U_Y 决定 Y ；若我们改变 X 的生成方式， f_Y 仍保持。这个**模块性**或自主性假设使结构方程支持干预解释。外生变量不等于“研究中没测到的所有东西”。它们表示在模型边界之外决定内生变量的背景。若 U_X 与 U_Y 相关，图中可能存在未观测共同原因；把残差假定独立是实质性无隐藏混杂假设，而不是记号便利。

因果 Markov 条件与分解 对一个 DAG G ，**因果 Markov 条件**大意是：每个变量在给定其直接原因后，与其非后代中的其他变量独立。由此联合分布按父节点分解：

$$P(v_1, \dots, v_n) = \prod_{i=1}^n P(v_i \mid pa_i).$$

例如 $Z \rightarrow X \rightarrow Y$ 且 $Z \rightarrow Y$ 给出

$$P(z, x, y) = P(z)P(x \mid z)P(y \mid x, z).$$

同一个概率分布可能按不同 DAG 分解，因此概率分解本身不赋予边因果意义。只有当图来自因果生成结构，截断分解才有干预解释。

因果 Markov 条件可由独立外生扰动的递归 SCM 推出，也可作为连接因果结构与概率独立的原则。反馈系统、选择样本和聚合变量可能不直接符合简单 DAG 设定，需要动态模型、循环模型或显式选择节点。

干预与截断分解 干预 $\text{do}(X = x)$ 用常数赋值 $X := x$ 替换 X 原有结构方程，其他方程保持不变。图上相当于删除所有指向 X 的箭

头。若观测分布按 DAG 分解，则干预后分布为

$$P(v \setminus x \mid \text{do}(x)) = \prod_{V_i \neq X} P(v_i \mid pa_i) \big|_{X=x},$$

这被称为**截断因子分解**或 g 公式的一种形式。

设 Z 同时影响治疗 X 和结果 Y : $Z \rightarrow X$ 、 $Z \rightarrow Y$ 、 $X \rightarrow Y$ 。观察条件概率为

$$P(y \mid x) = \sum_z P(y \mid x, z)P(z \mid x),$$

而干预分布为


$$P(y \mid \text{do}(x)) = \sum_z P(y \mid x, z)P(z).$$

差别在于干预切断 $Z \rightarrow X$ ，因此目标人群的 Z 分布不随设定的 x 改变。

5.1.3 等价性、因果阶梯与数值验证

Markov 条件从图推出独立。因果发现还常需要反方向原则：分布中出现的条件独立都由图中的 d-分离产生，而不是参数精确抵消。这是**忠实性假设**。若 X 对 Y 有一条正路径和一条同样大小的负路径，总效应恰好为零，图中相连却统计独立，分布便不忠实。忠实性使条件独立信息能够约束图，但仍通常不能唯一确定方向。具有相同骨架和相同无屏蔽碰撞点的 DAG 构成 **Markov 等价类**，蕴含同一组条件独立。例如没有碰撞点的三节点链 $X \rightarrow Z \rightarrow Y$ 、 $X \leftarrow Z \rightarrow Y$ 和 $X \leftarrow Z \leftarrow Y$ 在纯观测独立结构上等价。输出一个等价类而非任意单图，是因果发现的诚实表达(Verma, Pearl, 1990)。

因果推理的三个层级 Pearl 常用“因果阶梯”区分关联、干预和反事实(Pearl, Mackenzie, 2018):



较高层查询需要较强模型，但“层级更高”不表示总是更值得研究。天气预报可能只需关联，政策选择需要干预，责任归属才需个体反事实。方法应由问题决定。

数值例子：条件化如何制造关联 设申请者能力 A 与家庭资源 R 相互独立，各以一半概率高或低。学校录取规则是能力高或资源高者录取，即 $S = 1$ 当 $A = 1$ 或 $R = 1$ 。在全体人群中 $P(A = 1 \mid R = 1) = P(A = 1) = 1/2$ 。但在已录取者中，三种组合 $(1,0), (0,1), (1,1)$ 等概率出现，因此

$$P(A = 1 \mid R = 1, S = 1) = \frac{1}{2}, \quad P(A = 1 \mid R = 0, S = 1) = 1.$$

给定碰撞点 S 后，能力与资源出现负关联。

如果研究只收集名校学生，再发现低资源学生平均能力更高，不能推断资源降低能力，也不能把结果推广到所有申请者。选择机

制本身创造了比较。类似结构出现在只研究住院者、获批贷款者、已婚者或完成随访者的资料中。若录取规则是概率性的而非确定性，碰撞偏差仍可存在，只是大小取决于两条作用和基线概率。图告诉我们方向通道，数值模型决定偏差强度。

5.1.4 干预类型、线性模型与误用检查

设

$$\begin{aligned} Z &= U_Z, \\ X &= \alpha Z + U_X, \\ Y &= \beta X + \gamma Z + U_Y, \end{aligned}$$

其中外生变量均值为零且相互独立。 X 与 Y 的观察回归同时包含直接路径系数 β 与由 Z 产生的混杂。若遗漏 Z ，线性回归斜率一般不是 β 。

实施 $\text{do}(X = x)$ 后，第二个方程被 $X := x$ 替换：

$$Y_x = \beta x + \gamma U_Z + U_Y, \quad E(Y_x) = \beta x.$$

因果效应 $E(Y_{x+1} - Y_x) = \beta$ 。观察 $X = x$ 则筛选了满足 $\alpha U_Z + U_X = x$ 的单位，其 U_Z 分布不同，因而 $E(Y | X = x)$ 一般额外随 x 变化。

这个简单推导说明“控制 Z ”为何有效：给定 Z 后， X 的剩余变化来自与 U_Y 独立的 U_X 。若 U_X 与 U_Y 相关，表示还有隐藏共同原因，调整 Z 不再足够。

软干预、随机干预与策略 硬干预把 X 固定为常数。许多现实政策只改变 X 的分布或赋值机制。例如医生决策支持系统提高高风

险患者接受治疗的概率，而非强制所有人治疗。这类**随机干预**可写为从策略分布 $g(x|I)$ 抽取 X ，并替换原有 $P(x|pa_X)$ 。

软干预改变结构机制参数而不删除所有父节点，例如补贴降低价格但价格仍受成本影响。机制改变的粒度决定外推：随机试验的硬赋值效应未必等于政策通过市场逐步改变价格的效应。

动态策略根据过去历史选择处理，例如“若血压超过阈值则加药”。目标不是单个 $X = x$ ，而是整套规则 $g_t(H_t)$ 。SCM 和纵向潜在结果都能表达策略，但需要明确哪些历史信息在决策时可用，以及策略本身是否改变后续测量。

图的误用检查 第一，不要把时间先后直接当成果因边：先出现的变量仍可能只是共同原因的指标。第二，不要把预测模型的特征重要性转成箭头。第三，不要在见到数据关联后删除理论上存在但参数较弱的边，以免把不忠实误作不存在。第四，不要让同一节点同时混合处理前与处理后测量。第五，图的缺边是因果排除假设，往往比有边更强，应给出依据。

5.2 图与结构模型的工作方法

从概率事实到因果语义的四层结构 图模型常被误解为“给相关网络加上箭头”。更准确的理解有四层。第一层是变量与状态空间：研究者决定哪些对象进入模型、用什么时间和粒度表示。第二层是概率层：联合分布描述变量如何共同变化。第三层是结构层：每个内生变量由其直接原因和外生扰动生成，箭头编码可替换机制。第四层是查询层：观察、干预和反事实分别对结构提出不同操作。

同一概率分布可能兼容多个结构。若两个变量线性相关， $X \rightarrow Y$ 、 $Y \rightarrow X$ 或隐藏共同原因都可能产生相同协方差。结构信息来自

时间、实验、环境变化、机制知识或函数限制，而不是从相关系数上自动长出箭头。反过来，同一 DAG 也兼容许多参数和分布；图只表达一类条件独立与因果排除限制，并不决定效应大小。四层不能跳跃使用。变量层若把“医疗质量”混成资源、流程与患者选择，后续箭头没有稳定含义；概率层拟合准确不证明结构层正确；结构层给定也不保证目标查询可由现有分布识别。建模报告应逐层说明承诺，使读者知道争议发生在变量构造、边方向、函数形式还是数据支持。

路径推理、模块性与结构反事实 判断条件独立时，最稳妥的方法是枚举路径而非凭图形直觉。考虑 $A \leftarrow L \rightarrow Y$ 、 $A \rightarrow M \rightarrow Y$ 和 $A \rightarrow C \leftarrow U \rightarrow Y$ 同时存在。若目标是 A 对 Y 的总效应，路径 $A \leftarrow L \rightarrow Y$ 是后门，需要由 L 阻断；中介路径 $A \rightarrow M \rightarrow Y$ 是效应的一部分，不应阻断；碰撞路径经 C 默认关闭，但若条件化 C 或其后代就会打开。路径规则可归结为两问：路径上的非碰撞点是否被条件化，路径上的碰撞点或其后代是否被条件化。前者被条件化会关闭路径，后者被条件化会打开路径。这种非对称性解释了为何“控制更多变量”不具有单调安全性。一个变量可以在某条路径上阻断混杂，同时在另一条路径上打开选择；调整集必须针对所有相关路径共同判断。图操作还要与目标一致。估计直接效应时，中介可能需要以特定方式固定或调整；估计总效应时则通常不应把它当混杂。选择进入样本的变量若是处理和结果共同后果，即使它发生在数据收集之前，对研究目标仍可能是碰撞点。时间先后有帮助，却不能替代路径分析。

可以把每次判断写成审计表：列出路径、标记每个内部节点的角色、说明当前条件集使路径开放还是关闭、记录该路径是因果路径还是非因果路径。小图中这种方法稍显繁琐，复杂图中却能

防止凭视觉漏掉祖先和选择路径。

干预为何要求模块性 结构方程写成 $V_i = f_i(\text{pa}_i, U_i)$ 时, 干预 $\text{do}(X = x)$ 不是普通条件化, 而是把 X 的生成方程替换为常数 x , 其他方程保持不变。这个“其他机制保持不变”就是模块性承诺。若改变 X 的方式同时改变其他方程, 所执行的并非模型中定义的原子干预。

例如研究班级规模对成绩的影响。行政命令减少每班人数, 可能同时增加教师招聘、改变同伴组成和教室资源。若模型只替换“班级规模”方程而假定教师质量机制不变, 就需要一种能够单独改变规模的干预解释。现实政策若不可避免地联动其他机制, 应把处理定义成完整政策包, 或使用路径与多变量干预, 而不是把复杂实施硬塞进一个节点。

模块性也有范围。药物在不同基因型人群中可能通过相同受体机制产生不同强度, 这可以由效应修饰表示; 若新环境改变代谢通路本身, 则结果方程可能不再稳定。可迁移性问题由此不是简单比较协变量分布, 而是判断哪些模块跨环境保留。

结构反事实的计算与解释 SCM 中的个体反事实通常按溯因、行动、预测三步计算。先用个体事实证据更新外生变量 U 的分布; 再替换处理方程; 最后沿修改后的模型计算结果。这一过程与总体干预分布不同, 因为事实证据携带了关于该个体未观测背景的信息。设 $X = U_X$, $Y = 2X + U_Y$ 。观察某人 $X = 1, Y = 5$, 可溯因得到 $U_Y = 3$ 。若问同一个人在 X 被设为 0 时会怎样, 行动后方方程为 $X := 0$, 预测 $Y_0 = 3$ 。若只查看总体 $E(Y \mid \text{do}(X = 0))$, 则要对所有人的 U_Y 分布平均, 未必等于 3。个体反事实与平均处理效应回答不同层级的问题。当方程不可逆或存在测量误差时, 溯因

得到的不是单一 U ，而是后验分布；反事实也因此是分布。软件输出的精确个体数值通常依赖参数、噪声分布和函数形式，不能被随机试验的平均效应单独验证。报告应区分哪些部分由观察约束，哪些来自结构建模。

可反驳的画图与模型修订 可靠 DAG 通常从时间化的变量表开始，而不是从画布开始。对每个变量记录定义、测量时点、允许值、测量误差、是否可干预以及它可能扮演的角色。随后先画处理前共同原因和明确的有向机制，再加入选择、测量和缺失节点。缺边应有文字理由；“暂时没有证据”与“假定不存在直接作用”不是同一声明。建图过程应保留争议版本。领域专家可能对肥胖是否影响就医频率、教育是否直接影响健康存在分歧。与其强行形成一张共识图，不如保存几张合理 DAG，分别求调整集和识别结果；若结论只在某一图成立，分歧本身就是敏感性来源。共同调整集、部分祖先关系和图不确定性方法可以进一步形式化这种做法。

最后要用图外信息反驳图。检查时间顺序、已知实验、负对照、条件独立含义和跨环境变化。数据不满足某个图蕴含的独立性可以否定该图，但满足独立性通常不能证明所有箭头正确，因为参数抵消与 Markov 等价仍可能存在。DAG 的价值不是宣布真相，而是让假设足够具体以接受这种检查。

5.3 扩展结构：潜变量、测量与动态系统

5.3.1 潜变量、代理、选择与测量

DAG 中不画出的变量并不会停止作用。若未测共同原因 U 同时影响 A 和 Y ，观测图上的双向关联不能由调整已测后代自动消

除。代理变量 W 与 U 相关,有时能减少偏差,却不等于测到了 U ; 代理误差、差异测量和碰撞结构可能使调整更糟。

处理隐藏变量有多条路线。负对照利用理论上不应受处理影响的结局或不应影响结局的暴露来检测残余路径;工具变量利用外生变化绕开结果混杂;近端因果推断使用处理诱导与结果诱导代理,在完备性等条件下识别;敏感性分析则量化未测因素需要多强才能改变结论。每条路线都以新的结构假设交换信息,不能被“加入更多协变量”统一替代。潜变量和选择变量边缘化后的祖先图提供了更一般的图形表示(Richardson, Spirtes, 2002)。

潜变量还可能代表构念。社会经济地位、疾病严重度和组织文化由多个指标反映,直接选一个指标当真值会混合测量与因果结构。可在模型中显式区分潜在构念和观测指标,并说明处理是否影响测量过程。否则测量变化可能被误认为真实机制变化。

选择与测量也应进入图 数据表只包含被观察到的单位和数值,因此选择 S 与测量 M 不是外围问题。若 A 和 Y 共同影响进入样本,条件化 $S = 1$ 会打开碰撞路径;若 A 影响检测频率,观测结局 Y^* 同时由真实结局 Y 和检测过程决定。只画生物或社会生成过程,而省略数据生成过程,会使图无法解释手中数据。例如研究疫苗与感染。接种可能改变症状,症状影响检测,检测决定感染是否记录;职业要求又同时影响接种和定期筛查。记录中的阳性 Y^* 并非透明的真实感染 Y 。图中加入检测节点后,研究者可以判断使用住院结局、定期筛查子样本或校正检测概率分别需要什么假设。缺失也可用选择节点表达。完全随机缺失、给定观测变量随机缺失和非随机缺失对应不同图结构。多重插补在给定插补模型下恢复数据分布,却不能自动修复由处理和未观测结局共同造成的选择。先画缺失机制,再决定加权、插补、界限或收集追踪数据。

5.3.2 循环、时间与模型版本管理


现实系统包含反馈，而标准 DAG 要求无环。解决方式之一是展开时间：将状态写成 X_t, Y_t ，允许 $X_t \rightarrow Y_{t+1}$ 与 $Y_t \rightarrow X_{t+1}$ 。这样每个时间片保持有向无环，同时表示跨期反馈。关键是采样间隔足以区分过程顺序，并明确初始条件和历史长度。另一类模型直接允许循环或平衡方程。价格与供需、激素调节和生态竞争可能在短时间内达到稳定状态；干预会把系统带到新平衡。此时方程解的存在、唯一性和稳定性成为因果语义的一部分。静态相关只观察平衡点，难以区分调整过程，通常需要外部扰动或时间信息。循环 SCM 需要专门区分解、干预与唯一可解条件，不能直接沿用递归 DAG 的全部结论(Bongers et al., 2021)。动态结构还提醒我们不要把“滞后”自动当原因。共同趋势、季节性和测量延迟会产生领先关系；Granger 预测性说明过去 X 改善 Y 预测，不等同于对 X 的干预会改变 Y 。把时间先验、结构排除和冲击设计结合，才能提升方向解释。

模型检验与版本管理 图模型应像其他科学模型一样有版本和失败记录。每一版保存变量定义、边的依据、争议边、目标查询和数据日期。新增测量或领域知识时，不直接覆盖旧图，而记录哪项证据触发修改以及识别结论如何变化。版本差异能够揭示结果依赖哪些结构选择。检验分为内部与外部。内部检验检查图蕴含的条件独立、方程残差、支持与参数稳定；外部检验使用新环境、干预、负对照和机制测量。模型通过若干检验只表示尚未被这些风险反驳，不证明唯一正确。失败时应定位变量、边、函数或环境模块，而不是简单更换拟合器。可复核发布至少包括机器可读图、变量字典、识别查询与生成的调整集。图像截图不足以发现同名异义和版本漂移。将图与分析代码连接后，每次结构修改可以自动重

新计算调整集和目标表达式，使结构不确定性真正进入结果。

5.3.3 完整建模案例：治疗、依从与康复

考虑一项门诊康复研究。研究者想知道，对所有符合资格的患者提供强化康复课程，相对于常规指导，是否提高十二周功能评分。基线病情为 L ，分配的课程为 A ，实际完成的训练量为 M ，结局为 Y ，完成随访为 R 。一幅最小图应同时表示治疗路径、基线混杂和数据选择：



这幅图不是数据变量列表的图形版。 $L \rightarrow A$ 表示病情影响课程选择， $L \rightarrow Y$ 表示病情也影响康复，因而 L 位于后门路径。 M 是处理之后的依从与实际训练，对总效应而言它是中介，不应被当作普通混杂因素调整。 R 是数据是否被观察的节点；只分析 $R = 1$ 的患者，就同时在 L 和 Y 的共同结果上做了选择。

从图进入 SCM 时，可以先写一个用于检查语义的简化线性模

型：

$$L = U_L,$$

$$A = \mathbb{I}\{U_A < g(L)\},$$

$$M = 0.6A + 0.4L + U_M,$$

$$Y = 2A + 1.5M + 1.2L + U_Y.$$

假定外生扰动相互独立，并把 A 从 0 改为 1。直接路径 $A \rightarrow Y$ 贡献 2 分，经 $A \rightarrow M \rightarrow Y$ 的路径贡献 $0.6 \times 1.5 = 0.9$ 分，因此这个模型中的总效应为 2.9 分。如果回归时控制 M ，在线性且没有新混杂的设定下更接近估计直接效应 2，而不是原问题的总效应。

完整算例：从事实到个体反事实

设某患者 $L = 1$ 、 $A = 1$ 、 $M = 1.4$ 、 $Y = 6.3$ 。依据上述方程，溯因可得 $U_M = 0.4$ 与 $U_Y = 1.0$ 。现在把课程分配替换为 $A := 0$ ，保持该患者的外生背景不变，则 $M_0 = 0.8$ ， $Y_0 = 1.5 \times 0.8 + 1.2 + 1.0 = 3.4$ 。该模型对此人的反事实差异为 $6.3 - 3.4 = 2.9$ 。这个结果不是由事实数据单独读出；它依赖线性、可加性、外生扰动保持与方程参数。改用非线性依从模型后，个体差异可不再等于总体平均效应。

一份可审查的模型记录应让图、方程和查询互相对齐：

记录层	必须回答的问题
变量字典	A 是提供课程、实际参加还是完成剂量? Y 在哪个时间点测量?
图形承诺	每条边由什么时间、制度或机制证据支持? 哪些缺边是关键排除?
方程承诺	哪些模块在干预后保持? 函数形式和扰动独立来自哪里?
目标查询	要的是提供课程的总效应、经依从的间接效应, 还是某人的反事实?
反驳计划	哪个负对照、新环境、随机干预或独立测量最能区分备选模型?

失败诊断：把可见变量全部放入回归

若研究者同时控制 L 、 M 并只保留 $R = 1$ 的病例，他做了三件不同的事：用 L 阻断混杂，用 M 删去一部分目标效应，又通过 R 引入选择。“都调整了”无法描述这三种操作。正确做法是先命名目标，逐条枚举路径，再对失访机制单独建模。若不能为 $Y \rightarrow R$ 所代表的信息缺口提供假设，应做界限或敏感性分析，而不是把完整病例结果写成全体患者效应。

这个案例还显示了模型粒度的价格。若“强化课程”包含不同治疗师、强度和辅助器械，一个 A 节点可能没有唯一结构方程。研究者可把课程定义为完整策略包，也可拆分为可实施部件；两种做法的查询不同。图越细不一定越真，但变量与干预的对应必须足够稳定，才能支持后续识别和迁移。

5.3.4 图模型、参数模型与数据证据的边界

一幅 DAG 规定了变量角色、路径与一类排除限制，却不规定边的函数形式和效应大小。在 $L \rightarrow A \rightarrow Y$ 且 $L \rightarrow Y$ 的图中， A 对 Y 可以是线性常数效应，也可以只在 L 超过阈值后起作用，还可能改变结局方差而对均值无影响。这些模型共享同一张图，但对样本量、估计器和政策含义的要求不同。

因此建模应将图形层与函数层分开。图形层回答哪些条件独立和调整集由结构支持；函数层回答如何将有限数据中的模式延伸到未观察的协变量组合。线性、可加性、单调性、高斯噪声与平稳性都属于后者，不应因为图的箭头画得明确就被当作已证明。

模型层	典型承诺	可用的检查
变量层	节点在不同人、时间和环境中指向同一对象	重复测量、跨评定者一致、版本记录
图形层	直接原因、缺边、选择和 时间顺序	条件独立、已知干预、负对照、领域反例
函数层	线性、交互、误差分布与 噪声独立	残差图、外样本预测、替代学习器、模拟压力测试
干预层	替换某方程时其他模块保持	不同干预方式、剂量和环境的结果比较
反事实层	事实证据下外生背景能够溯因并在替代方程中保留	已知反事实试验、界限、多模型稳健性

参数抵消与近似不忠实 考虑 $X \rightarrow M \rightarrow Y$ 与 $X \rightarrow Y$ 同时存在的线性 SCM: $M = X + U_M$, $Y = M - X + U_Y$ 。从 X 到 Y 的间接效应为 1，直接效应为 -1，总效应精确抵消。在外生扰动独立时， X 与 Y 可以边际独立，虽然图中有两条因果路径。若发现算法使

用忠实性将独立解释为路径不存在，就会删除真实结构。

精确抵消在连续参数空间中可能很特殊，但近似抵消并不罕见。激励一方面增加工作时间，另一方面提高效率；药物改善主病程同时引起副作用。在有限样本中，小的剩余作用容易被独立检验当作零。报告应显示检验功效、等价阈值和领域上可能的反向路径，不能将“未拒绝独立”写成果缺边已证明。

模型选择与模型平均回答不同问题 当两张图在观测分布上等价时，以 BIC、交叉验证或贝叶斯后验在其中选择，结果必然来自函数、先验或复杂度偏好，而不是来自新的观测识别信息。对多张图的效应做加权平均可以表达特定先验下的决策不确定性，但不等于它们在本体论上都“部分为真”。若某些候选图中目标不可识别，还不应对可识别图求平均，因为这会丢掉最关键的结构性不确定性。

失败诊断：拟合检查代替了因果校准

一个 SCM 在观测数据上拟合良好，只表示它复现了当前环境的部分联合分布。两个模型可以对预测给出相同答案，却对 $\text{do}(A = a)$ 给出相反效应。模型校准应为观察拟合、图含义的独立、已知干预响应、环境变化与机制测量分别建立检查。“测试集误差很低”不能填充后四类证据。

本章小结

概率分布描述共同变化，SCM 增加生成机制与干预语义。DAG 通过链、叉、碰撞点和 d-分离编码条件独立；Markov 条件从图导出分解，忠实性支持反向学习，而 Markov 等价限制纯观测定向。干预替换一个结构方程并保留其他机制，这一模块性

假设是从条件概率走向因果效应的关键。

自测与研讨

1. 分别说明在链、叉和碰撞结构中给定中间变量会怎样改变端点关联。
2. 为什么同一概率分布的不同链式分解不能决定因果方向？
3. 对 $Z \rightarrow X \rightarrow Y$ 且 $Z \rightarrow Y$ 写出观测分布与 $\text{do}(X = x)$ 后分布。
4. 构造一个参数抵消导致不忠实的线性例子，并说明它如何妨碍因果发现。

延伸阅读

系统论述见 Pearl (2009, 第 1–3 章) 和 Spirtes et al. (2000)；概率图模型背景可读 Dawid (1979) 与 Lauritzen (1996)。Markov 等价的奠基工作见 Verma, Pearl (1990)，潜变量祖先图见 Richardson, Spirtes (2002)，循环 SCM 的正式语义见 Bongers et al. (2021)。面向应用的图模型解释可读 Hernán, Robins (2020) 与 Peters et al. (2017)。因果阶梯的通俗介绍见 Pearl, Mackenzie (2018)，但技术判断应回到正式模型定义。

路径分析的早期形式见 Wright (1921)，结构方程与概率经济学的连接见 Haavelmo (1944)；贝叶斯网络的计算与语义背景可读 Pearl (1988)。有向图中的独立性分解分别由 Lauritzen et al. (1990) 与 Geiger et al. (1990) 给出基础结果，含潜变量的有向混合图性质见 Richardson (2003)。

在应用研究中，DAG 的价值来自把混杂、选择和时间顺序变成可审查结构。流行病学中的奠基说明见 Greenland et al. (1999)，

以领域因果知识判断混杂的案例见Hernán et al. (2002), 面向实践的变量选择与偏差讨论可读Shrier, Platt (2008)。这些文本也说明画图软件不能替代节点语义和时间定义。

图形识别、do-calculus 与反事实

学习目标

读完本章，你应当能够：系统比较后门、前门、工具变量与 do-calculus；逐步说明删边图和行动交换的逻辑；区分总效应、路径效应、联合反事实与实际因果的识别要求。

6.1 图形识别：后门、前门与调整的边界

6.1.1 后门调整及其风险边界

给定处理 X 与结果 Y ，从 X 出发沿箭头指向 Y 的路径表示因果传递；其他在 X 与 Y 之间开放的路径可能造成非因果关联。协变量调整的目标是阻断所有相关非因果路径，同时不阻断希望估计的因果路径，也不打开新的碰撞路径。这种表述纠正两种常见误解。其一，变量只要预测结果就应该控制；其二，控制变量越多

越安全。图形识别关心变量在因果结构中的位置，而不是回归系数显著性。一个强结果预测因子可能只是中介，一个与处理和结果都相关的变量可能是碰撞点的后代。

后门准则 从 X 到 Y 、第一条边指向 X 的路径称为**后门路径**。集合 Z 满足经典后门准则，如果：

1. Z 不包含 X 的后代；
2. Z 阻断 X 与 Y 之间所有后门路径。

若准则成立，则

$$P(y \mid \text{do}(x)) = \sum_z P(y \mid x, z)P(z).$$

考虑 $X \leftarrow C \rightarrow Y$ 且 $X \rightarrow Y$ 。共同原因 C 打开后门路径，给定 C 后路径阻断， $\{C\}$ 是充分调整集。若还有 $C \rightarrow Z \rightarrow X$ ，调整 C 或在满足条件时调整其适当代理/中间节点都可能阻断路径，但不同集合会影响精度、测量成本和稳健性。

最小充分集与冗余调整

一个调整集可能包含不必要变量。**最小充分调整集**在删除任何成员后都不再充分。最小不一定统计效率最高：加入强结果预测因子可以降低方差；加入强处理预测但与结果无关的变量可能放大大方差；加入碰撞结构相关变量则可能产生偏差。图确定可接受集合，效率分析再在集合之间选择。后门准则是充分而非必要条件。更一般的调整准则允许某些处理后变量在特定图中进入集合，并系统处理因果路径上的后代限制(Perković et al., 2018; Shpitser et al., 2010)。初学分析若目标是总效应，优先选择明确的处理前共同原因通常较安全，但不应把“处理前”误当充分性证明。

四类不应机械调整的变量

中介

在 $X \rightarrow M \rightarrow Y$ 中，若目标是总效应，给定 M 会阻断经由中介的真实因果路径，得到的不是总效应。若目标是直接效应，调整中介仍需处理 M 与 Y 的混杂，且处理诱导的中介—结果混杂会使传统回归分解失败。

碰撞点

在 $X \rightarrow C \leftarrow U \rightarrow Y$ 中， C 默认阻断 X 与 U 的路径；给定 C 会使 X 与 U 相关，打开到 Y 的非因果路径。这就是碰撞点偏差。给定碰撞点的后代也可能打开路径。

工具变量

若 $Z \rightarrow X \rightarrow Y$ ，且 U 同时影响 X, Y ，一个理想工具 Z 与 U 独立且只通过 X 影响 Y 。把 Z 作为普通协变量加入结果回归并不能像工具变量估计那样消除未测混杂；在某些设定中还会放大残余混杂偏差。工具变量需要独立性、排除限制和相关性等专门假设。


处理的代理或后果

若病情严重度影响治疗，而研究者只观察治疗后的某个病情指标，调整该指标可能同时控制治疗效应并引入选择路径。变量名称中的“基线”也不能保证时间正确；需要确认测量发生在处理决定之前。

M 偏差与有限样本权衡 经典 M 结构为 $X \leftarrow U_1 \rightarrow C \leftarrow U_2 \rightarrow Y$ 。若 U_1 与 U_2 独立， X 与 Y 的路径被碰撞点 C 关闭；调整 C 反而打开路径。现实中 U_1, U_2 可能相关， C 也可能同时是混杂代理，于是调整与否取决于参数大小。图形分析指出偏差通道，却不自动量化净偏差。面对结构不确定，可比较多个合理 DAG，模拟可能参数，报告调整与不调整的敏感性结果。以一幅主观图宣布变量“绝不可控制”，与无图地控制一切同样武断。

6.1.2 前门、工具变量与分析流程

当 X 与 Y 存在未测混杂 U 时，后门调整可能失败。但若观察到中介 M ，在特定条件下仍可通过**前门准则**识别总效应。标准图



需要满足： M 截断 X 到 Y 的所有有向路径； X 与 M 之间没有未阻断后门路径；给定 X 后， M 与 Y 之间所有后门路径被阻断。在这些条件下，

$$P(y \mid \text{do}(x)) = \sum_m P(m \mid x) \sum_{x'} P(y \mid m, x') P(x').$$

第一部分 $P(m \mid x)$ 识别 X 对 M 的效应；第二部分通过调整 X 识别 M 对 Y 的效应；再对中介状态求和。公式展示了图结构如何

把两个可识别关系组合成原本被未测混杂遮蔽的总效应。真实研究中前门条件很强。所有效应必须经测得中介传递，中介—结果之间不能有给定处理后仍未控制的混杂，且中介测量误差可能严重影响结果。前门不是“有中介就能解决混杂”，而是特殊结构下的识别证明。

工具变量识别的另一种道路 工具变量 Z 满足：与处理 X 相关；不通过 X 之外的路径影响结果 Y （排除限制）；与 $X—Y$ 的未测混杂独立。对于二元鼓励、处理与结果，在单调性等附加假设下，Wald 比率

$$\frac{E(Y | Z = 1) - E(Y | Z = 0)}{E(X | Z = 1) - E(X | Z = 0)}$$

识别服从者中的局部平均处理效应(Angrist et al., 1996)。

排除限制通常不能由数据验证。一个政策资格阈值可能除了改变治疗使用，还改变其他资源；遗传工具可能通过多效性直接影响结果。弱工具使估计不稳定并放大偏差。工具变量因此不是未测混杂的通用修复，而是用一组结构假设换取一个特定局部目标。

从图到分析的实际流程 图形识别可按以下顺序进行：

1. 明确估计总效应、直接效应还是策略效应；
2. 只依据因果知识和时间信息画图，不按样本显著性删边；
3. 列出潜在未测共同原因和选择节点；
4. 用 d-分离或软件枚举可接受调整集；
5. 检查候选变量的实际测量时间、误差和正值性；
6. 若不存在调整集，考虑前门、工具变量、实验数据融合或部分识别；
7. 对替代图和关键未测路径做敏感性分析。

“没有可接受调整集”只说明普通协变量调整不足，不等于任何数据设计下都不可识别。do-calculus 正是用来判断更广泛的观测与实验信息能否识别目标。

6.1.3 目标敏感的调整集与图不确定性

考虑图：基线健康 L 影响治疗 X 、中介依从 M 和结果 Y ； X 影响 M 与 Y ； M 影响 Y ；治疗后的不良反应 R 同时受 X 与未测易感性 U 影响， U 也影响 Y 。若目标是 X 对 Y 的总效应，调整 L 可以阻断 $X \leftarrow L \rightarrow Y$ 和经 $L \rightarrow M \rightarrow Y$ 的后门；不应调整 M ，因为它承载部分总效应；也不应调整 R ，因为 $X \rightarrow R \leftarrow U \rightarrow Y$ 是碰撞路径，给定 R 会打开它。若目标是受控直接效应，研究者想比较在固定 $M = m$ 时的处理。此时需要识别联合干预 $\text{do}(X = x, M = m)$ 。 L 同时混杂 $X \rightarrow Y$ 和 $M \rightarrow Y$ ，可在适当序贯条件下调整；若存在治疗诱导的 $M \rightarrow Y$ 混杂，则普通中介回归不够。目标改变使“应该控制什么”改变，没有一份脱离目标的永久控制变量清单。若目标是实际治疗者中的 ATT，调整集的图形充分性可相同，但标准化或权重分布改为处理者。图解决路径，目标人群解决加权；两项都要写清。

选择图中的调整 设医院入组 S 同时受疾病严重度 L 和早期症状 Y_0 影响，而 Y_0 又预测最终结局 Y 。只分析 $S = 1$ 会改变 L, Y_0 的联合分布。若 L, Y_0 完整测量且给定后选择与未来潜在结果独立，可以对选择概率加权；若早期症状只在入组者中测量，目标人群分布缺失，单靠样本内部无法恢复。图形分析应把 S 明确画出，而不是把“便利样本”当普通总体。选择有时发生多次：进入数据库、满足完整记录、通过排除标准、留到随访。每次条件化都可能打开路径。把选择过程分节点表示，能区分需要治疗权重、删失权重还

是迁移权重。

调整与精度的区分 变量进入估计有两种理由。因果理由是阻断偏差路径；统计理由是提高精度。随机试验中基线结果强预测因子不是混杂，因为处理已随机，但调整它常降低方差。观察研究中工具变量强预测处理却不预测结果，加入倾向模型可能制造极端权重而不减少混杂。因此报告应分列：哪些变量为识别所必需，哪些为效率加入，哪些用于缺失或选择模型。若结果对效率变量选择高度敏感，可能提示模型外推或重叠问题，而不只是“稳健性更好”。

DAG 不确定性下的共同调整集 假设 Z 与 X 的时间关系明确，但 Z 对 Y 是直接共同原因还是仅通过另一个已测变量 C 作用不确定。可枚举两幅图，寻找在两图都阻断后门且不含禁止后代的集合。若 $\{Z, C\}$ 在一图包含冗余变量、在另一图必需，但两图均安全，可选择共同集；若一图把 C 视为碰撞点，另一图把它视为混杂，就不存在简单共同方案，应收集定向证据或分别报告。这种多图分析比用统计筛选决定变量更诚实。它把结构争议保留到结果解释中，并指出哪条边最值得通过时间测量、机制知识或干预澄清。

6.2 do-calculus、反事实与中介分析

6.2.1 三条演算规则与识别算法

给定一个因果图和若干观测或实验分布，do-calculus判断含干预的目标表达式能否转化为可由现有数据计算的表达式。它不是从数据自动发现图，也不是一种数值估计器。演算的输入已经包含因果结构假设；输出是识别公式或识别失败证明。先约定图

操作。 $G_{\bar{X}}$ 表示删除所有指向 X 的箭头，模拟对 X 的干预； $G_{\bar{Z}}$ 表示删除所有从 Z 发出的箭头，用于判断把行动交换为观察的条件； $G_{\bar{X}, \bar{Z}}$ 同时实施两种删除。 $Z(W)$ 表示在 $G_{\bar{X}}$ 中不是任何 W 节点祖先的那些 Z 节点。

三条规则 对互不相交的变量集合 X, Y, Z, W ，do-calculus 的标准形式如下(Pearl, 1995, 2009)。

规则一：插入或删除观察

若

$$(Y \perp\!\!\!\perp Z \mid X, W)_{G_{\bar{X}}},$$

则

$$P(y \mid \text{do}(x), z, w) = P(y \mid \text{do}(x), w).$$

直观上，在切断指向 X 的边后，给定 X, W ，观察 Z 不再提供关于 Y 的信息，于是可以删除该观察条件。

规则二：行动与观察交换

若

$$(Y \perp\!\!\!\perp Z \mid X, W)_{G_{\bar{X}, \bar{Z}}},$$

则

$$P(y \mid \text{do}(x), \text{do}(z), w) = P(y \mid \text{do}(x), z, w).$$

这里删除 Z 的出边，是为了检验 Z 除了作为对其后果的行动之外，是否还通过其他路径携带与 Y 有关的信息。条件成立时，对 Z 的干预可由观察 Z 代替，或反向交换。

规则三：插入或删除行动

若

$$(Y \perp\!\!\!\perp Z \mid X, W)_{G_{\overline{X, Z(W)}}},$$

则

$$P(y \mid \text{do}(x), \text{do}(z), w) = P(y \mid \text{do}(x), w).$$

它说明当相关图中对 Z 的行动不再影响 Y 时，可以删除该行动。 $Z(W)$ 的祖先限制保证不会不当地删除影响已观察条件 W 的行动。

关键辨析

三条规则的左右两边、条件变量和删边图必须同时正确。把规则一写成普通条件概率等式、把规则二写成两个不同 X 值之间的交换，或省略规则三的祖先限制，都会改变定理内容。

从规则到识别算法 使用规则可以手工推导后门和前门公式，但复杂图中需要系统算法。ID 算法递归利用祖先集、截断因子分解和图中的 **C-component** 识别 $P_x(y)$ ；若遇到称为 **hedge** 的图结构，则给出不可识别证据(Shpitser, Pearl, 2006)。do-calculus 对非参数 DAG 中的干预分布识别是完备的：如果目标可从观测分布识别，就存在由规则与概率运算得到的推导。完备性是相对于模型类和数据类型的。加入线性、单调性、参数限制、代理变量或多环境数据，原本非参数不可识别的目标可能变得可识别；反过来，图若错误，正确演算也会得到错误科学结论。识别结果也可能只是一条复杂泛函，有限样本中难以稳定估计。因此实际工作仍需检查正值性、维度、平滑性和估计器。符号可识别不等于统计上容易。

6.2.2 结构反事实、效应分解与实际因果

在 SCM 中,反事实把同一外生背景 $U = u$ 固定,并改变一个或多个结构方程。给定个体证据 $E = e$, 反事实查询 $P(Y_x = y | E = e)$ 可按三步理解:

1. **溯因**: 用证据更新外生变量分布, 得到 $P(U | E = e)$;
2. **行动**: 以 $X := x$ 替换 X 的方程;
3. **预测**: 在修改后的模型中由更新后的 U 推出 Y 。

设

$$X := U_X, \quad Y := 2X + U_Y.$$

观察某单位 $X = 1, Y = 3$, 可推得 $U_Y = 1$ 。询问“若该单位的 X 被设为 0”, 保持 $U_Y = 1$, 得到 $Y_0 = 1$ 。这与总体干预平均不同: 反事实利用了该单位的实际证据来推断背景。

固定同一个 U 是跨世界同一性的来源, 也是强模型假设。若结构方程或外生变量表示不充分, 个体反事实可能比平均干预更脆弱。

总效应与直接效应 在 $X \rightarrow M \rightarrow Y$ 且可能有 $X \rightarrow Y$ 时, 总效应比较

$$E(Y_x) - E(Y_{x'}).$$

受控直接效应把中介固定为同一指定值 m :

$$\text{CDE}(m) = E(Y_{x,m} - Y_{x',m}).$$

它回答在外部同时设定处理和中介时, 改变处理的效应。

自然直接效应试图让中介保持在基准处理下“自然会取的值”:

$$\text{NDE} = E\{Y_{x,M_{x'}} - Y_{x',M_{x'}}\}.$$

自然间接效应则比较中介在两处理状态下的变化,同时把结果方程中的处理保持固定。这样的嵌套反事实同时引用不同世界,通常需要比总效应更强的跨世界独立假设。

传统“总效应 = 直接效应 + 间接效应”只在指定尺度与定义下成立。非线性模型、处理—中介交互、处理诱导的中介—结果混杂都会使简单回归系数差失效。若处理影响一个随后同时影响中介和结果的变量,经典自然效应往往不能仅由标准观测数据识别。近年来的**干预型直接和间接效应**以随机化中介分布代替个体的自然中介值,减少某些跨世界解释负担,但回答的是不同政策问题。选择效应定义应由实质问题决定:是要把中介设为固定值、改变中介分布,还是理解个体自然路径。

实际因果与责任 SCM 也能形式化“在这个具体情境中, $X = x$ 是否导致 $Y = y$ ”。Halpern 与 Pearl 路线通常要求:事实中原因和结果都发生;在某种允许的结构应急情形下改变原因会改变结果;候选原因满足最小性(Halpern, 2016)。为处理先占和过度决定,定义会考虑将部分变量固定在实际值或替代值。实际因果定义对模型粒度和正常性排序敏感。在森林火灾模型中只用“雷击、纵火、火灾”三个二元变量,与加入湿度、点燃时刻和两条传播路径的模型,可能给出不同个例判断。法律责任还涉及可预见性、义务和主观过错,不能由结构方程中的实际原因自动推出。

反事实概率能从哪里来 干预分布 $P(Y_x)$ 在一致性语义下可与 $P(Y \mid \text{do}(x))$ 联系,但联合反事实如 $P(Y_x, Y_{x'})$ 不能一般地由两

个边缘干预分布决定。随机试验告诉我们不同人群在不同处理下的边缘分布，却没有让同一人的两个潜在结果同时出现。要识别获益概率 $P(Y_1 = 1, Y_0 = 0)$ ，通常需要单调性、功能形式、秩不变或其他跨世界约束；否则只能给出界限。把模型软件输出的个体反事实概率当作数据直接估计值，会掩盖这些约束。

6.2.3 演算实例、反事实图与错误诊断

1. 明确目标是总体干预、条件干预、路径效应还是个体反事实；
2. 给出完整图和每个节点的时间、测量及因果含义；
3. 在每次规则应用中写明操作后的图与 d-分离条件；
4. 将最终表达式限定在实际可获得的数据分布；
5. 区分非参数识别、参数识别和估计便利；
6. 对关键跨世界或模块性假设给出科学解释和敏感性分析。

前门公式的演算思路 在标准前门图中，先按观察到的中介状态使用全概率公式：

$$P(y | \text{do}(x)) = \sum_m P(m | \text{do}(x)) P(y | \text{do}(x), m).$$

由于 X 与 M 没有开放后门，规则二允许把第一项中对 X 的行动换成观察，得 $P(m | x)$ 。在第二项中，规则二先把观察 m 换成行动 $\text{do}(m)$ ；又因为 M 截断 X 到 Y 的全部有向路径，规则三随后删除对 X 的行动，得到 $P(y | \text{do}(m))$ 。这里每次交换都对应不同的删边图，不能把两步合并成一次普通条件化。

对 M 到 Y 的效应， X 阻断其后门路径 $M \leftarrow X \leftarrow U \rightarrow Y$ ，所

以

$$P(y \mid \text{do}(m)) = \sum_{x'} P(y \mid m, x') P(x').$$

组合便得到

$$P(y \mid \text{do}(x)) = \sum_m P(m \mid x) \sum_{x'} P(y \mid m, x') P(x').$$

推导的意义不是记忆双重求和，而是看到每一步行动—观察交换由哪条路径条件支持。若存在 $U_M \rightarrow M, Y$ ，第二步失败；若存在未经 M 的直接路径 $X \rightarrow Y$ ，删除行动失败。

双世界图与反事实独立 潜在结果中的某些跨世界条件很难从单一 DAG 直观看出。**单世界干预图 (SWIG)** 把干预节点拆成固定值与随机部分，将同一干预世界内的反事实独立读成图分离(Richardson, Robins, 2013)。这有助于翻译 $Y(a) \perp\!\!\!\perp A \mid L$ 等条件。自然直接效应中的 $Y_{x, M_{x'}}$ 同时引用 x 与 x' 两个世界，不能由一个普通单世界图完全表示。常见识别依赖中介在一个处理世界中的值与结果在另一个设置中的反事实关系。随机试验分别随机化处理和中介，也未必直接观察这种联合分布。这说明为什么自然效应比总效应脆弱。若政策问题实际是“把中介分布改善到某个可实施水平”，干预型效应可能更匹配行动，并避免对个体自然中介的强解释。但它不是同一问题的弱假设版本，而是改换了查询。

反事实界限的简单例子 在随机试验中观察二元结果，设 $p_1 = P(Y_1 = 1)$ 、 $p_0 = P(Y_0 = 1)$ 。获益比例

$$P(Y_1 = 1, Y_0 = 0)$$

不能由两个边缘概率唯一确定，但 Fréchet 界给出

$$\max(0, p_1 - p_0) \leq P(Y_1 = 1, Y_0 = 0) \leq \min(p_1, 1 - p_0).$$

若再假定处理不会伤害任何人，即 $Y_1 \geq Y_0$ ，获益比例缩为 $p_1 - p_0$ 。精度完全来自单调性，而不是试验额外观察了联合反事实。

这个例子适用于理解“个体获益概率”模型。模型给出比上述界限更窄的数字时，必定使用了特征、函数形式或跨世界依赖假设。报告应把这些假设与随机化识别的边缘效应区分。

演算错误的诊断方法 检查一条 do 推导时，可以逐行提出三问：左右两边改变了观察还是行动？所用图究竟删除入边还是出边？条件独立是否在该操作图中成立？再把最终公式代入一个简单 SCM 数值模拟；若等式在满足图的模型中失败，说明推导有错。符号软件可以执行 ID 算法，但手工标注每一步仍有教学价值。它让领域专家看见识别依赖哪条缺边，而缺边往往正是最需要实质审查的假设。

6.3 识别工作的深化与边界

6.3.1 识别层级与完整工作记录

后门、前门、工具变量与 do-calculus 经常被并列成四种“方法”，仿佛研究者可按软件熟悉程度任选。实际上它们对应不同结构信息。后门利用足以阻断处理与结果非因果路径的测量变量；前门利用一个截断有向路径且其自身混杂可处理的中介；工具变量利用只通过处理影响结果的外生变化；do-calculus 则是对一般图中观察与行动表达式进行系统转换的规则。选择顺序应从图与数

据开始。若存在可靠的处理前调整集，标准化通常最透明。若关键共同原因未测，但有满足前门条件的中介，前门可能识别总体效应；条件非常强，不能因图形看似相似就套用。工具变量在排除限制、独立性和单调性下通常识别局部效应，而非总体 ATE。复杂图无法由熟悉准则处理时，ID 算法能够判断非参数识别或给出 hedge 证据。

方法之间还会给出不同目标。按工具变量估计的服从者平均效应，与调整得到的总体平均效应数值不同不必表示一方错误；它们可能针对不同人群。前门公式依赖中介分布，政策若改变了中介的定义或测量过程，迁移也会失败。报告必须把识别结构和目标量同时命名。

从图到公式的完整工作记录 一份图形识别记录至少包含原图、目标查询、允许使用的数据分布、每次图操作和最终表达式。以调整为例，不应只给出公式，还要列出所有从处理进入的后门路径，说明调整集如何阻断，并检查集合不含处理后后代。以 do-calculus 为例，每一步都应注明删除入边或出边后的图以及成立的 d-分离。公式得到后还需检查可估计性。标准化可能要求数据中不存在的协变量组合；前门双重求和可能在连续高维中极难稳定估计；ID 算法给出的表达式可能包含多个条件密度和边缘化。非参数识别只说明无限数据下目标由分布唯一决定，不保证有限样本中有可接受精度。反向检查同样重要。把最终公式放入一个符合图的简单结构方程模拟，验证数值是否恢复干预效应；再故意加入一条被排除的边，观察哪一步等式失败。这种最小反例能暴露符号推导中被省略的条件，也便于向领域专家解释识别为何依赖某条缺边。

6.3.2 中介含义与不可识别证明

“效应有多少通过 M 发生”可能指至少三种问题。受控直接效应把所有人的中介设为同一值；自然直接效应让中介取基准处理下该个体自然会有值；干预型效应则从某个可定义的中介分布随机赋值。三者的干预对象、跨世界要求和政策含义不同。若中介是“抑郁程度”，把它固定为同一数值未必对应可实施干预；不同治疗达到同一量表分数可能通过不同机制影响结果。自然效应的嵌套反事实具有直观分解意义，却常依赖处理诱导的中介—结果混杂不存在等强假设。干预型效应更接近改变服务分配或风险分布，但它回答的是群体政策而非个体自然路径。中介测量还可能是结果过程的一部分。治疗影响就医频率，就医频率又决定中介是否被记录；只分析有测量者会引入选择。时间变化中介与反馈需要纵向定义，简单把一个随访值放入回归并比较处理系数，通常不能识别任何标准路径效应。


不可识别证明具有正面价值 当 ID 算法返回 hedge，结论不是“软件失败”，而是在给定图和观测分布下存在至少两个因果模型产生相同观测数据却给出不同目标值。这是一种明确的知识界限。它告诉研究者继续增加同类观测样本不会解决问题，必须获得实验、额外变量、跨环境分布或更强结构假设。不可识别证明也可以比较设计价值。若测量某个候选变量能够破坏 hedge，研究者就有理由优先收集它；若随机化某个上游节点使目标可识别，可以评估试验成本；若只能通过功能形式识别，则应把结果标记为参数依赖，并用替代模型检查。在写作中明确“不知道”往往比给出脆弱点估计更有贡献。它把争论从算法性能转向缺失信息：究竟需要何种干预、测量或领域承诺。因果推断的完备性不是保证所有问题都有答案，而是尽可能清楚地区分可由当前信息回答与不能

回答的查询。


6.3.3 完整识别档案：同一问题的三种图

设 A 是治疗, Y 是结局, 目标都是 $P(Y | \text{do}(A = a))$ 。下面三幅图只改变少数结构承诺, 识别结果却完全不同。这种并列比较比背诵公式更能显示公式中的信息来源。


后门可调整



前门可识别



仅观测不可识别



第一幅图中, L 阻断唯一后门路径, 因而

$$P(y | \text{do}(a)) = \sum_l P(y | a, l)P(l).$$

这一等式使用的不是“ L 对 Y 预测准确”, 而是给定 L 后处理没有其他开放的非因果路径。若另有未测 U 同时影响 A, Y , 等式第一步就不再成立。

第二幅图允许 A, Y 有未测混杂, 但 A 对 Y 的所有作用经 M 传递, A 到 M 没有未阻断后门, 而 M 到 Y 的后门可由 A 阻断。在这些条件下,

$$P(y | \text{do}(a)) = \sum_m P(m | a) \sum_{a'} P(y | m, a')P(a').$$

内层对 a' 的求和不是多余技巧, 而是用观察到的处理分布阻断

$M \leftarrow A \leftarrow U \rightarrow Y$ 。若 A 还有一条不经 M 的直接边，前门公式不再识别总效应。

第三幅图既没有可调整的 L ，也没有满足条件的中介或外生工具。观测 $P(A, Y)$ 可以同时由“ A 对 Y 作用较强、 U 较弱”和“ A 几乎没有作用、 U 造成大部分关联”的模型生成。增加同类样本可更精确地知道 $P(A, Y)$ ，却不能在两个结构解释之间做出选择。

完整算例：把识别推导写成审计轨迹

对第一幅图，先写目标 $EY(a)$ ，再对 L 标准化：

$$\begin{aligned} EY(a) &= \sum_l EY(a) \mid L = l P(l) \\ &= \sum_l EY(a) \mid A = a, L = l P(l) \\ &= \sum_l E(Y \mid A = a, L = l) P(l). \end{aligned}$$

第一个等号是全概率展开；第二个等号使用 $Y(a) \perp\!\!\!\perp A \mid L$ ；第三个等号使用一致性。正值性保证需要的 $E(Y \mid A = a, L = l)$ 在目标层中有数据含义。这种逐行标注使领域争议可以定位：若某个病情层的处理由医生完全决定，问题在正值性；若还有未记录病情同时影响处方和结局，问题在可交换性。

档案项	应保存的内容	最常见的失败
图与版本	原图、争议边、选择与测量节点	只保存一张美化后图像
目标与数据	干预分布、反事实或路径效应；可用分布	默认只有一个观测数据集
规则轨迹	每步图操作、d-分离条件与等式	只引用“由 do-calculus 可得”
可估计性	支持、维度、连续处理和样本量风险	把非参数识别误作精确估计
反例	破坏一条缺边或条件后的模拟结果	只展示有利于主结论的模型

失败诊断：用识别公式反推因果图

一个数据集能稳定估计后门公式，不证明真实结构就是第一幅图。不同 DAG 可对同一观测分布给出相同标准化数值，而在其他干预或环境下分歧。识别分析的条件句是“若该图与其语义成立，则目标等于此表达式”，不是“因为表达式可计算，图已被证实”。图的证据需要时间、制度、机制和新干预共同提供。

本章小结

图形调整以阻断非因果路径、保留目标因果路径为原则。后门准则给出标准化公式；中介、碰撞点、工具变量和处理后变量各有不同角色，不能按预测能力机械控制。前门和工具变量显示，协变量调整失败时仍可能在更强结构假设下识别特定效应。do-calculus 通过三条带有精确删边图条件的规则，把干预分布转换为可用数据表达式；ID 算法把这种推理系统化。结构反事实以溯因、行动、预测连接实际证据与替代世界。直接、间接和实际因果查询需要比总效应更强、更具体的模型，尤其要警

惕跨世界假设和模型粒度。

自测与研讨

1. 为一个包含共同原因、中介和碰撞点的五节点 DAG 找出总效应的最小调整集。
2. 为什么控制处理后的病情指标可能同时产生过度调整与碰撞点偏差？
3. 逐步解释前门公式的两个内层因果关系如何识别。
4. 工具变量估计的目标为何常是局部效应而非 ATE？
5. 写出三条 do-calculus 规则，并逐一解释横线和下划线图操作。
6. 为什么 do-calculus 完备不意味着它能从任意数据发现正确因果图？
7. 用一个线性结构方程完成溯因—行动—预测三步。
8. 比较受控直接效应与自然直接效应所对应的干预问题和识别假设。

延伸阅读

后门、前门和 do-calculus 的原始系统论述见 Pearl (2009)。一般调整准则见 Shpitser et al. (2010) 与 Perković et al. (2018)。工具变量的局部平均效应解释见 Angrist et al. (1996)；应用中的图形变量选择可结合 Hernán, Robins (2020) 阅读。

三条规则与图操作以 Pearl (1995) 和 Pearl (2009, 第 3 章) 为准。识别完备性与 ID 算法见 Shpitser, Pearl (2006)。SWIG 的原始技术报告见 Richardson, Robins (2013)；中介分析可读 Pearl (2001) 与 VanderWeele (2015)；实际因果的模型化见 Halpern

(2016)。

一般识别条件和完整因果层级算法可依次阅读Tian, Pearl (2002)与Shpitser, Pearl (2008); 当直接实验目标不可操纵而只能进行替代实验时, z-可识别性见Bareinboim, Pearl (2012)。调整集的可计算检查可结合Textor et al. (2016), 但软件输出必须由图假设解释。

工具变量的识别愿景、限制和单调性解释可对照Hernán, Robins (2006)与Swanson, Hernán (2018)。路径特定效应的图形可识别性见Avin et al. (2005); 自然直接和间接效应的早期交换条件见Robins, Greenland (1992), 半参数效率、多重稳健与敏感性分析见Tchetgen Tchetgen, Shpitser (2012)。

研究设计、估计方法与不确定性

学习目标

读完本章，你应当能够：从已经定义并识别的目标量选择研究设计和估计器；比较回归、匹配、加权、双重稳健与机器学习辅助估计；报告抽样、模型和结构不确定性。

7.1 从识别到估计：设计、模型与不确定性

7.1.1 结果建模、匹配与倾向得分

当标准化公式

$$E\{Y(a)\} = \int E(Y \mid A = a, L = l) dP(l)$$

已经由一致性、可交换性和正值性识别后，我们仍有多种估计方式。它们使用同一识别逻辑，却对结果模型、处理模型、平滑性和有限样本表现作不同选择。比较方法时首先应确认它们估计同一目标人群、同一效应尺度和同一处理策略。

“机器学习方法”“因果森林”或“倾向得分匹配”不是目标量。一个复杂估计器可以非常准确地估计错误或含混的目标。反之，设计清楚的随机试验用简单均值差就可能给出高质量答案。

结果回归与 g 计算 结果回归估计条件均值

$$m_a(l) = E(Y | A = a, L = l),$$

然后对目标人群的协变量分布标准化：

$$\hat{\mu}_a = \frac{1}{n} \sum_{i=1}^n \hat{m}_a(L_i), \quad \widehat{ATE} = \hat{\mu}_1 - \hat{\mu}_0.$$

这称为 g 计算或回归标准化。它直接模拟每个样本单位在两个处理状态下的预测结果，再求人群平均。

若 $m_a(l)$ 模型正确，估计可以一致。传统线性回归容易把模型系数误作效应：存在非线性、交互或非可合并链接时，处理系数未必等于边缘 ATE。g 计算通过显式标准化使目标更清楚，也允许使用灵活学习器。模型诊断不能只看整体预测误差。因果估计需要在每个处理状态下预测目标人群潜在结果；缺少重叠的区域正是反事实外推最强之处，即使总体预测良好也可能偏差很大。

匹配与设计阶段的可比性 匹配为每个处理单位寻找协变量相似的对照，试图重建类似随机试验的比较。可按精确变量、Maha-

lanobis 距离或倾向得分匹配。设计阶段通常不使用结果数据来反复挑选匹配规则，减少结果导向的分析选择。匹配后必须检查协变量平衡、共同支持、丢弃单位和目标人群变化。标准化均值差比逐变量显著性检验更适合平衡诊断，因为显著性受样本量影响。若大量处理单位找不到可比对照，得到的效应可能只针对重叠子人群，而非原定 ATT 或 ATE。最近邻匹配并不自动无偏。连续协变量的近似匹配存在残差差异，匹配后分析还需考虑成对或聚类结构，带放回匹配和一对多匹配改变权重。把匹配索引后简单做普通独立样本检验，可能给出错误标准误。

倾向得分与加权 倾向得分是

$$e(L) = P(A = 1 | L).$$

在条件可交换性成立时，给定真实倾向得分可使已测协变量在处理组间平衡(Rosenbaum, Rubin, 1983)。它压缩的是处理赋值相关信息，不是结果风险；倾向得分相近不保证未测混杂平衡。

ATE 的逆概率处理权重可写为

$$w_i = \frac{A_i}{e(L_i)} + \frac{1 - A_i}{1 - e(L_i)}.$$

加权后构造一个处理与已测 L 独立的伪人群，再比较加权结果均值。ATT、ATC 和重叠人群使用不同权重；权重公式必须与目标一致。

倾向模型的目标是平衡，而不是最大化处理预测准确率。一个几乎完美预测处理的模型可能产生极端权重，暴露正值性问题。应报告倾向分布、权重分位数、有效样本量和加权后平衡。稳定化和截断可改善方差，但必须说明它们对目标与偏差的影响。匹配

估计的渐近性质与倾向方法的应用诊断分别可见Abadie, Imbens (2006)和Austin (2011)。

7.1.2 双重稳健、正交化与试验估计

增广逆概率加权 (AIPW) 结合结果模型 $m_a(L)$ 和倾向模型 $e(L)$ 。处理水平 a 的均值可估为

$$\hat{\mu}_a = \frac{1}{n} \sum_{i=1}^n \left[\hat{m}_a(L_i) + \frac{\mathbb{I}(A_i = a)}{\hat{P}(A_i = a | L_i)} \{Y_i - \hat{m}_a(L_i)\} \right].$$

若结果模型或处理模型至少一个正确，在常规条件下估计仍可一致，因此称为**双重稳健**。这不是“两个错误模型相互抵消”的保证，也不抵抗未测混杂、处理定义错误或同时严重错设。有限样本中极端权重仍可能使估计不稳定(Bang, Robins, 2005)。目标最大似然估计 (TMLE) 以初始结果模型为起点，用倾向信息沿目标量相关方向更新，使最终估计满足有效影响函数方程(van der Laan, Rose, 2011)。它同样依赖识别假设，但在使用灵活学习器时提供系统的目标化估计与推断框架。

Double Machine Learning 高维协变量下，直接把机器学习预测带入因果参数公式可能产生正则化偏差，并因同一数据既训练又评估而过拟合。**Double/Debiased Machine Learning**使用 **Neyman 正交得分**，使目标估计对干扰函数的小误差一阶不敏感，并结合**交叉拟合**：在一部分样本训练处理和结果模型，在未参与训练的部分计算得分，再轮换合并(Chernozhukov et al., 2018)。

以部分线性模型

$$Y = \theta A + g(L) + \varepsilon, \quad A = m(L) + v$$

为例，可分别估计 g, m ，用残差化后的 Y 与 A 估计 θ 。正交性降低干扰函数误差传到 θ 的一阶影响；交叉拟合放宽对学习器复杂度的经验过程限制。

DML 不是“先用 ML 去混杂就得到因果”。它仍需要可交换性、重叠和正确得分结构；不同 DML 模型对应不同参数。若结构不是部分线性， θ 的解释需要另行说明。

随机试验中的估计细节 随机化识别简单均值差，但协变量调整可提高精度。应预先指定调整变量和模型，使用对随机化设计有效的标准误。分层、整群或不等概率随机化需要在分析中反映设计；回归调整的稳健性仍需依照随机化结构解释(Lin, 2013)。依从性不足时，**意向治疗效应**比较分配策略，保留随机化优势。按实际治疗比较会重新引入选择。若随机分配只通过实际治疗影响结果，且满足单调性等条件，可把分配作为工具变量估计服从者平均因果效应。这个目标与意向治疗效应不同，不应因后者“被稀释”就自动替换。多重结局、亚组和中期分析增加选择性报告风险。预注册、分析计划和对探索性结果的清楚标记，是估计可信度的一部分。

7.1.3 方法选择、数值诊断与分层不确定性

置信区间通常反映在模型和识别假设成立时的抽样变异。它不包括未测混杂、测量误差、处理版本不明确、图结构错误和模型选择空间。一个极窄区间可能精确地围绕有偏目标。

完整的不确定性报告至少包括：

- 点估计与决策相关的绝对、相对尺度；
- 抽样置信区间或兼容区间；

- 重叠、权重和协变量平衡诊断；
- 替代合理模型或调整集结果；
- 未测混杂、失访与测量误差敏感性分析；
- 从样本到目标人群的适用限制。

p 值只是在特定模型下衡量数据与零假设的不相容程度，不说明确效应大小、因果假设可信度或政策价值。统计不显著不等于无效，显著也不等于重要。

一张方法选择表

方法	主要优势	主要风险
g 计算	直接对应标准化目标，易表达非线性与交互	结果模型外推和错误
匹配	强调设计与共同支持，诊断直观	丢弃样本、残差不平衡、推断处理复杂
IPW	构造目标伪人群，适合纵向扩展	极端权重和倾向模型错误
AIPW/TMLE	双重稳健，可结合灵活学习	两模型同时失败、有限样本不稳定
DML	高维干扰函数、正交得分和交叉拟合	目标模型仍需正确，不能修复未测混杂

数值例子：权重为何会失控 假设一个样本有 1000 人，其中某高风险层只有 20 人，19 人接受治疗、1 人未治疗。若估计 ATE，未治疗者权重约为 $1/(1 - 0.95) = 20$ ，一个人的结局会代表该层大量反事实信息。若其结局恰为异常值，估计剧烈变化。这不是简单“模型方差太大”，而是数据几乎没有回答“高风险者不治疗会怎样”。截断权重到 10 可稳定计算，却相当于减少该人的代表性，

并引入偏差。把目标改为重叠人群效应可能更诚实：它关注各处理都有真实选择机会的人，而不外推到几乎确定治疗者。

权重诊断应在看结果前完成。报告最大值、中位数、尾部分位数和有效样本量

$$n_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}.$$

原始样本 1000 人若有效样本量只有 120，精度不应按 1000 人的直觉解释。

7.1.4 稳健性、标准误与决策解释

AIPW 中的结果预测为每个人填充两个处理下的条件均值，权重残差项校正结果模型在实际处理组中的系统误差。若倾向模型正确，残差加权可修正错误结果模型；若结果模型正确，残差平均为零，即使倾向模型错也可保持一致。但“至少一个正确”是在总体与规则条件下的渐近命题。有限样本里，一个严重错误结果模型与极端错误倾向模型可以共同产生灾难结果；灵活学习器若不交叉拟合，会因过拟合破坏标准推断。双重稳健也完全不涉及未测混杂和一致性。实践中应同时诊断两模型：倾向模型看平衡与重叠，结果模型看分层校准与外推；再比较 g 计算、IPW 和 AIPW。三者分歧大不是挑选最喜欢结果的理由，而是模型依赖警报。

标准误应尊重数据生成层次 班级内学生共享教师、同伴和处理实施，观测不独立。即使处理在学生层分配，结果误差也可能聚类；若处理在学校层随机，独立信息单位更接近学校数量。把几千名学生当独立可大幅低估标准误。重复测量、匹配组、网络和多阶段抽样都有类似问题。标准误、bootstrap 和交叉验证划分必须保持依赖单元。例如同一患者的多次记录不能随机分到训练与验证

折，否则泄漏个体背景并夸大泛化。小簇数量时，普通簇稳健标准误可能仍偏小，需要小样本修正、随机化推断或适合层级的模型。异方差稳健方差的小样本修正与聚类稳健推断的适用条件分别见MacKinnon, White (1985)和Cameron, Miller (2015)。设计信息不是采集完后可丢弃的元数据，而是推断分布的一部分。

从估计结果到决策 效应估计需与基线风险、成本和损害结合。风险比 0.8 在基线风险 50% 时对应 10 个百分点绝对下降，在基线风险 1% 时只对应 0.2 个百分点。政策资源有限时，绝对效应通常比相对效应更接近效用，但不同群体的成本和价值仍需显式权衡。决策还应考虑估计不确定性和不可逆性。一个平均收益略正但潜在严重损害不确定的政策，与可随时撤回的小成本试点，所需证据阈值不同。因果估计提供后果分布的一部分，决策理论加入效用、风险偏好和学习价值。

7.2 从设计到可复核估计

7.2.1 设计原则与正交估计

观察研究中最最重要的工作往往发生在查看结局模型之前。研究者要定义资格、时间零点、处理策略和随访，检查处理组与对照组是否在同一支持区域，并决定哪些变量依据因果结构进入设计。若等看到结果后才调整纳入标准和协变量，模型选择会与期望结论纠缠。

目标试验模拟提供一套组织方式：写出理想随机试验的资格、分配策略、随访、结局、因果对比和分析计划，再说明观察数据如何逐项对应。它不能凭名称消除混杂，但能暴露常见错位。比如新

使用者设计避免把已耐受药物的长期使用者与初始未使用者比较；主动对照使就医倾向与适应证更接近；克隆—删失—加权可以比较动态策略，却要求正确处理人工删失和重复单位。

设计阶段的平衡不是最终识别证明。倾向得分匹配后协变量均值接近，只说明已测变量在选定指标上平衡；未测混杂、非线性分布差异和处理版本仍需论证。反过来，极端不平衡是明确警报：目标总体包含数据无法支持的比较，应限制总体、收集新数据或承认外推。

双重稳健与正交化的真实含义 双重稳健估计结合结果模型 $\mu_a(X)$ 与倾向得分 $e(X)$ 。其一致性通常要求两类模型至少一类正确，而不是任意两个错误会相互抵消。有限样本中，倾向得分接近 0 或 1 会放大残差项；结果模型在稀疏区域外推也会不稳定。所谓“双重保险”不能替代重叠诊断和合理变量定义。正交得分进一步使目标估计对干扰函数的小扰动一阶不敏感。交叉拟合把样本分成若干折，在其他折训练干扰函数，再在留出折计算得分，从而减少复杂学习器对同一噪声过拟合。它允许使用随机森林、提升树或神经网络估计条件均值，但仍要求适当收敛率、独立同分布或相应抽样条件，以及原始识别假设。实际报告不应只写“使用 DML”。应说明得分函数、折数、重复分割、学习器候选、调参准则、截尾规则和标准误计算；比较不同学习器组合与简单参数模型；检查预测性能是否集中在有重叠区域。算法灵活性是估计工具，不是因果结构来源。

7.2.2 分层不确定性与可复核分析

抽样区间只覆盖在目标、识别与模型条件成立时的重复抽样波动。因果研究还存在至少四层不确定性：目标层的不确定性来

自处理版本和结局定义；结构层来自 DAG、未测混杂与选择机制；估计层来自函数形式、调参与有限样本；迁移层来自目标人群和实施环境变化。把它们压成一个标准误会制造虚假精确。分层报告可以采用组合方式。主结果给出抽样区间；替代合理调整集和估计器显示建模敏感性；E-value、偏差函数或负对照分析约束未测混杂；权重分布和有效样本量展示重叠；不同人群标准化检验迁移；对处理与结局重新定义展示目标敏感性。各分析应对应明确风险，避免把几十个任意模型称作“稳健性检查”。

决策还需要把不确定性映射到损失。若错过有效治疗与采用有害治疗的代价不同，置信区间跨零并不是唯一标准。可报告达到临床重要阈值的兼容范围、最坏情景净收益和信息价值。统计不确定性由此与行动责任连接，而不是以显著性结束。

从结果表到可复核分析 可复核报告需要让他人重建从原始问题到最终数字的路径。数据部分说明来源、纳入流程、时间范围、缺失和测量版本；设计部分给出目标试验或 DAG、调整理由与支持区域；估计部分给出公式、软件版本、随机种子和诊断；结果部分同时展示绝对与相对尺度、异质性和敏感性；讨论部分区分数据支持与模型承诺。表格应服务推理，而非堆满系数。基线表用于描述总体与重叠，不以显著性检验选择协变量；权重表报告分位数、截尾和有效样本量；主结果表明确分母、时间窗和效应尺度；敏感性表说明每个情景改变了哪项假设。图形可展示协变量平衡、倾向得分分布、累计风险和异质性校准。复现还包括失败记录。预先声明哪些诊断会使分析停止或改变目标，例如有效样本量过低、关键层无对照、负对照显示强偏差。若只有成功结果被保存，代码可运行也不等于研究过程可审查。把失败条件写进分析计划，是防止结果导向调整的重要部分。

7.3 复杂数据结构与可靠实现

7.3.1 删失、竞争事件与相关数据

随访数据中的“没有结局”可能表示尚未发生、失访、死亡、退出研究或记录中断。这些状态对应不同目标。若删失概率取决于既往处理和预后，完整案例分析会选择一群更健康或更依从者。逆概率删失加权在给定历史可交换与正值条件下重建未删失总体，但极端权重同样暴露支持缺口。竞争事件不能一概当删失。研究癌症复发时，死亡使未来复发不再可能；把死亡者删失并假定其仍有潜在复发时间，回答的是一个额外构造的净风险问题。累计发生风险把死亡保留为竞争结局，回答现实世界中的复发概率；复合结局又把死亡与复发按某种规则合并。选择必须服务临床问题，而不是由软件默认决定。

失访敏感性分析可以设定失访者相对已观察者的结局偏移、使用界限或模式混合模型。关键是把无法由数据识别的部分单独参数化。报告失访比例不够，还应展示失访与处理、预后和时间的关系，以及结论需要何种未观察结局分布才会改变。

聚类、网络与相关数据的标准误 个体记录并不保证独立抽样。学生嵌套学校，患者嵌套医院，居民处于社区和网络；处理也可能在集群层分配。若忽略相关性，点估计有时仍针对同一均值，标准误却通常过小。随机化推断和方差估计应尊重实际分配单位，而不是数据表的最细行。集群数量少时，常规聚类稳健标准误表现不佳，需要小样本修正、随机化检验或按集群分析。多层模型可以借力估计异质性，但其收缩和分布假设应与因果目标区分。处理在医院层、结局在患者层时，真正有效样本量更接近医院数，而非患者

总数。网络干扰进一步使一个人的处理进入他人结果。标准误问题与目标问题同时改变：需定义曝光映射、网络邻域和策略分配。若网络本身由处理影响，固定网络假设也会失败。设计阶段采用集群或两阶段随机化，通常比事后用复杂相关结构补救更可靠。

7.3.2 完整估计实例与数值稳定性

设目标是某慢病患者在确诊后立即进入强化管理，相对于常规管理，对一年住院风险的差。资格要求连续参保一年且确诊日未住院；处理按确诊后七日内是否进入计划定义；结局为一年内首次住院，死亡作为竞争事件另报。基线共同原因包括年龄、既往住院、合并症、医疗利用和地区资源。先用 DAG 说明这些变量阻断计划选择与住院的后门路径，再检查两组倾向得分分布。若极高风险患者全部进入计划，应把目标限制到有比较的患者，而非依赖模型外推。可使用交叉拟合 AIPW 估计风险差，同时报告结果回归与加权估计；权重截尾应作为敏感性而非隐藏步骤。诊断包括标准化差异、有效样本量、权重分位数、各医院支持和负对照结局。失访由删失权重处理，并对失访者风险偏移做敏感性分析。最后将结果按地区资源分层，检查从研究医院迁移到基层机构所需的实施稳定性。这个例子显示估计器只是整条链中的一环。

数值稳定性与软件正确性 正确公式也可能被数值实现破坏。极端权重造成少数单位主导估计，完全分离使倾向模型发散，高维矩阵病态使标准误不稳定，重复交叉拟合产生分割波动。应记录收敛警告、权重最大值、有效样本量和不同随机种子的结果，而不是只保留最终表格。软件验证可从小型已知答案开始。构造一个有限总体或模拟 SCM，手算目标和识别表达式，再检查代码；对权重为 1、无缺失、随机处理等特殊情形建立单元测试；比较两个

独立实现；确保数据排序、连接和时间窗口没有泄漏。很多“高级方法失败”实际来自单位重复、时间错位或变量编码。可复现环境应固定依赖版本并保存中间审计摘要，但不必把所有缓存留在项目中。权威源码、配置、数据谱系和最终成品应与可再生成的构建目录分离。清洁目录与严格分析并不冲突，前提是构建命令能够从零恢复全部检查。

7.3.3 完整估计案例：从粗比较到目标总体

设某慢性病管理项目的处理 A 为是否在确诊后七日内进入强化管理，结局 Y 为一年内住院，基线病情 L 简化为低风险和高风险两层。目标总体两层各占一半，但医生更常把高风险患者纳入项目。数据中的条件风险如下：

基线层	目标占比	$P(A = 1 L)$	$P(Y = 1 A = 1, L)$	$P(Y = 1 A = 0, L)$
低风险	0.50	0.20	0.10	0.20
高风险	0.50	0.80	0.30	0.50

在给定 L 后可交换、处理一致且两层都有正值性的假设下，标准化风险为

$$EY(1) = 0.5 \times 0.10 + 0.5 \times 0.30 = 0.20,$$

$$EY(0) = 0.5 \times 0.20 + 0.5 \times 0.50 = 0.35,$$

因而 ATE 为 -0.15 ，即一年住院风险平均下降 15 个百分点。低风险层的效应为 -0.10 ，高风险层为 -0.20 ，所以处理分配同时与基线风险和效应异质性有关。

直接比较处理组和对照组却会得到完全不同的印象。由于两个风险层在目标中各占一半，处理组中 80% 为高风险，对照组中只有 20% 为高风险。于是

$$E(Y | A = 1) = 0.2 \times 0.10 + 0.8 \times 0.30 = 0.26,$$

$$E(Y | A = 0) = 0.8 \times 0.20 + 0.2 \times 0.50 = 0.26.$$

粗风险差为零，虽然每个风险层内项目都降低住院。这个计算不只展示“混杂可造成偏差”，还说明估计器必须把两组重新带回同一目标总体。


完整算例：AIPW 的填充与校正

对处理水平 $a = 1$ ，AIPW 在每个单位上构造

$$\widehat{m}_1(L_i) + \frac{A_i}{\widehat{e}(L_i)} \{Y_i - \widehat{m}_1(L_i)\}.$$

第一项为所有人填入“如果进入强化管理”的条件风险；第二项只在实际处理者中出现，用逆处理概率放大残差，校正结果模型的系统误差。对 $a = 0$ 做同样计算并相减，才得到 ATE。若结果模型正确，残差在条件下平均为零；若倾向模型正确，加权残差会修正错误的填充。但如果高风险层从未有对照，任何一项都需外推，“双重稳健”不会创造缺失的比较。

一项完整分析应保留下列次序，而不是从“选什么算法”开始：



把诊断改写为分析决策 诊断的价值在于它会改变分析，而不是为附录增加一张图。若倾向得分两组几乎不重叠，预先规定的动作应是收缩目标人群、收集新对照或改用部分识别，不是不断更换分类器。若加权后平衡仍差，应修订处理模型或不再使用该权重。若负对照结果显示强关联，应将未测混杂纳入主结论的不确定性，而不是把它降格为“补充分析”。

同样，估计器之间的差异需要触发解释。在相同目标下， g 计算、IPW 与 AIPW 若结果接近，只表示对这些建模选择不敏感；若差异很大，需检查外推、极端权重和函数形式。不能从三个结果中选一个最显著的作为“主模型”。

失败诊断：有效样本量与原始行数混为一谈

假设原始数据有 5000 人，但少数未处理的高风险患者获得很大权重，使 n_{eff} 只有 450。报告“样本量 5000”会让读者误以为每个反事实区域都有充足信息。应同时给出原始行数、独立分配单位数、权重后有效样本量和每个关键层的实际对照数。若信息单位是医院而不是患者，还应把医院数放在推断首位。

从单一区间到分层不确定性 对上述住院案例，主表可报告 ATE 的抽样区间，但还应有三类另行结果。第一类是目标敏感性：把“七日内进入”改为“十四日内进入”，结局和处理含义如何改变。

第二类是结构敏感性：未测病情需要多强才会将风险差推回零。第三类是迁移敏感性：项目从大型医院进入基层机构时，依从、容量和对照治疗是否保持。这些问题不宜被合成一个更宽的置信区间，因为它们来自不同证成来源。

7.3.4 有限样本推断：随机性来自哪一层

标准误不是估计器名称的固定配件。它要描述的是，在什么重复过程中，当前估计会如何变动。随机试验中可以把处理分配当作随机性来源；从超总体抽样时可把单位抽样当作来源；固定区县的全部医院数据则未必有一个明确的医院超总体。同一个数字在不同重复概念下可以有不同方差。

数据生成结构	不可拆分的信息单位	推断与重抽样原则
个人随机试验	单个受试者，但要保留分层分配	按随机化设计或预先指定的稳健方差
整群随机试验	被随机化的学校、医院或社区	在群层重排处理，方差反映群数
重复测量	同一人的完整时间轨迹	按人划分训练折和 bootstrap，不拆行
匹配或带放回对照	匹配组与被重复使用的单位	保留匹配及权重依赖，不当作独立两组
空间或网络数据	由溢出与同一冲击连接的单位	由设计定义暴露和分配，不只换用稳健标准误

例如一项学校级干预有 30 所学校、每校 200 名学生。若处理在学校层随机分配，6000 行记录不能提供 6000 次独立处理比较。学校内教师、同伴和实施使结局相关；自由度与有效信息更接近 30 个群。普通个人级 bootstrap 会在每所学校内抽出大量看似新的独立单位，系统性低估方差。

小样本中稳健方差也会失效 “使用群稳健标准误”只是开始。群数很少、群规模差异很大或处理群比例失衡时，常用大样本近似仍可能给出过窄区间。可根据设计使用群层随机化检验，使用小样本自由度修正，或者在有限数量匹配群内做精确重排。如果只有两个处理医院和两个对照医院，无论患者数多少，对普遍医院效应的统计推断都很脆弱。

随机化推断也不会自动解决处理后失访、不依从和干扰。它使用已知分配机制评估特定零假设；当结局只在选择后的人中观测，接受的处理版本因人而异，或一人的分配影响他人时，目标和估计方法都要重新定义。

多次交叉拟合与分割不确定性 在样本不大时，一次随机分拆可使某些稀少层几乎只落在一个训练集或评价集，导致 DML 与 AIPW 结果随随机种子明显变化。可重复若干次按处理与关键层分层的交叉拟合，报告各次点估计、标准误与最终汇总规则。重复分割不是为了在许多结果中选一个最有利数字，而是暴露训练样本选择对有限样本结果的影响。

需要注意，把多次分割的点估计标准差直接当作总标准误也不正确。每次估计仍共享同一原始样本，分割变动只是算法不稳定的一部分。最终区间应基于目标估计的影响函数或相应理论，并将分割范围作为附加诊断报告。

失败诊断：随机拆行制造了虚假外样本

电子健康记录中同一患者有多次就诊，若按行随机分到训练折和验证折，模型可以通过诊断组合、时间模式甚至隐式标识识别同一人。验证折不再表示新患者。更严重的是，后期就诊包含早期处理及结局的后果，会把处理后信息泄漏到基线预测。分

折必须在因果单位与时间零点上完成，并在多中心数据中考虑是按患者、机构还是未来时段检验外推。

本章小结

识别之后仍可用多种估计器。 g 计算建模结果，匹配强调设计，IPW 建模处理赋值，AIPW 与 TMLE 结合二者，DML 以正交得分和交叉拟合容纳高维学习。任何方法都必须与目标量、重叠和研究设计配套；置信区间只覆盖部分不确定性，诊断和敏感性分析不可省略。

自测与研讨

1. 为什么处理模型的分类准确率不是倾向得分质量的主要标准？
2. 解释 AIPW 的两部分分别承担什么功能，“双重稳健”不保证什么？
3. 交叉拟合与 Neyman 正交性分别解决哪类机器学习偏差？
4. 为一项观察研究设计包含重叠、平衡和敏感性分析的报告清单。

延伸阅读

倾向得分的经典论文是 Rosenbaum, Rubin (1983)，应用诊断可读 Austin (2011)，匹配估计理论见 Abadie, Imbens (2006)。双重稳健的经典说明见 Bang, Robins (2005)；潜在结果估计的系统处理见 Imbens, Rubin (2015)；观察性纵向方法见 Hernán, Robins (2020)；TMLE 见 van der Laan, Rose (2011)；DML 的正式框架见 Chernozhukov et al. (2018)。随机试验中的回归调整

见Lin (2013), 有限样本和聚类方差问题可结合MacKinnon, White (1985)与Cameron, Miller (2015)阅读。

匹配与分层的历史基础可由Cochran (1968)和Rubin (1973)追溯, 现代方法综述见Stuart (2010); 平衡诊断不应被倾向得分模型的预测精度替代, 具体比较见Austin (2009)。估计倾向得分的效率结果见Hirano et al. (2003), 直接以平衡为目标的加权和估计可对照Li et al. (2018)与Imai, Ratkovic (2014)。

缺失协变量下的影响函数与加权基础见Robins et al. (1994), TMLE 的原始学习框架见van der Laan, Rubin (2006)。重叠不足时应改变目标或样本而非依赖外推, 见Crump et al. (2009); 小样本稳健标准误的有限样本问题见Imbens, Kolesár (2016)。未测混杂敏感性可分别从非参数界限(Ding, VanderWeele, 2016)与回归遗漏变量解释(Cinelli, Hazlett, 2020)进入。

第三部分

发现、迁移、机器学习与应用

因果发现与结构学习

学习目标

读完本章，你应当能够：理解约束、评分、函数模型、连续优化和多环境方法的识别来源；区分 Markov 等价、算法稳定性与因果正确性；设计包含隐藏混杂、反馈和测量误差的压力测试。

8.1 因果发现：从条件独立到结构搜索

8.1.1 发现目标、约束方法与评分搜索

因果发现试图利用分布、时间、干预或环境变化信息，约束变量间可能的因果结构。它不意味着在无假设情况下让算法读取“真正箭头”。不同方法的识别力来自不同假设：因果 Markov 条件、忠实性、无隐藏混杂、无环性、噪声独立、函数形式、时间先后或干预目标已知。结构发现与效应识别是两项任务。前者询问哪些图与数据和假设相容；后者在给定结构后询问某个 $P(Y \mid \text{do}(X = x))$ 是否可计算。一个算法可以恢复大部分骨架却在关键混杂边上犯

错，导致效应严重偏差；也可能图未完全定向，但某个具体效应在整个等价类中都可识别。

基于约束的方法 **PC 算法**从完全无向图开始，反复检验变量在不同条件集下是否独立；若 $X \perp\!\!\!\perp Y \mid S$ ，就删除边并记录分离集。得到骨架后，算法识别无屏蔽碰撞点：若 X 与 Y 不相邻、二者都邻接 Z ，且 Z 不在相应分离集中，则定向为 $X \rightarrow Z \leftarrow Y$ 。随后应用 Meek 规则，在不制造新碰撞点或有向环的条件下传播方向(Spirtes et al., 2000)。

PC 输出通常是 **CPDAG**，表示一组 Markov 等价 DAG。箭头表示在等价类中方向一致，未定向边表示观测条件独立不足以判断。把 CPDAG 中每条无向边任意定向再作为确定科学发现，是对算法输出的过度解释。PC 依赖因果充分性，即相关外生扰动独立、没有未建模共同原因。**FCI 算法**允许隐藏混杂和选择偏差，输出 **PAG**表示潜在祖先图的等价类。PAG 端点中的箭头、尾和圆圈表达不同确定程度；信息更诚实，但解释也更复杂。条件独立检验是约束方法的瓶颈。线性高斯情形可用偏相关，非线性关系需要核、距离或其他检验。条件集增大时样本需求迅速上升；显著性水平影响边的删留；相近于不忠实的微弱依赖会使方向不稳定。稳定性选择和多次重采样有助于展示而非隐藏这种不确定性。

基于评分的方法 评分方法为候选图计算拟合与复杂度权衡，如 BIC 或贝叶斯边缘似然，再搜索高分结构。**GES**在等价类空间中先贪婪加边、再贪婪删边；在大样本和适当假设下具有一致性(Chickering, 2002)。评分搜索把独立性信息综合进全局目标，常比逐项检验稳定，却仍面临超指数图空间、局部最优和评分假设错误。贝叶斯结构学习能给出图后验分布，但后验可信度取决

于先验、似然模型和候选空间；它不是从数据中得到的无条件“因果概率”。领域约束可以减少搜索空间：禁止未来指向过去，要求随机化处理没有父节点，或指定已知不可能边。约束应在分析前说明，不能在看到不喜欢的结果后临时加入。

8.1.2 函数限制、连续优化与时间结构

若数据生成满足

$$Y = f(X) + N_Y, \quad N_Y \perp\!\!\!\perp X,$$

而反向通常无法表示为 $X = g(Y) + N_X$ 且 $N_X \perp\!\!\!\perp Y$ ，**加性噪声模型**可超越 Markov 等价识别方向(Hoyer et al., 2009)。识别力来自“机制函数与噪声独立”这一非对称限制。

LiNGAM在线性、无环、无隐藏混杂且噪声非高斯时，利用独立成分分析识别完整方向(Shimizu et al., 2006)。高斯线性模型缺少这种高阶分布非对称，通常只能恢复等价类。若真实存在反馈、测量误差或隐藏混杂，LiNGAM 的定向保证不再成立。

函数模型提示一个重要原则：数据能够定向，是因为模型排除了反向生成机制，而不是因为相关性本身带方向。使用前应论证独立噪声或函数形式为何适合领域；不能先运行多种模型，再只报告最符合直觉的方向。

连续优化与 NOTEARS 传统 DAG 搜索的无环约束是组合性的。NOTEARS 把邻接权重矩阵 W 的无环性写成光滑等式

$$h(W) = \text{tr}\{\exp(W \circ W)\} - d = 0,$$

从而把线性结构学习转化为带约束的连续优化(Zheng et al., 2018)。其原始论文由 Zheng、Aragam、Ravikumar 与 Xing 发表于 NeurIPS 2018，而不是“Zhang 等 2019”。

NOTEARS 的重要贡献是计算重参数化，不是取消因果假设。原始线性版本仍依赖线性 SEM、独立噪声、无环和通常的因果充分性。后续工作扩展到非线性、非参数和带先验结构，但可优化性不等于可识别性。算法找到唯一数值解，也可能只是正则化在统计等价结构中选出一个代表。梯度型 DAG 学习还面临阈值选择、局部最优和规模问题。评估应区分权重预测、骨架恢复、方向恢复和下游效应估计，不能只报告一个结构 Hamming 距离。

时间序列与 PCMCI 时间顺序提供方向约束：未来通常不能成为过去的原因。但自相关、共同趋势、滞后选择和同时作用使简单 Granger 预测关系不等于因果。若 X 的过去提高对 Y 的预测，只能说明相对于已纳入历史的信息， X 有增量预测价值。PCMCI 先用基于条件独立的筛选寻找每个变量的候选过去父节点，再对候选关系进行条件独立检验，适合高维多变量时间序列(Runge et al., 2019)。其因果解释依赖因果 Markov、忠实性、充分滞后、平稳性或相应扩展，以及对同时混杂的处理。采样频率决定可见结构。若真实过程在两次测量之间完成，观测上可能表现为同时关系或错误滞后；聚合会制造或掩盖依赖。因果时间序列分析必须把物理时间尺度、测量过程和模型滞后共同设计。

8.1.3 环境变化、评估规范与贯穿案例

观察数据常只能恢复等价类；主动干预可以打破等价。例如对 X 随机干预后，指向 X 的边被切断，比较干预与观测分布可以区分 $X \rightarrow Y$ 和 $X \leftarrow Y$ 。在实验成本受限时，主动因果发现选择最

有信息的干预目标。多环境数据也提供结构信息。若环境改变某些机制而其他条件分布保持不变，可利用**不变因果预测**寻找在各环境中稳定预测结果的父变量集合(Peters et al., 2016)。但环境变化必须与所声称的机制改变相配；域标签不是天然工具变量。

评估与报告规范 模拟数据知道真图，适合检验方法在明确假设下的统计与计算表现，但模拟机制若偏向某算法，会高估其优势。真实数据没有完整真图，可使用已知干预靶点、专家确认边、跨环境预测和下游实验作为部分基准。

最低报告标准包括：

- 变量与时间窗口的选择依据；
- 算法所需的全部因果与统计假设；
- 条件独立检验、评分、阈值和超参数；
- 等价类而非被任意完全定向的单图；
- 重采样下边和方向的稳定性；
- 与替代算法、领域先验和干预证据的比较；
- 对隐藏混杂、测量误差和选择过程的敏感性。

发现算法最适合作为“受约束的假设生成器”：压缩候选结构、指出最有价值的新实验，并记录不确定性。把输出箭头当作无需验证的结论，会把形式工具从科学辅助变成权威幻觉。

贯穿案例：基因调控网络 研究者测量一批细胞中转录因子 T 、两个靶基因 G_1, G_2 和炎症状态 I 。观测到四者相关。PC 算法可能利用 $G_1 \perp\!\!\!\perp G_2 \mid T$ 支持 $G_1 \leftarrow T \rightarrow G_2$ ；若给定 I 后独立关系改变，又提示炎症是共同调节或选择背景。但单细胞数据有掉零、批次效应和细胞周期混杂。把测量缺失当真实零会制造非线性依赖；只选择某标记阳性细胞可能条件化碰撞点；不同细胞不是同一动态轨迹

的时间点。算法输出前，变量测量和采样图已经决定可解释范围。若使用 CRISPR 敲低 T ，观察 G_1, G_2 随之变化，方向证据增强。但敲低有脱靶效应且可能触发应激，干预节点应包括实际分子操作，而不只是理想 $\text{do}(T)$ 。多个独立向导、救援实验和剂量响应有助于区分直接调控与操作副作用。时间数据可显示 T 变化先于靶基因，却仍可能由更快的未测信号共同驱动。染色质结合证据提供机制位置，但结合不保证功能影响。可靠网络来自条件独立、时间、干预和机制证据的组合，不来自单一热图。

8.1.4 稳定性、隐藏结构与比较对象

对数据重复抽样并运行发现算法，可计算每条边出现频率和方向频率。若 $X - Y$ 在 95% 样本出现但方向各半，说明骨架稳定、方向不确定；若边只出现 52%，不应在最终图中画成确定粗箭头。稳定错误仍可能发生。若所有样本都受同一未测批次混杂，算法会稳定恢复一条伪边；若模型假设系统错，重采样不会暴露。因此稳定性回答“对抽样扰动敏感吗”，不回答“因果假设正确吗”。应与替代检验、算法、变量集和实验验证结合。阈值也应透明。把频率大于 0.7 的边保留只是决策规则，0.69 与 0.71 没有本体差异。可直接显示频率、等价端点与候选图，而不是用阈值制造确定外观。

隐藏混杂、反馈与测量误差的压力测试 应用前可模拟三类偏离：加入影响两个节点的隐藏变量；让某对变量在时间上互相作用；给关键变量加入不同强度测量误差。观察算法何时错误定向、何时删掉真边、何时输出不稳定。压力测试参数应由领域上合理范围决定。若结论只在零测量误差、无反馈和完全充分变量下成立，应在摘要中限制主张。若一个下游效应在多幅受扰图中仍由同一调整集识别，这个局部结论可能比完整网络恢复更稳健。发现研究

的价值有时不是得到最终真图，而是发现“现有数据无法区分隐藏混杂与直接作用”，从而设计测量或干预。把不确定性转化为实验优先级，是比强制定向更成熟的产出。

算法比较应比较同一对象 结构 Hamming 距离混合漏边、加边和反向；SID 衡量图错误对干预分布的影响；下游 ATE 误差又只关注特定查询。一个算法骨架更接近真图，但关键处理—结果边方向错误，可能有较差因果决策。评估指标应与用途一致。比较还需统一变量、预处理、先验约束和超参数预算。给一种算法提供时间顺序而不给另一种，结果反映信息差异而非纯算法优劣。真实基准中“专家真图”也有不确定，应把已实验确认边与推测边分级。

8.2 发现分析的完整 workflow

8.2.1 方向信息来自哪些假设

仅凭一个观测分布，许多 DAG 属于同一 Markov 等价类。发现算法之所以能输出更多方向，是因为加入了额外假设。PC 和 FCI 依赖因果 Markov、忠实性与可靠的条件独立检验；GES 依赖评分一致性和搜索空间；LiNGAM 使用线性、无环与非高斯噪声；加性噪声模型要求结果由原因的函数加独立噪声生成；多环境方法要求某些机制在环境变化下保持不变。这些假设不是算法说明书中的技术脚注，而是识别信息的来源。数据量增大只能让算法更准确地利用假设，不能让错误假设自动消失。若真实系统存在近似抵消，忠实性可能失败；若选择机制改变样本，观察到的独立性未必对应总体图；若存在反馈，把数据强行投影为 DAG 会得到时间聚合后的替代结构。因此每个方向都应附带“来源标签”：由

时间先验确定、由干预环境确定、由非高斯性确定、由独立检验确定，还是只由评分偏好选择。来源标签让领域专家可以分别质疑，而不是面对一张看似同等确定的有向图。

从数据表到候选结构及其评价 发现分析首先要定义变量和时间。重复测量应区分同时关系、滞后关系与汇总指标；测量误差大或由共同设备产生时，要考虑测量节点；抽样和缺失若依赖变量，也应进入选择模型。随后声明允许的边、禁止的边和背景顺序，例如出生日期不能由成年收入造成，但记录中的“首次诊断日期”未必等于疾病起始。第二步是运行多种与假设相匹配的方法，而非把所有算法放进排行榜。约束方法提供等价类和分离集，评分方法展示另一种搜索偏好，函数模型在适用时提供额外方向。超参数如显著性阈值、惩罚强度和最大父节点数应进行稳定性分析。输出应包括 CPDAG 或 PAG、不确定边和跨重采样出现频率，而非只给一张完全有向图。

第三步是领域审查与干预设计。对关键边列出可能机制、替代方向、隐藏共同原因和可执行实验。若候选图预测 X 与 Y 在给定 Z 后独立，可在新数据中检验；若两个等价结构只能由干预区分，应选择信息增益高且伦理可行的干预。发现的终点不是发表一张网络，而是缩小下一轮实验与测量的空间。

评价对象必须与算法输出一致 模拟研究常用结构 Hamming 距离比较估计 DAG 与真 DAG，但若观测数据只能识别 CPDAG，用任意真 DAG 的方向惩罚算法并不公平。存在隐藏混杂时，PAG 中的圆圈和双向边表达的是不确定祖先关系；把它强制转成 DAG 再计算准确率，会掩盖算法正确保留的不确定性。评价至少分三层。图形层检查骨架、箭头端点和祖先关系；查询层检查算法导出的调

整集、可识别效应或干预预测是否正确；决策层检查根据图选择的实验或政策会造成什么损失。一个图在边级别有若干错误，仍可能正确识别特定效应；另一张边数漂亮的图，若错在关键混杂路径上，决策后果更严重。真实数据没有完整真图时，可使用已知干预、跨环境预测、保留样本条件独立、机制数据库和专家盲评。但这些也只是部分基准。报告应说明基准本身覆盖哪些边、是否与训练信息独立，以及算法有没有利用同源知识造成信息泄漏。

8.2.2 动态边界与发现到识别的衔接

无环性可以通过展开时间恢复： $X_t \rightarrow Y_{t+1} \rightarrow X_{t+2}$ 在时间展开图中无环，却在把时间聚合后表现为 X 与 Y 反馈。时间序列发现需要指定最大滞后、采样频率和同时效应解释。采样间隔过长会把多个过程压成同一时点，过短则使真实作用分散到许多滞后并降低检验功效。反馈系统还可能含有稳定控制。恒温器使温度与加热功率呈负相关，虽然加热提高温度；市场价格与供需相互调整，静态相关难以给出结构方向。此时结构应包括控制规则、外部扰动与时间动态，或使用循环结构模型。把反馈数据交给无环算法得到的箭头，只能被解释为某种预测近似。系统边界决定哪些变量被视为外生。医院流程图若省略转诊网络和床位政策，许多“外生噪声”其实来自更大系统；基因网络若只测少量基因，潜在混杂广泛存在。扩展边界会增加复杂性，却可能改变关键边方向。报告应说明边界选择服务什么查询，并对最可能的外部驱动进行压力测试。

发现与识别必须接续而非混同 从数据得到候选图后，不能立刻把某条边的回归系数称为因果效应。发现阶段的不确定性要传递到识别阶段：对等价类中的每张合理图求调整集和效应，检查结论是否方向一致；若部分图不可识别，应报告识别状态的不确定

性；若效应只在排除某条边时稳定，就把该边设为优先实验对象。同样，识别目标可以反过来指导发现。若研究只关心 A 对 Y 的总效应，无须准确恢复所有边；重点是识别可能的共同原因、祖先关系和选择路径。局部结构学习、IDA 等方法利用等价类给出可能效应集合，比宣布一个全局真图更匹配任务。这种接续关系也约束自动化。算法可以生成候选结构、搜索分离集和计算识别式，但变量语义、干预版本、制度背景与使用后果仍需领域判断。最可靠的工作流是“算法缩小空间—专家审查结构—新设计区分候选—识别与估计目标”，而不是一次运行结束因果研究。

8.3 算法推演与报告规范

8.3.1 约束方法与评分搜索的最小推演

考虑三变量 X, Z, Y 。若数据表明 X 与 Y 相关，但给定 Z 后独立，候选骨架通常是 $X - Z - Y$ ，且 Z 不是碰撞点；可能方向包括 $X \rightarrow Z \rightarrow Y$ 、 $X \leftarrow Z \rightarrow Y$ 或 $X \leftarrow Z \leftarrow Y$ 。仅由这些独立性不能选择其一。若另有时间知识 X 先于 Z 先于 Y ，才能定向为链。若 X 与 Y 边际独立、给定 Z 后相关，则 $X \rightarrow Z \leftarrow Y$ 的碰撞结构得到支持。PC 算法正是通过不同条件集寻找分离关系，再按碰撞点和传播规则定向。有限样本中，独立检验错误会级联：一条误删边改变分离集，继而改变多个箭头方向。因此显著性阈值不是普通调参。阈值较严会保留更多边，较松会误删弱边；高维条件集又降低功效。报告应展示阈值路径、最大条件集大小和稳定边，并将弱边标为待验证，而非用单一 p 值制造确定图。

评分搜索为何需要复杂度惩罚 评分方法在候选图中平衡拟合与复杂度。若只最大化似然，增加父节点通常不会降低样本内拟合，最终得到近乎完全图；BIC 等评分用参数数量惩罚过度复杂。得分等价性保证同一 Markov 等价类中的图得到相同分数，使搜索目标与观测可识别对象一致。搜索空间随变量数超指数增长，GES 等算法通过前向加边和后向删边在等价类空间中贪心移动。贪心不保证有限样本全局最优，背景约束和初始化会影响结果。连续优化方法把无环约束写成矩阵函数并使用梯度算法，却没有消除统计假设；阈值化、局部极值和尺度选择仍需检查。比较评分时应保持数据似然、缺失处理和变量类型一致。高斯线性评分不适合任意离散或强非线性数据。更高分只表示在指定模型族和惩罚下更优，不是对真实因果方向的直接概率。

8.3.2 多环境不变性与最低报告规范

若多个环境改变了某些上游分布，但结果机制 $P(Y | \text{pa}_Y)$ 保持，真正父节点集合可能使条件关系跨环境不变。环境可以来自实验、政策、地点或时间。与单一观测分布相比，变化提供了方向信息：原因分布改变而机制保持，结果随之变化；把结果当原因往往无法保持同一条件机制。不变性必须与环境生成方式结合。环境若直接改变 Y 机制，简单不变假设失败；若所有环境变化太弱或只改变无关变量，也没有识别力。选择环境、记录哪些模块可能变化，与选择协变量同样重要。环境标签本身还可能代理未测混杂，需要进入图中审查。实际分析可寻找在各环境中预测残差分布稳定的变量集合，再用留一环境验证。但预测稳定不是充分因果证明：多个父节点组合可能同时稳定，选择机制也可能制造伪不变。最有力的情形是环境来自已知干预，并与机制知识共同限定改变位置。


发现研究的最低报告规范 报告首先给出数据生成背景、变量字典、时间粒度、样本选择和缺失处理；其次列出算法假设、背景约束、超参数范围与独立检验；再次展示等价类、不确定端点和稳定性，而非只展示最终美化网络。关键边应有来源、机制解释和替代结构。评价部分区分模拟真图、部分领域真值、干预验证与保留环境预测。若使用合成数据，生成机制应覆盖非线性、弱边、潜变量、选择和测量误差，而非只匹配算法自身假设。若使用真实数据，明确哪些“真边”来自同一数据库，防止循环验证。最后说明图将如何被使用。若用于选择调整集，应传播图不确定性；若用于提出实验，列出最能区分候选的干预；若只用于探索，避免使用“恢复真实网络”等强措辞。可复核材料包括代码、随机种子、完整边表和各重采样结果。

8.3.3 完整发现案例：从独立表到新实验

假设工厂想诊断产品缺陷 Y 的生成结构。 A 是原料批次属性， B 是加工温度， C 是反应压力。时间上 A 在加工前确定， B, C 在同一工序中记录， Y 在检测端产生。将稳定性足够高的条件独立结果整理后，得到：

检验结果	对骨架的含义	对方向的含义
B 与 C 不独立	边际关联不足以保留 $B - C$	可能由 A 的叉路径造成
$B \perp\!\!\!\perp C \mid A$	删除 $B - C$ ，分离集为 $\{A\}$	$B - A - C$ 中 A 不是碰撞点
$A \perp\!\!\!\perp Y \mid B, C$	删除 $A - Y$	A 对 Y 的关联可由 B, C 传递
给定 A, Y 后 B 与 C 不独立	给定 Y 打开 $B - Y - C$	支持 $B \rightarrow Y \leftarrow C$

先根据无条件与有条件检验建立骨架，得到 $A - B$ 、 $A - C$ 、 $B - Y$ 、 $C - Y$ 四条边。因为 B, C 不相邻，且其分离集包含 A 而不包含 Y ，PC 规则把 $B - Y - C$ 定向为碰撞结构。再加入原料先于工序的背景顺序，得到候选图：



这个结果的证据强度并不均匀。 A 到 B, C 的方向主要来自时间与工艺知识； B, C 指向 Y 来自碰撞点规则；骨架则来自在特定检验和显著性阈值下的样本判断。最终图应在边表中保存这些来源，而不是将四条箭头渲染成相同确定度。

完整算例：稳定性不等于真实性

对数据做 500 次重抽样，假设 $A - B$ 出现率为 0.96， $A - C$ 为 0.93， $B - Y$ 为 0.88， $C - Y$ 为 0.74； $B \rightarrow Y$ 的方向率为 0.82， $C \rightarrow Y$ 只有 0.58。合格报告会说：原料到两个工艺变量的骨架稳定， $B - Y$ 边较稳定， $C - Y$ 及其方向需新证据。不合格报告会在 0.7 处截断，只画一张没有频率的有向图。更重要的是，若所有批次都受同一个未记录设备老化 U 影响，错误边也可以在 500 次中都很稳定。重抽样检查的是抽样波动，不是潜变量假设。

从候选图到最有价值的干预 发现分析的下一步不是用图中四条回归系数撰写机制故事，而是问哪个可行干预最能区分备选结构。若工艺允许小幅随机改变 B 且保持 C 的设定规则，可检验 Y 分布

是否随之改变。若 B, C 由同一控制器联动，则所执行的不是原子干预 $\text{do}(B = b)$ ；应把控制器设定作为处理，重新定义图与查询。

干预还要考虑信息增益与成本。如果 $C - Y$ 的方向最不稳定，但改变 C 有安全风险，可先利用一次设备维修所形成的已知环境变化，或增加上游压力调节阀的测量。发现输出的价值由此可以用“它使哪个下一步设计更有效”来衡量，而不只是图有多稠密。

从图不确定性到查询不确定性 假设业务真正关心的是改变 B 对 Y 的效应。对重抽样得到的每张候选图，可依次记录：该效应是否可识别，需要什么调整集，估计的方向与范围如何。若大多数候选图都要求调整 A 且效应为正，但少数允许未测 U 的 PAG 中效应不可识别，应报告“在因果充分的 DAG 集合中方向稳定，在允许潜在混杂时识别不稳定”。这比将一张众数图当成真图更准确。

可以把发现报告拆成四个表：边及端点稳定性表，方向信息来源表，候选结构下的识别表，以及建议干预与预期区分能力表。这四个表分别回答“数据稳不稳”、“方向从哪里来”、“对关心的效应有什么影响”和“下一步怎样学得更多”。

失败诊断：数据预处理在图之前已经定向

若工厂只保留通过初检的产品，初检同时受 B 和潜在缺陷影响，则数据集已经条件化了碰撞点。若又将多个时点平均成一个批次值，快反馈会被压成同时关联。任何发现算法看到的都是这个被选择、被聚合的分布。因此预处理日志、排除流程和原始时间粒度是因果发现报告的一部分，不是可省略的数据清洗细节。

8.3.4 算法比较实验：必须先统一问题

对 PC、FCI、GES、LiNGAM 和 NOTEARS 做一张谁的边更准的排行榜，往往没有清楚含义。PC 在因果充分假设下输出 CPDAG，FCI 允许潜在混杂并输出 PAG，LiNGAM 在更强函数与噪声假设下寻求完全 DAG。若强制所有算法交付一张无不确端点的 DAG，保留了正确不确定性的算法反而会被惩罚。

方法	目标对象	额外定向信息	主要压力测试
PC	CPDAG	独立与忠实性	弱边、高维条件集、检验阈值
FCI	PAG	允许潜在混杂的独立约束	选择偏差、样本量、圆圈端点解释
GES	CPDAG	评分一致性与搜索假设	惩罚强度、局部最优、变量类型
LiNGAM	DAG	线性非高斯独立噪声	高斯近似、测量误差、隐藏混杂
NOTEARS	加权 DAG	结构方程、正则化和无环优化	阈值、局部解、模型错设

公平比较要么将真值降为各算法都能识别的共同对象，例如骨架或确定祖先关系；要么分别按 CPDAG、PAG 和 DAG 的语义评估。下游任务也需统一：若目的是估计 A 对 Y 的效应，可比较各输出是否得到有效调整集、效应界限或不可识别警报，而不必要求恢复与查询无关的全部边。

独立检验的误差会沿图传播 在 PC 中，一次错误删边不只影响该边。它会改变后续候选条件集，改变分离集，再通过碰撞点和 Meek 规则改变多个箭头。因此不能把每条边看成一次独立假设检

验。样本量与检验难度还随条件集大小变化：给定变量越多，有效样本越稀疏，非参数检验更难稳定。原始 PC 还会受变量输入顺序影响，稳定化版本把这类算法依赖显式化并部分消除(Colombo, Maathuis, 2014)。

一份分析应展示不同显著性阈值、最大条件集和检验类型下的骨架路径。若一条关键边在高斯线性部分相关检验中消失，却在非线性检验中稳定，差异可能是函数形式而非结构本身。应回到散点、残差与测量过程诊断，不是选择更符合先验的图。

现实基准没有完整真图 在基因网络、气候系统或社会网络中，所谓“真图”常是某个数据库或专家小组得到的部分结构。已知边更容易来自可测、作用强或研究热门的变量；未记录边不等于已证伪。如果算法的背景知识也来自同一数据库，再用该数据库评价会造成信息泄漏。

可将真值分级为直接随机干预支持、多种独立实验支持、时间与机制支持、专家推测和完全未知。报告分别计算各层覆盖与错误，并使用不参与训练的新干预作为最强测试。现实基准的价值是提供部分反驳，不是把一张尚未完整的知识图谱临时定义为自然全图。即使在二变量方向基准中，真值整理、选择偏差与样本量也会限制结论强度(Mooij et al., 2016)。

失败诊断：多算法一致被当成独立复现

PC、GES 和 NOTEARS 若在同一份数据、同一组变量上给出 $X \rightarrow Y$ ，这是对建模偏好的一种稳健性检查，不是三份独立证据。它们共享样本选择、测量误差、漏变量和时间聚合。独立复现至少需要新数据、新环境或新干预，并且验证规则在看到新结果前固定。

本章小结

因果发现利用条件独立、评分、函数噪声非对称、时间或环境变化约束结构。PC/FCI 输出等价类，GES 搜索高分等价类，LiNGAM 与加性噪声模型以函数限制获得额外方向，NOTEARS 解决连续优化表达，PCMCI 处理高维时间依赖。所有方向信息都来自可陈述假设；稳定性、等价类和干预验证应进入报告。

自测与研讨

1. PC 算法为何先恢复骨架，再寻找无屏蔽碰撞点？
2. LiNGAM 比线性高斯模型多用了什么信息，又多承担了什么风险？
3. NOTEARS 解决的是计算问题还是无假设识别问题？解释其无环约束。
4. 为一个时间序列发现结果设计至少三种真实性检查。

延伸阅读

约束方法与 FCI 见 [Spirtes et al. \(2000\)](#)，祖先图上的推理见 [Zhang \(2008\)](#)，顺序稳定化见 [Colombo, Maathuis \(2014\)](#)；GES 见 [Chickering \(2002\)](#)；LiNGAM 与加性噪声模型分别见 [Shimizu et al. \(2006\)](#) 和 [Hoyer et al. \(2009\)](#)；NOTEARS 原始论文是 [Zheng et al. \(2018\)](#)；PCMCI 见 [Runge et al. \(2019\)](#)；多环境不变性见 [Peters et al. \(2016\)](#)。方法全景与实践限制可读 [Glymour et al. \(2019\)](#)，二变量现实基准见 [Mooij et al. \(2016\)](#)。

PC 算法的早期稀疏图恢复方案见 [Spirtes, Glymour \(1991\)](#)，背景知识与定向规则见 [Meek \(1995\)](#)。评分搜索在百万变量场景中

的计算扩展见Ramsey et al. (2017), 高维评分与混合方法的一致性见Nandy et al. (2018), PC 在高维稀疏条件下的理论见Kalisch, Bühlmann (2007)。连续加性噪声模型的正式可识别结果见Peters et al. (2014), 多环境联合因果推断见Mooij et al. (2020)。

综述层面可对照Heinze-Deml et al. (2018)和Vowels et al. (2023); 模拟基准可能因变量尺度泄漏方向的警告见Reisach et al. (2021)。高维加性模型 CAM 见Bühlmann et al. (2014), 干预怎样提供额外方向信息见Eberhardt, Scheines (2007), 干预 Markov 等价类及其贪心学习见Hauser, Bühlmann (2012)。

外部效度、可迁移性与数据融合

学习目标

读完本章，你应当能够：区分样本代表性、效应修饰与形式可迁移性；使用标准化、加权和选择图组织跨总体推断；审查重叠、测量协调、制度变化与系统反馈。

9.1 外部效度、可迁移性与数据融合

9.1.1 目标人群、标准化与变量选择

一项随机试验可以在入组样本中无偏估计治疗效应，却不能仅凭随机化说明结果适用于未入组者。**内部效度**关心样本内处理比较是否有效；**外部效度**关心结论能否适用于其他人群、地点、时间或干预版本。文献中常区分**普遍化**（目标人群包含试验样本）与**迁移**（试验样本和目标人群可能来自不同总体），但术语使用并不

完全统一。更重要的是明确两个域：源域 $S = 1$ 提供何种实验或观测数据，目标域 $S = 0$ 要回答哪个因果目标，它们在哪些机制上不同。平均效应不是处理的固定属性。若治疗效果随年龄、基线风险、医疗资源或依从策略变化，样本构成改变就会改变 ATE。外推因此不是在结果末尾加一句“需要更多研究”，而是一个可以建模的因果问题。

从样本效应到目标人群效应 设试验中处理随机化， $S = 1$ 表示进入试验，目标为整个目标人群中的 $E\{Y(a)\}$ 。若给定基线协变量 L 后，潜在结果与入组状态可交换：

$$Y(a) \perp\!\!\!\perp S \mid L,$$

并且试验与目标人群在相关 L 上都有支持，则

$$E\{Y(a)\} = \sum_l E(Y \mid A = a, S = 1, L = l)P(L = l).$$

右侧用试验估计每个 L 层的处理结果，用目标人群的 L 分布重新标准化。若目标只包含 $S = 0$ 的非试验成员，则权重分布换成 $P(L \mid S = 0)$ 。这与内部效应的混杂调整形式相似，但可交换对象不同：内部效度要求处理组可比，迁移要求源域与目标域在给定效应相关变量后可比。选择概率加权提供等价实现。试验中较少代表目标人群的单位获得较大权重。与处理权重一样，接近零的试验参与概率产生极端权重；若目标人群包含试验从未覆盖的协变量组合，非参数迁移不可识别。

哪些变量需要用于迁移 不是所有预测结果的变量都是效应修饰因子。一个变量可以强烈预测未治疗风险，却不改变绝对处理效

应；也可能在风险比尺度上无修饰、在风险差尺度上有修饰。迁移变量的选择依赖效应尺度与结构。理想集合应阻断选择 S 与潜在结果之间导致效应差异的路径。纳入基线结局预测因子常有稳健性收益，但过度细分会破坏重叠。若一个未测变量同时影响入组和处理反应，单靠已测人口学标准化仍不足。机制知识在这里特别重要。若药物通过某受体发挥作用，而受体分布在两域不同，受体或其可靠代理是迁移关键；若两域只在与效果无关的行政变量上不同，无需为表面代表性调整。样本“看起来像”目标人群不是充分标准。

9.1.2 选择图、多源融合与时间变化

Pearl 与 Bareinboim 用**选择图**在因果图上增加选择节点，标记哪些机制可能跨域变化(Pearl, Bareinboim, 2014)。若 $S_X \rightarrow X$ ，表示 X 的生成机制在源域与目标域不同；没有选择节点指向某变量，则假定其条件机制稳定。

假设源域有 X 的随机试验，目标域只有观测数据，且选择只影响中介前的协变量 Z 。若在适当干预图中

$$Y \perp\!\!\!\perp S \mid Z, \text{do}(X),$$

则 Z 是对迁移 **S-可容许**的：源域中按 Z 分层的实验效应可用目标域 $P(z)$ 加权。

更复杂情形可用 do-calculus 与选择节点推导**迁移公式**。某些目标域机制虽然变化，却能由目标观测数据直接估计；稳定的干预关系则从源实验带入。可迁移性因此不是要求两域完全相同，而是要求差异的位置已知且可由可用数据桥接。

多源数据融合 现实证据可能包括一个小型随机试验、大型电子病历、多个国家调查和机制实验。**数据融合**寻求组合各源的互补信息：试验提供处理赋值的内部效度，观察数据提供目标人群分布、长期结局或稀有亚组。

融合前必须统一：

- 变量定义与测量尺度；
- 时间零点、随访和删失规则；
- 处理版本与依从策略；
- 每个数据源的选择机制；
- 哪些结构方程被假定跨源稳定。

同名变量不保证同一构念。不同医院的“重症”可能由不同编码规则产生；不同国家的教育年限代表不同课程质量。若测量机制跨域变化，直接把变量视为共同节点会把测量差异误作因果异质性。融合也可能降低而非提高可信度。一个内部偏差严重的大数据集会以高精度支配结果；贝叶斯或加权整合若没有明确偏差模型，只是把不相容来源平均。应先写出每个来源为哪个目标提供何种识别信息，再决定组合。

时间迁移与政策改变 从过去迁移到未来不仅是协变量再加权。诊断技术、背景治疗、行为响应和制度规则可能改变因果机制本身。COVID-19 早期治疗效果无法仅按年龄结构加权到后期，因为病毒变体、免疫背景和标准护理同时变化。政策还可能改变系统均衡。小规模补贴试验估计的是部分覆盖时的个体反应，全国推广会改变价格、劳动力供给和社会规范。SUTVA 下的个体效应无法直接迁移到不同政策饱和度。应把覆盖率、网络或市场状态纳入处理定义，或使用结构经济模型与干扰设计。

9.1.3 敏感性、数值标准化与测量协调

迁移假设通常比样本内随机化更难验证。可以进行：

- 比较源域和目标域的协变量支持与参与概率；
- 在源域内部留出子群，检验迁移方法能否恢复已知结果；
- 对未测效应修饰因子的分布和交互强度设定情景；
- 比较多个效应尺度和处理版本；
- 使用目标域中的负对照或短期可观测结局检查机制稳定性；
- 若缺乏重叠，报告目标子人群或部分识别界限。

外部效度不应以“样本是否人口学代表”二元判断。一个非代表性样本在测得关键效应修饰因子并有良好重叠时可以迁移；一个表面代表样本若处理、测量或机制与目标应用不同，仍可能不适用。

数值例子：同一分层效应，不同总体效应 设试验中年轻人占 80%、老年人占 20%；治疗使年轻人风险下降 2 个百分点，使老年人下降 10 个百分点。试验 ATE 为

$$0.8 \times (-0.02) + 0.2 \times (-0.10) = -0.036.$$

目标人群年轻人与老年人各占一半，则在分层效应可迁移时，目标 ATE 为

$$0.5 \times (-0.02) + 0.5 \times (-0.10) = -0.06.$$

试验内部估计没有错，直接搬用 -3.6 个百分点却回答了错误人群。

若年龄只是基线风险预测因子，而风险差在两层相同，重新加权不会改变风险差；在风险比尺度上却可能因基线风险不同出

现另一表现。因此效应修饰和迁移必须指定尺度。一个变量是否“必须调整”不能脱离目标尺度宣布。若目标人群包含试验中完全没有的 90 岁以上人群，公式要求的分层结果不存在。用回归平滑外推不是非参数识别，而是增加关于年龄—效应曲线的模型。报告应把重叠内标准化与重叠外模型外推分开。

测量协调的因果含义 两个数据源都含“血压”，源域使用诊室单次测量，目标域使用家庭一周均值。二者误差结构和对白大衣效应的敏感度不同。若把它们当同一 L ，选择差异可能其实是测量差异；若血压用于识别效应修饰，错误会破坏迁移可交换性。协调可使用验证子样本中同时测两种指标，建立测量桥接模型；也可把潜在真实血压和两个测量节点显式画出。简单 z 分数标准化只统一单位与边际分布，不证明构念等价。结局也需协调。一个系统用住院编码，另一个用临床判定；治疗还可能改变就医概率。外推时必须区分真实疾病机制是否稳定与结局观测机制是否稳定。选择图可以分别把选择节点指向潜在结局和测量节点。

迁移失败诊断与公平责任 若加权后的源域能复现目标域中处理前或已知短期关系，却无法复现目标结局，可能有三种原因：遗漏效应修饰、处理或结局定义不一致、结果机制真实变化。仅继续增加人口学权重无法区分。可使用“桥接结果”：选择在两域都观察、对机制变化敏感的中间结局，检查模型；使用多源实验比较同一分层效应；或在目标域开展小型校准试验。若少量目标实验与大源试验不一致，可用分层模型估计变化，而非强行假定完全相同。运输公式的失败也是信息：它指出哪个机制需要目标域数据。最有价值的新样本不一定扩大总量，而可能专门覆盖缺失协变量层或直接测量疑似变化机制。

公平与外部效度 训练与试验样本往往对边缘群体覆盖不足。总体平均效果良好可能掩盖某群体没有重叠或测量质量更差。以“总体可迁移”为唯一验收，会把不确定性集中到最缺乏证据的人。报告应按政策相关群体展示支持范围、分层效应与迁移权重，不把极端权重产生的高方差估计包装为同等证据。必要时限制部署、优先收集目标群体数据，或采用保守决策界限。外部效度因此也有分配伦理：谁被纳入知识基础，会影响谁承担模型失败。

9.2 从迁移公式到政策责任

9.2.1 迁移目标与选择图表达

外部效度不是问研究“能否推广”这一笼统问题，而是定义目标总体中的效应。例如试验样本以 $S = 1$ 表示，目标总体以 $S = 0$ 表示，要估计

$$E\{Y(1) - Y(0) \mid S = 0\}.$$

若给定处理前变量 X 后，试验参与与潜在结果独立，并且目标总体中的每类 X 在试验中都有支持，则可用试验内条件效应按目标分布标准化。随机化解决试验内部处理比较，参与交换性和参与正值性则连接试验与目标，两者缺一不可。

需要迁移的变量是效应修饰和选择机制的交集，而非所有结局预测因子。一个强预测因子若不改变处理效应，试验与目标分布不同不会造成平均效应差；一个弱边际预测因子却可能强烈修饰效应。领域知识、分层试验结果和机制证据共同决定变量选择，纯粹用预测重要性排序会偏离目标。目标总体也可能随时间变化。把十年前试验迁移到今天，不只是年龄和疾病分布变化，治疗标准、诊断阈值、竞争风险和实施能力都可能改变。时间应作为环境

机制的一部分，而非仅在回归中加入年份。

选择图怎样组织跨域差异 选择图用特殊节点指向在源域和目标域之间可能改变的机制。若选择节点只指向基线变量 X ，而 Y 的结构机制给定 A, X 后稳定，可以通过目标域 $P(X)$ 与源域试验条件效应组合。若选择直接指向 Y ，说明结果机制存在未由测量变量解释的变化，简单重加权通常不足。图的价值是区分分布变化与机制变化。人口年龄结构改变属于输入分布变化；同样治疗在新医院因执行质量不同而改变效果，属于处理或结果机制变化；结局编码系统改变则是测量机制变化。三者可能产生相似的观测差异，却需要不同修复：重加权、重新校准实施模型或做测量桥接研究。多源数据融合可让不同数据源贡献不同模块。随机试验提供处理到结果的内部效应，登记数据提供目标协变量分布，机制研究约束中介路径，政策数据库提供环境差异。但来源之间必须有共同变量语义和可连接单位；若“严重度”在各库中定义不同，形式上的同名节点不能直接拼接。

9.2.2 测量协调与规模效应

跨域研究常把测量差异当作数据清洗问题。实际上测量过程可能决定因果目标。试验中的抑郁结局由临床访谈获得，目标系统只有处方记录；二者不仅噪声大小不同，还可能测量不同构念。若处理影响求医和处方机会，处方记录甚至是处理后选择变量。协调应建立构念—指标图：先定义希望比较的潜在构念，再记录每个数据源的观测指标、阈值、测量时点和缺失机制。可以使用共同样本、校准研究、潜变量模型或多指标设计建立桥梁，但每种方法都增加假设。没有桥接数据时，把变量重命名为同一英文缩写不会创造可比性。处理也需要协调。一个试验的“常规照护”可能包含

频繁随访，目标地区的常规照护几乎没有服务；药物剂量、供应、依从支持和共同治疗都会改变版本。迁移结论应针对完整策略，并说明哪些组成部分被假定等价。

规模扩大为何可能改变效应本身 小规模试验通常把资源价格、人员行为和网络环境视为背景不变。全面部署会改变这些背景：培训需求降低执行质量，补贴推高价格，推荐系统改变内容供给，疫苗覆盖产生群体免疫。个体潜在结果因此依赖总体处理比例或网络配置，简单把试验平均效应乘以人口规模会失败。处理这种问题需要定义饱和度或政策水平。可比较不同集群覆盖率下的直接效应与溢出效应，或建立供需和网络传播模型。外推对象不再是“同一个体处理从0变1”，而是整个系统从一种配置转向另一种配置。识别需要集群随机化、分阶段实施或结构模型，并清楚说明均衡假设。规模效应也可能改变受益者组成。试点期最有动机、最易服务的人先参与，扩展后进入边缘群体；早期执行者经验丰富，后期机构能力较弱。监测部署过程应持续更新目标总体、实施版本和支持区域，而不是把一次外部效度分析视为永久许可证。

外部效度的分配责任 哪些人进入试验、哪些结局被测量、哪些亚组有足够支持，会决定谁能从证据中受益。若弱势群体长期被排除，模型对他们的不确定性更高；按预测置信度分配资源又可能进一步排除他们，形成证据贫困循环。外部效度因此不仅是技术准确性，也是研究资源的分配问题。负责任的报告应展示目标群体覆盖、重叠和分层不确定性，不用总体平均掩盖支持缺口。部署可以采用分阶段策略：在证据充分群体中先实施，在缺口群体中同步开展有保护措施的研究；也可以使用保守决策界限，避免把高方差外推包装成个性化精确。价值判断还进入目标选择。最大

化总体平均收益可能牺牲小群体，最小化最坏群体风险则可能降低平均效率。统计模型不能独自选择公平准则，但可以明确不同准则需要哪些效应、成本和不确定性信息，使规范分歧不再隐藏在默认损失函数中。

9.3 迁移分析的计算、诊断与治理

9.3.1 标准化计算与普遍化诊断

设试验中低风险层占 80%，处理效应为风险下降 2 个百分点；高风险层占 20%，处理效应为下降 10 个百分点。试验平均效应是 $0.8 \times (-0.02) + 0.2 \times (-0.10) = -0.036$ 。目标人群若低风险占 30%、高风险占 70%，标准化效应为 $0.3 \times (-0.02) + 0.7 \times (-0.10) = -0.076$ 。两个数值都正确，却回答不同总体。差异不是试验“失去内部效度”，而是效应修饰与人群组成共同作用。若只报告相对风险，而基线风险也跨域变化，绝对收益差异可能更大。迁移报告应同时展示分层效应、源域与目标分布以及加权后的总体结果。如果目标高风险层在试验中完全没有样本，上式中的 -0.10 无法由试验估计。用回归预测出的数值依赖外推模型；应限制目标、补充试验或给出基于机制与外部数据的范围。正值性诊断比权重公式更先决定结论可信度。

试验普遍化的诊断顺序 第一步比较资格标准：哪些目标成员原则上不能进入试验，排除是否与效应修饰相关。第二步比较参与倾向与协变量分布，展示试验和目标中的重叠。第三步检查处理、结局和随访是否同义。第四步估计参与权重或标准化模型，并报告权重分位数与有效样本量。第五步使用替代变量集、截尾和结果模

型检查敏感性。诊断不能只看加权后基线均值。参与模型可能在边缘群体外推，结局机制可能跨机构变化，未测效应修饰仍存在。可利用目标域观测结局、不同试验或负对照环境检查模型，但这些数据也有自身混杂。最可靠的结论会明确哪些差异已由数据桥接，哪些仍由稳定性假设承担。普遍化与可迁移性有时区分为目标总体是否包含试验样本，但实质逻辑相近：都是把源域条件关系与目标域分布组合。术语选择不应遮蔽共同的交换与支持条件。

9.3.2 证据冲突与部署后审计


两个试验给出不同效果，可能因人群、剂量、对照、结局或执行质量不同，也可能只是抽样波动。数据融合前应建立差异表，而不是立即做一个加权平均。若差异可由测量的效应修饰解释，可分别标准化到共同目标；若处理版本不同，应保留为不同策略；若结果机制直接变化，层次模型的“研究随机效应”只能描述异质，不能解释可迁移性。观察研究与试验冲突时，试验在内部处理比较上通常更强，但观察研究可能覆盖长期、罕见结局和不同实施环境。应检查试验依从、失访和结局时窗，同时对观察研究做偏差分析。冲突可生成新的目标：短期生物效应是否稳定，而长期政策效应为何随系统改变。证据综合的输出可以是分层结论，而非单一数值。例如对试验覆盖人群给出较窄效应，对外推人群给出宽范围，对新实施版本暂不量化。这样的结构比一个忽略来源差异的总体元分析更适合决策。

部署后的持续迁移审计 迁移不是发布前一次性步骤。部署会改变参与者、执行者和环境，原有目标分布不断更新。系统应监测处理版本、关键效应修饰、重叠、结局测量和策略依从；当这些指标越过预定阈值，触发重新估计、局部试验或暂停外推。结果监测要

避免选择反馈。政策决定谁接受处理，接受又决定谁产生标签；只比较部署后处理组与未处理组会重现混杂。可保留小比例随机探索、使用分阶段推广或设计可信的准实验。若伦理上不能随机，应至少保存完整决策日志和处理概率，为离策略评价提供依据。模型退役也是迁移治理的一部分。新治疗替代旧对照、编码体系改变或关键群体缺乏支持时，应明确结束旧结论的适用期，而不是无限再校准。证据有生命周期，外部效度报告应包含下一次审查条件。

9.3.3 完整迁移案例：从专科试验到城市系统

某专科中心完成了一项康复项目随机试验，现在城市医疗系统想判断全面推广后的一年住院风险差。 $S = 1$ 表示进入试验， $S = 0$ 表示只在目标总体登记； A 为康复项目， Y 为住院， L 包含基线风险与行动能力。试验保证 $S = 1$ 中 A 的可交换性，却不保证试验参与者与城市患者拥有相同结局机制。



实线部分表示，试验招募使 L 的分布不同，而 L 修饰处理效应。若给定 L 后潜在结果可在试验与目标间交换，且目标每个 L 层都在试验有支持，则

$$EY(a) | S = 0 = \sum_l E(Y | A = a, L = l, S = 1)P(l | S = 0).$$

虚线部分表示一个更强风险：实施容量 V 在专科中心与城市系统中不同，并直接影响 Y 。若 V 没有测量，只对 L 标准化无法修复机制变化。这不是权重模型的小误差，而是小规模试验中的“每人每周两次指导”与全市推广时的处理版本已经不同。

完整算例：总体组成改变的数值后果

将 L 分为可独立行走和行动受限两层。试验分别估计的住院风险差为 -0.08 与 -0.18 。试验中两层占比为 0.75 和 0.25 ，因而试验平均为

$$0.75 \times (-0.08) + 0.25 \times (-0.18) = -0.105.$$

城市目标中两层占比为 0.35 和 0.65 ，若分层效应可迁移，目标平均为

$$0.35 \times (-0.08) + 0.65 \times (-0.18) = -0.145.$$

差异来自效应修饰与总体组成，不是试验随机化失效。但若城市中还有“需他人协助行走”而试验完全排除的第三层，该层效应不能由两个已观察数字插值。必须限定目标、补充试验或给出外推范围。

参与权重的解释与诊断 当试验参与可由 L 解释时，可为试验中的人赋予与其在目标中代表性成比例的权重。一种参与几率权重与

$$\frac{P(S = 0 \mid L)}{P(S = 1 \mid L)}$$

成比例。它使试验中稀少、目标中常见的行动受限者获得更大代表性。权重并不证明这些人与未参加者在所有效应修饰上相同；它

只实施已写出的可迁移假设。

诊断应先分层回答三个问题。第一，目标中有哪些人几乎不可能进入试验？第二，大权重是因为少数合理的稀有类型，还是参与模型函数形式不稳定？第三，加权后已测 L 是否与目标分布对齐？应报告权重分位数、有效样本量、每个目标层的试验人数和截尾后目标的变化。

测量协调先于数值融合 专科中心可能以专业评定表测量行动能力，城市登记系统却只有辅具申请和诊断编码。即使两边都有一个名为“行动限制”的二元变量，切点、记录动机和测量时点不同也会使标准化失真。应先建立变量映射表，报告可互换、需校准和无法对齐的字段；再用重叠子样本或验证研究估计测量桥接。

结局测量也需同样审查。试验中的住院由独立委员会裁定，目标数据中则来自医保结算；跨市就医或康复项目对就医行为的改变会造成差异漏报。若测量误差受 A 或 S 影响，它不是简单降低精度，而会改变迁移查询的含义。

风险层	可观测诊断	应对动作
总体支持	目标层在试验无或极少样本	限定目标、补充招募或报告外推范围
效应修饰	分层效应差异且人群组成改变	按目标分布标准化并报告分层结果
测量协调	字段同名但时点、切点或来源不同	建立映射与验证子研究
实施版本	容量、依从或对照治疗跨域变化	改写处理策略并进行局部试验
系统反馈	覆盖率扩大后等待、价格或行为变化	监测饱和度并使用分阶段部署

失败诊断：把内部效度高写成全部人群可用

随机化使试验内的处理比较可信，但不回答目标中缺失的效应修饰、处理版本或规模效应。“高质量 RCT 已证明有效”至少应拆成三句：试验内哪个策略比较被识别，目标总体与试验差异由哪些变量桥接，全面部署是否保留相同干预与结局机制。任何一句缺少时，数值都应带有相应的限定。

9.3.4 多源数据融合：每个来源只提供它识别的部分

现实中常没有一份数据同时包含随机处理、长期结局、代表性人群和完整测量。数据融合的任务不是把所有行连接成一张大表，而是明确每个来源识别哪个因子或桥接关系。例如，随机试验可识别短期处理效应，城市登记可提供目标协变量分布与长期结局，一个小型验证子研究可连接两种测量标尺。

数据来源	主要可提供的信息	不能单独提供的信息
专科中心 RCT	已定义处理版本下的内部处理比较	全市人群组成、大规模实施效应
城市登记	目标总体分布、常规实施与长期结局	无未测混杂的处理效应
测量验证子研究	专业评定与登记代理之间的误差桥接	处理效应与系统规模反馈
部署试点	目标环境中的依从、容量、安全与短期效果	未试点地区的无条件长期效应

一个可识别的融合式必须对这些信息接口有明确要求。例如要用 RCT 的短期行动改善 M 与登记中 M 到长期住院 Y 的关系推断 A 到 Y ，需要 M 足以中介处理的长期影响，登记中 $M - Y$ 关系

可在测量的共同原因后交换，且试验与登记中 M 的测量可比。任何一项都比“两个数据集样本大”更重要。

证据冲突要先对齐估计对象 假设 RCT 报告风险差 -0.10 ，登记调整研究为 -0.04 ，部署试点为 -0.07 。不能先假定三个数字在估计同一个常数真值。应分别列出资格、处理版本、对照水平、随访时窗、结局尺度与效应人群。若 RCT 为密集专业康复，登记的处理为“至少一次转诊”，数值差异首先反映处理不同，而不是某一研究“错了”。

对齐后仍有冲突时，可把每个偏差方向显式化。专科试验依从较高，可能高估全面实施效果；登记中未测病情使重症者更容易接受康复，可能将保护效应向零拉；试点规模小，容量反馈尚未完全出现。这些方向不会自动告诉真值，但会指出需要的负对照、依从调查、容量实验与未测混杂敏感性参数。

规模改变会让干预本身内生变化 在 500 人试验中，每位治疗师负责 10 人；全市推广后若仍只有 50 位治疗师，每人负责数上升、等待延长，项目实际剂量与质量会变化。此时不能说“个体效应不变，只是更多人参加”。覆盖率通过系统资源反过来改变处理版本。

可把治疗师负荷和等待时间放入干预描述，定义不同覆盖率下的总体效应；也可在不同地区分阶段提高覆盖率，直接学习饱和和度反应。政策容量是因果变量，不是预算附注。对存在网络、市场与供给约束的系统，只估计低覆盖个体效应不足以支持全面部署。

失败诊断：把数据源标签当作一个普通协变量

在联合数据中加入“来源 = RCT/登记”指示变量并拟合一个大回归，不会自动使两个数据生成机制可交换。来源节点可能同

时改变招募、处理分配、结局测量与实施强度。应使用选择图或明确的数据融合假设分别标记哪些模块改变，再检查手中数据是否为每个改变提供桥接。

本章小结

内部效度不能自动保证外部效度。迁移把源域实验关系与目标域协变量分布或观测机制结合；选择图明确哪些机制跨域变化。可靠融合要求统一变量、时间和处理版本，并说明每个数据源提供的识别信息。效应修饰、重叠、测量变化和系统均衡是外推的核心限制。

自测与研讨

1. 推导试验效应按目标人群协变量分布标准化的公式，并列出三项假设。
2. 为什么强结局预测因子不一定是迁移所需的效应修饰变量？
3. 为两个医疗系统画选择图，标出治疗、测量和基线风险的可能变化机制。
4. 解释小规模政策试验推广到全国时，个体效应为何可能失效。

延伸阅读

选择图与形式可迁移性见Pearl, Bareinboim (2014)和Bareinboim, Pearl (2016)。试验普遍化与加权方法可读Cole, Stuart (2010)、Stuart et al. (2011)和Westreich et al. (2017)；嵌套与非嵌套试验设计及其抽样含义见Dahabreh et al.

(2019)与Dahabreh et al. (2021)。Degtiar, Rose (2023)提供了外部效度方法的系统综述。将可迁移性置于目标试验框架中时,可结合Hernán, Robins (2020)。

形式可迁移性的一般判定算法见Bareinboim, Pearl (2013)。基于倾向分层的试验普遍化见Tipton (2013), 样本与总体相似度的量化诊断见Tipton (2014); 不同推广估计器的模拟和经验比较可读Kern et al. (2016)。抽样权重在实际随机试验中的实现见Buchanan et al. (2018), 而Westreich et al. (2019)强调内部效度、目标效度和研究设计等级不能混为一谈。

跨地点预测政策效果的早期计量方案见Hotz et al. (2005), 教育干预普遍化方法的专题综述见Tipton, Olsen (2018)。这些文献应与正文的处理版本、重叠和规模反馈共同阅读, 避免把统计重加权误当成机制自动稳定。

迁移不仅是抽样权重问题。从证据进入新政策环境所需的支撑因素见Cartwright (2007), 随机试验为何不能仅凭设计标签保证外部适用性可对照Deaton, Cartwright (2018)。

因果机器学习与跨学科应用

学习目标

读完本章，你应当能够：区分预测、异质效应与策略学习；比较元学习器、因果森林和表示学习；在医学、经济、政策与算法系统案例中贯通目标、识别、估计、迁移和决策。

10.1 因果机器学习：异质性、策略与表示

10.1.1 因果机器学习的任务位置与元学习器

机器学习可在因果研究中承担至少三类工作。第一，灵活估计结果回归、倾向得分等干扰函数，提高平均效应估计的稳健性。第二，学习条件平均处理效应

$$\tau(x) = E\{Y(1) - Y(0) \mid X = x\},$$

发现效应异质性并支持个体化决策。第三，从高维图像、文本或传感器数据中学习适合因果建模的变量表示。

三类工作都没有取消识别假设。神经网络能够逼近复杂条件均值，却不能仅凭拟合把未测混杂变成已测；因果森林可以估计异质性，却需要训练数据支持每个目标亚组的处理比较；表示学习若没有多环境、干预或结构先验，也常存在不可识别的潜变量变换。

预测风险与预测处理效应 高风险者不一定最受益。设一个患者不治疗时风险为 0.40，治疗后为 0.35；另一患者不治疗时风险 0.15，治疗后 0.02。前者基线风险更高，后者绝对获益更大。只用结局预测模型给高风险者分配治疗，可能错过真正的效应修饰。预测任务观察每个单位的一个事实结果，并可用交叉验证直接评估误差；处理效应任务缺少个体真值 $Y_i(1) - Y_i(0)$ ，不能用普通监督标签评估。异质性算法的验证需要随机试验、伪结果、策略价值、校准曲线或独立实验等间接方法。

元学习器 S-learner 用一个模型拟合 $E(Y | A, X)$ ，把处理作为普通特征，再比较同一 X 下 $A = 1$ 与 $A = 0$ 的预测。它简洁并共享信息，但强正则化可能忽略较弱的处理交互。

T-learner 分别拟合

$$\mu_1(x) = E(Y | A = 1, X = x), \quad \mu_0(x) = E(Y | A = 0, X = x),$$

再取差。它允许两个处理组有完全不同响应面，但样本不平衡时小组模型不稳定，两模型误差也会在相减时累积。

X-learner 先用两个结果模型为处理组和对照组构造插补效应，再分别建模并按倾向得分组合，常适合处理组规模高度不平衡的情形(Künzel et al., 2019)。优势依赖结果模型和组合方式，不是所有数据上的统一最优。

R-learner从 Robinson 残差化出发, 估计

$$Y - m(X) \approx \{A - e(X)\}\tau(X),$$

通过对正交化残差的损失最小化学习 $\tau(X)$ (Nie, Wager, 2021)。它把异质性学习与正交得分结合, 减少干扰函数估计误差的影响。

元学习器是组织现有预测算法的模板, 不自带因果有效性。处理和结果模型应交叉拟合, 超参数选择应以与因果目标相关的损失为准, 并检查重叠。

10.1.2 因果森林与策略学习

因果森林在随机森林的递归分割中寻找处理效应差异, 而非只寻找结果均值差异。**诚实性**要求用于选择分割的样本与用于估计叶节点效应的样本分开, 减轻自适应选择偏差。广义随机森林进一步以局部矩条件统一处理多类参数(Athey et al., 2019; Wager, Athey, 2018)。因果森林可输出 CATE 估计、方差与变量重要性, 但解释需谨慎。一个变量频繁用于分割, 可能因它关联基线风险、处理概率或其他效应修饰代理; 这不表示该变量本身是效应异质性的原因。局部估计还依赖邻域中的处理重叠, 极端个体上的“个性化”往往只是模型外推。验证可使用: 总体平均校准; 把预测效应分组后在独立数据中比较组内试验效应; 检查最佳线性预测; 评估由模型诱导的策略价值。只展示一幅色彩丰富的 CATE 分布, 不能证明真实异质性。

从效应预测到策略学习 若处理有成本或副作用, 决策目标不是最大化每个人的预测效应, 而是最大化期望效用。策略 $\pi(x) \in \{0, 1\}$

的价值可写为

$$V(\pi) = E\{Y(\pi(X)) - c\pi(X)\},$$

其中 c 表示成本或效用折算。预算、公平、容量和风险约束都可限制策略类。

策略学习容易产生“赢家诅咒”：从同一数据尝试许多规则并选择估计价值最高者，会高估价值。应使用样本分割、离策略评估和独立验证，并与简单基准规则比较。经验福利最大化与观察数据策略学习分别给出了规则复杂度、约束和遗憾界限的正式处理(Athey, Wager, 2021; Kitagawa, Tetenov, 2018)。策略的外部效应比平均效应更脆弱，因为边界附近个体的排序、资源反馈和实施依从都会改变实际价值。伦理上，最大平均结局不必等于公平决策。若历史数据反映资源不平等，按预测获益分配可能继续排除缺乏数据的群体。应明确效用函数、受保护群体约束和不可接受的因果路径，而不是把价值选择隐藏在损失函数中。

10.1.3 因果表示、分布外泛化与解释边界

传统因果模型通常假定变量已经给定，而图像、语音与文本是高维观测。**因果表示学习**试图从观测中恢复具有独立机制、可干预和可迁移意义的潜在变量(Schölkopf et al., 2021)。单一观测分布通常不足以唯一识别潜在因果变量。任意可逆变换可以保留观测分布，却改变潜在坐标和图。额外信息可能来自已知干预、多环境机制变化、时间顺序、对象分解、稀疏性或弱监督。无监督解缠的一般不可识别结果说明，仅靠重构与因子先验不能保证恢复真实生成因素(Locatello et al., 2019)。声称模型“自动发现真实概念”时，必须说明是哪项额外结构打破不可识别性。表示还涉及语

义选择。把皮肤颜色、疾病严重度或社会地位压成潜变量，不能保证它对应一个伦理上可干预或科学上稳定的实体。表示应通过下游干预预测、机制稳定性和领域解释验证，而不只靠重构误差。

分布外泛化的条件 常见口号说“因果模型天然具有更好的 OOD 泛化”。其合理核心是：若结果机制 $P(Y | Pa_Y)$ 在环境间稳定，而环境只改变非因果相关或某些上游分布，使用真正父变量预测可保持稳定。**独立因果机制**原则把系统视为若干相对自主模块，局部变化不必改变其他机制(Peters et al., 2017)。但因果并不自动等于稳健。目标环境若干干预结果机制本身、出现新处理版本、改变测量过程或引入未见父变量，旧因果模型同样失效。反因果预测有时反而更稳定，例如影像诊断中疾病产生图像，预测方向从结果原因到观测结果；是否稳定取决于环境改变哪一模块。OOD 主张应明确训练环境、预期变化集合和稳定机制，而不是在任意未知分布上承诺泛化。最好的检验是预先指定的跨环境评估和机制压力测试。

解释 AI 不等于因果解释 SHAP、特征重要性和部分依赖图通常解释模型预测如何随输入变化，属于**预测归因**。它们可回答“哪些特征推动了这个模型的分值”，不自动回答“改变该特征会怎样改变现实结果”。特征相关结构、模型外不可行动组合和反向因果都会破坏因果解释。

反事实解释常寻找使模型输出改变的最小输入修改，例如“收入增加多少会使贷款获批”。这仍可能只是模型决策边界反事实。若收入修改同时要求教育、职业和时间变化，直接改一个数值并非可实现的现实干预。

因果解释需要把可行动变量、结构约束和后果模型纳入。例如改变培训机会可能影响收入与职业，再影响审批；公平分析还

要检查敏感属性通过哪些路径作用。因果模型不是给解释贴标签，而是限制哪些替代输入构成连贯世界。

10.1.4 异质性验证、策略评估与合作边界

模型在独立试验样本中为每人预测 $\hat{\tau}(X)$ ，研究者按预测值分成五组。不能把每组内观测治疗者与未治疗者的原始差直接当真效应，除非试验随机化或观察研究识别仍成立。随机试验中可在每组估计处理差，并检查预测效应从低到高是否单调、平均预测是否与观察组效应校准。若最高预测组观察效应最大，仍需置信区间和多重选择处理。分组边界由训练数据确定较好；若在验证数据反复调整边界直到趋势漂亮，验证已变成训练。外部验证还要覆盖相同特征范围，否则高效应组可能主要是外推。一个模型可以正确排序却数值不校准，适合有限资源优先排序但不适合收益—成本计算；也可以平均校准却不能排序，不适合个性化。评价指标应对应使用目的。

策略价值的离线评估 给定历史随机试验，策略 $\pi(X)$ 的价值可以用逆概率加权估计：只让实际处理与策略建议一致的单位贡献，并按其被分到该处理的概率加权。增广估计再结合结果模型提高效率；双重稳健离策略评价把行为策略与结果模型的两类信息结合(Dudík et al., 2011)。若历史处理几乎从不执行策略在某类人上的选择，价值评估缺少支持。离线价值高不保证上线价值。医生可能不遵循建议，患者行为会响应，资源约束使同时治疗人数改变质量。部署实验应把“提供建议”而非“理想接受治疗”作为处理，并测量采纳、中介和系统反馈。策略比较还要防止选择偏差：从上千候选规则中挑估计价值最高者，会利用噪声。训练、选择、评估三阶段分离，或用统一复杂度惩罚与置信下界作保守决策，更符

合真实风险。

表示可识别性的直观反例 设潜变量 Z_1, Z_2 生成图像 X ，编码器恢复 (Z_1, Z_2) 。任何可逆混合

$$(\tilde{Z}_1, \tilde{Z}_2) = g(Z_1, Z_2)$$

都可配合新解码器同样重构 X 。仅凭重构损失无法知道哪组坐标对应“形状”和“光照”，更不能知道它们的因果方向。

多环境若只改变光照分布而形状机制稳定，可提供解缠线索；已知干预光源则更强。时间数据可限制后因不能生成先因，但未必消除同步混合。所谓“因果表示”必须说明使用了哪种非对称信息。大型生成模型提供丰富语义特征，却可能把训练语料中的社会关联编码为潜变量。特征对预测有用不等于它是可干预原因。把表示用于公平或政策前，应检查变量语义、代理路径和跨环境稳定性。

因果与预测的合作边界 纯预测在许多任务中足够：短期需求预报、图像分类和异常检测不必都回答干预问题。强行给预测模型加“因果”标签不会提高效用。因果建模在行动会改变数据分布、需要解释替代政策或迁移机制时尤为重要。理想系统可以分层：预测模块估计当前状态，因果模块模拟行动后果，决策模块结合效用，监测模块检测机制漂移。把四层合成一个黑箱分数，会混淆错误来源；分层接口使我们知道是状态估计错、因果模型错，还是目标函数不当。

10.2 跨学科案例：从问题到可辩护结论

10.2.1 健康与教育：观察研究和工具变量

问题与目标试验

某地区希望用电子健康记录评估加强针预防未来 90 天内住院的效果。含混问题“打加强针有没有用”应改写为：在某一资格日期符合条件、此前完成基础免疫且当时未感染的人群中，立即接种加强针相对于未来 90 天不接种，对 COVID 相关住院累积风险的影响。目标试验需对齐资格判定、策略分配与随访开始。若把接种者的随访从接种日前若干周开始，而他们必须保持存活且未住院才能进入接种组，这段时间被错误计作“接种保护期”，产生**不死时间偏差**。

因果结构

年龄、基础疾病、既往感染、医疗利用和防护行为可能同时影响接种与住院。日历时间影响病毒流行、疫苗供应和住院风险。图中应至少包含这些处理前共同原因。检测频率可能受接种影响又决定感染是否记录；若结局定义依赖检测，测量过程也需建模。在给定协变量历史后主张可交换，并保证各层有接种与未接种者，可通过标准化或加权估计风险差。动态接种中可按每周连续模拟目标试验，再适当合并；必须避免同一人的重复克隆带来的标准误错误。

可回答与不可回答

该研究可以估计在特定时期、特定变体和医疗系统中的策略效果。它不能仅凭一个总体风险比证明所有个体都获益，也不能自动迁移到新变体或不同既往免疫背景。健康寻求行为若未充分测量，仍可能有残余混杂。负对照结局、不同时间窗和未测混杂敏感性分析可以评估但不能逻辑消除风险。

案例二：教育回报与工具变量

为什么普通回归不够

研究者希望估计多受一年教育对成年收入的效应。能力、家庭资源、地区机会和未来偏好可能同时影响教育与收入；简单回归调整已测家庭变量仍可能遗漏能力或动机。某项义务教育法把最低离校年龄从 15 岁提高到 16 岁，可作为教育年限的工具。令 Z 为出生队列是否受新法约束， X 为教育年限， Y 为收入。工具变量解释需要：

1. **相关性**：新法确实增加部分人的受教育年限；
2. **独立性**：在适当队列趋势控制后，法规暴露与潜在收入背景可比；
3. **排除限制**：法规不通过教育之外的路径影响收入；
4. **单调性**：法规不会使任何人反而减少教育。

目标是局部效应

在这些条件下，Wald 比率识别**服从者局部平均处理效应**：只对那些因新法而多读书的人。它不是所有人的平均教育回报，也未必适用于本来会读大学的人。工具改变的是某个教育区间，效

应还可能随年限非线性变化。排除限制可能因法规同时改变童工执法、学校质量或地区迁移而失败；队列趋势与其他同期政策也威胁独立性。应展示第一阶段、弱工具稳健推断、伪阈值与同期制度检查。工具变量用制度知识换取对未测混杂的处理，不是统计技巧自动生成外生性。

10.2.2 政策评估：断点回归与双重差分

设计逻辑

一项助学金只发给考试分数低于阈值 c 的学生。令运行变量为 R ，资格处理为 $A = \mathbb{I}(R < c)$ ，结果为一年后继续就读。若阈值附近个体除处理概率外在潜在结果上连续，则阈值两侧的结果跳跃识别局部处理效应(Imbens, Lemieux, 2008)。

断点回归不要求阈值两侧所有协变量完全相同，但要求个体不能精确操控分数跨越阈值，且没有其他政策在同一阈值同时跳变。应检查运行变量密度、预处理协变量连续性和制度执行。

锐断点与模糊断点

若资格完全决定领取，属于锐断点；若资格只提高领取概率，属于模糊断点，可把阈值资格作为工具估计局部服从者效应。局部性是设计优势也是限制：带宽越窄，比较越可信但样本少；结果不能无假设推广到远离阈值的人。分析不应以高阶全局多项式强行拟合整个分数范围。常用局部线性回归、数据驱动带宽和偏差校正置信区间，并报告不同合理带宽。若分数离散或样本在阈值附近很少，连续渐近近似需要谨慎。

案例四：最低工资与双重差分

反事实趋势

某省在 2025 年提高最低工资，邻省未提高。**双重差分**比较两地政策前后就业变化之差：

$$\hat{\tau}_{DID} = \{\bar{Y}_{T,post} - \bar{Y}_{T,pre}\} - \{\bar{Y}_{C,post} - \bar{Y}_{C,pre}\}.$$

核心不是“做两次减法就有因果”，而是**平行趋势**：若没有政策，处理地区与对照地区的平均结果变化本应相同。

平行趋势涉及未观测反事实，无法由政策前趋势完全证明。多期政策前数据可以发现明显违背；领域知识应检查同期产业冲击、人口迁移和预期效应。政策可能提前被企业预期，使处理在正式日期前开始。

错位实施与异质效应

当不同地区在不同时间采用政策，传统双向固定效应回归可能把已处理地区当作后来处理地区的对照，并在效应异质时产生难解释权重。应使用按采用队列与时间定义的组一时平均效应，再聚合到明确目标(Callaway, Sant'Anna, 2021; Sun, Abraham, 2021)。区域间劳动力和价格溢出会违反无干扰。若企业跨省迁移，对照地区也受政策影响，估计的是复杂均衡差异而非孤立个体处理效应。空间缓冲区、不同暴露定义或结构模型可帮助澄清。

10.2.3 算法系统：公平路径与网络干扰

统计公平指标的冲突

贷款模型使用收入、职业、邮编和信用历史预测违约。敏感属性 S 为族群。人口统计平等要求批准率在族群间相同；机会平等要求在某一真实结局层次条件下错误率相同；校准要求同一预测分数代表同一风险。在基准率不同且预测不完美时，这些指标通常不能同时满足。统计差异不能告诉我们差异来自何种历史过程。因果图可区分 S 通过歧视性机会影响收入、通过允许的业务需要影响风险，或通过邮编代理绕过显式删除。**反事实公平**要求在保持同一个体背景的结构反事实中改变敏感属性时，预测不变(Kusner et al., 2017)。但“改变族群而保持其他什么不变”本身涉及复杂社会本体论。

路径特定规范

实际治理常允许某些路径、禁止另一些路径。例如可能允许年龄通过工作经验影响收入，却不允许族群通过历史红线政策形成的社区资源影响批准。路径特定效应可以形式化这种区分，但可识别性依赖中介混杂和跨世界假设；何种路径“公平”则是规范与法律判断，不由图自动决定。以路径效应约束结果模型的形式化方案见Nabi, Shpitser (2018)。部署还引入反馈：批准贷款改变未来信用历史，模型训练数据只观察获批者的还款，形成选择标签；不同群体的探索率影响后续证据。一次静态公平审计不足，需要记录决策、结果观测机制和政策更新。

案例六：推荐系统中的干扰 平台测试新推荐算法时，用户不是独立单位。内容创作者会响应流量，朋友分享会传播处理，库存与

竞争会产生全局效应。普通用户级 A/B 测试估计的是低比例、短期部署下的直接效果，未必等于全量上线后的总体效果。一般干扰下的曝光映射与平均因果效应需要相应设计和估计量(Aronow, Samii, 2017)。可根据机制选择聚类随机化、网络随机化、市场级切换实验或饱和度设计。目标量需区分：被处理用户的直接效应；邻居处理对未处理用户的溢出；不同处理覆盖率下的总体效应；长期均衡效应。聚类减少跨组污染，却降低有效样本量，并要求聚类级推断。指标也可能是中介而非最终价值。点击率上升可能通过低质内容增加短期停留，却降低长期满意度。因果图帮助把推荐、曝光、点击、创作者响应和长期留存分层，避免把容易测量的近期指标当作全部结果。

10.2.4 跨案例综合、冲突证据与行动建议

六个案例使用不同方法，但共享同一分析骨架：

1. 把含混问题转成处理策略、对照、结果、时间和人群；
2. 选择与制度和机制相符的目标量；
3. 说明设计提供了哪种可交换性或局部准实验；
4. 列出不可检验的排除、连续、趋势、无干扰或迁移假设；
5. 采用与设计相符的估计和标准误；
6. 报告局部性、外部效度和替代机制。

方法名称不能代替这六步。一篇“使用 DID”的研究可能因平行趋势不可信而失败，一篇简单随机试验也可能因处理版本、失访或干扰而答错问题。高质量因果研究的标志是推理链完整，而不是技术标签新颖。

当多种设计给出不同答案 假设教育回报的普通调整估计为 8%，工具变量局部效应为 15%，断点附近效应为 5%。不能简单平均为

9.3%，因为它们可能估计不同人群、不同教育边际与不同尺度。普通调整接近全体样本 ATE 但依赖无未测混杂；工具变量针对因制度改变教育者；断点只针对阈值附近。比较应先把每个结果写成“谁、哪种处理变化、何时的什么结局”。若统一后仍不一致，再检查假设：工具是否有直接作用，断点是否被操控，观察调整是否遗漏能力。异质性可能是真实科学发现，而非需要消除的麻烦。三角互证最有价值的情形，是不同偏差和不同局部人群对理论作共同约束。例如若机制预言低教育者边际收益更高，工具变量针对被义务教育法影响者得到较大效应，与理论相容；若所有结果被不加区分地称为“教育效应”，则看似冲突。

应用报告的最小因果表 每项应用可用一页表格报告八项内容：文字查询；数学目标；处理与对照版本；目标人群；设计或自然制度；识别假设；估计与诊断；不可回答事项。摘要中的效应数字必须能追溯到这张表。对准实验，还应报告制度时间线和可能同时变化；对算法系统，报告部署反馈和标签选择；对医疗研究，报告时间零点与删失；对网络研究，报告干扰单位。领域差异不取消共同推理结构，而是决定哪类失败最突出。

从论文结论到行动建议 一个局部平均效应为正，不自动推出全面推广。决策者还需比较成本、容量、伤害、群体分布与迁移证据。可以先在缺乏证据的群体开展分阶段试点，并把部署设计成继续学习的实验；也可在高不确定、高伤害情形采用保守策略。政策改变会产生新数据，但若按模型建议选择处理，后续观测受到选择，不能直接评价未选策略。保留一定随机探索、清晰记录建议与实际行动，并预先定义更新规则，能避免系统把自身选择当作因果证据。

10.3 从效应学习到可信部署

10.3.1 端到端因果机器学习 workflow

高维算法进入研究前，仍需先写目标合同和识别证明。第一阶段定义总体、策略、结局、时间与效用；第二阶段确定数据结构和调整变量；第三阶段才选择机器学习估计结果回归、倾向得分、CATE 或策略价值。若目标与识别含混，模型容量越大，只会更精确地拟合错误对象。训练流程应把干扰函数估计、效应学习和最终评估分开。交叉拟合减少同样本过拟合；诚实分割把异质性发现与叶节点估计分开；独立验证或嵌套样本分割评估校准与策略价值。超参数不能只按结果预测误差选择，因为最优预测器未必保留处理交互；可结合正交损失、伪结果风险和策略价值，但要说明其统计依据。输出也不应止于每人一个效应分数。应报告总体校准、分组试验效应、支持区域、预测不确定性、变量重要性的非因果含义，以及跨环境稳定性。若模型用于资源分配，还要加入成本、容量、公平和安全约束，并通过离线评估或小规模随机试验验证实际策略。

个体化边界与策略验证 CATE 是给定特征人群的平均处理效应，即使特征向量非常丰富，它仍不是某个个体两个潜在结果的可观测量。把模型输出写成“张三服药会降低 17.3 个百分点”容易制造虚假个体精确。更准确的解释是：在训练数据支持且识别假设成立的相似特征亚群中，估计平均差异为何。个体化程度受重叠和样本量限制。高维空间中看似独特的个体附近可能只有一种处理，模型只能依靠光滑性或参数共享外推。置信区间若只反映树或网络的抽样波动，却忽略识别和外推，不应作为临床确定性。部署界面可显示证据等级、邻域支持和可替代规则，而非只显示单点分

数。效应异质性的解释也要谨慎。模型发现年龄分裂，可能因为年龄代理疾病阶段、治疗选择或测量质量；这不表示改变年龄会改变效应。要主张机制性修饰，需要时间、交互的科学解释和独立数据验证。异质性分析首先服务决策分层，其次才可能生成机制假说。

策略学习必须经过行动层验证 一个 CATE 模型排序良好，不保证由它产生的策略价值高。策略还取决于治疗成本、阈值、容量与依从。若模型对边界附近个体误差较大，小幅估计波动会改变大量分配；若干预改变后续数据和行为，离线数据中的价值函数会漂移。离线评估可使用逆概率加权、直接法或双重稳健价值估计，但同样依赖处理机制与重叠。尝试许多策略后选择估计价值最高者会产生赢家诅咒，应把策略搜索与价值评估分开，并与“全部处理”“无人处理”和简单临床规则比较。只有复杂策略显著超过透明基线，增加的实施成本才有理由。上线应采用可逆、分阶段设计。先在支持充分且风险可控的群体进行随机或准随机试点，监测真实依从、资源挤压、群体差异和未预期伤害；设置停止规则与人工复核；保留策略版本和反馈数据。策略学习的终点是经验证的行动制度，不是一份离线排行榜。

10.3.2 可信部署的共同失败点

疫苗、教育、断点、双重差分、公平与推荐系统看似分属不同领域，却共享同一推理链。它们都需要明确处理版本和时间零点；都可能因选择和测量打开非因果路径；都要区分局部设计识别的人群与政策目标；都面对部署后行为和系统环境变化。方法名称只有放回这条链才有意义。领域差异则决定哪一环最脆弱。医学中处理依从、竞争风险和结局误分类突出；教育与劳动经济学中制度选择、溢出和长期结果重要；断点回归依赖阈值附近不可操

纵与局部连续性；多期 DID 需要处理异质效应和错位实施；算法系统的策略会反过来改变曝光、标签和内容生态。

跨案例学习不应复制估计器，而应迁移审计问题。看到任何“自然实验”，先问外生变化影响谁、通过哪些路径；看到任何“公平模型”，先问敏感属性和允许路径的规范含义；看到任何“个性化策略”，先问个体附近是否存在可比较处理和离线价值能否迁移。共同语法让方法在领域变化时仍保持纪律。

高性能模型最常见的四种失败 第一是目标泄漏：用处理后变量或结局代理训练决策模型，使离线预测看似准确却无法在决策时使用。第二是选择反馈：模型决定谁被检测、治疗或展示，后续标签只在被选择者中出现。第三是环境漂移：实施改变行为与供给，训练分布中的稳定关系消失。第四是自动化权威：精细数值掩盖未测混杂和价值判断，使使用者停止质疑。对应防线分别是时间化特征审计、显式建模观测策略、持续随机探索或再校准，以及把结构假设与不确定性呈现在决策界面。安全关键系统还需要越界检测：当输入离开支持区域、权重极端或关键变量缺失时，模型应拒绝给出个体化建议，退回简单保守规则。这些防线会降低表面覆盖率，却提高因果使用的可信度。一个知道何时不作答的系统，比在所有个体上输出三位小数的系统更符合因果推断的证据结构。

10.3.3 完整策略学习案例：有限容量下如何分配

某医疗系统有一项为期半年的强化随访项目，只能覆盖 30% 的符合资格患者。目标不再是估计一个 ATE，而是在容量限制下选择策略 $\pi(X) \in \{0, 1\}$ ，使总体住院风险最低。系统已把目标总体分成三个预先定义的层：

人群层	总体占比	常规风险	随访后风险	风险差
高基线风险	0.25	0.40	0.34	-0.06
中等且可改变	0.35	0.25	0.13	-0.12
低风险	0.40	0.08	0.06	-0.02

如果按未处理基线风险从高到低排序，先覆盖全部 25% 的高风险层，再覆盖 5% 的中等层，每个总体成员预期减少的住院为

$$0.25 \times 0.06 + 0.05 \times 0.12 = 0.021.$$

如果按处理效应排序，容量全部用于中等且可改变层的 30 个百分点，预期减少

$$0.30 \times 0.12 = 0.036.$$

这个简单计算说明，高风险预测与高处理收益预测不是同一任务。如果随访对最高风险患者影响有限，仅以基线风险排序会放弃更多可避免事件。

但“效应最大者优先”也不是无条件答案。高风险层可能有更高的严重事件损失，中等层可能更容易完成随访，不同区域的实施成本也不同。若效用将住院、死亡、费用和患者负担按不同权重合并，策略应排序的是预期净效用差，不是单一风险差。这些权重是规范和管理选择，必须与统计估计分开公开。

完整算例：离线策略价值的双重稳健估计


令 $\pi(X)$ 是待评价策略， $e_a(X) = P(A = a | X)$ ， $m_a(X) = E(Y | A = a, X)$ 。对越小越好的结局，策略风险可用

$$\widehat{V}(\pi) = \frac{1}{n} \sum_{i=1}^n \left[\widehat{m}_{\pi(X_i)}(X_i) + \frac{\mathbb{I}\{A_i = \pi(X_i)\}}{\widehat{e}_{A_i}(X_i)} \{Y_i - \widehat{m}_{A_i}(X_i)\} \right]$$

估计。结果模型为每人填入策略所选处理下的风险，与历史决策一致的人用逆处理概率残差校正。估计仍要求给定 X 后历史处理可交换，并且待评价策略选择的行动在数据中有正概率。若历史上某类患者从未被纳入强化随访，离线价值对该类人只能外推。

策略开发与评价必须分样本 若在同一份数据中尝试一万个决策树，再报告估计价值最高的一棵，最大值中已经包含选择噪声。正确流程要把干扰函数拟合、策略搜索与最终价值评估分开。在样本较少时，可用嵌套交叉拟合，但外层测试折不能参与策略选择和阈值调整。

任何复杂策略都应与四个基线比较：无人处理，全部处理，按基线风险排序，以及一条临床或业务现行规则。“全部处理”即使超出容量，仍可作为理论上限与容量价值参考。若个性化模型只比简单规则改善极少，实施、审计和漂移成本可能超过收益。



将公平与安全写入策略约束 策略可以有资源约束 $E\pi(X) \leq 0.30$ ，也可加入最低服务、群体损害和不确定性约束。例如要求每个区域至少保留一定覆盖，可防止模型因历史数据较少而放弃偏远地区；

要求策略在效应下置信界仍达到最小收益，可减少由高不确定个体的激进分配。

这些约束会降低估计的平均价值，但可能提高可实施性和长期信任。不应把它们当作算法补丁；应在策略目标中明确说明谁选择了哪个约束、保护什么价值、放弃多少预期收益。因果模型可以估计后果，不能从数据中自动推出公正的分配规则。

从离线优势到可撤回试点 离线估计比简单规则好，只是进入试点的条件。部署会改变预约、依从、医生工作量和后续标签。首轮试点应在支持充分、损害可控的人群中保留随机对照，并事先规定容量超载、群体损害、依从大幅下降和输入超出支持时的停止规则。模型版本、训练数据截止日期、策略阈值和实际分配要能够逐个追溯。

随着策略接管更多决策，数据会越来越展示未选动作的结果。完全取消探索会导致新群体或新环境中的效应无法学习。可以在伦理允许的近似决策之间保留小比例随机化，或使用分阶段推广产生新比较。学习能力本身是长期策略的一项价值，不应被一次性最大化眼前估计收益消耗掉。

失败诊断：用处理效应排名宣称个体决策已被证明

上表中 -0.12 是一个人群层的平均风险差，不是对该层每个人的确定效果。当模型继续将人群切得更细，每个局部的比较数据更少，结果更依赖正则化和跨人群共享。界面不应显示“此人收益 12%”，而应显示对应群体的估计、支持程度、不确定范围和可替代规则。对超出支持的人，拒绝个性化并退回经验安全策略，是模型正确使用的一部分。

本章小结

因果机器学习用灵活预测器估计干扰函数、CATE 和策略，也探索高维因果表示。元学习器、R-learner 与因果森林对异质性采取不同组织方式，但共同依赖识别、重叠和诚实验证。策略学习增加效用与约束；OOD 稳定性依赖具体机制变化；预测归因和模型反事实不能自动解释现实因果。应用因果推断要求把方法嵌入真实制度。疫苗研究依赖时间对齐和目标试验；教育工具变量识别局部服从者效应；断点回归依赖阈值连续性；双重差分依赖反事实趋势；算法公平需要把统计指标、因果路径与规范判断分开；推荐系统必须处理干扰和均衡。每种设计都通过特定假设换取特定目标。

自测与研讨

1. 用数字例子说明高基线风险者为何不一定有最大治疗获益。
2. 比较 S、T、X 和 R 学习器在样本不平衡与强正则化下的取舍。
3. 因果森林的“诚实”解决什么问题？它不解决什么问题？
4. 为一句“因果模型能 OOD 泛化”的主张写出必要的环境变化假设。
5. 为疫苗观察研究画出包含日历时间、健康行为和检测的 DAG。
6. 为什么义务教育法工具变量通常不能识别全人群教育 ATE？
7. 断点回归的局部性如何同时构成可信度来源和外推限制？
8. 在错位政策实施中，传统双向固定效应为何可能混合错误比较？

9. 选择一个算法公平路径，分别给出因果判断和规范判断。
10. 为具有朋友网络的推荐实验定义直接效应与溢出效应。

延伸阅读

因果森林见Wager, Athey (2018)与Athey et al. (2019); 元学习器和 R-learner 分别见Künzel et al. (2019)、Nie, Wager (2021); 策略学习见Kitagawa, Tetenov (2018)与Athey, Wager (2021), 离策略评价见Dudík et al. (2011)。因果表示学习综述见Schölkopf et al. (2021), 其无监督识别边界可对照Locatello et al. (2019); 因果与机器学习的系统背景见Peters et al. (2017)。

目标试验与流行病学案例见Hernán, Robins (2020); 工具变量见Angrist et al. (1996); 断点回归见Imbens, Lemieux (2008); 现代多期 DID 见Callaway, Sant'Anna (2021)和Sun, Abraham (2021); 反事实公平与路径约束分别见Kusner et al. (2017)和Nabi, Shpitser (2018); 干扰与网络实验可从Hudgens, Halloran (2008)及Aronow, Samii (2017)继续阅读。

异质性学习还可比较贝叶斯非参数树模型(Hill, 2011)、诚实递归分割(Athey, Imbens, 2016)、随机试验中的通用机器学习推断(Chernozhukov et al., 2025)以及表示平衡方法(Shalit et al., 2017)。四者分别依赖不同的平滑、分割、校准和可交换性条件, 预测到的局部差异不能直接当作个体确定效应。

准实验应用中, 断点设计的系统计量综述见Lee, Lemieux (2010)。错位处理时的 DID 权重分解见Goodman-Bacon (2021), 双向固定效应在异质效应下的偏差见de Chaisemartin, D'Haultfœuille (2020), 近期识别与估计争论的综合地图见Roth

et al. (2023)。阅读时应核对每种估计器针对的是哪一组、哪一时期和哪种反事实趋势。

框架综合、理论边界与开放问题

学习目标

读完本章，你应当能够：翻译 Rubin、Pearl、Woodward 与机制论的共同结构和不可消除差异；分析可检验性、模型不确定性、复杂系统与 AI 辅助研究；形成可预注册、可失败的因果推理链。

11.1 框架比较：Rubin、Pearl、Woodward 与机制论

11.1.1 任务比较、框架翻译与设计优先性

把 Rubin、Pearl、Woodward 和机制论列成四个互斥阵营，会夸大冲突。Rubin 潜在结果框架主要为处理效应、设计与估计提供语言；Pearl 的 SCM 为干预、反事实和图形识别提供统一形式

语义；Woodward 分析什么样的反事实变化具有因果和解释意义；机制论说明产生现象的实体、活动与组织。它们的抽象层次和主要问题不同。真正比较应沿五个维度展开：因果对象是什么；如何表示替代情形；识别依赖什么；解释需要什么；模型如何获得经验支持。只有当两个框架对同一查询、同一假设给出不相容答案时，才构成实质冲突。

潜在结果与 SCM 的翻译 考虑处理 A 、结果 Y 和处理前协变量 L 。潜在结果框架定义 $Y(a)$ ，并以

$$Y(a) \perp\!\!\!\perp A \mid L$$

表达条件可交换性。SCM 可以写为

$$L = f_L(U_L), \quad A = f_A(L, U_A), \quad Y = f_Y(A, L, U_Y).$$

若外生背景满足相应独立结构，图 $L \rightarrow A$ 、 $L \rightarrow Y$ 、 $A \rightarrow Y$ 给出后门调整。干预 $A := a$ 产生反事实 $Y_a = f_Y(a, L, U_Y)$ ，与 $Y(a)$ 对应。

二者由此可表达同一 ATE 和同一标准化公式。潜在结果记号直接突出处理比较和目标人群；图则直观展示多变量条件独立与错误调整路径。潜在结果并非“没有因果图”，图模型也并非“没有设计思想”。现代实践常同时使用二者。翻译并非毫无剩余。一个完整 SCM 为每个内生变量指定结构方程，天然支持多节点干预和嵌套反事实；潜在结果分析可以只定义研究所需处理的反事实，避免对无关变量作过多结构承诺。选择全面模型还是局部目标，取决于问题复杂度和可辩护知识。

争论一：先设计还是先建图 随机试验传统强调设计优先：处理赋值机制已知时，因果比较不依赖复杂结果模型。观察研究中的设计模拟、匹配和盲于结果的平衡检查延续这一精神。图模型传统强调显式结构：即使处理随机，选择、依从、中介和干扰仍需因果图；观察研究若不画结构，所谓“设计阶段”也隐含变量角色判断。两者不是非此即彼。最佳流程是先定义目标试验与处理策略，再画出支持识别的因果结构；设计决定哪些比较可信，图检查哪些路径仍开放。若图完全由分析后数据关系绘制，会削弱设计；若“设计优先”成为拒绝表达未测路径的理由，也会隐藏假设。

11.1.2 干预、图与机制的本体论分歧

潜在结果有时被概括为“没有操纵就没有因果”。更准确的要求是处理状态必须足够明确，能够支持有意义的替代结果。年龄、种族或基因型难以像药物一样直接操纵，但可以研究相关政策、机制分解或明确的构成性反事实。Woodward 把干预理解为理论上的变量改变，不限于人类实际可执行操纵。因此地震强度对建筑倒塌也可有因果效应，只要能定义切断通常原因、改变地震强度且不通过其他路径影响倒塌的理想干预。干预主义的重点是差异制造关系，而不是把因果等同于伦理上可做的实验。不过，可定义干预仍不能解决变量本体问题。“将族群设为另一值，同时保持其他背景不变”可能不是连贯变化，因为族群身份与社会经历共同构成。此时应把查询分解为制度、歧视路径或资源干预，而非假装一个二元开关足够。

争论三：图是否预设了待发现的因果 Cartwright 等批评图模型从箭头开始，似乎把科学家要发现的因果结构预先放入模型。这个批评对不透明地把相关网络标成因果图很有力，却不否定假设

模型本身。任何观察研究都需要背景假设；图的优势是使它们可见，并推出可检验条件独立和干预后果。图结构可以来自多种证据：实验、时间、机制、自然制度、跨环境稳定性和发现算法。它不是由一次回归“证明”，而是在证据网络中逐步修订。机制知识可支持某条箭头与排除路径，图模型则把机制主张转成识别含义；二者在这里具有接口。

机制与差异制造 机制论者可能认为，知道 X 的干预改变 Y 仍没有解释“如何发生”。干预主义者则指出，单纯列出部件也未说明哪些变化真正与结果相关。两种要求可以组合成**机制化的差异制造**：机制模型指出变量和路径，干预反事实检验部件变化对现象的贡献。例如解释基因表达，不仅要列出转录因子、结合位点和聚合酶，还要说明改变某结合事件如何系统改变表达，以及关系在何种细胞背景中稳定。反过来，若随机敲除显示平均表达变化，却没有追踪补偿通路，外推到其他细胞类型仍缺乏机制根据。机制并不总比变量模型“更深”。不同研究目的需要不同层级：评估一项政策的总体净效应可能不必穷尽心理机制；设计新药则可能必须知道分子通路。解释深度应以能够回答相关反事实、支持控制与迁移为尺度，而非以部件数量衡量。

11.1.3 可统一的工作流与不可消除的差异

框架	主要对象	强项	典型限制
潜在结果	处理状态下的替代结果	估计目标、试验设计、平均效应	多变量结构需额外组织
SCM/ DAG	结构方程、图与干预分布	识别演算、多节点反事实、路径	图结构与模块性需外部支持
干预主义	干预下不变的差异关系	解释方向、实验与控制	合格干预使用因果概念，变量定义困难
机制论	实体、活动、组织与现象	生成解释、层级与迁移依据	机制边界、完整性和效应量化困难

表格不是胜负榜。一个成熟研究可以用潜在结果定义目标，用 DAG 识别，用随机设计或稳健估计获得效应，用机制实验解释异质性，再用干预不变性评估迁移。

不可被统一消除的差异 仍有真实哲学分歧。第一，因果事实是否能还原为反事实或概率结构，还是需要不可还原的力量与过程。第二，实际因果中的正常性与责任是语义要素还是语用附加。第三，宏观变量的干预关系能否在没有微观机制完全还原时客观成立。第四，模型中的模块性是世界属性、科学实践规范还是有效理想化。这些问题不会被一个更大数据集自动解决。形式模型可以澄清分歧后果，实验可排除某些主张，哲学分析则解释概念与证据标准。多元方法的意义正是让各类理由在同一问题上彼此制约。

一个整合工作流

1. 用潜在结果或策略语言明确比较对象与目标人群；
2. 用 DAG/SCM 表达变量关系、选择、干扰和可获得数据；
3. 用设计与识别演算证明目标如何连接观测；
4. 用适合的统计方法估计并报告不确定性；
5. 用机制证据解释关系的稳定范围和失败模式；
6. 用干预主义问题检验模型是否支持相关控制与解释；
7. 对个例责任和规范决策另行加入正常性、价值与制度分析。

11.1.4 证明、证据多元与整合失败

在 L 混杂 A 与 Y 的标准情形中，潜在结果证明使用条件可交换性：

$$\begin{aligned} E\{Y(a)\} &= \sum_l E\{Y(a) \mid L = l\}P(l) \\ &= \sum_l E(Y \mid A = a, L = l)P(l). \end{aligned}$$

DAG 证明则在 $G_{\bar{A}}$ 中看到 L 阻断所有后门路径，用调整准则得到同一公式。

两种证明的实质承诺可对应：潜在结果可交换性排除给定 L 后的处理选择信息；图的缺边与 d -分离表达同一排除结构。DAG 更容易处理多个中介与碰撞点，潜在结果更直接显示目标人群与处理比较。选择哪种证明是表达优势，不是因果“哲学阵营”胜负。当隐藏混杂存在但有前门中介时，图演算特别简洁；潜在结果也能表达识别，却需要一组较难直观的序贯独立条件。反过来，随机化设计与有限总体推断在潜在结果表中非常自然，不必先指定所有变量的结构方程。

证据多元与真理多元 承认多种证据并不意味着同一明确命题可以既真又假。若两个框架在相同变量、干预与模型假设下分别推出 $P(Y | \text{do}(X))$ 为不同值，至少有一个推导或翻译错误。多元主义主要关于查询、层级和证据角色，而非放弃一致性。机制证据与统计效应冲突时，应寻找接口假设：实验机制是否发生在目标剂量，测量是否捕捉同一结果，补偿路径是否在人群中存在，处理实施是否真正改变机制。把冲突说成“定量与定性各有真理”会失去诊断机会。同样，哲学理论可以对“因果”概念核心有竞争分析。多元实践不必预先解决形而上学还原问题，但应记录何种概念承诺使某推论有效。例如用遗漏作原因时，引入正常性；用能力外推时，引入倾向稳定；用干预关系解释时，引入模块性。

反还原不等于反形式化 机制或力量论者反对把因果完全还原为统计与反事实，不意味着拒绝数学模型。机制可用反应网络、动态系统和多层图表达；能力可通过多环境响应曲线约束。形式化的价值是明确推论，不要求所有哲学含义都被符号消除。反过来，使用 SCM 也不强迫接受一种特殊的因果物质。结构方程可被解释为机制规律、干预不变关系或科学模型中的模态承诺。不同本体解释可能共享形式后果，经验数据先约束这些共同后果，剩余分歧再由哲学论证处理。

整合失败的三个征兆 第一，只把不同术语放在同一段落，没有说明如何共享变量或证据。第二，在一个框架遇到反例时，临时调用另一框架，却不修改原定义。第三，用“整体”“复杂”“机制”等词免除可检验后果。真正整合应提供翻译、接口和冲突处理规则。例如一项政策研究若声称同时采用机制论和潜在结果，应说明机制变量怎样指导处理版本、调整集和效应异质性，试验结果又怎

样反驳机制。否则机制只是装饰性叙述。

11.2 开放问题：可检验性、复杂系统与 AI 辅助研究

11.2.1 可检验性、模型不确定性与变量形成

“因果假设不可检验”过于笼统。一个 DAG 可能蕴含条件独立，可由数据反驳；结构方程可能预测干预响应和跨环境稳定性，可由实验检验；机制模型可能预言中间过程的时序和局部扰动效果。模型的某些部分有经验后果。但关键识别假设往往不能从同一观测数据完全确认。未测混杂不存在、排除限制成立、失访在给定历史后可忽略，这些主张涉及未观测或干预世界。数据与模型相容只说明尚未被相应检验否定，不等于模型为真。更现实的证据观是三角互证：使用偏差结构不同的方法研究同一问题。随机试验、自然实验、机制实验、观察队列、负对照和跨环境数据若在各自限制下收敛，结论比单一精确估计更可信；若不一致，差异本身帮助定位机制变化或偏差。

模型不确定性 教科书图通常是一幅确定 DAG，真实研究却可能有多幅合理图。某变量既可能是共同原因，也可能是早期疾病的代理；时间顺序不清会改变它是混杂还是中介。只报告首选图会低估结构不确定性。可以采取四种策略。第一，列出所有领域上合理的关键边方向，而非穷举无关图。第二，寻找在所有候选图中都有效的调整集或效应结论。第三，对无法统一识别的情形报告图依赖结果。第四，用最有区分力的新测量或干预选择后续研究。贝叶斯模型平均能在候选图间加权，但先验概率和模型类仍是实质选择；

把后验平均当作消除结构争论并不恰当。部分识别则承认现有信息只支持区间。宽而诚实的界限往往比模型驱动的窄区间更适合作决策。

变量从哪里来 因果图假定节点已经确定，而科学中的变量是测量、分类和理论抽象的产物。社会经济地位可由收入、教育、职业或社区资源定义；“治疗”可能包含临床决策、剂量与依从；心理构念依赖量表和文化语境。不同构造会改变图、干预和效应。测量模型应进入因果模型，而不是把指标当成构念本身。若潜在疾病 D 影响症状量表 M ，治疗也影响报告行为，则 M 不是透明的 D 。多指标、验证测量、测量不变性检验和定性研究可以支持变量构造。高维表示学习将问题扩大：即使潜变量可重构数据，也不保证它具有稳定干预语义。未来因果科学的重要任务不是只学习更多箭头，而是学习可解释、可操纵且跨环境稳定的变量层级。

11.2.2 复杂系统、自动化与 AI 边界

DAG 无环性适合在固定时间展开系统，但经济、生态、神经和社会系统有反馈。可以按时间展开 $X_t \rightarrow Y_{t+1} \rightarrow X_{t+2}$ ，或使用动态 SCM、微分方程和均衡模型。不同表示对应不同干预：一次性冲击、持续策略、改变反馈增益或改变网络结构。干扰使单位结果依赖他人处理，网络又可能由处理改变。若平台政策改变用户连接，固定网络上的溢出模型不足。市场和政策还存在一般均衡：个体响应汇总后改变价格和机会，反过来改变个体行为。复杂不意味着不能因果分析，而是目标必须从“单个节点的孤立效应”扩展为动态策略、覆盖率、网络暴露或均衡反事实。实验设计也需在个体、群组、时间和市场层次协调。

发现与识别的自动化边界 自动发现算法可以搜索巨大结构空间，符号算法可以判断识别，软件可以生成估计代码。这些进展适合把可形式化的推理机械化。最难自动化的部分仍包括：决定变量与处理版本、识别制度细节、判断排除限制是否可信、选择伦理上相关的结果、解释模型为何能迁移。未来系统应输出的不只是单一图或点估计，而是一份**假设账本**：每条边的证据来源、算法依赖、未定向关系、识别所需假设、可反驳预测和推荐实验。自动化的评价标准也应从“是否给出答案”转向“是否暴露答案依赖什么”。

生成式 AI 的合理角色 大型语言模型可以检索候选文献、把自然语言假设转成初步 DAG、检查分析报告是否遗漏常见偏差、生成模拟场景或解释公式。它特别适合结构化已有知识和提出反例。风险同样明显：模型可能虚构文献、混淆作者年份、把可能性写成共识、生成形式正确但图条件错误的 **do-calculus** 公式，并以流畅语言掩盖不确定性。不可核实的“最新理论”、作者张冠李戴和演算规则错误等常见问题，正说明没有来源约束的自动汇编不适合直接成为学术读本。

可靠 workflow 应要求：

1. 文献条目回到出版物、DOI 或作者机构页面核验；
2. 引文附近保留支持的具体主张，而不是只列书名；
3. 公式与定义对照原始定理；
4. AI 提出的图由领域专家确认变量、时间与边；
5. 分析脚本、版本与决策记录可复现；
6. 对无法核实的内容删除或明确标注，不用“可能最新”填补空白。

AI 可以成为审稿清单和假设生成助手，不能成为未署名的认识论担保人。

因果 AI 与智能的限度 因果模型被寄望于帮助 AI 进行规划、反事实解释和跨环境泛化。一个能区分观察与行动的系统，确实比只拟合静态相关的系统更适合政策选择。但智能行动还需要目标、价值、模型更新、部分可观测性和对其他行动者的理解。因果层级也不是通用智能的单一刻度。系统能够计算 $P(Y | \text{do}(X))$ ，不表示它知道应该干预什么；能够生成反事实，不表示反事实变量有社会和伦理意义；能够发现稳定机制，不表示在制度改变时仍安全。因果推理是智能的重要组件，而不是价值对齐或常识理解的完整替代。

11.2.3 开放科学、研究议程与学科纪律

可复现性不仅要求共享代码。因果结论还依赖研究问题的历史版本、纳入标准、图、变量字典、数据清理、识别推导和敏感性选择。提高可复现性需要同时改革方法、报告、激励与验证环节，而非只建立代码仓库(Munafò et al., 2017)。应保存：

- 预先定义的目标试验或估计目标；
- 带版本的 DAG 与边依据；
- 原始到分析变量的转换记录；
- 主分析与探索分析的区分；
- 所有合理调整集和模型规格；
- 失败的诊断、负结果与适用边界。

开放数据可能受隐私限制，但合成数据、代码、数据字典和受控访问协议仍能提高审计性。复现同一个数字只是最低标准；更高标准是另一团队能够理解为什么这个数字被当作特定因果问题的答案。

结束语：因果推理是一种纪律 从亚里士多德的“为什么”到现代结构模型，因果研究不断改变表达形式，却始终面对同一张力：事实不会自行告诉我们何种差异最值得解释，模型也不能脱离事实任意规定答案。科学进步发生在二者互相约束之处。成熟的因果推理不以断言强度衡量，而以可审计性衡量。它敢于写出“在这些假设下”，敢于区分“数据表明”与“模型推出”，敢于在不可识别时给出界限或提出新实验。因果工具的价值，不是让研究者免于判断，而是让判断留下结构、证据与可反驳的痕迹。

未来研究议程的四条主线 第一条是弱假设下的可靠推断。与追求更复杂点估计相比，部分识别、敏感性分析和多图推断能更诚实地处理结构不确定。研究需要把界限与实际决策结合：即使效应只在区间内，若整个区间都支持同一行动，仍可作稳健决策。第二条是**多尺度动态因果**。细胞、个体、网络与制度相互反馈，单层DAG难以表达涌现与均衡。未来模型需明确不同时间尺度上的状态聚合、跨层干预和机制变更，同时保持可识别查询，而不是只增加节点数量。第三条是**测量与表示的共同设计**。因果变量不应在数据收集后才由算法任意发现。领域理论、质性研究、传感设计与弱干预可以共同定义可解释表示；测量不变性应和结构不变性同时检验。

第四条是**人机协作的证据治理**。AI可维护文献—主张图、检查引文与公式、枚举候选DAG和设计区分实验；人类负责目标、变量语义、制度知识和价值判断。系统应保留每次假设变更与证据来源，使自动化提高审计性而非只提高生成速度。

11.2.4 预注册、失败案例与停止规则

传统预注册常只列回归式，无法防止研究者在处理定义、时间零点、调整集和目标人群上事后选择。更完整预注册应包含：目标试验协议；DAG 版本与边依据；主目标量；允许的调整集；重叠与模型失败时的处置；敏感性参数范围；迁移人群；探索性分析边界。预注册不禁止学习。若数据暴露新测量问题或机制，研究者可以修改，但应保留版本、说明触发证据，并把修改后结果标为探索或在新数据验证。预注册的作用是清楚区分确认性与探索性决定，减少未披露分析弹性，而不是禁止合理修订(Nosek et al., 2018; Simmons et al., 2011)。透明修订比僵硬执行一个已知错误计划更科学。注册报告制度可在收集结果前评审问题和设计，减少只发表显著结论。低功效、选择性报告与大量分析自由度共同降低研究发现的后验可信度(Ioannidis, 2005)。因果研究尤其受益，因为最重要判断常在数据分析之前完成，却最容易在最终论文中被压缩。

失败案例库 方法社区通常展示成功识别，较少保存失败。建立失败案例库可记录：因何种碰撞点造成方向反转；怎样的时间错位产生巨大假效应；发现算法在何种测量误差下稳定错误；迁移在哪个未测修饰变量上失效；AI 如何生成不存在的文献。失败库应包含最小可复现实例、错误推理链、诊断信号和修正方案。它不仅用于教学，也可作为自动审查工具的测试集。一个因果助手若能回答教科书公式，却不能识别真实失败模式，仍不适合研究部署。

何时应当停止并说“不知道” 当目标定义不连贯、关键处理层没有支持、可接受模型给出相反决策且无区分证据，或结论完全依赖不可辩护排除限制时，最合格的输出可能是“不知道”。这不是研究失败，而是防止行动获得虚假确定性。“不知道”还应带结构：

不知道哪个目标、原因是什么、现有数据排除了什么、哪项新证据最有价值。结构化无知可以指导实验与资源分配；一个没有假设账本的点估计反而终止学习。

11.3 综合研究的实践规范

11.3.1 框架翻译与成熟研究链

潜在结果把因果查询写成同一单位在不同处理下的结果；SCM 用结构方程生成这些替代状态；干预主义强调关系在适当干预下的不变性；机制论要求说明产生过程的实体、活动与组织。它们在清楚指定处理和结果时可以共享效应目标，却对模型中还应包含什么持不同立场。翻译应从具体命题开始。 $Y(a) \perp\!\!\!\perp A \mid L$ 在潜在结果中表达条件可交换；在 DAG 中可由 L 阻断相关后门路径支持；在设计语言中对应给定 L 后处理组可比；机制知识则为为何没有剩余共同原因提供实质理由。四种表述互相说明，但任何一种都不能由另三种纯语法推出。不可翻译部分同样重要。实际因果中的正常性与责任、机制中的组织层级、干预主义对理想干预的限制，以及潜在结果对总体和赋值机制的强调，不应被一个统一符号消除。好的综合保留差异所在，并说明研究任务为何需要其中某一层。

一条成熟研究链如何形成 成熟因果研究从问题表开始，经变量表、结构模型、识别证明、设计与估计，最后进入迁移和决策。每个环节既接收上游承诺，也向下游传递限制。变量定义改变会重写图；图改变会改变识别式；识别式决定需要估计哪些函数；数据支持限制可使用的策略；迁移分析决定结论能服务谁。研究链应

允许回退。若正值性诊断失败，可以缩小总体或重新设计，而不是继续优化估计器；若负对照反驳无混杂，可增加测量或改用界限；若部署试点显示机制改变，应更新选择图与策略目标。预注册不是冻结所有判断，而是预先说明哪些证据触发哪种修订，并保存版本轨迹。团队协作也可按链条分工。领域专家负责处理版本、机制与可实施性；设计者负责赋值、抽样和时间；统计学家负责识别式与估计；数据工程师负责测量谱系；伦理与政策参与者负责效用、分配与责任。任何一方都不能独自完成因果结论，但每项判断应有明确责任人。

11.3.2 受限 AI 与经验可检验性

生成式 AI 适合执行结构化辅助：把问题改写成多个候选估计目标，检查推导是否遗漏条件，生成简单 SCM 反例，整理文献中的变量与假设，或把分析计划转成可运行检查。它也可以暴露研究者默认前提，提供不同 DAG 供专家比较。价值来自扩大审计覆盖，而非取代判断。风险主要有三类。其一是来源幻觉：生成不存在的文献、定理或数据事实。其二是语义漂移：在摘要和代码之间悄悄改变总体、时间窗或效应尺度。其三是自动化偏见：把流畅解释误认作识别证明。所有 AI 产物都应保留来源、版本和人工核验者，关键公式必须逐行复算，关键文献必须回到原始出版物。可采用“双记录”制度：一份记录 AI 收到的任务、材料和输出，另一份记录研究者接受、拒绝和修改的理由。AI 不得拥有最终图、排除限制或政策发布的单独决定权；敏感数据应受访问控制；自动生成的分析应在隔离环境运行并通过预定测试。这样它成为可审计工具，而不是匿名共同作者。

可检验性来自预测风险而非口号 因果模型经常包含不能由单一观测分布验证的结构，但这不等于完全不可检验。模型可能蕴含条件独立、跨环境不变性、干预结果、时间顺序和机制中间量。越多结构承诺产生越多失败机会。研究者应主动寻找这些风险，而非只展示模型已经拟合的事实。模型比较也不应只看样本内似然。两个模型都解释观测分布时，可选择能区分它们的干预、环境或负对照；若暂时不能实验，就报告它们对目标效应的共同与分歧范围。贝叶斯或集合方法可以表达结构不确定性，但先验权重不能替代缺失证据。公开失败案例尤其重要。许多方法论文只展示假设近似成立的基准，使用者难以知道真实系统中如何崩溃。失败库应记录数据生成机制、误用路径、诊断信号和后果，并允许按目标、识别、估计、迁移分类检索。因果科学的成熟不仅体现在成功公式，也体现在可复用的失败知识。

11.3.3 停止规则与有纪律的无知

停止条件可以事先定义：目标处理无法形成连贯版本；关键混杂不可测且没有可辩护设计；目标人群完全缺乏重叠；模型集合给出跨越重大伤害与收益的宽范围；测量无法区分关键构念；系统反馈使局部效应与政策查询脱节。达到条件时，最好的结论可能是提出新数据需求，而非输出点估计。“不知道”也有层次。可以知道效应方向但不知道大小，知道某总体但不知道另一总体，知道短期但不知道长期，或只知道界限。精确陈述已知边界能够指导下一步信息价值：是测量一个共同原因、扩大某亚组、延长随访，还是随机化实施强度。停止不是放弃行动。决策者仍可采用预防原则、可逆试点、最坏情景规则或延迟部署；研究者应说明这些选择来自价值与风险容忍，而非伪装成数据结论。因果推理的最终纪律，是让不确定性保持可见，并拒绝用技术复杂度填补实质知识空白。

本章小结

潜在结果与 SCM 在许多标准效应问题上可相互翻译，但侧重点不同；干预主义分析因果解释的差异制造结构，机制论分析生成过程。设计、图、估计与机制不是竞争按钮，而是推理链的不同环节。真正分歧集中在因果的还原性、正常性、层级与模块性，而非符号偏好。因果模型可以由条件独立、干预响应和跨环境稳定性部分检验，但关键识别假设通常需要外部支持。变量构造、结构不确定、反馈与干扰仍是基础挑战。AI 可辅助检索、形式化和检查，却必须受原始来源与专家判断约束。未来进步既依赖新算法，也依赖更透明的假设账本和开放研究流程。

自测与研讨

1. 把一个三变量潜在结果假设翻译成 SCM 与 DAG，并指出翻译新增了什么承诺。
2. “设计优先”与“图模型优先”在哪些步骤可以兼容？
3. 用一个难以操纵的属性说明理想干预定义的边界。
4. 为一项机制研究写出对应的差异制造检验。
5. 将一幅确定 DAG 改写成三幅候选图，并找出可区分它们的最小新证据。
6. 举例说明观测指标与理论构念之间的测量机制如何改变因果结论。
7. 为一个存在反馈和网络干扰的问题定义动态策略效应。
8. 制定一份使用生成式 AI 辅助因果研究的核验清单。
9. “可复现一个数字”和“可复现一条因果推理链”有什么区别？

延伸阅读

潜在结果路线见Holland (1986)和Imbens, Rubin (2015); SCM 见Pearl (2009); 干预主义见Woodward (2003); 机制路线见Machamer et al. (2000)与Glennan (2017)。这些文本的目标不同, 比较时应先统一查询。

结构学习边界可回看Spirtes et al. (2000)与Peters et al. (2017); 因果表示与独立机制见Schölkopf et al. (2021); 现代因果研究的设计与透明报告可结合Hernán, Robins (2020)。开放科学的系统改革见Munafò et al. (2017), 预注册、分析弹性与发表可信度可依次对照Nosek et al. (2018)、Simmons et al. (2011)和Ioannidis (2005)。开放问题没有单一权威答案, 阅读时应特别核查论文的问题设定与识别条件。

若要把开放科学原则落实到期刊、资助和研究机构层面的可执行规范, 可读Nosek et al. (2015)提出的透明与开放促进标准。它应与本章的假设账本、代码复现和因果主张复核并用: 材料公开提高可审计性, 却不会自动使目标量、识别假设或迁移条件成立。

不同框架的综合比较可由Imbens (2020)检验潜在结果与DAG 在实践中的互补和张力, 再以Paul, Hall (2013)区分类别因果与实际因果任务。证据能否支持干预、机制和外推三种承诺, 可对照Deaton, Cartwright (2018)、Cartwright (2007)与Russo, Williamson (2007); 这些分歧提醒读者, 统一符号不等于统一证据标准。

第四部分

专题附录与学习工具

比较哲学专题：中国思想、自由意志与量子因果

A.1 中国哲学中的因果相关问题

学习目标

本附录旨在帮助读者辨认中国哲学文本中与生成、条件、报应、感应和行动后果有关的问题，同时避免把这些概念直接等同于现代干预效应、结构方程或西方形而上学中的事件因果。

A.1.1 比较研究的方法限制

“中国哲学有没有因果观”这个问题预先假定了一个统一的中国传统和一个稳定的“因果”概念。事实上，先秦诸子、汉代宇宙论、佛教论书和宋明理学使用不同词汇、服务不同论证。现代汉语“因果”还深受佛教译语和近代西学影响。比较应从具体文本的问题出发，而不是先找一个现代术语的古代对应物。对先秦哲学论

辩背景的经典研究可参见Graham (1989)。

本附录采用三项限制。第一，区分历史影响与概念相似：两个传统都讨论条件依赖，不证明其间有直接继承。第二，区分描述性生成与规范性报应：说明行为会带来后果，不等于给出自然科学机制。第三，区分诠释与形式化：现代图模型可以帮助澄清某种依赖结构，但不能反过来充当古典文本的原意证明。

A.1.2 “故”“由”“生”与解释语言

先秦文献中存在丰富的理由和生成表达。“故”可表示缘故或推论根据，“由”可表示经由或根源，“生”可表示产生与展开。这些词跨越逻辑、实践和宇宙论语境，不能统一翻译为现代技术意义的 cause。

《墨子》后期篇和《荀子》等文本包含对名、类、故与知识根据的细致讨论；《荀子·天论》又反对把自然异常直接理解为政治吉凶，强调天行有常以及人应当掌握物类规律(Mozi, 2010; Xunzi, 2014)。这样的论证可与自然化解释比较，但若称其为“实验因果推断”，就超出了文本支持。

中国古代医学与农学尤其重视多条件配合、时令和环境。它们展示实践性的条件推理：同一处方在体质、季节和病程不同情况下结果不同。与现代异质性和机制背景存在可比较之处，但具体有效性仍需现代证据，历史持续使用本身不是因果效力证明。

A.1.3 儒家：行动、德性与后果

《论语》和《孟子》的核心问题是如何成就人格、秩序与善政。它们经常讨论学习、习惯、榜样、制度和民生如何塑造行动。例如“性相近也，习相远也”把长期习染置于人格差异的解释中；孟子关于恒

产与恒心的论述把物质生活条件与道德行为联系起来(Confucius, 2003; Mengzi, 2008)。

这些论述有时可转写为经验假说：经济稳定是否改变违法风险，榜样与礼制是否改变合作行为。但文本本身还包含规范性和修养论意义。“德”不是一个可以与其他暴露等量替换的单一变量，“善政”也不是处理组标签。若要作现代经验研究，需要把制度、资源和行为机制重新操作化，并承认这种操作化是当代理论工作。

汉代**天人感应**把政治秩序、道德状态与自然征兆联系。它不是整个儒家传统的单一因果模型，也不能简单概括为“有机整体论”。后世儒者对灾异解释有不同态度，其中包括批评把异常天象机械对应人事。研究这类文本应区分宇宙论、政治劝诫与经验预测功能。

“德福一致”同样需要谨慎。儒家并不总主张有德者在经验世界中必然得到财富和安全；孔子、颜回等叙事恰恰呈现德与外在遭遇可能分离。道德理由解释“应当怎样”，不必是一条保证外在结果的自然规律。

A.1.4 道家：生成、自发与控制限度

《道德经》以“道生一，一生二，二生三，三生万物”等语言描述世界生成，又以“无为”批评强制、过度设计和自以为是的治理(Laozi, 2003)。这里的“生”不是一串可直接画成时间 DAG 的事件关系；它兼有本原、分化和秩序呈现的意义。

无为也不等于什么都不做，更不等于否认因果。它常指不以僵硬意志破坏事物自身发展条件。与现代政策分析比较时，可以把它理解为提醒干预会有反馈、副作用与知识限制，但不能据此推

出某项具体“不干预”政策有效。

《庄子》通过视角转换、技艺故事和语言悖论质疑固定分类与自满知识(Zhuangzi, 2009)。这对因果建模有方法论启示：变量划分受问题和视角影响，局部控制可能忽视系统变化。不过，《齐物论》不是统计相对主义，也没有声称所有因果模型同样有效。庄子的怀疑主要针对把有限区分绝对化。

A.1.5 佛教：缘起不是简单链式因果

佛教传统中与“因果”最常关联的是**缘起**、业与果报。缘起的基本表达是“此有故彼有，此生故彼生；此无故彼无，此灭故彼灭”，用于说明现象依条件而起，反对独立自存的实体。十二支缘起又服务于对苦及其止息的分析。

“因”与“缘”在不同论书中有精细分类。结果往往依赖主要条件、辅助条件和相续关系，因而不宜把缘起缩成单一充分原因(Gethin, 1998)。它与机制论、多重条件和关系本体论可以比较，但其修行与解脱目的不能被现代因果发现算法替代。

龙树《中论》以缘起论证空性：依赖条件而有的事物不具独立自性(Nāgārjuna, 2013)。这不是说经验中没有依赖或行动没有后果，而是反对把关系中的事物理解为自性实体。用“量子纠缠证明空性”既忽略物理理论的数学内容，也把哲学论证误作待经验验证的自然假说。

A.1.6 业与道德责任

业首先与有意行动相关，果报讨论行动如何在相续中产生后果。不同佛教传统对业的储存、成熟、主体连续性和时间尺度有不同解释。把业简单画成“善行 → 好运、恶行 → 厄运”的确定规律，

会遗漏意向、众缘、时间与解脱论背景。

从现代经验研究看，善恶行为可能通过声誉、制度反应、心理习惯和社会网络产生后果；这些机制可以被分别研究。但即使某些社会机制被证实，也不等于验证轮回或跨世果报。相反，现代数据无法检验的宗教主张也不应冒充已确认的科学因果规律。

A.1.7 可以怎样开展严谨比较

一个可行的比较项目应完成以下步骤：

1. 选择明确文本、版本、年代与诠释传统；
2. 确定文本在回答生成、责任、修养、解释还是解脱问题；
3. 重构原论证，不先套用“相关—干预—反事实”层级；
4. 只在功能明确处比较，例如多条件依赖、系统反馈或行动后果；
5. 标明现代形式化是分析工具，不是历史同一性断言；
6. 对可经验化命题另行定义变量、干预和证据；
7. 保留不可互译之处，不以“中西融合”掩盖概念差异。

关键辨析

古典思想能够启发当代因果问题，不需要被宣布为现代科学的先声。尊重文本差异、明确比较层次，反而能产生比“古人早已发现某算法”更有价值的哲学对话。

本章小结

中国哲学文献包含多样的生成、条件、行动后果与知识限制讨论，但不存在一套可不加区分地称为“中国因果观”的统一理论。儒家关心修养与秩序，道家强调生成和控制限度，佛教缘起分析条件依存与无自性。它们可与现代因果理论作受限比较，

不能直接等同或充当经验科学证据。

自测与研讨

1. 为什么“缘起”不能直接翻译成 DAG 中的一条边？
2. 选一段儒家政治论述，区分其中的规范主张与可经验化假说。
3. “无为”对现代干预思想有哪些启示，又不能推出什么？
4. 设计一项中西因果概念比较，写明文本范围和禁止作出的历史断言。

A.2 因果性、自由意志与责任

学习目标

本附录帮助读者区分决定论、可预测性、可控制性和道德责任，理解神经科学实验能够支持的有限结论，并说明因果模型为何可以澄清责任结构、却不能独自决定责任规范。

A.2.1 四个经常混淆的问题

决定论主张给定某一时刻的完整世界状态和自然规律，未来只有一种可能。**可预测性**关心有限观察者能否从信息和计算预测结果。决定论系统可能因混沌、信息不全或计算复杂而不可预测；随机系统的总体分布又可能高度可预测。

自由意志至少包括替代可能性、行动源头性、理由响应和自我控制等不同概念。**道德责任**则关心何时适宜赞扬、责备或制裁。证明行为有神经原因不会自动证明主体不自由，因为任何现实行动若要发生都需要某种实现过程；真正争论是这种过程是否以恰

当方式属于行动者并响应理由。

把四个问题压缩为“有原因就没有自由”，预设了自由必须是无因事件。许多兼容主义者恰恰认为，完全无因的随机动作更不像自主行动；自由需要行动由主体的欲望、判断和能力以适当方式产生。

A.2.2 兼容主义与理由响应

兼容主义不要求在完全相同的过去和规律下仍能产生另一结果，而把自由联系到反事实能力：若主体有不同理由、判断或意图，他会以适当方式改变行动。Fischer 与 Ravizza 把道德责任与机制的理由响应性及主体对机制的所有权联系(Fischer, Ravizza, 1998)。

Woodward 式干预语言可帮助表达这种思想。设 R 为主体认识到的理由， D 为审议， A 为行动。若对 R 的适当改变会通过 D 系统改变 A ，而操纵、强迫或病理过程没有绕过审议机制，则行动表现出理由响应。相反，强迫者直接控制 A ，或成瘾机制使 D 对理由变化不敏感，可能削弱控制。

这不是用一个 DAG 定义全部自由。哪些理由算相关、何种敏感度足够、主体如何“拥有”机制，仍是规范与人格理论问题。图模型能区分路径，不能设定责任阈值。

A.2.3 不兼容主义的挑战

不兼容主义者认为，即使行动通过主体心理机制产生，只要这一机制和全部输入由过去与规律唯一决定，主体就没有最终控制。结果论证主张：若我们不能改变过去与自然律，也不能改变由二者必然推出的行动(van Inwagen, 1983)。

自由意志主义者由此引入行动者因果、事件非决定性或特殊决策结构。但随机性本身不提供控制：若关键选择只是量子或神经噪声的结果，主体似乎同样不是其作者。理论必须说明非决定过程如何增强而非削弱理由导向的行动。

实际责任制度常不等待形而上学争论解决，而根据能力、知识、意图、强迫和可预见性分层。因果分析能够帮助判断药物、脑损伤或外部压力怎样影响这些能力，却不能由决定论真伪直接推出现行责任规则。

A.2.4 Libet 实验能说明什么

Libet 等实验要求参与者在自选时刻屈腕，并报告最初意识到行动意图的时间；头皮脑电中的准备电位在报告意图前出现(Libet et al., 1983)。这常被通俗化为“大脑在意识决定之前已经决定”，但这一结论超出实验直接支持。

首先，准备电位是多次试次按动作时刻平均的缓慢信号，不等于单次试验中已经形成不可逆决定。积累到阈值的随机波动模型可以在无早期固定决定的情况下产生类似平均波形(Schurger et al., 2012)。其次，主观意图时间依赖快速钟表报告，存在注意和记忆误差。再次，任意屈腕缺少理由权衡，与长期计划、道德选择和自我控制差异很大。

后续研究用脑成像在报告决定前对左右选择作高于机会的预测(Soon et al., 2008)。高于机会但远非完美的分类可能反映预备偏向，而非已经决定的行动；预测一类简单任务也不能直接推广到所有自主行为。

这些实验确实挑战一种天真的内省图景：意识不一定在某个清晰瞬间从无到有发出行动命令。它们支持把决策看成时间展开

的神经过程，但没有单独裁决决定论、替代可能性或道德责任。

A.2.5 预测行为是否消除自由

若算法能以 95% 准确率预测某人是否戒烟，这说明行为与已测历史高度相关，不说明个体在具体时刻没有控制。预测可能利用主体稳定目标，而这些目标正是自主性的组成部分。反之，不可预测也可能来自噪声，而非自由。

预测还可能改变行为。向主体显示风险预测会引发反思或反抗，使原模型失效。这种**反身性**要求把预测系统作为因果干预纳入模型。法律和社会使用预测时，还需考虑错误成本、群体差异和自我实现效应。

A.2.6 责任归属的因果层次

一次伤害事件可能同时有多个原因：行为人的动作、设备缺陷、组织激励和监管不足。实际因果分析可以评价每个因素在不同应急情形下是否改变结果；机制调查可以追踪事故链；统计证据可以说明风险增加。但责任还需要回答：行为人是否有义务、是否能够预见、是否有合理替代、制裁目的是什么。

原因也不等于责任份额。两个因素都可能是必要原因，或任一因素单独足够；责任制度可能因角色与义务不同分配不同。自动系统参与决策时，模型开发者、部署机构、操作人员与制度设计者形成分布式因果网络，更需要把技术因果与规范归责分开。

A.2.7 一个谨慎的综合

因果科学能够告诉我们行动受哪些机制影响、哪些能力可通过治疗或制度改变、强迫与操纵如何绕过审议，以及预测在何种环境有效。自由意志哲学则决定这些事实与控制、作者性和责任概念如何关联。二者应互相约束，却不应互相冒充。

本章小结

决定论不等于可预测性，有因不等于不自由，随机也不等于自主。兼容主义以理由响应与机制所有权分析控制，不兼容主义追问最终来源。Libet 类实验揭示意识报告与神经准备的复杂时间关系，但不能单独否定自由意志。因果模型可澄清责任路径，规范归责仍需义务、能力与制度理由。

自测与研讨

1. 分别给出决定但不可预测、随机但可作概率预测的例子。
2. 画出理由、审议、强迫和行动的因果图，说明何种路径削弱控制。
3. Libet 实验的观测结论与“自由意志不存在”之间缺少哪些论证？
4. 为什么准确预测一个行动既可能与自主相容，也可能反映操纵？

A.3 量子因果：经典模型的边界

学习目标

本附录帮助读者理解 Bell 相关为何挑战经典局部因果模型、无信号条件与无因果影响的差别，以及量子因果模型试图推广哪些经典概念。内容只作专题导论，不以量子理论证明任何传统哲学或宏观社会因果主张。

A.3.1 经典因果模型预设了什么

经典 DAG 以普通随机变量和条件概率表示系统。若两个远隔实验站的测量设置分别为 X, Y ，结果为 A, B ，共同背景为 Λ ，一个局部隐藏变量模型要求

$$P(a, b | x, y) = \sum_{\lambda} P(\lambda) P(a | x, \lambda) P(b | y, \lambda).$$

这是一种因果分解：共同源 Λ 可同时影响两端，左端设置不直接影响右端结果，右端设置也不直接影响左端结果；设置还被假定与 Λ 独立。

Bell 定理表明，量子理论允许、实验也观察到违反 Bell 不等式的相关，无法由满足上述条件的局部隐藏变量模型复现(Bell, 1964)。挑战针对的是一组联合假设，不是简单证明“世界没有因果”或“任何事物都可超光速影响任何事物”。

A.3.2 纠缠相关与无信号

纠缠系统的联合测量结果可以强相关，同时满足**无信号条件**：

$$P(a | x, y) = P(a | x), \quad P(b | x, y) = P(b | y).$$

改变远端测量设置不能被本地观察者用于可控地传递经典信息。因而，“存在无法由局部共同原因解释的相关”与“存在可操作的超光速通信”不是同一命题。

在经典图中，若 X 是 B 的原因，通常预期某些干预会改变 B 的分布；但精细参数抵消也可能使因果影响在边缘分布中不可见。Wood 与 Spekkens 指出，用经典因果模型解释量子无信号与 Bell 违反，往往需要不忠实的精细调节(Wood, Spekkens, 2015)。这推动研究者发展把量子系统本身纳入节点和通道的因果框架。

A.3.3 量子因果模型在推广什么

量子因果模型以量子态、通道、测量操作和算子代替或扩展经典条件概率。经典共同原因可由共享量子态表示，直接因果联系可由量子通道表示；干预则对应实验者选择的局部量子操作。研究目标包括：从量子数据推断可能的因果结构；区分共同原因与直接通道；建立适合量子网络的 Markov 条件和 d-分离类准则(Allen et al., 2017; Costa, Shrapnel, 2016)。

这里的“量子”不是把所有节点换成波函数就完成。不同方案对潜在量子系统、实验设置、时间顺序和可观察操作作不同形式化。经典因果模型在宏观实验设计中仍极其有效；量子扩展针对的是经典变量分解不足以表达的微观过程。

A.3.4 不定因果顺序

经典 DAG 假定事件可排列成无环的偏序。量子信息研究讨论某些过程无法表示为固定的“A 先于 B”或“B 先于 A”，而可出现操作顺序的量子叠加。**过程矩阵**框架允许在不预设全局因果顺序时计算局部操作的联合概率，并提出可违反的因果不等式(Oreshkov et al., 2012)。

应谨慎区分三件事：我们不知道顺序；顺序由随机变量决定；过程本身没有经典确定顺序。只有第三种才是严格意义上的不定因果顺序候选。实验实现还涉及控制系统、后选择和操作定义，不能凭一个“量子开关”图示就宣称日常时间因果被推翻。

A.3.5 量子结果没有证明什么

Bell 违反不证明意识造成坍缩，不证明宏观事件可以逆因果，也不证明佛教缘起、道家整体论或任何其他古典学说获得物理确认。不同理论可能共享“关系重要”“局部实体图景受限”等宽泛主题，但宽泛相似不足以建立逻辑蕴涵。

同样，量子概率不是社会科学中未测混杂的替代解释。教育、医疗或政策数据通常由经典测量与宏观机制生成，使用经典 DAG 的限制来自选择、测量、反馈和制度复杂性，而不是量子纠缠。跨领域借用必须指出具体数学结构和经验后果。

A.3.6 量子因果与本书主线的关系

量子专题强化了三项一般教训。第一，因果模型总有适用域；经典概率分解在某些物理情形受到实验证据限制。第二，条件独立与干预语义必须随系统允许的操作而定义。第三，违反一个模

型类不等于接受任意替代理论，科学进步需要提出更精确且可检验的新结构。

对非物理专业读者，理解到这一层已经足够。深入研究需要线性代数、量子力学、量子信息与广义概率理论，不能只靠经典 DAG 直觉。

本章小结

Bell 相关不能由满足测量独立与局部性的经典隐藏变量分解复现，但通常仍满足无信号。量子因果模型以量子操作和通道推广共同原因、直接作用和干预；过程矩阵研究不预设固定全局顺序的过程。这些成果限定并扩展经典因果建模，不为宏观神秘因果或古典哲学提供自动证明。

自测与研讨

1. 写出局部隐藏变量分解，并解释每个因子的因果含义。
2. 为什么 Bell 违反与可控超光速通信不是同一断言？
3. 区分未知顺序、随机顺序与不定因果顺序。
4. 评价一句“量子纠缠证明万物互为因果”的论证错误。

术语、时间线和学习路径

B.1 术语与符号表

本表给出全书统一用法。定义服务于本书的入门与跨学科目的；进入具体文献时，应注意同一术语在哲学、统计学和计算机科学中可能具有更窄或不同的技术含义。

术语	本书用法
ATE (平均处理效应)	$E\{Y(1) - Y(0)\}$ ，目标人群中普遍处理与普遍不处理的平均结果差。
ATT	$E\{Y(1) - Y(0) \mid A = 1\}$ ，实际接受处理者中的平均处理效应。
CATE	$E\{Y(1) - Y(0) \mid X = x\}$ ，给定协变量层的条件平均处理效应。
CPDAG	完成部分有向无环图，表示具有相同骨架和无屏蔽碰撞点的一组 Markov 等价 DAG。
DAG	有向无环图；在因果解释下，节点表示变量，边表示相对于模型变量集的直接因果关系。

术语	本书用法
d-分离	依据链、叉、碰撞点及条件集合判断图中路径是否阻断的准则。
do-calculus	在带有精确图条件时插入、删除或交换观察与行动的三条演算规则，用于识别干预分布。
do-operator	$\text{do}(X = x)$ ，表示以 $X := x$ 替换 X 的通常生成机制，而不是观察到 $X = x$ 。
Double ML	使用 Neyman 正交得分和交叉拟合估计低维因果或结构参数的框架。
FCI	允许潜在混杂和选择偏差、根据条件独立恢复 PAG 的约束型因果发现算法。
g 公式	通过对条件结果分布按协变量历史标准化，表达干预分布的识别公式。
INUS 条件	某因素是不充分但为一个不必要而充分的条件组合中不可缺少的部分。
LiNGAM	在线性、无环、无隐藏混杂和非高斯独立噪声假设下识别因果方向的函数模型。
Markov 等价	多个 DAG 蕴含同一组条件独立，因而仅凭相应观测独立结构无法区分。
NOTEARS	用光滑精确的无环约束把 DAG 结构学习改写为连续优化的方法族。
PAG	部分祖先图，表示在潜在混杂存在时由观测独立约束的一组因果结构。
PC 算法	在因果充分、Markov 和忠实性等假设下，由条件独立检验恢复 CPDAG 的算法。
SCM	结构因果模型，由外生变量、内生变量、结构函数及外生分布组成。
SUTVA	稳定单位处理值假设，通常涵盖无未说明处理版本与无单位间干扰。

术语	本书用法
不死时间偏差	进入某处理组必须保持存活或无事件的一段时间被错误计入处理风险期造成的偏差。
不变性	某条件机制或变量关系在指定的一类干预、环境变化下保持稳定。
部分识别	假设与数据只能把目标限制在一个集合或区间，而不能唯一确定点值。
处理版本	同一处理标签下实际实施的剂量、时机、方式、依从和联合措施。
反事实	与实际证据关联、描述同一单位或系统在替代行动或状态下结果的模型量。
反事实公平	在特定结构模型中改变敏感属性、保持规定背景后，决策或预测满足某种不变要求。
反事实依赖	在适当替代情形中，原因的变化伴随结果变化；是许多因果理论的核心但非充分无争议定义。
干扰	一个单位的结果依赖其他单位的处理，需用处理向量、网络暴露或饱和度定义。
干预	外部改变某变量生成机制的行动；合格干预须说明作用路径和保持不变的模块。
工具变量	与处理相关、与未测混杂独立、且只经处理影响结果的变量；具体识别还需额外条件。
共同原因	同时影响两个或更多变量、可使它们出现非因果关联的上游因素。
归纳问题	从已观察实例推向未观察实例的非演绎规则如何获得非循环理性辩护的问题。
后门路径	从处理出发的第一条边指向处理的路径；开放后门会造成处理—结果非因果关联。
机制	实体与活动在时空中组织并产生某种现象的结构；机制边界相对于解释问题。

术语	本书用法
交叉拟合	在不同样本折上分别训练干扰函数并计算目标得分，以减少过拟合与经验过程限制。
结果回归	对 $E(Y A, L)$ 建模，再对目标协变量分布标准化以估计反事实均值。
可交换性	处理组在无条件或给定协变量后具有相同潜在结果分布，使单位间可提供反事实比较。
可迁移性	利用源域数据与跨域机制假设识别目标域因果查询的能力。
碰撞点	路径上两个箭头相向进入的节点；默认阻断路径，条件化其本身或后代可能打开路径。
平行趋势	双重差分中，若无处理，处理组与对照组平均结果变化应相同的反事实假设。
潜在结果 前门准则	$Y(a)$ ，单位在处理策略 a 下会出现的结果。 借助满足特定路径条件的中介，在处理—结果有未测混杂时识别总效应的图形准则。
倾向得分	$e(L) = P(A = 1 L)$ ，给定处理前协变量的处理概率；其平衡性质不覆盖未测变量。
实际因果	关于某个具体事件在具体情境中是否造成结果的判断，区别于变量类型的平均效应。
识别	在给定假设下，因果目标可唯一写成可获得数据分布的函数。
时间零点 双重稳健	资格判定、处理分配与随访开始对齐的时刻。 结果模型或处理模型至少一个正确时估计仍可一致的性质，不代表两个任意错误模型可以互救。
随机化	以已知随机机制分配处理，提供处理与潜在结果的概率可交换性。
辛普森反转	总体关联与每个分层内关联方向不同的现象；应由因果结构决定是否分层。

术语	本书用法
一致性	实际接受处理 a 时, 观测结果等于该处理定义下潜在结果 $Y(a)$ 。
因果发现	在明确统计和因果假设下, 由观测、时间、多环境或干预数据约束因果结构。
因果过程	能够传递结构、标记或守恒量并通过交互连接事件的过程概念。
因果阶梯	区分关联、干预和反事实查询的层级框架; 更高层查询需要额外结构。
因果力量	把原因理解为对象或结构在适当背景下产生某类结果的能力或倾向。
因果 Markov 条件	给定直接原因后, 一个变量与其非后代中的其他变量独立, 并导出图分解。
因果效应	两个明确处理或干预策略下结果的对比; 需指定人群、时间和效应尺度。
因果解释	通过相关方向性依赖、机制或可干预结构回答现象为何发生; 不等于效应估计。
因果充分性	建模变量的相关外生扰动独立, 通常解释为不存在所考虑变量之间的未建模共同原因。
正值性	在目标人群相关协变量层中, 每个待比较处理策略都有正概率或数据支持。
忠实性	分布中的条件独立都来自图中 d -分离, 而不是参数精确抵消。
中介	位于处理到结果因果路径上的变量; 是否调整取决于总效应或直接效应目标。
自然直接效应	把中介保持为基准处理下自然值时改变处理的嵌套反事实效应。
总体效应	在干扰或市场均衡情形中, 改变全体处理策略或覆盖率所造成的总体结果变化。

术语	本书用法
最小充分调整集	能阻断所有目标非因果路径, 且删除任一成员后不再充分的协变量集合。

B.1.1 常用符号

A, X 处理、暴露或干预变量; 具体含义由章节上下文说明。

Y 结果变量。

L, Z, C 协变量集合; 字母本身不保证其是混杂、中介或碰撞点。

U 模型边界外的外生背景变量。

$Y(a), Y_a$ 处理或干预设为 a 时的反事实结果。

pa_i 图中变量 V_i 的父节点集合。

$G_{\bar{X}}$ 删除所有指向 X 箭头后的图。

$G_{\underline{X}}$ 删除所有从 X 发出箭头后的图。

$\perp$ 统计条件独立或图中的 d-分离; 具体语义由下标和上下文决定。

B.2 时间线、学习路径与综合练习

B.2.1 选择性时间线

这份时间线只标记对本书主线有直接作用的文本与方法。日期表示作品发表或通常采用的版本年代, 不表示理论在该年一次完成, 也不构成“古代思想必然走向现代算法”的单线进步史。

年代	事件及其在本书中的意义
约前 350 年	亚里士多德《物理学》第二卷讨论四因，《后分析篇》把科学知识 with 把握“为什么”联系。
13 世纪	阿奎那在经院哲学框架中讨论第一因、次级原因与自然秩序。
1644 年	笛卡尔《哲学原理》以广延、运动和定律组织机械自然哲学。
1714 年	莱布尼茨《单子论》集中表述充足理由与前定和谐。
1739–1748 年	休谟《人性论》与《人类理解研究》分析恒常结合、必然性观念与归纳问题。
1781/1787 年	康德《纯粹理性批判》以经验第二类比论证客观事件次序需要因果规则。
1843 年	穆勒《逻辑体系》系统表述归纳方法与原因复合。
1912–1913 年	罗素《论因果概念》批评含混因果律在精确物理中的地位。
1923 年	Neyman 以潜在处理结果分析随机农业试验，奠定设计基础。
1935 年	Fisher《实验设计》系统发展随机化、重复与区组原则(Fisher, 1935)。
1955–1965 年	亨普尔等发展覆盖律科学解释模型，随后遭遇方向性与相关性反例。
1956 年	Reichenbach《时间的方向》系统讨论共同原因与概率筛除。
1964 年	Bell 提出可实验检验的不等式，限制局部隐藏变量解释。
1970 年	Suppes 系统发展概率因果理论。

年代	事件及其在本书中的意义
1973 年	Lewis 发表《反事实》和《因果》，建立可能世界与反事实依赖路线。
1974 年	Rubin 发表处理效应估计论文；Mackie 出版《宇宙的水泥》并系统分析 INUS 条件。
1983 年	Rosenbaum 与 Rubin 证明倾向得分在观察研究中的平衡作用。
1984 年	Salmon 出版《科学解释与世界的因果结构》，突出因果过程与网络。
1986 年	Holland 发表“统计学与因果推断”；Robins 发展时间变化处理的 g 方法。
1989 年	Cartwright 出版《自然的能力及其测量》，发展因果能力论。
1993/2000 年	Spirtes、Glymour 与 Scheines 系统发展基于约束的因果发现；后续版纳入更完整理论。
1995 年	Pearl 正式发表因果图中的行动演算，即 do-calculus。
2000/2009 年	Pearl《Causality》第一版与第二版系统统一 SCM、干预、识别与反事实。
2000 年	Lewis 发表《作为影响的因果》，以事件变化处理部分先占问题。
2000 年	Machamer、Darden 与 Craver 发表机制概念经典论文。
2003 年	Woodward《Making Things Happen》系统提出干预主义因果解释。
2006 年	Shimizu 等提出 LiNGAM；Shpitser 与 Pearl 证明干预分布识别的完备结果。

年代	事件及其在本书中的意义
2008 年	Hudgens 与 Halloran 形式化有干扰时的直接与间接效应。
2012–2016 年	Pearl、Bareinboim 等系统发展选择图、可迁移性与数据融合。
2016 年	Hernán 与 Robins 系统倡导用观测数据模拟目标试验。
2018 年	Chernozhukov 等发表 Double/Debiased ML; Zheng 等发表 NOTEARS; Wager 与 Athey 发展因果森林推断。
2019 年	Runge 等系统发表 PCMCI 相关高维时间序列方法; 广义随机森林框架发表。
2021 年	因果表示学习与独立机制研究形成系统综述; 现代多期 DID 异质效应方法集中发表。

B.2.2 六周核心路径

适合已经有概率统计基础、希望快速掌握主线的读者。每周建议投入 6 至 8 小时。

1. **问题与历史**：第 1、2 章。写出关联、干预、反事实和实际因果各一个例子，并重构一条历史论证。
2. **当代哲学**：第 3 章。比较反事实、概率、机制与干预证据在一个医学案例中的接口。
3. **两种形式语言**：第 4、5 章。把一个潜在结果模型翻译成 DAG 与 SCM。
4. **识别与估计**：第 6、7 章。手工推导后门与前门公式，并为同一目标比较估计器。

5. **发现与迁移**：第 8、9 章。审查一个发现算法，并把试验结果标准化到目标总体。
6. **应用与综合**：第 10、11 章。完成一份从目标、识别到部署边界的研究方案。

B.2.3 十二周课程路径

周	阅读	核心作业
1	第 1 章	把三个公共问题改写成明确因果查询。
2	第 2 章	重构四因、休谟归纳和覆盖律论证，不使用现代术语替代原论证。
3	第 3 章	分析先占案例，并比较概率、机制与干预理论。
4	第 4 章	定义 ATE、处理版本和时间零点，逐行推导标准化公式。
5	第 5 章	对三个 DAG 判断 d-分离，写出结构方程和干预分布。
6	第 6 章	找调整集，推导前门公式，并完成一次结构反事实计算。
7	第 7 章	比较 g 计算、IPW、AIPW 与 DML 的目标、诊断和不确定性。
8	第 8 章	选择一种发现算法，制作“假设—输出—失败”表。
9	第 9 章	把试验结果迁移到目标总体，报告重叠与测量限制。

10	第 10 章前半	设计异质性验证和策略评价，不以预测误差替代因果评价。
11	第 10 章后半	用一个跨学科案例完成目标、识别、估计与部署审计。
12	第 11 章	提交完整研究方案并进行结构化同伴审查。

B.2.4 综合研究作业模板

最终作业不要求真实数据计算，而要求提交一条完整、可审计的因果推理链。

1. **问题**：用一句话写明单位、处理策略、对照、结果、时间和目标人群。
2. **目标**：给出符号定义和效应尺度，说明为何适合决策。
3. **设计**：写出理想目标试验或准实验制度。
4. **结构**：提交 DAG、节点字典、时间顺序和每条关键边的依据。
5. **识别**：逐步推导观测数据公式；若不可识别，给出界限或所需新数据。
6. **估计**：选择方法、诊断、标准误和缺失处理，但不以软件名称代替理由。
7. **稳健性**：至少处理一个未测混杂、一个选择或测量问题和一幅替代图。
8. **迁移**：定义源域、目标域、效应修饰与机制变化。
9. **解释**：区分效应估计、机制解释与个例归因。
10. **伦理**：指出结果选择、干预可接受性和群体分配中的规范判断。

B.2.5 同伴审查问题

审阅他人方案时，按以下顺序提问：

1. 研究问题是否在看到数据和方法之前已经有明确含义？
2. 目标量是否与文字问题一致，还是只因软件容易计算而选择？
3. 每项识别假设能否用领域语言解释？
4. 图中是否遗漏选择、测量、处理版本、时间与干扰？
5. 估计方法是否与目标人群和重叠范围一致？
6. 置信区间之外还有哪些结构不确定性？
7. 结论是否从样本平均效应过度推广到个体、机制或其他人群？
8. 哪一项新测量或实验最能改变当前结论？

B.2.6 原始文献阅读法

阅读因果论文时，不要只摘取“核心观点”。建议在每篇文献上记录：作者要解决的旧问题；正式对象与符号；定理的全部条件；例子承担的是证明、直觉还是反例；结论没有覆盖什么；后续文献修正了哪一项。对于哲学文本，还要区分作者主张、论敌立场和后世标签。

二手综述适合建立地图，原始文献用于确认道路是否真实存在。若标题、年份或定理无法在出版物与作者存档中核实，应暂停使用，而不是以流畅摘要填补证据空白。

本章小结

时间线展示的是多条问题传统的交汇，而非单线进步。六周路径适合快速建立框架，十二周路径适合系统课程。综合作业以完整推理链而非代码或点估计为验收对象；原始文献阅读应记录问题、对象、条件、结论与边界。

综合练习与参考分析

本附录提供的是分析骨架，不是唯一标准答案。因果问题通常容许多幅合理模型；评分重点应放在目标是否明确、假设是否公开、推导是否有效，以及结论是否忠实于证据边界。建议先独立完成题目，再对照参考分析，并主动构造一个会改变答案的替代模型。

C.1 概念、历史与哲学

练习一：把宽泛问题拆成查询

题目。某大学发现经常参加学习中心辅导的学生平均成绩较高，校方提出“辅导提高成绩”。请把这句话拆成关联、干预、机制、个例和政策问题，并定义一个可研究的主要目标。

参考分析。关联问题是 $E(Y | A = 1) - E(Y | A = 0)$ ，其中 A 表示实际参加辅导， Y 表示学期成绩。干预问题必须指定策略，例如“在开学第二周向符合条件的一年级学生提供每周两小时、连续十二周的小组辅导，相比只开放普通答疑，对期末标准化课程成绩的平均影响”。机制问题可追问辅导是否通过增加练习、纠正误解、

同伴规范或教师关注起效。个例问题是某位学生这次及格是否由辅导造成；政策问题还要考虑资源、机会成本与不同群体可及性。

潜在混杂包括原有能力、学习动机、时间资源、课程难度和求助倾向。若较主动学生更常参加，他们本来就可能成绩更高。处理还有多版本：一对一和小组、线上和线下、出勤频率不同。主要目标可以定义为所有符合资格新生中“被提供并积极邀请参加标准辅导方案”的意向治疗效应；这样比“实际出勤”的效应更接近校方可执行政策，也减少依从选择，但估计的是提供策略而非每小时辅导的生物式剂量效应。

机制证据、平均效应与个例归因不能互换。若随机邀请提高总体成绩，仍需过程数据理解为什么；若某学生在辅导后明显进步，也不能仅凭时间先后确认个例原因。一个合格答案应让每个问题对应不同证据，而不是用“相关不等于因果”结束讨论。

练习二：四因与现代解释

题目。用亚里士多德四因和现代机制语言分别解释一座桥为何能够承重，并指出哪些翻译成立、哪些只是类比。

参考分析。质料因包括钢材、混凝土与连接件；形式因包括拱、桁架、梁和载荷分布的结构；动力因包括设计、施工与具体受力过程；目的因是跨越障碍并安全运输。现代工程模型可把材料强度、几何结构和施工误差放入力学方程，并通过载荷试验研究改变某部件的后果。

材料与结构可以较自然地分别对应构成与组织，施工和受力机制对应某些动力因。但形式因不等于 DAG 中的一个“形状变量”：结构是模型对象及约束方式，可能分布在许多变量关系中。目的因在人工物中来自设计功能，可转化为验收指标，却不由桥

未来通行反向施力。设计目的也不保证实际效果，一座为了抗震而设计的桥可能因施工缺陷失败。

完整工程解释需要多层：力学定律限制可能响应，具体材料和边界条件决定实例，制造记录说明缺陷来源，功能标准说明为什么关注某类失效。现代模型没有证明四因说整体正确，也没有让所有非动力解释消失。严谨答案应避免“亚里士多德预见工程系统论”与“现代科学只剩动力因”两种极端。

练习三：休谟、康德与一条新规律

题目。一个算法在过去十年数据上准确预测电力需求。分别用休谟和康德的视角说明我们能否相信下一年预测，并给出现代研究设计回应。

参考分析。休谟会指出，过去准确到未来准确的跨越不是演绎：政策、气候、产业和用户行为可能变化。用“过去十年关系稳定”证明“下一年仍稳定”正使用待辩护的归纳。准确率说明形成期待的经验基础很强，却不构成必然纽带。

康德的问题更一般：要把负荷变化理解为客观事件秩序，我们必须以规则组织经验，而非把时间序列看作任意表象。但先验因果原则不会告诉我们具体算法或需求规律为真；具体规律仍需经验判定。因此康德回应休谟的层级，不是给每个预测模型一张可靠性证书。

现代回应可把稳定性拆分。建立结构图，区分天气、价格、工作制度和模型输入；用滚动时间验证而非随机打乱交叉验证；在疫情、价格改革和极端天气环境中压力测试；若模型用于调价，还要把预测造成的行为反应纳入。可为不同机制变化建立情景，而不是假定联合分布整体不变。结论应是“在指定变化集合和监测

规则下可暂时部署”，而非“历史准确证明未来必然准确”。

练习四：先占与过度决定

题目。两套独立消防喷淋同时启动，任一套单独都足以扑灭火灾。实际火灾被扑灭。两套系统是否都是原因？比较若无检验、过程理论和结构模型。

参考分析。对任一系统，若它不启动，另一套仍足够，所以简单若无检验判定它不是必要原因。直觉可能认为两套都对扑灭有因果贡献，这属于对称过度决定。过程理论可追踪两股水流都到达火源并吸收热量，支持两条实际过程；如果一套水流实际上被墙挡住，它虽有备份能力，却没有参与实际过程。

结构模型可设 $F = 1$ 表示扑灭， S_1, S_2 表示启动，方程 $F = S_1 \vee S_2$ 。不同实际因果定义允许把另一变量固定为反事实 0，从而使每个 S_j 在应急情形中关键；但允许何种应急决定答案。若问“哪套系统必须正常才能保证在单故障下安全”，两套冗余都重要；若问“哪股水实际冷却了火源”，需要连续过程数据。

责任判断又不同。若一套由承包商维护失败但另一套成功，故障系统不是扑灭原因，却可能是风险增加或违反义务的原因。答案必须说明结果描述、候选事件粒度和规范问题。只说“两个都是”或“两个都不是”而不标明查询不够完整。

练习五：整合概率、机制与干预证据

题目。一种食品添加剂与过敏急诊相关。动物实验显示它可激活炎症通路，小型随机挑战试验结果不确定。构造证据整合方案。

参考分析。先定义处理版本、剂量、摄入时机和目标过敏人群。观察关联可能由饮食结构、既往过敏和医疗利用混杂；急诊记

录还受就医选择影响。应画出这些路径，并在可行范围内调整或使用自我对照、政策变更等设计。

机制证据说明一条可能通路，但动物剂量、物种差异和人类代谢限制迁移。可在人类样本测量相应生物标志、时间顺序和剂量反应，并检验阻断通路是否改变反应。随机挑战试验内部效度较强，但样本小和严重过敏者被排除会限制精度与外部效度；不确定区间不能简单读成“无效”。

概率、机制和试验结果应在共同模型中对照。若观察效应只在机制标志阳性者出现，支持异质性；若随机挑战无任何短期标志改变，而动物所需剂量远高于人类暴露，机制解释减弱。最终可报告效应界限、易感亚组和还需多大样本，而不是用“有机制所以因果”或“试验不显著所以安全”作二元结论。

C.2 形式基础与研究设计

练习六：d-分离与选择偏差

题目。医生能力 D 与患者严重度 L 都影响是否转入专科中心 S ； D 影响治疗质量 A ， L 和 A 影响康复 Y 。研究只使用 $S = 1$ 患者。分析 D 与 L 、 A 与 Y 的路径。

参考分析。图含 $D \rightarrow S \leftarrow L$ ，给定入中心 $S = 1$ 打开能力与严重度之间的路径。在中心样本中，高能力医生可能接收相对不严重患者，低能力地区只有极严重者被转入，形成负关联。又有 $D \rightarrow A \rightarrow Y$ 、 $L \rightarrow Y$ ；打开的 $A \leftarrow D \leftrightarrow L \rightarrow Y$ 路径（其中关联由选择产生）会混杂治疗质量与康复。

仅调整样本中的 L 可能阻断这条特定路径，但如果转诊还受早期结果、资源或未测医生判断影响，选择结构更复杂。目标若是

中心患者中的处理效应，与全体患者中的效应不同；迁移到全体还需中心参与概率和效应修饰变量。

可行设计包括收集所有转诊候选者、记录转诊规则、使用选择权重，或在中心内部随机质量改进措施。答案应明确条件化碰撞点不是说研究必然无效，而是样本选择改变了哪些关系、需要哪些额外数据修复。

练习七：潜在结果表与选择

题目。六个人的 $(Y(1), Y(0))$ 依次是

$$(1, 0), (1, 0), (1, 1), \quad (0, 0), (0, 1), (0, 0).$$

计算 ATE。若前三人接受处理、后三人未处理，观察均值差是多少？解释差异。

参考分析。个体效应依次为 $1, 1, 0, 0, -1, 0$ ，总和 1，所以 ATE 为 $1/6$ 。实际处理组观察 $Y(1) = (1, 1, 1)$ ，均值 1；对照组观察 $Y(0) = (0, 1, 0)$ ，均值 $1/3$ ，观察差为 $2/3$ 。它远大于 ATE，因为赋值把本来在处理下结果较好的人集中到处理组。

该表还显示对照中第五人受处理会受害，但平均差掩盖这种异质性。若随机分配，期望上的组间差等于 ATE，但单次小样本仍会因随机不平衡偏离。扩大样本降低随机误差，不会修复系统选择。

观察研究需要找到使赋值与两列潜在结果可交换的协变量。若前三人的选择由可测基线能力决定，分层可能有效；若由未记录预后判断决定，无法从这张观测表确认。潜在结果框架把问题定位在缺失的反事实列与赋值机制，而不是只比较一个回归系数。

练习八：标准化数值计算

题目。目标人群中 $P(L = 1) = 0.4$ 。观测数据给出 $E(Y | A = 1, L = 1) = 0.7$ 、 $E(Y | A = 0, L = 1) = 0.5$ 、 $E(Y | A = 1, L = 0) = 0.3$ 、 $E(Y | A = 0, L = 0) = 0.2$ 。在条件可交换、一致和正值下计算 ATE，并说明每项假设失败的后果。

参考分析。处理下标准化均值为 $0.4 \times 0.7 + 0.6 \times 0.3 = 0.46$ ；不处理为 $0.4 \times 0.5 + 0.6 \times 0.2 = 0.32$ ，ATE 为 0.14。不能直接按处理组自己的 L 分布加权，因为那会保留处理选择造成的构成差异。

条件可交换性要求给定 L 后处理不再包含潜在结果信息；若还有未测严重度，条件均值不能替代反事实均值。一致性要求观测处理与定义的 a 对应；若不同剂量混合且效果不同，四个条件均值没有统一干预含义。正值性要求两个 L 层都有两种处理；若 $L = 1$ 者从不未处理，0.5 只能来自模型外推而非该数据层。

估计阶段还会有抽样误差，但题目给的是总体条件均值，所以 0.14 是识别函数值。把识别假设与有限样本置信区间分开，是本题的关键。

练习九：调整集争议

题目。 C 影响处理 X 和结果 Y ； X 影响中介 M ， M 影响 Y ； X 和未测 U 都影响副作用 R ， U 影响 Y 。讨论估计总效应时调整 C, M, R 的后果。

参考分析。 C 位于 $X \leftarrow C \rightarrow Y$ 后门，应调整。 M 位于目标有向路径 $X \rightarrow M \rightarrow Y$ ，调整会阻断间接效应，得到某种直接关联而非总效应。 R 是 $X \rightarrow R \leftarrow U \rightarrow Y$ 中碰撞点，默认关闭；调整 R 打开 X 与 U 的非因果路径。

因此总效应的标准充分集是 $\{C\}$ ，而不是所有三个变量。若目

标改为受控直接效应，需要定义对 M 的联合干预并处理 $M \rightarrow Y$ 混杂；仍不能随意调整 R 。若 R 还是失访原因，只观察 R 某状态者，选择偏差已经进入数据，需要显式建模。

本题强调变量角色相对目标与时间。软件中“加入更多控制后系数改变”不能判断哪个更因果；改变可能来自去混杂、过度调整或碰撞偏差。答案应由路径而非显著性选择。

练习十：前门条件破坏

题目。广告 X 通过品牌认知 M 影响购买 Y ，消费者兴趣 U 混杂广告曝光与购买。讨论前门识别，并分别加入以下边： $X \rightarrow Y$ ； $U \rightarrow M$ ； $V \rightarrow M, Y$ 。

参考分析。基础图若所有广告效应都经 M 、 $X \rightarrow M$ 无未阻断后门、给定 X 后 $M \rightarrow Y$ 后门被阻断，则前门公式成立。 $X \rightarrow Y$ 加入一条不经中介的直接路径，违反 M 截断所有有向路径；仅通过品牌认知不能恢复总效应。

$U \rightarrow M$ 使 $X \leftarrow U \rightarrow M$ 成为 $X \rightarrow M$ 后门，第一段效应不能由 $P(m|x)$ 识别。 $V \rightarrow M, Y$ 是中介—结果未测共同原因，即使给定 X 仍开放，第二段效应失败。三种破坏对应前门三条件，不能用“我们测了一个中介”概括。

修复可能分别是：测量并建模直接路径所需机制、测量 U 并调整第一段、测量 V 或随机干预中介。现实广告还可能有处理版本、竞争溢出与测量误差，使基础前门条件很强。合格结论应说“在这些结构条件下可识别”，不是“前门解决所有未测混杂”。

练习十一：权重诊断

题目。ATE 加权分析中，倾向得分最小 0.01、最大 0.995，权重最大 200，有效样本量从 5000 降到 430。研究者把权重截断到 99 百分位后得到更窄区间。如何报告和解释？

参考分析。极端倾向表明某些协变量层几乎只接受一种处理，实践正值性严重。最大权重 200 意味着少数反事实比较支配总体，原始 5000 不能代表实际信息量；有效样本量 430 更接近精度警告。

截断降低方差和单点影响，却改变了估计方程并引入偏差；更窄区间不表示识别更可信。应报告截断前后权重分布、平衡、有效样本量和效应，说明 99 百分位为何选择，并比较重叠人群目标或限制目标人群的分析。

还应回到处理定义与协变量：极端概率可能来自结构性禁忌，此时 ATE 对该人群没有现实支持；也可能是过拟合倾向模型，需简化或交叉拟合；若强处理预测变量不是混杂，可移除以改善精度，但必须确认路径。不能只调截断阈值直到结果显著。

C.3 发现、迁移与机器学习

练习十二：发现算法输出

题目。PC 算法输出 $X - Z - Y$ ，两条边均未定向，没有碰撞点。团队报告“发现 X 通过 Z 导致 Y ”。评价这一结论，并设计下一步。

参考分析。无碰撞三节点骨架对应 $X \rightarrow Z \rightarrow Y$ 、 $X \leftarrow Z \rightarrow Y$ 、 $X \leftarrow Z \leftarrow Y$ 等 Markov 等价结构。观测条件独立最多支持 $X \perp\!\!\!\perp Y | Z$ 与相应骨架，不能在当前假设下确定中介方向。团队把等价

类中的一个代表当真图，主张过度。

下一步可利用时间：若 X 明确先于 Z 、 Z 先于 Y ，可排除部分方向，但共同原因和测量滞后仍需考虑。可对 X 随机或自然干预，看 Z, Y 分布；也可干预 Z 区分中介与共同原因。非高斯函数模型提供方向时，应单独论证独立噪声与无隐藏混杂。

报告应保留 CPDAG，展示边在重采样与不同条件独立检验下稳定性，并说明若三种方向分别成立，对目标效应识别有何不同。发现的正确产出是候选结构与最有信息的新实验，而非一条未经验证的故事。

练习十三：试验迁移

题目。药物试验中 20% 参与者超过 65 岁，目标临床人群中 60% 超过 65 岁。试验分层风险差分别为年轻人 -0.03 、老年人 -0.12 。计算目标 ATE，并审查迁移假设。

参考分析。若年龄层内试验效应可迁移，目标风险差为 $0.4 \times (-0.03) + 0.6 \times (-0.12) = -0.084$ 。试验未经加权 ATE 是 $0.8 \times (-0.03) + 0.2 \times (-0.12) = -0.048$ 。差异来自效应异质性与人群构成。

计算还需要两年龄层在试验中都有足够样本，且年龄已阻断试验参与与潜在结果差异。若老年试验参与者更健康、合并用药更少，年龄分层不足；需测量相应效应修饰或机制。处理剂量、依从、结局测量和医疗背景也应跨域一致。

老年层只有少量试验参与者时， -0.12 估计不精确，加权会放大方差。应报告分层区间、参与权重与有效样本量，必要时在目标域开展补充试验。标准化公式给出识别逻辑，不保证数据支持充分。

练习十四：异质性模型验证

题目。一个因果森林声称能准确预测每位患者的治疗效应。它在训练数据中把患者分为“获益”“无获益”两组，两组观测效应显著不同。设计可信验证。

参考分析。首先限制语言为 CATE 预测，不宣称恢复确定个体效应。用独立随机试验或未参与训练的折，固定模型和分组阈值。在每组中按原随机化比较处理与对照，估计组内效应和区间；检验预测效应的校准与排序，而不是把训练分组差异重复当验证。

检查每组处理重叠、样本量和特征范围。若模型只在高基线风险者预测高获益，要区分风险预测与效应修饰。使用策略价值评估模型诱导的治疗规则，并与“全部治疗”“无人治疗”和简单临床规则比较，纳入治疗成本。

在另一医院外部验证，检查测量、处理版本与机制变化。若只能保持排序而数值失准，可用于优先排序但不能直接计算净收益。变量重要性不应解释为变量自身造成异质性。最终报告模型失败群体和不确定性，而不是给每人一个无区间的“个体效应”。

练习十五：模拟目标试验

题目。用电子病历比较开始降压药与暂不开始对一年卒中的影响。列出目标试验协议和最常见时间偏差。

参考分析。资格可定义为某日首次达到血压阈值、过去一年未使用该类药物且无近期卒中；策略为资格日开始指定药物方案与当日暂不开始；分配在理想试验中随机；随访从同一资格日开始到一年、卒中、死亡或失访；结局为预先定义的卒中；主要对比可为意向策略风险差。

观测模拟需在每个资格时点识别新使用者，测量此前病情、医

疗利用、合并用药和医生决策相关协变量。若把实际开始者从处方日计时、未开始者从更早门诊计时，会有时间零点错位；若“使用者”要求未来连续服药三个月，这三个月形成不死时间。把既往使用者与新使用者混合还会产生存活与耐受选择。

治疗随时间改变时，可估计初始策略效应，或定义依从动态策略并使用删失权重。死亡可能是竞争事件，目标应明确卒中累积风险还是无死亡世界中的假想效应。目标试验不会消除未测医生判断，但让该问题及所需敏感性分析清楚出现。

C.4 综合、比较与因果审计

练习十六：框架翻译

题目。潜在结果分析假设 $Y(a) \perp\!\!\!\perp A \mid L$ 。用 SCM/DAG 表示，并说明图表达比该单一条件多了什么、少了什么。

参考分析。可构造 $L = f_L(U_L)$ 、 $A = f_A(L, U_A)$ 、 $Y = f_Y(A, L, U_Y)$ ，并假定相关外生变量独立。DAG 有 $L \rightarrow A$ 、 $L \rightarrow Y$ 、 $A \rightarrow Y$ ； L 阻断 A 与 Y 的后门，于是图蕴含对应可交换性。

图额外明确 L 、 A 、 Y 的直接关系和缺边，能够与其他变量、中介、选择组合并用于 do-calculus。完整 SCM 还定义 L 、 A 的反事实和多节点干预。潜在结果条件则只承诺目标处理的比较，可能不需要为所有变量指定结构。

反向翻译也非唯一：多幅图可蕴含同一可交换条件，条件本身不说明 L 内部因果关系。若 L 是一组变量，某些可能为碰撞点，简单写“给定 L 可交换”需外部依据。翻译的目的不是宣布框架等同，而是查明共同识别内容与额外承诺。

练习十七：跨文化比较的边界

题目。有人说“佛教缘起就是现代因果网络，因此古代已经发现因果图”。请给出学术上可接受的改写。

参考分析。原说法把宽泛的条件依存与具有精确 d-分离、Markov、干预语义的 DAG 等同，缺乏历史和形式根据。缘起在佛教文本中服务于苦、无常、无我与解脱论证，不只是变量关系；“因”“缘”也有不同论书分类。现代 DAG 则是概率与结构模型工具。

可接受改写是：“缘起与现代因果模型都反对把现象理解为完全孤立自存，并重视条件结构；比较二者对依赖、实体和干预的不同处理，可以澄清各自问题。”随后应选具体文本，说明译本与诠释传统，再选现代模型的具体概念，而非用“网络”作模糊桥梁。

若要经验研究佛教修行的后果，应重新定义可执行干预、目标人群与结果，不能从缘起教义直接推出疗效。若用 DAG 表示十二支，也应声明这是当代分析重构，不是原文本隐藏的数学模型。比较的价值在揭示相似与不可互译之处，而非争夺发现优先权。

练习十八：自由意志实验推论

题目。一项脑成像模型在参与者报告选择前五秒以 60% 准确率预测左右按键。媒体称“科学证明自由意志不存在”。分析推理缺口。

参考分析。观测结论是某些脑信号对简单按键有略高于机会的预测信息。它不说明单次选择已不可逆决定，不说明信号是决定原因而非准备偏向，也不说明主观报告时间精确。40% 错误还表明模型远非完全预测。

任务是无理由的任意选择，与长期审议、道德行动和自我控制

不同。从“行动有先行神经条件”到“不自由”还需接受自由必须由无神经原因的意识瞬间启动；兼容主义拒绝这一前提，并把理由响应的神经实现视为自由机制的一部分。

实验可以改进我们对意识时序和决策积累的理解，也可检验强迫、病变怎样影响控制。它不能独自判定决定论或责任。合格报道应写“预测到准备偏向，对某种即时内省模型构成挑战”，而非把哲学结论伪装为分类准确率。

练习十九：量子因果的误用

题目。评论命题：“纠缠粒子彼此瞬时影响，所以所有相关都可能是真因果，社会科学不必控制混杂。”

参考分析。 Bell 违反排除的是满足特定局部性、测量独立等条件的经典隐藏变量分解，不证明任意相关都是直接因果。量子相关通常满足无信号，不能用于可控超光速通信。“影响”在量子因果模型中需要以允许的操作和通道精确定义。

社会科学变量由宏观经典测量与制度过程产生，混杂、选择和测量误差仍按相应模型分析。除非研究具体量子系统，不能用微观量子形式替代对教育、收入或政策共同原因的控制。跨层类比没有给出可检验数学结构。

更一般的教训恰好相反：每个因果模型有适用域，超出时应提出更精确模型和实验，而不是放弃结构约束。量子理论对经典局部模型的成功挑战来自明确不等式和可重复实验，不来自“世界神秘所以任何解释皆可”。

练习二十：完整因果审计

题目。某市用风险模型决定谁接受强化就业服务，一年后接受者就业率高，政府准备全面按模型部署。请提交审计摘要。

参考分析。首先区分风险预测与服务效应预测。模型可能把本来最容易就业者选入，接受者高就业率不能说明服务有效。定义目标：对符合条件失业者，提供标准强化服务相对普通服务，对一年稳定就业和收入的平均及分组效应。明确模型推荐、实际接受和依从是不同变量。

绘图纳入基线技能、健康、求职动机、工作人员判断、服务分配、实际参与和就业；工作人员未记录判断可能混杂。若政策已经按风险确定分配，某些层没有对照，正值性不足。可在政策边界随机鼓励、分阶段随机推出，或在公平可接受范围保留探索。

审查结局测量：行政就业是否漏掉非正规工作，服务是否改变记录概率；审查干扰：服务名额和劳动力竞争使一个人接受影响他人；审查迁移：试点期人员和资源是否能在全量覆盖保持。按群体报告支持、效果和错误，不把受保护属性的预测重要性当因果理由。

决策层面比较服务成本、可能伤害和分配目标。上线后记录推荐、实际服务与结果，预先设漂移和暂停阈值。最终结论若证据不足，应是“现有关联不能识别服务效应；建议在指定人群开展随机分阶段评估”，而不是用模型预测准确率为政策因果性背书。

本章小结

二十道练习反复使用同一纪律：先写查询和目标，再画结构、列假设、证明识别、选择估计、检查迁移与规范边界。参考分析刻意保留不确定性，因为成熟因果推理的产物不是总有一个点

答案，而是一条能被复核、反驳和改进的推理链。

核心原始文献精读指南

本附录不是书目重复，而是一份阅读任务说明。每组文献都列出进入问题、应重构的论证、容易误读之处以及读后应形成的产出。自学者不必一次读完全部原著；应先选择与自己的路径相符的十组，并用文末模板留下可核查笔记。

D.1 如何精读因果文献

阅读之前先写下作者试图解决的既有困难，不要从当代教科书标签倒推。阅读过程中分开记录定义、假设、论证、例子与修辞性评价。一个例子可能只是帮助直觉，并不证明定理；一个定理可能只在无隐藏混杂、线性或忠实性下成立，不能把标题当作无条件结论。

对哲学文本，至少重构一个前提—结论链，并写出最强反例；对技术论文，至少写出输入、输出、识别条件和失败证据；对应用方法，至少说明其目标人群与局部性。所有直接引语保留页码，所有二手概括回到原文确认。若原文与本书表述冲突，应以原文和最新勘误为准，并记录为何修订。

D.2 因果哲学与科学解释

第一组：亚里士多德的“为什么”

核心阅读是《物理学》第二卷第三章及第七至九章，与《后分析篇》第一卷相关章节(Aristotle, 1994, 1996)。进入问题不是“哪四个变量导致结果”，而是自然知识需要哪些类型的说明。读者应把质料、形式、动力和目的分别应用于人工物与自然物，比较目的在两类对象中的来源。

第二项任务是重构“偶然”与“自发”为什么没有消除自然目的。不要把亚里士多德目的论读成未来事件向过去传力，也不要把形式因简化为几何形状。读后产出应是一张两栏表：原文中的解释角色；现代机制、结构或功能语言能否部分重述。对于不能重述之处，应说明是理论冲突还是问题不同。

第二组：休谟的两条论证

阅读《人性论》第一卷第三部和《人类理解研究》第四至七节(Hume, 1999, 2000)。把两条论证分开：一条追问因果必然性观念的印象来源，另一条追问从过去到未来的归纳如何得到理性辩护。两条论证相关，却不是同一结论。

抄录并比较《研究》中关于原因的两种定义：对象间恒常结合与心灵从一个观念过渡到另一个观念。标记休谟何处作心理发生学说明，何处对客观关系保持怀疑。常见误读是把他压缩为“相关即因果”或“否认因果存在”。读后应提交一个现代例子，分别指出观察到的规律、由习惯形成的期待、额外的不变性假设和可能的机制证据。

第三组：康德的经验第二类比

阅读《纯粹理性批判》A189/B232 以后关于经验第二类比的论证(Kant, 1998)。先解释知觉顺序为何可逆，而对象事件顺序为何需要规则规定。房屋与船的对比不只是例子；它承担从主观表象顺序到客观变化判断的关键工作。

读者应区分三项命题：一般因果原则是经验可能条件；具体自然规律来自经验；物自身是否服从因果不由现象知识决定。常见误读是说康德以先验哲学证明每个通俗因果判断都真。读后用一段话回答：康德回应了休谟的哪个问题，又没有回应哪个统计识别问题？再把“规则”与现代结构不变性作有限比较，明确二者的理论背景差异。

第四组：穆勒、罗素与亨普尔的科学方法

从穆勒《逻辑体系》第三卷选读五法，再读罗素《论因果概念》和亨普尔关于 D-N 模型的章节(Hempel, 1965; Mill, 1974; Russell, 1912)。三者分别把经验比较、数学函数和解释论证置于中心，适合在同一案例中对照。

对穆勒，找出每种方法隐含的“其他条件相同”如何失败；对罗素，区分他批评的传统格言与现代干预因果；对亨普尔，重构解释项、被解释项和定律的逻辑关系。读后至少提交旗杆方向反例、共同原因反例和无关前提反例各一例，并说明现代 DAG 分别增加了哪种结构。不要简单写“机制论取代覆盖律”，而要说明覆盖律仍在哪些推导和统一任务中价值。

第五组：Lewis 的反事实理论

按《Counterfactuals》中的相似性语义、1973 年《Causation》、2000 年《Causation as Influence》顺序阅读(Lewis, 1973a, b, 2000)。先掌握反事实条件句的评价，再看因果依赖链，最后理解从“是否发生”转向“何时、如何发生”的修正。

为早期先占、晚期先占、对称过度决定和遗漏各画事件链。每个案例回答：简单若无检验结果是什么；直觉判断是什么；影响分析改变了哪项事件描述；相似世界排序是否已经使用因果知识。常见误记是把《作为影响的因果》写成 1986 年，或把所有反事实理论都等同于潜在结果。读后应说明可能世界语义与结构方程反事实在模型明确性上的区别。

第六组：概率、INUS 与因果过程

选读 Reichenbach 共同原因、Suppes 概率提升、Mackie INUS 和 Salmon 因果过程(Mackie, 1974; Reichenbach, 1956; Salmon, 1984; Suppes, 1970)。不要寻找一个统一定义，先问每位作者试图修复哪种前序理论不足。

为同一疾病案例写出概率提升、共同原因剔除、两个替代充分条件组合和一条实际过程。检查概率提升在分层后是否反转，INUS 中的充分性是否仅相对于模型背景，标记传递如何区分真实过程与伪过程。读后应比较“类型风险因素”和“具体病例原因”所需证据，并指出为什么群体概率、充分条件组合和能量/信息过程不能任意相互替换。

第七组：Woodward 的干预主义

阅读《Making Things Happen》关于干预变量、不变性和解释的核心章节(Woodward, 2003)。为一个三变量图写出合格干预条件：干预改变 X，切断其通常原因，并除经 X 外不影响 Y。再找一个人类无法实际操作但理想干预仍连贯的变量，解释“操纵主义”标签为何可能误导。

重点审查循环批评：判断干预没有旁路作用似乎已使用因果知识。Woodward 目标不是以非因果词彻底还原因果，而是阐明因果概念网络与科学解释。读后比较一条仅在观测样本拟合良好的关系和一条在多种干预下稳定的关系；说明后者为何更有解释深度，又在哪种机制改变时失效。

第八组：新机制论

阅读 Machamer、Darden 与 Craver《Thinking about Mechanisms》，再以 Glennan 的系统著作为扩展(Glennan, 2017; Machamer et al., 2000)。选择一个熟悉机制，分别列实体、活动、时空组织、起始条件、终止条件和现象。只列部件不算完成，必须说明活动如何连接并产生整体行为。

接着设计三个干预：移除部件、改变活动速率、打乱组织顺序。若模型真，应预言不同失效模式。记录机制图在哪些地方是已观察，哪些是推断，哪些只在体外系统确认。读后讨论机制完整性的相对性：解释药物副作用需要分解到哪层，评估总体政策又为何可能不需要穷尽微观过程。

D.3 潜在结果、结构图与识别

第九组：Neyman、Rubin 与 Holland

先读 Neyman 随机农业试验论文的英文译本，再读 Rubin 1974 和 Holland 1986(Holland, 1986; Neyman, 1990; Rubin, 1974)。追踪潜在结果如何从有限总体随机化进入更一般统计因果语言。写出个体效应为何不可观察、随机化怎样识别平均效应，以及随机化没有解决哪些问题。

特别核对 Holland 关于单位、处理和时间稳定性的讨论。不要把“Rubin 因果模型”理解成匹配软件，也不要将潜在结果当数据库中本可收集但漏掉的一列。读后为一个含糊处理提出两个版本，展示一致性如何因版本混合失败；再用一张六单位潜在结果表计算 ATE、观察差与随机化期望。

第十组：倾向得分与观察研究设计

精读 Rosenbaum 与 Rubin 1983 的平衡得分定义和定理(Rosenbaum, Rubin, 1983)。证明或用模拟理解：给定真实倾向得分，处理与协变量独立；但这并不意味着潜在结果在未测变量上平衡。区分倾向得分用于匹配、分层、加权和协变量调整的不同实现。

读者应记录定理需要的强可忽略性和正值条件，不把它们当倾向模型拟合后自动获得。构造一个处理预测准确率极高却重叠很差的例子，说明为何 AUC 不是主要质量指标。读后形成一页设计报告：变量选择的因果理由、匹配或权重规则、结果揭盲前平衡标准、丢弃单位、目标人群变化和标准误方案。

第十一组：Pearl 的《Causality》

技术主线建议读第 1 至 3 章：结构模型、因果图、干预、后门、前门和 do-calculus (Pearl, 2009)。先手算三节点链、叉、碰撞点的条件独立，再用结构方程验证。每次看到 $P(y \mid \text{do}(x))$ ，都写出被替换的方程和保留的模块。

三条 do-calculus 规则必须从原定理抄写一次，标明 $G_{\bar{X}}$ 、 $G_{\bar{Z}}$ 和祖先限制。不要用通俗“删除相关”替代图条件。读后手工完成后门和前门推导，并说明演算的完备性相对于什么模型类。书中关于反事实的章节可结合溯因—行动—预测练习；任何个体反事实数值都要标明结构函数和外生背景如何获得。

第十二组：目标试验与《What If》

阅读 Hernán 与 Robins 关于目标试验、标准化、IPW 和时间变化处理的章节 (Hernán, Robins, 2016, 2020)。选择一项电子病历研究，先写资格、策略、分配、时间零点、随访、结局、对比和分析，再看现有数据如何逐项模拟。

重点辨认不死时间、既往使用者、治疗—混杂反馈和信息性删失。对每种偏差写出时间图，而不只是列名称。读后比较基线处理的标准化公式与纵向 g 公式，说明普通调整处理后混杂为何同时阻断效应和打开路径。完成一份“不可模拟之处”清单，比假装观测研究等于随机试验更重要。

D.4 因果发现与结构学习

第十三组：因果发现基础

以 Spirtes、Glymour 与 Scheines 的系统著作为理论基础(Spirtes et al., 2000)。先掌握因果 Markov、忠实性、因果充分与 Markov 等价，再阅读 PC 和 FCI。手工从一个四节点分布的条件独立集合恢复骨架、碰撞点与 CPDAG。

每一次删边都记录条件集和检验不确定性；每一条未定向边都保留，不为了叙事完整任意定向。比较 PC 在隐藏混杂下为何失败、FCI 的圆圈端点表示什么。读后用模拟破坏忠实性和加入测量误差，观察输出变化。评价因果发现论文时，先问其输出是真 DAG、等价类还是得分最高代表，再看声明是否越过输出语义。

第十四组：ID 算法与中介效应

阅读 Shpitser 与 Pearl 的识别工作和 Pearl 中介论文，再以 VanderWeele 教材补充效应定义(Pearl, 2001; Shpitser, Pearl, 2006; VanderWeele, 2015)。不要求初学者完整实现 ID 算法，但要理解可识别与存在 hedge 的不可识别证据，以及完备性不等于图可从数据验证。

对中介部分，分别写总效应、受控直接效应、自然直接/间接效应和干预型效应的问题语言。用一幅含处理诱导中介—结果混杂的图检查传统系数分解。读后产出应标出每个效应需要的单世界或跨世界假设，并说明若政策只能够改变中介分布，哪种效应最有行动意义。

第十五组：LiNGAM、NOTEARS 与 PCMCI

阅读 LiNGAM 原文、NOTEARS 原文和 PCMCI 论文(Runge et al., 2019; Shimizu et al., 2006; Zheng et al., 2018)。为每篇写“额外方向信息来自哪里”：非高斯独立噪声、光滑无环约束结合评分模型、时间与条件独立筛选。注意 NOTEARS 的贡献首先是计算重参数化，原始论文发表于 2018 年。

复现实验时统一变量、样本量和超参数预算，分别报告骨架、方向和下游干预误差。加入隐藏混杂、反馈与采样频率变化作压力测试。读后不要问“哪个算法最好”，而要形成适用矩阵：何种数据、何种结构假设、输出不确定性、最可能失败方式、可用何种干预验证。

D.5 估计、迁移与因果机器学习

第十六组：双重稳健与 Double ML

先理解 AIPW 影响函数结构，再读 Double/Debiased ML 的正交得分与交叉拟合(Chernozhukov et al., 2018)。在部分线性模型中写出结果和处理残差，解释为何干扰函数的小误差对目标参数的一阶影响消失。用同折训练与交叉拟合比较过拟合偏差。

阅读时不要把“double”误解为两个机器学习模型投票，也不要把正交性理解为无未测混杂。记录参数模型：部分线性系数、ATE 或其他得分分别需要什么。读后报告学习器、折分单位、调参范围、重叠与标准误；若数据有患者重复记录或学校聚类，折分必须按独立单元而非行随机。

第十七组：异质性与因果森林

阅读 Wager 与 Athey 因果森林、广义随机森林与元学习器论文(Athey et al., 2019; Künzel et al., 2019; Wager, Athey, 2018)。比较分割标准、诚实样本分离和局部矩估计。为 S、T、X 学习器画出训练流程，说明样本不平衡时各自如何共享信息。

验证部分比训练结果更重要。预先固定模型，在独立随机数据中检查分组效应、校准、排序与策略价值。不要用普通个体 MSE，因为真实个体效应不可观察；不要把分割变量重要性解释为变量自身的因果效应。读后应能区分高基线风险、强处理效应与高净效用，并给每种用途选择相应评价指标。

第十八组：可迁移性与数据融合

阅读 Pearl 与 Bareinboim 的选择图工作及数据融合论文(Bareinboim, Pearl, 2016; Pearl, Bareinboim, 2014)。为源试验和目标人群画一幅选择图，把人口构成变化、处理机制变化和结局测量变化放在不同节点。尝试推导简单标准化迁移公式。

读者应区分样本“代表性”与效应相关机制的可比性。一个人口学不代表的试验可在测得关键修饰且有重叠时迁移；表面代表样本若处理版本和测量不同仍会失败。读后制作跨源变量字典，列出时间零点、量表、编码与机制稳定性。若目标域存在源域未覆盖层，应明确外推模型而非继续称非参数识别。

第十九组：准实验设计

断点回归阅读 Imbens 与 Lemieux，多期双重差分阅读 Callaway-Sant'Anna 和 Sun-Abraham，工具变量回到 Angrist、

Imbens 与 Rubin(Angrist et al., 1996; Callaway, Sant’Anna, 2021; Imbens, Lemieux, 2008; Sun, Abraham, 2021)。每种设计都写出制度来源、局部目标和不可检验假设。

断点需检查阈值操纵、其他政策跳变和带宽；DID 需检查反事实平行趋势、预期、错位实施与溢出；IV 需检查相关性、独立、排除和单调性。不要把“自然实验”当假设已经成立的认证。读后为同一政策比较三种设计可能估计的不同人群，并解释不同数值为何可能来自异质性而非哪篇论文错误。

第二十组：因果表示与开放问题

阅读 Peters 等教材关于独立因果机制、Peters 等不变预测论文，以及因果表示学习综述(Peters et al., 2016, 2017; Schölkopf et al., 2021)。先用可逆潜变量变换说明单环境重构为何不能唯一恢复因果变量，再标记多环境、干预、时间或弱监督提供何种额外信息。

对 OOD 主张，写清训练环境、目标环境可能改变的模块和保持稳定的条件机制。若环境改变结果机制本身，父变量预测也会失败。读后设计一个最小多环境实验，说明它区分了哪些表示、仍留下哪些等价。评价大型模型中的“因果概念”时，要求下游干预预测和机制稳定性证据，不以语义可读性或重构效果替代。

D.6 阅读产出与核验工具

文献笔记模板

每篇文献使用同一页模板：

1. **书目信息与版本**：标题、作者、年份、出版物、DOI 或稳定地址；使用哪一版、是否有勘误。
2. **问题**：作者反对或修正谁，问题为何在当时重要。
3. **对象**：事件、变量、潜在结果、图、机制还是策略。
4. **核心主张**：用自己的话写不超过三句，再给原文页码。
5. **假设**：逐条列数学与实质含义，区分定义、模型条件和经验前提。
6. **论证或定理**：从前提到结论写中间步骤，不以“作者证明”跳过。
7. **例子与反例**：例子支持哪个步骤，改变什么条件会失败。
8. **证据**：哪些来自数据、实验、历史文本或概念直觉。
9. **边界**：作者明确没有声称什么，后续研究指出什么限制。
10. **连接**：它与本书另一框架可否翻译，翻译增加或丢失什么。

完成笔记后，再写一段“最强反对意见”和一段“作者可能回应”。若无法准确表述反方，应继续阅读而非急于评价。每月选择一篇笔记回到原文复核，检查自己的摘要是否把条件删掉、把局部效应扩大或把例子当成定理。

怎样核验一个文献主张

读本、综述和讲义适合建立地图，却不应成为关键主张的终点。核验从“主张—出处配对”开始：把准备写进论文的句子拆成可核查单位，判断它声称的是作者原话、定理推论、经验结果、历史影响还是自己的综合判断。不同类型需要不同证据。定理应回到定义、假设和正式陈述；经验数值应回到样本、估计量、区间与附录；历史影响不能仅凭两篇文章主题相似，而需书信、引用史或可靠史学研究；综合判断则应明确标为解释，而不是借一条引文让来源承担没有说过的话。

找到原文后，先确认版本。经典著作可能有多个译本、分卷和页码系统；预印本、会议论文和期刊版可能在标题、定理编号或实验上不同。笔记中记录所用版本、出版年、稳定地址和访问日期；若引用页码，注明页码属于哪个版本。技术文献还应查看作者主页、期刊勘误、补充材料和后续修订。一个错误年份通常不会推翻理论，却会暴露文献链未经真正核对；本书因此把书目信息的准确性视为论证质量的一部分。

第二步检查上下文窗口。至少向前读到问题和定义，向后读到限制或例外。摘要中的“**identify**”“**robust**”“**generalize**”常有严格限定：识别可能只相对于一个非参数结构模型，稳健可能只针对两个干扰模型之一正确，泛化可能只覆盖给定环境族。只摘结果句而漏掉限定，会把局部结论扩成普遍承诺。哲学文本中也一样：作者可能在重构常识、提出条件分析、给出反例，或仅说明某种立场为何有吸引力，不能把每一句陈述都当最终主张。

第三步做符号与对象核对。同一个字母在不同论文中可能代表处理、工具变量或选择指标；“**direct effect**”“**individual effect**”“**cause**”也可能对应完全不同的对象。引用一个公式时，重写其随机变量、下标、条件集合和概率空间，并确认自己的问题使用相同单位与时间顺序。若从论文的二元处理推广到连续策略、从单时点推广到纵向、从独立单位推广到网络干扰，应把推广当作新的论证，而不是静默换词。

第四步检查结论在证明或设计中从哪里获得。对识别论文，逐行标出使用图分离、交换性、一致性、正值或函数形式的步骤；对估计论文，区分大样本性质、有限样本模拟和真实数据示例；对实验论文，检查分配、盲法、失访、主要结局与分析集；对算法论文，检查数据生成机制是否直接满足算法假设，以及评价指标是否能够观察真实目标。模拟表现说明方法在那些模拟世界中的行为，

不自动说明真实世界满足生成设定。

第五步进行反向引用检查。不要只看新论文如何引用经典论文，也看经典论文实际写了什么；不要只看作者怎样描述竞争方法，也找竞争方法的原始来源。若一个广为流传的说法始终只互相引用二手文献，找不到最初论证，应降低确信度。引用数量和期刊声望可以帮助排序阅读，不能替代内容核验。对争议性概念，最好寻找至少两种相反传统的代表文本，并把分歧落实到对象、判断和证据，而非以阵营标签结束。

第六步记录核验结果。建议在每条重要引文旁使用四级状态：已核原文与条件；已核原文但尚未复核证明或数据；仅由可信二手来源定位；暂未核验。写作交付前，所有承担核心论证的引文都应达到第一或第二级，第四级内容应删除或明确标记为待证。这个做法看似缓慢，却能防止错误在笔记、讲义和模型输出之间反复制。

关键辨析

DOI 存在、期刊真实、标题相关，只能证明文献存在，不能证明它支持当前句子。最常见的引文错误不是伪造文献，而是把真实文献放在一个它没有证明的主张后面。

如何读论文中的定理、图表与实验

定理阅读可分四层。第一层辨认对象：定理讨论分布、图、参数、算法输出还是渐近极限。第二层列出量词：结论是对所有模型、几乎处处、给定某个图，还是存在一种构造。第三层区分充分条件与必要条件；发现一个充分调整集，不代表其他集合都无效，证明某算法在假设下相合，也不代表假设失败时必然给出可识别的错误警报。第四层寻找否定结果：完备性、不可识别证书和下界

经常比一个新估计器更能界定问题。

面对证明，先写“证明路线图”，再补代数细节。路线图回答从哪个表示出发，中间使用什么独立性、分解或极限定理，最终把不可观测对象换成什么。若证明依赖附录中的正则条件，不应以“技术条件”统一略过；至少判断它控制的是重叠、光滑、复杂度、矩存在还是唯一性。真正影响应用边界的条件应译成领域语言。例如，正值不是抽象地要求概率大于零，而是要求目标人群的每个相关类型都有比较策略的经验支持。

读因果图时，先遮住论文给出的故事，只看节点、边、时间和选择。逐条检查是否有处理后的变量被当作基线混杂，是否把测量指标当成潜在构念本身，是否省略共同原因却又声称无隐藏混杂。然后恢复领域故事，判断每条排除限制是否可信。图表的清晰不等于结构正确；恰恰因为图把假设变得醒目，读者才应把争议画成替代图，而不是在同一图上争论直觉。

读结果表时，先找估计对象和分母。风险差、风险比、优势比与生存时间差不能只按显著性横向比较；ATE、ATT、LATE 和重叠人群效应也可能针对不同总体。随后看区间、标准误单位、缺失处理和多重分析。基线平衡表不能证明无未测混杂，处理模型的预测性能不能证明权重有效，普通拟合优度也不能证明因果结构。表格若只报告点估计而缺少有效样本量、权重尾部或重叠诊断，结论的可迁移范围通常难以判断。

读模拟实验时，建立“生成—观察—拟合—评价”四栏。生成栏写真实图、函数、噪声和异质性；观察栏写哪些变量被删去、聚合、测错或选择；拟合栏写模型实际看见什么及怎样调参；评价栏写指标是否针对结构、效应、预测还是决策。若训练和评价共享同一模型族，优异结果可能只说明模型设定匹配。应优先查看错误、低重叠、弱信号、隐藏混杂和样本量变化下的曲线，并关注失败是

否有诊断信号。

真实数据案例的任务通常是展示工作流而非验证真实因果效应，因为真实反事实不可见。判断案例价值时，看作者是否说明目标试验、变量时间、缺失、设计决策、敏感性和结论边界；不要用结论“看起来合理”评价方法正确。若不同合理设定产生不同结果，这不是必须隐藏的尴尬，而是暴露识别脆弱性的证据。好的论文会把这种研究者自由度转成规范曲线、敏感性区间或明确的替代分析。

从阅读笔记到一篇可审查的综述

综述不是逐篇摘要的堆叠。开始写作前，先规定比较轴：理论分析比较对象、反例和充分必要条件；方法综述比较目标量、识别条件、估计性质和诊断；应用综述比较制度、总体、时间、测量和可迁移性。同一段落若频繁在这些轴之间跳换，读者很难知道差异来自理论立场还是研究问题不同。

建立一张证据矩阵，每行为一项主张，每列记录原始来源、版本与页码、支持类型、关键条件、相反证据以及自己的判断。矩阵能够显示哪些段落只有单一来源，哪些重要争论没有反方，哪些引用只是背景而没有承担证据。正文中先写问题和争点，再按比较轴组织来源；年代顺序只在思想演变本身构成问题时使用。

写每一节时，可采用“共同问题—竞争回答—判别条件—当前边界”四段结构。先以中立语言说明各方共同面对的困难；随后尽可能强地陈述至少两种回答；再说明什么反例、数据或理论代价能够区分它们；最后标记现有证据仍未决定的部分。所谓“平衡”不是给每个观点相同字数，而是让每个观点在其最强版本上接受相同严格度的检验。

引用应紧贴它支持的句子，避免一段末尾堆放五个来源而不知各自作用。直接引语只用于措辞本身重要的地方，并控制长度；通常应以准确释义为主，同时提供页码。释义不能通过改写逃避忠实义务。若原文只说方法在某假设下相合，综述不能写成“该方法可以发现真实因果图”；若原文批评某种因果概念，不能扩成作者否认科学中的所有因果推理。

定稿前做三次分离审查。第一次只审书目事实：作者、年份、标题、版本和链接。第二次只审推理：每个“因此”是否由此前证据支持，每个比较是否使用相同对象。第三次只审范围：是否把局部平均扩成总体，把统计总体扩成个体，把识别结论扩成模型为真，把一种学科传统扩成全部因果概念。三次分开比一次笼统校对更容易发现系统性错误。

D.7 十二周原始文献研讨方案

若本附录用于小型读书会，可由三至六人组成，每周围绕一组主文献和一个共同案例展开。第一周读休谟与康德，建立“规律、必然性与客观顺序”问题；第二周读 Lewis 和概率分析，以先占与共同原因测试理论；第三周读 Woodward 和新机制论，对同一生物或工程系统分别写干预解释与机制解释。前三周的成果是一张概念地图，要求每条连接都注明是相容、竞争还是问题不同。

第四周读 Neyman、Rubin 和 Holland，手算有限总体随机化；第五周读 Pearl 的图与干预章节，完成后门和前门推导；第六周读目标试验材料，把一个公开的观察研究方案重新规定为理想试验。三周共同使用一个纵向案例，以便看见记号变化背后的共同目标，也看见 SUTVA、结构模块化和时间变化策略并非完全相同的假设体系。

第七周比较 PC、FCI、LiNGAM 和 NOTEARS，重点报告输出语义与失败模式，不做算法排行榜；第八周读 AIPW 和 Double ML，区分因果识别假设与灵活估计；第九周读异质性方法，用随机试验或半合成数据讨论可验证的分组效应与策略价值。每组报告必须包含一项负面结果或压力测试，防止研讨会只复述论文自选的成功示例。

第十周读迁移与数据融合，为源域和目标域画选择图；第十一周读不变预测与因果表示综述，讨论环境信息提供的额外识别；第十二周回到一个真实研究问题，提交预注册式方案和文献审计。最终展示按“问题、目标、结构、假设、设计、估计、反驳、范围”组织，不按软件流程组织。

每次研讨设置四个角色并轮换。陈述者负责忠实重构，不负责捍卫作者；审计者逐项检查版本、定义与假设；反对者提出最强反例和替代模型；迁移者尝试把结论用于新领域并标记失真。讨论结束时，全组只形成三类共识：原文明确支持的、在额外假设下可推出的、仍有争议的。强迫结论统一通常不如准确定位分歧有价值。

研讨的质量可以用可核查产出评价：是否留下原文页码，是否画出竞争图，是否重现一个推导，是否记录不可检验假设，是否在下周修正误读。发言流畅、术语丰富和结论新颖都不能替代这些证据。十二周结束后，成员应能独立审查一篇新论文，而不只是熟悉指定阅读列表。

本章小结

精读原始文献的目标不是积累名言，而是恢复问题、对象、假设和推论。哲学文本需要论证重构，技术论文需要条件与失败证明，应用方法需要制度和目标人群。统一笔记模板使不同传统可比较，也让书目中的每个引用都能回到具体、可核查的学

术工作。

参考文献

- ABADIE A, IMBENS G W, 2006. Large Sample Properties of Matching Estimators for Average Treatment Effects[J/OL]. *Econometrica*, 74(1):235-267. DOI: [10.1111 /j.1468-0262.2006.00655.x](https://doi.org/10.1111/j.1468-0262.2006.00655.x).
- ALLEN J M A, BARRETT J, HORSMAN D C, et al., 2017. Quantum Common Causes and Quantum Causal Models[J/OL]. *Physical Review X*, 7(3):031021. DOI: [10.1103/PhysRevX.7.031021](https://doi.org/10.1103/PhysRevX.7.031021).
- ALLISON H E, 2004. *Kant's Transcendental Idealism: An Interpretation and Defense*[M]. Revised and Enlarged. New Haven: Yale University Press.
- ANGRIST J D, IMBENS G W, RUBIN D B, 1996. Identification of Causal Effects Using Instrumental Variables[J/OL]. *Journal of the American Statistical Association*, 91(434):444-455. DOI: [10.1080/01621459.1996.10476902](https://doi.org/10.1080/01621459.1996.10476902).
- AQUINAS T, 2006. *Summa Theologiae: Questions on God*[M]. LEFTOW B, DAVIES B. Cambridge: Cambridge University

Press.

Aristotle, 1994. Posterior Analytics[M]. BARNES J. 2nd ed. Oxford: Clarendon Press.

Aristotle, 1996. Physics[M]. WATERFIELD R. Oxford: Oxford University Press.

Aristotle, 2016. Metaphysics[M]. REEVE C D C. Indianapolis: Hackett.

ARONOW P M, SAMII C, 2017. Estimating Average Causal Effects under General Interference, with Application to a Social Network Experiment[J/OL]. The Annals of Applied Statistics, 11(4):1912-1947. DOI: [10.1214/16-AOAS1005](https://doi.org/10.1214/16-AOAS1005).

ATHEY S, IMBENS G, 2016. Recursive Partitioning for Heterogeneous Causal Effects[J/OL]. Proceedings of the National Academy of Sciences, 113(27):7353-7360. DOI: [10.1073/pnas.1510489113](https://doi.org/10.1073/pnas.1510489113).

ATHEY S, TIBSHIRANI J, WAGER S, 2019. Generalized Random Forests[J/OL]. The Annals of Statistics, 47(2):1148-1178. DOI: [10.1214/18-AOS1709](https://doi.org/10.1214/18-AOS1709).

ATHEY S, WAGER S, 2021. Policy Learning with Observational Data[J/OL]. Econometrica, 89(1):133-161. DOI: [10.3982/ECTA15732](https://doi.org/10.3982/ECTA15732).

AUSTIN P C, 2009. Balance Diagnostics for Comparing the Distribution of Baseline Covariates between Treatment Groups in Propensity-Score Matched Samples[J/OL]. Statistics in Medicine, 28(25):3083-3107. DOI: [10.1002/sim.3697](https://doi.org/10.1002/sim.3697).

- AUSTIN P C, 2011. An Introduction to Propensity Score Methods for Reducing the Effects of Confounding in Observational Studies[J/OL]. *Multivariate Behavioral Research*, 46(3):399-424. DOI: [10.1080/00273171.2011.568786](https://doi.org/10.1080/00273171.2011.568786).
- AVIN C, SHPITSER I, PEARL J, 2005. Identifiability of Path-Specific Effects[C]//*Proceedings of the Nineteenth International Joint Conference on Artificial Intelligence*. Professional Book Center: 357-363.
- BACON F, 2000. *The New Organon*[M/OL]. JARDINE L, SILVERTHORNE M. Cambridge: Cambridge University Press. DOI: [10.1017/CBO9781139164030](https://doi.org/10.1017/CBO9781139164030).
- BANG H, ROBINS J M, 2005. Doubly Robust Estimation in Missing Data and Causal Inference Models[J/OL]. *Biometrics*, 61(4):962-973. DOI: [10.1111/j.1541-0420.2005.00377.x](https://doi.org/10.1111/j.1541-0420.2005.00377.x).
- BAREINBOIM E, PEARL J, 2012. Causal Inference by Surrogate Experiments: z-Identifiability[C]//*Proceedings of the Twenty-Eighth Conference on Uncertainty in Artificial Intelligence*. AUAI Press: 113-120.
- BAREINBOIM E, PEARL J, 2013. A General Algorithm for Deciding Transportability of Experimental Results[J/OL]. *Journal of Causal Inference*, 1(1): 107-134. DOI: [10.1515/jci-2012-0004](https://doi.org/10.1515/jci-2012-0004).
- BAREINBOIM E, PEARL J, 2016. Causal Inference and the Data-Fusion Problem[J/OL]. *Proceedings of the National Academy of Sciences*, 113(27):7345-7352. DOI: [10.1073/pnas.1510507113](https://doi.org/10.1073/pnas.1510507113).
- BEEBEE H, 2006. *Hume on Causation*[M/OL]. London: Routledge. DOI: [10.4324/9780203966600](https://doi.org/10.4324/9780203966600).

- BELL J S, 1964. On the Einstein Podolsky Rosen Paradox[J/OL]. *Physics Physique Fizika*, 1(3): 195-200. DOI: [10.1103/PhysicsPhysiqueFizika.1.195](https://doi.org/10.1103/PhysicsPhysiqueFizika.1.195).
- BONGERS S, FORRÉ P, PETERS J, et al., 2021. Foundations of Structural Causal Models with Cycles and Latent Variables [J/OL]. *The Annals of Statistics*, 49(5): 2885-2915. DOI: [10.1214/21-AOS2064](https://doi.org/10.1214/21-AOS2064).
- BUCHANAN A L, HUDGENS M G, COLE S R, et al., 2018. Generalizing Evidence from Randomized Trials Using Inverse Probability of Sampling Weights[J/OL]. *Journal of the Royal Statistical Society: Series A*, 181(4): 1193-1209. DOI: [10.1111/rssa.12357](https://doi.org/10.1111/rssa.12357).
- BÜHLMANN P, PETERS J, ERNEST J, 2014. CAM: Causal Additive Models, High-Dimensional Order Search and Penalized Regression[J/OL]. *The Annals of Statistics*, 42(6): 2526-2556. DOI: [10.1214/14-AOS1260](https://doi.org/10.1214/14-AOS1260).
- CALLAWAY B, SANT'ANNA P H C, 2021. Difference-in-Differences with Multiple Time Periods[J/OL]. *Journal of Econometrics*, 225(2): 200-230. DOI: [10.1016/j.jeconom.2020.12.001](https://doi.org/10.1016/j.jeconom.2020.12.001).
- CAMERON A C, MILLER D L, 2015. A Practitioner's Guide to Cluster-Robust Inference[J/OL]. *Journal of Human Resources*, 50(2): 317-372. DOI: [10.3368/jhr.50.2.317](https://doi.org/10.3368/jhr.50.2.317).
- CARTWRIGHT N, 1989. *Nature's Capacities and Their Measurement*[M]. Oxford: Clarendon Press.
- CARTWRIGHT N, 2007. *Hunting Causes and Using Them: Ap-*

- proaches in Philosophy and Economics[M/OL]. Cambridge: Cambridge University Press. DOI: 10.1017/CBO9780511618758.
- CARTWRIGHT N, HARDIE J, 2012. Evidence-Based Policy: A Practical Guide to Doing It Better[M/OL]. New York: Oxford University Press. DOI: 10.1093/acprof:osobl/9780199841608.001.0001.
- CHERNOZHUKOV V, CHETVERIKOV D, DEMIRER M, et al., 2018. Double/Debiased Machine Learning for Treatment and Structural Parameters[J/OL]. The Econometrics Journal, 21(1): C1-C68. DOI: 10.1111/ectj.12097.
- CHERNOZHUKOV V, DEMIRER M, DUFLO E, et al., 2025. Fisher-Schultz Lecture: Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments, with an Application to Immunization in India[J/OL]. Econometrica, 93(4): 1121-1164. DOI: 10.3982/ECTA19303.
- CHICKERING D M, 2002. Optimal Structure Identification with Greedy Search[J/OL]. Journal of Machine Learning Research, 3: 507-554. <https://jmlr.org/papers/v3/chickering02b.html>.
- CINELLI C, HAZLETT C, 2020. Making Sense of Sensitivity: Extending Omitted Variable Bias[J/OL]. Journal of the Royal Statistical Society: Series B, 82(1): 39-67. DOI: 10.1111/rssb.12348.
- COCHRAN W G, 1968. The Effectiveness of Adjustment by Subclassification in Removing Bias in Observational Studies[J/OL]. Biometrics, 24(2): 295-313. DOI: 10.2307/2528036.
- COLE S R, FRANGAKIS C E, 2009. The Consistency Statement in

- Causal Inference[J/OL]. *Epidemiology*, 20(1): 3-5. DOI: 10.1097/EDE.0b013e31818ef366.
- COLE S R, STUART E A, 2010. Generalizing Evidence from Randomized Clinical Trials to Target Populations: The ACTG 320 Trial[J/OL]. *American Journal of Epidemiology*, 172(1): 107-115. DOI: 10.1093/aje/kwq084.
- COLLINS J, HALL N, PAUL L A, 2004. Causation and Counterfactuals[G/OL]. Cambridge, MA: MIT Press. DOI: 10.7551/mitpress/1752.001.0001.
- COLOMBO D, MAATHUIS M H, 2014. Order-Independent Constraint-Based Causal Structure Learning[J/OL]. *Journal of Machine Learning Research*, 15(116): 3921-3962. <https://jmlr.org/papers/v15/colombo14a.html>.
- Confucius, 2003. Confucius: Analects, with Selections from Traditional Commentaries[M]. SLINGERLAND E. Indianapolis: Hackett.
- COSTA F, SHRAPNEL S, 2016. Quantum Causal Modelling [J/OL]. *New Journal of Physics*, 18: 063032. DOI: 10.1088/1367-2630/18/6/063032.
- CRAVER C F, 2007. Explaining the Brain: Mechanisms and the Mosaic Unity of Neuroscience[M/OL]. Oxford: Oxford University Press. DOI: 10.1093/acprof:oso/9780199299317.001.0001.
- CRAVER C F, DARDEN L, 2013. In Search of Mechanisms: Discoveries across the Life Sciences[M/OL]. Chicago: University of Chicago Press. DOI: 10.7208/chicago/9780226039824.001.0001.

- CRUMP R K, HOTZ V J, IMBENS G W, et al., 2009. Dealing with Limited Overlap in Estimation of Average Treatment Effects [J/OL]. *Biometrika*, 96(1):187-199. DOI: [10.1093/biomet/asn055](https://doi.org/10.1093/biomet/asn055).
- CUNNINGHAM S, 2021. *Causal Inference: The Mixtape*[M/OL]. New Haven: Yale University Press. DOI: [10.12987/9780300255881](https://doi.org/10.12987/9780300255881).
- DAHABREH I J, HANEUSE S J P A, ROBINS J M, et al., 2021. Study Designs for Extending Causal Inferences from a Randomized Trial to a Target Population[J/OL]. *American Journal of Epidemiology*, 190(8):1632-1642. DOI: [10.1093/aje/kwaa270](https://doi.org/10.1093/aje/kwaa270).
- DAHABREH I J, ROBERTSON S E, TCHETGEN TCHETGEN E J, et al., 2019. Generalizing Causal Inferences from Individuals in Randomized Trials to All Trial-Eligible Individuals[J/OL]. *Biometrics*, 75(2):685-694. DOI: [10.1111/biom.13009](https://doi.org/10.1111/biom.13009).
- DAWID A P, 1979. Conditional Independence in Statistical Theory [J/OL]. *Journal of the Royal Statistical Society: Series B*, 41(1):1-31. DOI: [10.1111/j.2517-6161.1979.tb01052.x](https://doi.org/10.1111/j.2517-6161.1979.tb01052.x).
- De CHAISEMARTIN C, D'HAULTFŒUILLE X, 2020. Two-Way Fixed Effects Estimators with Heterogeneous Treatment Effects [J/OL]. *American Economic Review*, 110(9):2964-2996. DOI: [10.1257/aer.20181169](https://doi.org/10.1257/aer.20181169).
- DEATON A, CARTWRIGHT N, 2018. Understanding and Misunderstanding Randomized Controlled Trials[J/OL]. *Social Science & Medicine*, 210:2-21. DOI: [10.1016/j.socscimed.2017.12.005](https://doi.org/10.1016/j.socscimed.2017.12.005).

- DEGTIAR I, ROSE S, 2023. A Review of Generalizability and Transportability[J/OL]. *Annual Review of Statistics and Its Application*, 10: 501-524. DOI: [10.1146/annurev-statistics-042522-103837](https://doi.org/10.1146/annurev-statistics-042522-103837).
- DESCARTES R, 1983. *Principles of Philosophy*[M]. MILLER V R, MILLER R P. Dordrecht: Kluwer Academic.
- DING P, VANDERWEELE T J, 2016. Sensitivity Analysis without Assumptions[J/OL]. *Epidemiology*, 27(3): 368-377. DOI: [10.1097/EDE.0000000000000457](https://doi.org/10.1097/EDE.0000000000000457).
- DOWE P, 2000. *Physical Causation*[M/OL]. Cambridge: Cambridge University Press. DOI: [10.1017/CBO9780511570650](https://doi.org/10.1017/CBO9780511570650).
- DUDÍK M, LANGFORD J, LI L, 2011. Doubly Robust Policy Evaluation and Learning[C]//*Proceedings of the 28th International Conference on Machine Learning*. Madison, WI: Omnipress: 1097-1104.
- EBERHARDT F, SCHEINES R, 2007. Interventions and Causal Inference[J/OL]. *Philosophy of Science*, 74(5): 981-995. DOI: [10.1086/525638](https://doi.org/10.1086/525638).
- FISCHER J M, RAVIZZA M, 1998. *Responsibility and Control: A Theory of Moral Responsibility*[M]. Cambridge: Cambridge University Press.
- FISHER R A, 1935. *The Design of Experiments*[M]. Edinburgh: Oliver.
- FRANGAKIS C E, RUBIN D B, 2002. Principal Stratification in Causal Inference[J/OL]. *Biometrics*, 58(1): 21-29. DOI: [10.1111](https://doi.org/10.1111)

- 1/j.0006-341X.2002.00021.x.
- GEIGER D, VERMA T, PEARL J, 1990. Identifying Independence in Bayesian Networks[J/OL]. *Networks*, 20(5): 507-534. DOI: 10.1002/net.3230200504.
- GETHIN R, 1998. *The Foundations of Buddhism*[M]. Oxford: Oxford University Press.
- GLENNAN S, 2017. *The New Mechanical Philosophy*[M/OL]. Oxford: Oxford University Press. DOI: 10.1093/oso/9780198779711.001.0001.
- GLENNAN S, ILLARI P, 2018. *The Routledge Handbook of Mechanisms and Mechanical Philosophy*[G/OL]. London: Routledge. DOI: 10.4324/9781315731544.
- GLYMOUR C, ZHANG K, SPIRITES P, 2019. Review of Causal Discovery Methods Based on Graphical Models[J/OL]. *Frontiers in Genetics*, 10: 524. DOI: 10.3389/fgene.2019.00524.
- GOODMAN-BACON A, 2021. Difference-in-Differences with Variation in Treatment Timing[J/OL]. *Journal of Econometrics*, 225(2): 254-277. DOI: 10.1016/j.jeconom.2021.03.014.
- GRAHAM A C, 1989. *Disputers of the Tao: Philosophical Argument in Ancient China*[M]. La Salle, IL: Open Court.
- GREENLAND S, 2003. Quantifying Biases in Causal Models: Classical Confounding vs Collider-Stratification Bias[J/OL]. *Epidemiology*, 14(3): 300-306. DOI: 10.1097/01.EDE.0000042804.12056.6C.
- GREENLAND S, PEARL J, ROBINS J M, 1999. *Causal Diagrams*

- for Epidemiologic Research[J/OL]. *Epidemiology*, 10(1):37-48. DOI: 10.1097/00001648-199901000-00008.
- HAAVELMO T, 1944. The Probability Approach in Econometrics [J/OL]. *Econometrica*, 12(Supplement):1-115. DOI: 10.2307/1906935.
- HACKING I, 1983. Representing and Intervening: Introductory Topics in the Philosophy of Natural Science[M/OL]. Cambridge: Cambridge University Press. DOI: 10.1017/CBO9780511814563.
- HALL N, 2004. Two Concepts of Causation[G]//COLLINS J, HALL N, PAUL L A. Causation and Counterfactuals. Cambridge, MA: MIT Press: 225-276.
- HALPERN J Y, 2016. Actual Causality[M]. Cambridge, MA: MIT Press.
- HALPERN J Y, PEARL J, 2005. Causes and Explanations: A Structural-Model Approach. Part I: Causes[J/OL]. *The British Journal for the Philosophy of Science*, 56(4):843-887. DOI: 10.1093/bjps/axi147.
- HAUSER A, BÜHLMANN P, 2012. Characterization and Greedy Learning of Interventional Markov Equivalence Classes of Directed Acyclic Graphs[J/OL]. *Journal of Machine Learning Research*, 13(79):2409-2464. <https://www.jmlr.org/papers/v13/hauser12a.html>.
- HEINZE-DEML C, MAATHUIS M H, MEINSHAUSEN N, 2018. Causal Structure Learning[J/OL]. *Annual Review of Statistics and Its Application*, 5:371-391. DOI: 10.1146/annurev-statistic

s-031017-100630.

- HEMPEL C G, 1965. Aspects of Scientific Explanation and Other Essays in the Philosophy of Science[M]. New York: Free Press.
- HERNÁN M A, HERNÁNDEZ-DÍAZ S, ROBINS J M, 2004. A Structural Approach to Selection Bias[J/OL]. *Epidemiology*, 15(5): 615-625. DOI: 10.1097/01.ede.0000135174.63482.43.
- HERNÁN M A, HERNÁNDEZ-DÍAZ S, WERLER M M, et al., 2002. Causal Knowledge as a Prerequisite for Confounding Evaluation: An Application to Birth Defects Epidemiology [J/OL]. *American Journal of Epidemiology*, 155(2): 176-184. DOI: 10.1093/aje/155.2.176.
- HERNÁN M A, ROBINS J M, 2006. Instruments for Causal Inference: An Epidemiologist's Dream?[J/OL]. *Epidemiology*, 17(4): 360-372. DOI: 10.1097/01.ede.0000222409.00878.37.
- HERNÁN M A, ROBINS J M, 2016. Using Big Data to Emulate a Target Trial When a Randomized Trial Is Not Available[J/OL]. *American Journal of Epidemiology*, 183(8): 758-764. DOI: 10.1093/aje/kwv254.
- HERNÁN M A, ROBINS J M, 2020. Causal Inference: What If [M/OL]. Boca Raton: Chapman & Hall/CRC. <https://www.hsph.harvard.edu/miguel-hernan/causal-inference-book/>.
- HERNÁN M A, TAUBMAN S L, 2008. Does Obesity Shorten Life? The Importance of Well-Defined Interventions to Answer Causal Questions[J/OL]. *International Journal of Obesity*, 32(S3): S8-S14. DOI: 10.1038/ijo.2008.82.

- HILL J L, 2011. Bayesian Nonparametric Modeling for Causal Inference[J/OL]. *Journal of Computational and Graphical Statistics*, 20(1): 217-240. DOI: [10.1198/jcgs.2010.08162](https://doi.org/10.1198/jcgs.2010.08162).
- HIRANO K, IMBENS G W, RIDDER G, 2003. Efficient Estimation of Average Treatment Effects Using the Estimated Propensity Score[J/OL]. *Econometrica*, 71(4): 1161-1189. DOI: [10.1111/1468-0262.00442](https://doi.org/10.1111/1468-0262.00442).
- HITCHCOCK C, 2024. Causal Models[G/OL]//ZALTA E N, NODELMAN U. *The Stanford Encyclopedia of Philosophy*. Fall 2024. Stanford: Metaphysics Research Lab, Stanford University, [2026-07-22]. <https://plato.stanford.edu/archives/fall2024/entries/causal-models/>.
- HOLLAND P W, 1986. Statistics and Causal Inference[J/OL]. *Journal of the American Statistical Association*, 81(396): 945-960. DOI: [10.1080/01621459.1986.10478354](https://doi.org/10.1080/01621459.1986.10478354).
- HOTZ V J, IMBENS G W, MORTIMER J H, 2005. Predicting the Efficacy of Future Training Programs Using Past Experiences at Other Locations[J/OL]. *Journal of Econometrics*, 125(1-2): 241-270. DOI: [10.1016/j.jeconom.2004.04.009](https://doi.org/10.1016/j.jeconom.2004.04.009).
- HOYER P O, JANZING D, MOOIJ J M, et al., 2009. Nonlinear Causal Discovery with Additive Noise Models[C/OL]// *Advances in Neural Information Processing Systems 21*. Curran Associates: 689-696 [2026-07-22]. <https://proceedings.neurips.cc/paper/2008/hash/f7664060cc52bc6f3d620bcdcd94a4b6-Abstract.html>.
- HUDGENS M G, HALLORAN M E, 2008. Toward Causal Infer-

- ence with Interference[J/OL]. *Journal of the American Statistical Association*, 103(482):832-842. DOI: [10.1198/016214508000000292](https://doi.org/10.1198/016214508000000292).
- HUME D, 1999. *An Enquiry Concerning Human Understanding*[M]. ed. by BEAUCHAMP T L. Oxford: Oxford University Press.
- HUME D, 2000. *A Treatise of Human Nature*[M]. ed. by NORTON D F, NORTON M J. Oxford: Oxford University Press.
- ILLARI P, RUSSO F, 2014. *Causality: Philosophical Theory Meets Scientific Practice*[M]. Oxford: Oxford University Press.
- IMAI K, RATKOVIC M, 2014. Covariate Balancing Propensity Score[J/OL]. *Journal of the Royal Statistical Society: Series B*, 76(1):243-263. DOI: [10.1111/rssb.12027](https://doi.org/10.1111/rssb.12027).
- IMBENS G W, 2020. Potential Outcome and Directed Acyclic Graph Approaches to Causality: Relevance for Empirical Practice in Economics[J/OL]. *Journal of Economic Literature*, 58(4):1129-1179. DOI: [10.1257/jel.20191597](https://doi.org/10.1257/jel.20191597).
- IMBENS G W, KOLESÁR M, 2016. Robust Standard Errors in Small Samples: Some Practical Advice[J/OL]. *The Review of Economics and Statistics*, 98(4):701-712. DOI: [10.1162/REST_a_00552](https://doi.org/10.1162/REST_a_00552).
- IMBENS G W, LEMIEUX T, 2008. Regression Discontinuity Designs: A Guide to Practice[J/OL]. *Journal of Econometrics*, 142(2):615-635. DOI: [10.1016/j.jeconom.2007.05.001](https://doi.org/10.1016/j.jeconom.2007.05.001).
- IMBENS G W, RUBIN D B, 2015. *Causal Inference for Statistics*,

- Social, and Biomedical Sciences: An Introduction[M/OL]. Cambridge: Cambridge University Press. DOI: [10.1017/CBO9781139025751](https://doi.org/10.1017/CBO9781139025751).
- IOANNIDIS J P A, 2005. Why Most Published Research Findings Are False[J/OL]. PLOS Medicine, 2(8): e124. DOI: [10.1371/journal.pmed.0020124](https://doi.org/10.1371/journal.pmed.0020124).
- KALISCH M, BÜHLMANN P, 2007. Estimating High-Dimensional Directed Acyclic Graphs with the PC-Algorithm [J/OL]. Journal of Machine Learning Research, 8: 613-636. <https://www.jmlr.org/papers/v8/kalisch07a.html>.
- KANT I, 1998. Critique of Pure Reason[M]. GUYER P, WOOD A W. Cambridge: Cambridge University Press.
- KERN H L, STUART E A, HILL J, et al., 2016. Assessing Methods for Generalizing Experimental Impact Estimates to Target Populations[J/OL]. Journal of Research on Educational Effectiveness, 9(1): 103-127. DOI: [10.1080/19345747.2015.1060282](https://doi.org/10.1080/19345747.2015.1060282).
- KITAGAWA T, TETENOV A, 2018. Who Should Be Treated? Empirical Welfare Maximization Methods for Treatment Choice [J/OL]. Econometrica, 86(2): 591-616. DOI: [10.3982/ECTA13288](https://doi.org/10.3982/ECTA13288).
- KÜNZEL S R, SEKHON J S, BICKEL P J, et al., 2019. Metalearners for Estimating Heterogeneous Treatment Effects Using Machine Learning[J/OL]. Proceedings of the National Academy of Sciences, 116(10): 4156-4165. DOI: [10.1073/pnas.1804597116](https://doi.org/10.1073/pnas.1804597116).
- KUSNER M J, LOFTUS J, RUSSELL C, et al., 2017. Counterfactual Fairness[C/OL]//Advances in Neural Information Processing

- Systems 30: 4066-4076 [2026-07-22]. <https://proceedings.neurips.cc/paper/2017/hash/a486cd07e4ac3d270571622f4f316ec5-Abstract.html>.
- Laozi, 2003. Daodejing: Making This Life Significant[M]. AMES R T, HALL D L. New York: Ballantine Books.
- LAURITZEN S L, 1996. Graphical Models[M]. Oxford: Oxford University Press.
- LAURITZEN S L, DAWID A P, LARSEN B N, et al., 1990. Independence Properties of Directed Markov Fields[J/OL]. Networks, 20(5): 491-505. DOI: 10.1002/net.3230200503.
- LEE D S, LEMIEUX T, 2010. Regression Discontinuity Designs in Economics[J/OL]. Journal of Economic Literature, 48(2): 281-355. DOI: 10.1257/jel.48.2.281.
- LEIBNIZ G W, 2014. Leibniz's Monadology: A New Translation and Guide[M]. STRICKLAND L. Edinburgh: Edinburgh University Press.
- LEWIS D, 1973a. Causation[J/OL]. The Journal of Philosophy, 70(17): 556-567. DOI: 10.2307/2025310.
- LEWIS D, 1973b. Counterfactuals[M]. Cambridge, MA: Harvard University Press.
- LEWIS D, 2000. Causation as Influence[J/OL]. The Journal of Philosophy, 97(4): 182-197. DOI: 10.2307/2678389.
- LI F, MORGAN K L, ZASLAVSKY A M, 2018. Balancing Covariates via Propensity Score Weighting[J/OL]. Journal of the American Statistical Association, 113(521): 390-400. DOI: 10.10

80/01621459.2016.1260466.

LIBET B, GLEASON C A, WRIGHT E W, et al., 1983. Time of Conscious Intention to Act in Relation to Onset of Cerebral Activity (Readiness-Potential)[J/OL]. *Brain*, 106(3): 623-642. DOI: 10.1093/brain/106.3.623.

LIN W, 2013. Agnostic Notes on Regression Adjustments to Experimental Data: Reexamining Freedman's Critique[J/OL]. *The Annals of Applied Statistics*, 7(1): 295-318. DOI: 10.1214/12-AOAS583.

LIPSITCH M, TCHETGEN TCHETGEN E, COHEN T, 2010. Negative Controls: A Tool for Detecting Confounding and Bias in Observational Studies[J/OL]. *Epidemiology*, 21(3): 383-388. DOI: 10.1097/EDE.0b013e3181d61eeb.

LOCATELLO F, BAUER S, LUCIC M, et al., 2019. Challenging Common Assumptions in the Unsupervised Learning of Disentangled Representations[C/OL]//*Proceedings of Machine Learning Research: Proceedings of the 36th International Conference on Machine Learning*: vol. 97. PMLR: 4114-4124. <https://proceedings.mlr.press/v97/locatello19a.html>.

MACHAMER P, DARDEN L, CRAVER C F, 2000. Thinking about Mechanisms[J/OL]. *Philosophy of Science*, 67(1): 1-25. DOI: 10.1086/392759.

MACKIE J L, 1974. *The Cement of the Universe: A Study of Causation*[M]. Oxford: Clarendon Press.

MACKINNON J G, WHITE H, 1985. Some Heteroskedasticity-Consistent Covariance Matrix Estimators with Improved Finite

- Sample Properties[J/OL]. *Journal of Econometrics*, 29(3):305-325. DOI: 10.1016/0304-4076(85)90158-7.
- MANSKI C F, 1990. Nonparametric Bounds on Treatment Effects [J]. *American Economic Review*, 80(2): 319-323.
- MEEK C, 1995. Causal Inference and Causal Explanation with Background Knowledge[C]//*Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence*. Morgan Kaufmann: 403-410.
- Mengzi, 2008. *Mengzi: With Selections from Traditional Commentaries*[M]. VAN NORDEN B W. Indianapolis: Hackett.
- MENZIES P, PRICE H, 1993. Causation as a Secondary Quality [J/OL]. *The British Journal for the Philosophy of Science*, 44(2): 187-203. DOI: 10.1093/bjps/44.2.187.
- MILL J S, 1974. *A System of Logic Ratiocinative and Inductive: vol. 7*[M]. ed. by ROBSON J M. Toronto: University of Toronto Press.
- MOOIJ J M, MAGLIACANE S, CLAASSEN T, 2020. Joint Causal Inference from Multiple Contexts[J/OL]. *Journal of Machine Learning Research*, 21(99): 1-108. <https://www.jmlr.org/papers/v21/17-123.html>.
- MOOIJ J M, PETERS J, JANZING D, et al., 2016. Distinguishing Cause from Effect Using Observational Data: Methods and Benchmarks[J/OL]. *Journal of Machine Learning Research*, 17(32): 1-102. <https://jmlr.org/papers/v17/14-518.html>.
- MORGAN S L, WINSHIP C, 2015. Counterfactuals and Causal

- Inference: Methods and Principles for Social Research[M]. 2nd ed. Cambridge: Cambridge University Press.
- Mozi, 2010. The Mozi: A Complete Translation[M]. JOHNSTON I. New York: Columbia University Press.
- MUMFORD S, ANJUM R L, 2011. Getting Causes from Powers [M/OL]. Oxford: Oxford University Press. DOI: [10.1093/acprof:oso/9780199695614.001.0001](https://doi.org/10.1093/acprof:oso/9780199695614.001.0001).
- MUNAFÒ M R, NOSEK B A, BISHOP D V M, et al., 2017. A Manifesto for Reproducible Science[J/OL]. Nature Human Behaviour, 1: 0021. DOI: [10.1038/s41562-016-0021](https://doi.org/10.1038/s41562-016-0021).
- NABI R, SHPITSER I, 2018. Fair Inference on Outcomes[C/OL]// Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence: vol. 32: 1: 1931-1940. DOI: [10.1609/aaai.v32i1.11553](https://doi.org/10.1609/aaai.v32i1.11553).
- Nāgārjuna, 2013. Nāgārjuna's Middle Way: Mūlamadhyamakakārikā[M]. SIDERITS M, KATSURA S. Boston: Wisdom Publications.
- NANDY P, HAUSER A, MAATHUIS M H, 2018. High-Dimensional Consistency in Score-Based and Hybrid Structure Learning[J/OL]. The Annals of Statistics, 46(6A):3151-3183. DOI: [10.1214/17-AOS1654](https://doi.org/10.1214/17-AOS1654).
- NEYMAN J, 1990. On the Application of Probability Theory to Agricultural Experiments: Essay on Principles, Section 9[J/OL]. Statistical Science, 5(4): 465-472. DOI: [10.1214/ss/1177012031](https://doi.org/10.1214/ss/1177012031).
- NIE X, WAGER S, 2021. Quasi-Oracle Estimation of Hetero-

- geneous Treatment Effects[J/OL]. *Biometrika*, 108(2):299-319. DOI: [10.1093/biomet/asaa076](https://doi.org/10.1093/biomet/asaa076).
- NOSEK B A, ALTER G, BANKS G C, et al., 2015. Promoting an Open Research Culture[J/OL]. *Science*, 348(6242):1422-1425. DOI: [10.1126/science.aab2374](https://doi.org/10.1126/science.aab2374).
- NOSEK B A, EBERSOLE C R, DEHAVEN A C, et al., 2018. The Preregistration Revolution[J/OL]. *Proceedings of the National Academy of Sciences*, 115(11):2600-2606. DOI: [10.1073/pnas.1708274114](https://doi.org/10.1073/pnas.1708274114).
- ORESHKOV O, COSTA F, BRUKNER Č, 2012. Quantum Correlations with No Causal Order[J/OL]. *Nature Communications*, 3: 1092. DOI: [10.1038/ncomms2076](https://doi.org/10.1038/ncomms2076).
- PAUL L A, HALL N, 2013. *Causation: A User's Guide*[M/OL]. Oxford: Oxford University Press. DOI: [10.1093/acprof:oso/9780199673445.001.0001](https://doi.org/10.1093/acprof:oso/9780199673445.001.0001).
- PEARL J, 1988. *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*[M]. San Mateo, CA: Morgan Kaufmann.
- PEARL J, 1995. Causal Diagrams for Empirical Research[J/OL]. *Biometrika*, 82(4):669-688. DOI: [10.1093/biomet/82.4.669](https://doi.org/10.1093/biomet/82.4.669).
- PEARL J, 2001. Direct and Indirect Effects[C/OL]//*Proceedings of the Seventeenth Conference on Uncertainty in Artificial Intelligence*. Morgan Kaufmann: 411-420. https://ftp.cs.ucla.edu/pub/stat_ser/R273-U.pdf.
- PEARL J, 2009. *Causality: Models, Reasoning, and Inference*[M].

2nd ed. Cambridge: Cambridge University Press.

PEARL J, BAREINBOIM E, 2014. External Validity: From Do-Calculus to Transportability Across Populations[J/OL]. *Statistical Science*, 29(4): 579-595. DOI: 10.1214/14-STS486.

PEARL J, MACKENZIE D, 2018. *The Book of Why: The New Science of Cause and Effect*[M]. New York: Basic Books.

PERKOVIĆ E, TEXTOR J, KALISCH M, et al., 2018. Complete Graphical Characterization and Construction of Adjustment Sets in Markov Equivalence Classes of Ancestral Graphs[J/OL]. *Journal of Machine Learning Research*, 18(220): 1-62. <https://jmlr.org/papers/v18/16-319.html>.

PETERS J, BÜHLMANN P, MEINSHAUSEN N, 2016. Causal Inference by Using Invariant Prediction: Identification and Confidence Intervals[J/OL]. *Journal of the Royal Statistical Society: Series B*, 78(5): 947-1012. DOI: 10.1111/rssb.12167.

PETERS J, JANZING D, SCHÖLKOPF B, 2017. *Elements of Causal Inference: Foundations and Learning Algorithms*[M/OL]. Cambridge, MA: MIT Press. <https://mitpress.mit.edu/9780262037310/elements-of-causal-inference/>.

PETERS J, MOOIJ J M, JANZING D, et al., 2014. Causal Discovery with Continuous Additive Noise Models[J/OL]. *Journal of Machine Learning Research*, 15(58): 2009-2053. <https://www.jmlr.org/papers/v15/peters14a.html>.

PSILLOS S, 2002. *Causation and Explanation*[M/OL]. Chesham: Acumen. DOI: 10.1017/UPO9781844653317.

- RAMSEY J, GLYMOUR M, SANCHEZ-ROMERO R, et al., 2017. A Million Variables and More: The Fast Greedy Equivalence Search Algorithm for Learning High-Dimensional Graphical Causal Models, with an Application to Functional Magnetic Resonance Images[J/OL]. *International Journal of Data Science and Analytics*, 3(2): 121-129. DOI: [10.1007/s41060-016-0032-z](https://doi.org/10.1007/s41060-016-0032-z).
- REICHENBACH H, 1956. *The Direction of Time*[M]. Berkeley: University of California Press.
- REISACH A, SEILER C, WEICHWALD S, 2021. Beware of the Simulated DAG! Causal Discovery Benchmarks May Be Easy to Game[C/OL]//*Advances in Neural Information Processing Systems 34*. Curran Associates: 27772-27784. https://proceedings.neurips.cc/paper_files/paper/2021/hash/e987eff4a7c7b7e580d659feb6f60c1a-Abstract.html.
- RICHARDSON T, 2003. Markov Properties for Acyclic Directed Mixed Graphs[J/OL]. *Scandinavian Journal of Statistics*, 30(1): 145-157. DOI: [10.1111/1467-9469.00323](https://doi.org/10.1111/1467-9469.00323).
- RICHARDSON T, SPIRTES P, 2002. Ancestral Graph Markov Models[J/OL]. *The Annals of Statistics*, 30(4): 962-1030. DOI: [10.1214/aos/1031689015](https://doi.org/10.1214/aos/1031689015).
- RICHARDSON T S, ROBINS J M, 2013. Single World Intervention Graphs (SWIGs): A Unification of the Counterfactual and Graphical Approaches to Causality[R/OL]. Working Paper 128. Seattle: Center for Statistics, [2026-07-22]. <https://csss.uw.edu/files/working-papers/2013/wp128.pdf>.
- ROBINS J M, 1986. *A New Approach to Causal Inference in Mor-*

- tality Studies with a Sustained Exposure Period—Application to Control of the Healthy Worker Survivor Effect[J/OL]. *Mathematical Modelling*, 7(9–12): 1393-1512. DOI: [10.1016/0270-0255\(86\)90088-6](https://doi.org/10.1016/0270-0255(86)90088-6).
- ROBINS J M, GREENLAND S, 1992. Identifiability and Exchangeability for Direct and Indirect Effects[J/OL]. *Epidemiology*, 3(2): 143-155. DOI: [10.1097/00001648-199203000-00013](https://doi.org/10.1097/00001648-199203000-00013).
- ROBINS J M, HERNÁN M A, BRUMBACK B, 2000. Marginal Structural Models and Causal Inference in Epidemiology [J/OL]. *Epidemiology*, 11(5): 550-560. DOI: [10.1097/00001648-200009000-00011](https://doi.org/10.1097/00001648-200009000-00011).
- ROBINS J M, ROTNITZKY A, ZHAO L P, 1994. Estimation of Regression Coefficients When Some Regressors Are Not Always Observed[J/OL]. *Journal of the American Statistical Association*, 89(427): 846-866. DOI: [10.1080/01621459.1994.10476818](https://doi.org/10.1080/01621459.1994.10476818).
- ROSENBAUM P R, 2010. *Design of Observational Studies* [M/OL]. New York: Springer. DOI: [10.1007/978-1-4419-1213-8](https://doi.org/10.1007/978-1-4419-1213-8).
- ROSENBAUM P R, RUBIN D B, 1983. The Central Role of the Propensity Score in Observational Studies for Causal Effects [J/OL]. *Biometrika*, 70(1): 41-55. DOI: [10.1093/biomet/70.1.41](https://doi.org/10.1093/biomet/70.1.41).
- ROTH J, SANT'ANNA P H C, BILINSKI A, et al., 2023. What's Trending in Difference-in-Differences? A Synthesis of the Recent Econometrics Literature[J/OL]. *Journal of Econometrics*, 235(2): 2218-2244. DOI: [10.1016/j.jeconom.2023.03.008](https://doi.org/10.1016/j.jeconom.2023.03.008).
- RUBIN D B, 1973. Matching to Remove Bias in Observational Stud-

- ies[J/OL]. *Biometrics*, 29(1):159-183. DOI: [10.2307/2529684](https://doi.org/10.2307/2529684).
- RUBIN D B, 1974. Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies[J/OL]. *Journal of Educational Psychology*, 66(5): 688-701. DOI: [10.1037/h0037350](https://doi.org/10.1037/h0037350).
- RUBIN D B, 1978. Bayesian Inference for Causal Effects: The Role of Randomization[J/OL]. *The Annals of Statistics*, 6(1): 34-58. DOI: [10.1214/aos/1176344064](https://doi.org/10.1214/aos/1176344064).
- RUNGE J, NOWACK P, KRETSCHMER M, et al., 2019. Detecting and Quantifying Causal Associations in Large Nonlinear Time Series Datasets[J/OL]. *Science Advances*, 5(11): eaau4996. DOI: [10.1126/sciadv.aau4996](https://doi.org/10.1126/sciadv.aau4996).
- RUSSELL B, 1912. On the Notion of Cause[J/OL]. *Proceedings of the Aristotelian Society*, 13: 1-26. DOI: [10.1093/aristotelian/13.1.1](https://doi.org/10.1093/aristotelian/13.1.1).
- RUSSO F, WILLIAMSON J, 2007. Interpreting Causality in the Health Sciences[J/OL]. *International Studies in the Philosophy of Science*, 21(2): 157-170. DOI: [10.1080/02698590701498084](https://doi.org/10.1080/02698590701498084).
- SALMON W C, 1984. *Scientific Explanation and the Causal Structure of the World*[M]. Princeton: Princeton University Press.
- SCHAFFER J, 2005. Contrastive Causation[J/OL]. *The Philosophical Review*, 114(3): 327-358. DOI: [10.1215/00318108-114-3-327](https://doi.org/10.1215/00318108-114-3-327).
- SCHÖLKOPF B, LOCATELLO F, BAUER S, et al., 2021. Toward Causal Representation Learning[J/OL]. *Proceedings of the IEEE*, 109(5): 612-634. DOI: [10.1109/JPROC.2021.3058954](https://doi.org/10.1109/JPROC.2021.3058954).
- SCHURGER A, SITT J D, DEHAENE S, 2012. An Accumulator

- Model for Spontaneous Neural Activity Prior to Self-Initiated Movement[J/OL]. Proceedings of the National Academy of Sciences, 109(42): E2904-E2913. DOI: [10.1073/pnas.1210467109](https://doi.org/10.1073/pnas.1210467109).
- SHADISH W R, COOK T D, CAMPBELL D T, 2002. Experimental and Quasi-Experimental Designs for Generalized Causal Inference[M]. Boston: Houghton Mifflin.
- SHALIT U, JOHANSSON F D, SONTAG D, 2017. Estimating Individual Treatment Effect: Generalization Bounds and Algorithms[C/OL]//Proceedings of Machine Learning Research: Proceedings of the 34th International Conference on Machine Learning: vol. 70. PMLR: 3076-3085. <https://proceedings.mlr.press/v70/shalit17a.html>.
- SHIMIZU S, HOYER P O, HYVÄRINEN A, et al., 2006. A Linear Non-Gaussian Acyclic Model for Causal Discovery[J/OL]. Journal of Machine Learning Research, 7: 2003-2030. <https://jmlr.org/papers/v7/shimizu06a.html>.
- SHPITSER I, PEARL J, 2006. Identification of Joint Interventional Distributions in Recursive Semi-Markovian Causal Models[C/OL]//Proceedings of the Twenty-First National Conference on Artificial Intelligence. AAAI Press: 1219-1226 [2026-07-22]. <https://aaai.org/Papers/AAAI/2006/AAAI06-191.pdf>.
- SHPITSER I, PEARL J, 2008. Complete Identification Methods for the Causal Hierarchy[J/OL]. Journal of Machine Learning Research, 9: 1941-1979. <https://www.jmlr.org/papers/v9/shpitser08a.html>.
- SHPITSER I, VANDERWEELE T J, ROBINS J M, 2010. On the Va-

- lidity of Covariate Adjustment for Estimating Causal Effects [C/OL]//Proceedings of the Twenty-Sixth Conference on Uncertainty in Artificial Intelligence. AUAI Press: 527-536 [2026-07-22]. https://event.cwi.nl/uai2010/papers/UAI2010_0016.pdf.
- SHRIER I, PLATT R W, 2008. Reducing Bias through Directed Acyclic Graphs[J/OL]. BMC Medical Research Methodology, 8: 70. DOI: 10.1186/1471-2288-8-70.
- SIMMONS J P, NELSON L D, SIMONSOHN U, 2011. False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant[J/OL]. Psychological Science, 22(11): 1359-1366. DOI: 10.1177/0956797611417632.
- SOON C S, BRASS M, HEINZE H J, et al., 2008. Unconscious Determinants of Free Decisions in the Human Brain[J/OL]. Nature Neuroscience, 11(5): 543-545. DOI: 10.1038/nn.2112.
- SPIRITES P, GLYMOUR C, 1991. An Algorithm for Fast Recovery of Sparse Causal Graphs[J/OL]. Social Science Computer Review, 9(1): 62-72. DOI: 10.1177/089443939100900106.
- SPIRITES P, GLYMOUR C, SCHEINES R, 2000. Causation, Prediction, and Search[M]. 2nd ed. Cambridge, MA: MIT Press.
- STRAWSON G, 1989. The Secret Connexion: Causation, Realism, and David Hume[M]. Oxford: Clarendon Press.
- STREVENSON M, 2008. Depth: An Account of Scientific Explanation [M]. Cambridge, MA: Harvard University Press.
- STUART E A, 2010. Matching Methods for Causal Inference: A

- Review and a Look Forward[J/OL]. *Statistical Science*, 25(1): 1-21. DOI: [10.1214/09-STS313](https://doi.org/10.1214/09-STS313).
- STUART E A, COLE S R, BRADSHAW C P, et al., 2011. The Use of Propensity Scores to Assess the Generalizability of Results from Randomized Trials[J/OL]. *Journal of the Royal Statistical Society: Series A*, 174(2): 369-386. DOI: [10.1111/j.1467-985X.2010.00673.x](https://doi.org/10.1111/j.1467-985X.2010.00673.x).
- SUN L, ABRAHAM S, 2021. Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects [J/OL]. *Journal of Econometrics*, 225(2): 175-199. DOI: [10.1016/j.jeconom.2020.09.006](https://doi.org/10.1016/j.jeconom.2020.09.006).
- SUPPES P, 1970. *A Probabilistic Theory of Causality*[M]. Amsterdam: North-Holland.
- SWANSON S A, HERNÁN M A, 2018. The Challenging Interpretation of Instrumental Variable Estimates under Monotonicity[J/OL]. *International Journal of Epidemiology*, 47(4): 1289-1297. DOI: [10.1093/ije/dyx038](https://doi.org/10.1093/ije/dyx038).
- TCHETGEN TCHETGEN E J, SHPITSER I, 2012. Semiparametric Theory for Causal Mediation Analysis: Efficiency Bounds, Multiple Robustness and Sensitivity Analysis[J/OL]. *The Annals of Statistics*, 40(3): 1816-1845. DOI: [10.1214/12-AOS990](https://doi.org/10.1214/12-AOS990).
- TCHETGEN TCHETGEN E J, VANDERWEELE T J, 2012. On Causal Inference in the Presence of Interference[J/OL]. *Statistical Methods in Medical Research*, 21(1): 55-75. DOI: [10.1177/0962280210386779](https://doi.org/10.1177/0962280210386779).
- TEXTOR J, van der ZANDER B, GILTHORPE M S, et al., 2016.

- Robust Causal Inference Using Directed Acyclic Graphs: The R Package dagitty[J/OL]. *International Journal of Epidemiology*, 45(6): 1887-1894. DOI: [10.1093/ije/dyw341](https://doi.org/10.1093/ije/dyw341).
- TIAN J, PEARL J, 2002. A General Identification Condition for Causal Effects[C]//*Proceedings of the Eighteenth National Conference on Artificial Intelligence*. AAAI Press: 567-573.
- TIPTON E, 2013. Improving Generalizations from Experiments Using Propensity Score Subclassification[J/OL]. *Journal of Educational and Behavioral Statistics*, 38(3): 239-266. DOI: [10.3102/1076998612441947](https://doi.org/10.3102/1076998612441947).
- TIPTON E, 2014. How Generalizable Is Your Experiment? An Index for Comparing Experimental Samples and Populations [J/OL]. *Journal of Educational and Behavioral Statistics*, 39(6): 478-501. DOI: [10.3102/1076998614558486](https://doi.org/10.3102/1076998614558486).
- TIPTON E, OLSEN R B, 2018. A Review of Statistical Methods for Generalizing from Evaluations of Educational Interventions [J/OL]. *Educational Researcher*, 47(8): 516-524. DOI: [10.3102/0013189X18781522](https://doi.org/10.3102/0013189X18781522).
- Van INWAGEN P, 1983. *An Essay on Free Will*[M]. Oxford: Clarendon Press.
- Van der LAAN M J, ROSE S, 2011. Targeted Learning: Causal Inference for Observational and Experimental Data[M/OL]. New York: Springer. DOI: [10.1007/978-1-4419-9782-1](https://doi.org/10.1007/978-1-4419-9782-1).
- Van der LAAN M J, RUBIN D, 2006. Targeted Maximum Likelihood Learning[J/OL]. *The International Journal of Biostatistics*, 2(1). DOI: [10.2202/1557-4679.1043](https://doi.org/10.2202/1557-4679.1043).

VANDERWEELE T J, 2009. Concerning the Consistency Assumption in Causal Inference[J/OL]. *Epidemiology*, 20(6): 880-883. DOI: [10.1097/EDE.0b013e3181bd5638](https://doi.org/10.1097/EDE.0b013e3181bd5638).

VANDERWEELE T J, 2015. *Explanation in Causal Inference: Methods for Mediation and Interaction*[M]. New York: Oxford University Press.

VANDERWEELE T J, DING P, 2017. Sensitivity Analysis in Observational Research: Introducing the E-Value[J/OL]. *Annals of Internal Medicine*, 167(4): 268-274. DOI: [10.7326/M16-2607](https://doi.org/10.7326/M16-2607).

VANDERWEELE T J, HERNÁN M A, 2013. Causal Inference under Multiple Versions of Treatment[J/OL]. *Journal of Causal Inference*, 1(1): 1-20. DOI: [10.1515/jci-2012-0002](https://doi.org/10.1515/jci-2012-0002).

VERMA T, PEARL J, 1990. Equivalence and Synthesis of Causal Models[C]//*Proceedings of the Sixth Conference on Uncertainty in Artificial Intelligence*. San Mateo, CA: Morgan Kaufmann: 255-270.

VOWELS M J, CAMGOZ N C, BOWDEN R, 2023. D'ya Like DAGs? A Survey on Structure Learning and Causal Discovery[J/OL]. *ACM Computing Surveys*, 55(4): 1-36. DOI: [10.1145/3527154](https://doi.org/10.1145/3527154).

WAGER S, ATHEY S, 2018. Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests[J/OL]. *Journal of the American Statistical Association*, 113(523): 1228-1242. DOI: [10.1080/01621459.2017.1319839](https://doi.org/10.1080/01621459.2017.1319839).

WESTREICH D, COLE S R, 2010. Invited Commentary: Positivity in Practice[J/OL]. *American Journal of Epidemiology*, 171(6):

- 674-677. DOI: [10.1093/aje/kwp436](https://doi.org/10.1093/aje/kwp436).
- WESTREICH D, EDWARDS J K, LESKO C R, et al., 2017. Transportability of Trial Results Using Inverse Odds of Sampling Weights[J/OL]. *American Journal of Epidemiology*, 186(8): 1010-1014. DOI: [10.1093/aje/kwx164](https://doi.org/10.1093/aje/kwx164).
- WESTREICH D, EDWARDS J K, LESKO C R, et al., 2019. Target Validity and the Hierarchy of Study Designs[J/OL]. *American Journal of Epidemiology*, 188(2): 438-443. DOI: [10.1093/aje/kwy228](https://doi.org/10.1093/aje/kwy228).
- WOOD C J, SPEKKENS R W, 2015. The Lesson of Causal Discovery Algorithms for Quantum Correlations: Causal Explanations of Bell-Inequality Violations Require Fine-Tuning[J/OL]. *New Journal of Physics*, 17: 033002. DOI: [10.1088/1367-2630/17/3/033002](https://doi.org/10.1088/1367-2630/17/3/033002).
- WOODWARD J, 2003. *Making Things Happen: A Theory of Causal Explanation*[M]. New York: Oxford University Press.
- WOODWARD J, 2010. Causation in Biology: Stability, Specificity, and the Choice of Levels of Explanation[J/OL]. *Biology & Philosophy*, 25(3): 287-318. DOI: [10.1007/s10539-010-9200-z](https://doi.org/10.1007/s10539-010-9200-z).
- WRIGHT S, 1921. Correlation and Causation[J]. *Journal of Agricultural Research*, 20(7): 557-585.
- Xunzi, 2014. *Xunzi: The Complete Text*[M/OL]. HUTTON E L. Princeton: Princeton University Press. DOI: [10.1515/9781400852550](https://doi.org/10.1515/9781400852550).
- ZHANG J, 2008. Causal Reasoning with Ancestral Graphs[J/OL].

Journal of Machine Learning Research, 9(47):1437-1474. <https://jmlr.org/papers/v9/zhang08a.html>.

ZHENG X, ARAGAM B, RAVIKUMAR P K, et al., 2018. DAGs with NO TEARS: Continuous Optimization for Structure Learning[C/OL]//Advances in Neural Information Processing Systems 31: 9472-9483. <https://proceedings.neurips.cc/paper/2018/hash/e347c51419ffb23ca3fd5050202f9c3-Abstract.html>.

Zhuangzi, 2009. Zhuangzi: The Essential Writings[M]. ZIPORYN B. Indianapolis: Hackett.

主题索引

- C-component, 103
- CPDAG, 137
- d-分离, 77
- do-calculus, 101
- Double/Debiased Machine Learning, 119
- FCI 算法, 137
- GES, 137
- hedge, 103
- INUS 条件, 43
- LiNGAM, 138
- Markov 等价类, 79
- Neyman 正交, 119
- PAG, 137
- PC 算法, 137
- R-learner, 174
- S-learner, 173
- S-可容许, 156
- T-learner, 173
- X-learner, 173
- 一致性, 56
- 三角互证, 202
- 不变因果预测, 140
- 不变性, 45
- 不死时间偏差, 179
- 业, 217
- 个例因果, 40
- 主层, 60
- 事实问题, 22
- 交叉拟合, 119

人机协作的证据治理, 206

估计, v, 61

倾向得分, 118

假设账本, 204

充足理由律, 19

先驱叙事, 20

共同原因原则, 42

内部效度, 154

决定论, 219

前定和谐, 19

前门准则, 98

加性噪声模型, 138

动力因, 17

单世界干预图, 107

单因叙事, 21

双重差分, 182

双重稳健, 119

双重防止, 39

反事实公平, 183

反事实解释, 176

反身性, 222

受控直接效应, 104

可交换性, 62

可识别, 61

可预测性, 219

后门路径, 96

因果 Markov 条件, 78

因果依赖, 37

因果影响, 39

因果推断的根本问题, 55

因果能力, 44

因果表示学习, 175

因果过程, 43

外部效度, v, 154

多尺度动态因果, 206

天人感应, 216

对照性, 3

对称过度决定, 38

干预主义, 45

干预型直接和间接效应, 105

平均处理效应, 55

平行趋势, 182

弱假设下的可靠推断, 206

归纳统计模型, 29

归纳问题, 23

形式因, 17

忠实性, 79

恒常结合, 22

意向治疗效应, 120

截断因子分解, 79

效应修饰因子, 155

数据融合, 157

断点回归, 181

方向约束, 31

- 方法论问题, 3
无为, 216
无信号条件, 225
早期先占, 38
时间零点, 58
晚期先占, 38
普遍化, 154
最小充分调整集, 96
有向无环图, 76
服从者局部平均处理效应, 180
本体论问题, 3
机制化的差异制造, 198
标准化公式, 62
模块性, 78
次级原因, 18
正值性, 63
测量与表示的共同设计, 206
淘汰叙事, 21
混杂, 42, 62
溯因, 104
演绎律则模型, 29

独立因果机制, 176
目标试验, 65
目标量, v
目的因, 17
稳定单位处理值假设, 57
第一因, 18

类型因果, 40
结构因果模型, 77
结构相关性, 31
缘起, 217

自然直接效应, 105
自然间接效应, 105
自由意志, 219
若无检验, 36
行动, 104
观念关系, 22
解释论问题, 3
认识论问题, 3
识别假设, v
诚实性, 174
负对照暴露, 66
负对照结局, 66
质料因, 17
软干预, 82
辛普森反转, 42
迁移, 154
迁移公式, 156
过程矩阵, 226

选择图, 156
道德责任, 219
问题相关性, 31
随机干预, 82

预测, 104

预测归因, 176

预防原因, 42